



THÈSE DE DOCTORAT

Utilisation de graphes pour la classification
et l'extraction de structures. Généralisation
à des interactions d'ordre supérieur.

Louis HAUSEUX

Centre Inria d'Université Côte d'Azur

**Présentée en vue de l'obtention
du grade de docteur en Informatique
d'Université Côte d'Azur**

Dirigée par : Konstantin AVRACHENKOV, Di-
recteur de recherche, Inria, Sophia Antipolis

Co-encadrée par : Josiane ZERUBIA, Direc-
trice de recherche, Inria, Sophia Antipolis

Soutenue le : 8 septembre 2026

Devant le jury, composé de :

Nicolas NISSE, Directeur de recherche, Inria
Sophia Antipolis

Dieter MITSCHKE, Professeur, Pontificia Uni-
versidad Católica de Chile

Hocine CHERIFI, Professeur, Université de
Bourgogne

Pierre CHARBONNIER, Directeur de re-
cherche, Cerema, Strasbourg

Zoltan KATO, Professeur, Szegedi Tudomá-
nyegyetem

**UTILISATION DE GRAPHEs POUR LA CLASSIFICATION ET
L'EXTRACTION DE STRUCTURES. GÉNÉRALISATION À DES
INTERACTIONS D'ORDRE SUPÉRIEUR.**

Louis HAUSEUX



Jury :

Président du jury

Nicolas NISSE, Directeur de recherche, Inria
Sophia Antipolis

Rapporteurs

Dieter MITSCHÉ, Professeur, Pontificia Universidad Católica de Chile
Hocine CHERIFI, Professeur, Université de Bourgogne

Examineurs

Pierre CHARBONNIER, Directeur de recherche, Cerema, Strasbourg
Zoltan KATO, Professeur, Szegedi Tudományegyetem

Directeur de thèse

Konstantin AVRACHENKOV, Directeur de recherche, Inria, Sophia Antipolis

Co-encadrante de thèse

Josiane ZERUBIA, Directrice de recherche, Inria, Sophia Antipolis

Louis HAUSEUX

***Utilisation de graphes pour la classification et l'extraction de structures.
Généralisation à des interactions d'ordre supérieur.***

v+187 p.

Table des matières

1	Introduction générale	7
1.1	Propos liminaire	7
1.2	Une brève histoire du clustering. L’omniprésence de l’algorithme de Single-Linkage	9
1.2.1	Les deux grandes familles de clustering	9
1.2.2	Du partitionnement à la hiérarchie	9
1.3	Problématique : que devient la connexité lorsque $K \geq 2$?	10
1.4	La percolation comme mesure de performance	11
1.5	Contributions du manuscrit	12
1.6	Organisation du manuscrit	13

Du Single-Linkage à ses fondements

2	Le Single-Linkage : trois points de vue (heuristique, géométrique & statistique)	17
2.1	Introduction au Single-Linkage	18
2.2	Le Single-Linkage en pratique : l’arbre minimum couvrant	20
2.2.1	Différents algorithmes pour l’arbre minimum couvrant	20
2.2.2	Graphe de GABRIEL et triangulation de DELAUNAY	21
2.3	Le Single-Linkage en théorie : persistance de graphes géométriques	22
2.4	Le modèle statistique du Single-Linkage : HARTIGAN et les amas de forte densité	24
2.4.1	Amas de forte densité (<i>high-density clusters</i>)	24
2.4.2	L’estimateur de densité des K -Plus Proches Voisins (K -NN)	25
2.4.3	Lien entre le Single-Linkage et la hiérarchie de HARTIGAN 1-NN	26
2.4.4	Amas de forte densité <i>discrets</i>	27
3	Le Single-Linkage : un point de vue axiomatique	29
3.1	Rappels : partitions, relations d’équivalence	30
3.1.1	Le clustering, ou <i>partitionnement</i>	30
3.2	Le théorème d’impossibilité de KLEINBERG	31
3.3	Le besoin d’ajouter une vue hiérarchique	31
3.3.1	Équivalence entre les dendrogrammes et les ultramétriques	33

4	Les limites du Single-Linkage	37
4.1	Quand la notion de densité manque : l'effet de chaînage	38
4.1.1	Consistance et inconsistance du Single-Linkage	39
4.2	Les liaisons dangereuses : Complete- et Average-Linkage	40
4.3	Introduire la densité locale : le Robuſt Single-Linkage	41
4.3.1	Critique du Robuſt Single-Linkage	42
4.4	L'état de l'art : HDBSCAN	42
4.4.1	La gestion explicite de la frontière des clusters : DBSCAN	42
4.4.2	HDBSCAN	43
4.4.3	Le seuil de percolation (<code>min_cluster_size</code>) pour une meilleure gestion du bruit	44
4.4.4	Un clustering multi-échelle : le critère d'excès de masse (<i>excess of mass</i>)	44
4.4.5	Les limites de l'approche : le paradoxe du choix de K	46
5	Une vue générale sur le clustering hiérarchique. Ou comment introduire des <i>a priori</i>.	47
5.1	L'arbre comme espace de résolution : unifier le clustering	48
5.1.1	Formalisation convexe du problème de clustering	48
5.1.2	Quand les problèmes NP-complets deviennent triviaux	48
5.2	« Hacker » HDBSCAN : l'exploration de l'arbre hiérarchique	49
5.3	Application I : Détection d'anomalies 3D guidée par un modèle théorique (©Naval Group)	50
5.3.1	Le problème	50
5.3.2	L'exploration guidée	51
5.3.3	Le post-traitement	51
5.4	Application II : Segmentation d'instance 4D sur SemanticKITTI	52
5.4.1	La méthode	53

La généralisation du Single-Linkage avec des interactions d'ordre supérieur

6	HGP-Clusterer : la généralisation du Single-Linkage dans l'espace euclidien	57
6.1	Retour sur la non prise en compte de la densité	58
6.1.1	L'échec du Robuſt Single-Linkage et de (H)DBSCAN sur le modèle de HARTIGAN	58
6.1.2	La hiérarchie exacte de HARTIGAN lorsque $K = 2$	59
6.2	Du graphe géométrique au complexe de Čech : les K -polyèdres	61
6.2.1	Le complexe de Čech	61
6.2.2	Les K -polyèdres	62

6.3	K -polyèdres de Čech et amas discrets de forte densité K -NN	63
6.3.1	Les régions témoins d'un simplexe	63
7	Le phénomène de percolation au cœur des performances	67
7.1	Introduction à la percolation	68
7.1.1	Le cadre mathématique	69
7.2	Percolation et non-consistance	73
7.2.1	Lecture générale avec la densité f	73
7.2.2	Le cas simple des niveaux de densité constants	74
7.3	La <i>vitesse de percolation</i>	76
7.4	Comparaison empirique entre K -polyèdres, K -Robust Single-Linkage et DBSCAN	77
7.5	Et lorsque $K \rightarrow +\infty$?	80
7.5.1	Le champ gaussien limite	80
7.5.2	Comportements sur le champ gaussien de HGP-Clusterer, (H)DBSCAN et Robust Single-Linkage	82
7.5.3	Et à haut rappel $\varepsilon \rightarrow 0$	84
8	À la recherche de la généralisation de l'arbre minimum couvrant	87
8.1	L'approche persistante : les simplexes K -séparants	88
8.1.1	Le graphe élémentaire des facettes	89
8.2	Une condition nécessaire pour un simplexe séparant : être de GABRIEL	91
8.3	La bonne structure à observer : la mosaïque de DELAUNAY d'ordre K	95
8.3.1	Un K -simplexe de GABRIEL est nécessairement dans la mosaïque de DELAUNAY d'ordre K	96
9	HGP-Clusterer en pratique	99
9.1	Et lorsqu'on impose une partition stricte des données?	100
9.2	Optimisations pour $K = 2$ avec des résultats empiriques	101
9.2.1	Les propriétés géométriques du 2-graphe de GABRIEL	101
9.2.2	Digression au cas $K \geq 2$	102
9.2.3	L'algorithme pour $K = 2$	103
9.2.4	Résultats sur les huiles d'olive italiennes	104
9.2.5	Résultats sur SIPU	105
9.3	Lorsque la mosaïque de DELAUNAY n'est plus disponible : le complexe de VIETORIS-RIPS	107
9.4	La richesse structurelle de la mosaïque d'ordre K : vers la réduction de dimension?	109
9.4.1	UMAP : <i>Uniform Manifold Approximation and Projection for Dimension Reduction</i>	110

Vers des données davantage structurées

10	Introduction	117
10.1	Détection de communautés et méthodes de Monte-Carlo	117
10.1.1	De l'optimisation à l'échantillonnage de GIBBS	117
10.1.2	Le théorème ergodique et les chaînes de MARKOV	118
10.1.3	Dynamiques de clusters face à la frustration	119
10.1.4	La percolation comme garantie théorique pour le recouvrement des communautés	119
10.2	Extraction de réseaux de fissures au sein d'images : le retour vers des modèles géométriques plus explicites ?	120
10.2.1	Les limites de l'apprentissage profond en extraction de réseaux .	120
10.2.2	Le retour à des modèles physiques ? Du pixel au graphe spatial .	120
11	Un cadre bayésien pour la détection de communautés sur graphes	123
11.1	Cadre bayésien général	124
11.1.1	Modèle probabiliste, postérieure et algorithmes	124
11.1.2	Algorithmes et tirages au hasard	126
11.1.3	Recouvrement de communautés	128
11.1.4	Recouvrement de communautés partiel, presque parfait et parfait	131
11.1.5	Rééchantillonnage postérieur et couplages invariants	132
11.2	Dynamiques de clusters : généralisation de SWENDSEN-WANG aux inter- actions d'ordre supérieur	134
11.2.1	Mesures de GIBBS sur graphes pondérés signés	134
11.2.2	Frustration	135
11.2.3	Dynamiques de clusters	136
11.2.4	Liens et réversibilité de la dynamique	136
11.2.5	Le cas arête par arête : SWENDSEN-WANG signé	138
11.2.6	Dynamiques triangulaire et obstruction par percolation	138
11.2.7	Règles locales sur un triangle isotrope	139
11.3	Le rôle de la percolation dans les performances théoriques. Application au modèle de SANKARARAMAN-BACCELLI	141
11.3.1	Percolation nécessaire	141
11.3.2	Le modèle de SANKARARAMAN-BACCELLI dans le cadre bayésien .	143
11.3.3	Retrouver la borne de SANKARARAMAN-BACCELLI par SWENDSEN- WANG arêtes	145
11.3.4	La grille triangulaire : une borne strictement meilleure pour la dynamique triangulaire	146
11.4	Ouverture : le modèle de SANKARARAMAN-BACCELLI pour l'assemblage d'haplotypes	148

12	Extension au traitement du signal : application à la détection des fissures sur des images	151
12.1	Un classique : le filtre de FRANGI	153
12.2	Une structure plus riche : le graphe de FRANGI	154
12.2.1	Extension à la multimodalité	157
12.2.2	Interactions d'ordre supérieur	158
12.3	Résultats	158
12.3.1	Jeux de données et protocole	158
12.3.2	Images géologiques visibles : Vaches Noires	159
12.3.3	Fusion multimodale : FIND	161
12.3.4	Milieu granulaire en imagerie visible-thermique : VT-GraF	163
12.3.5	Sensibilité aux paramètres : CrackForest	164
12.3.6	Conclusion sur les résultats du graphe de FRANGI	166
12.4	Ouverture : vers une réconciliation de l'apprentissage profond et des modèles mathématiques	166
13	Conclusion générale	169
13.1	Bilan des contributions	170
13.2	Ouvertures et perspectives de recherche	172

Appendix

A	Cartographie des publications	177
	Table des figures	179
	Liste des tableaux	181

Utilisation de graphes pour la classification et l'extraction de structures. Généralisation à des interactions d'ordre supérieur.

Résumé

Problématique Au cours de cette thèse, nous nous penchons sur le problème de structuration automatique de données à partir d'observations locales, imparfaites et parfois bruitées. Le point de départ en est le clustering. Nous avons alors rencontré à de multiples reprises – et par des voies toutes différentes – l'algorithme du Single-Linkage. Nous nous sommes concentrés sur trois approches : une approche heuristique (construction de l'arbre minimum couvrant sur les données) ; une approche géométrique (persistance des composantes d'un graphe géométrique) ; ainsi qu'une approche statistique (estimation des clusters de forte densité). La première approche permet de disposer d'un algorithme optimisé (notamment dans l'espace euclidien) ; la seconde permet de comprendre le mécanisme mathématique à l'œuvre (la percolation) et la dernière approche permet d'avoir un cadre mathématique satisfaisant et de comprendre le Single-Linkage au sein d'un modèle statistique non paramétrique.

Les limites du Single-Linkage (et de ses descendants) Il manque néanmoins au Single-Linkage une notion de robustesse : en dimension $p \geq 2$, des ponts de bruit peuvent fusionner prématurément des clusters distincts (c'est l'effet de chaînage). Les méthodes proposées jusqu'à nos jours, telles le Robust Single-Linkage, DBSCAN puis HDBSCAN introduisent une notion densité locale fondée sur les K plus proches voisins (là où le Single-Linkage ne prenait en compte que le plus proche voisin). Cependant, ces algorithmes font l'erreur d'imposer une condition d'ordre K aux points tout en propageant la connexité à l'ordre 1 (connexité binaire par arêtes).

Contribution principale La contribution centrale de cette thèse est l'algorithme HGP-Clusterer. L'idée est de remplacer le graphe géométrique par le complexe de Čech. Pour $K \geq 2$, les objets élémentaires ne sont plus les arêtes, mais les $(K - 1)$ -simplexes, qui encodent l'intersection simultanée de K boules. Nous établissons la correspondance exacte entre les clusters de forte densité de l'estimateur des K -voisins – et ce à tout niveau de la hiérarchie – et les composantes que notre algorithme identifie, les K -polyèdres. Après cette généralisation des approches géométrique et statistique, nous finissons l'analogie en identifiant la bonne structure contenant toute l'information du K -arbre minimum couvrant (et disposer ainsi d'un algorithme pratique optimisé dans le cadre euclidien) : il s'agit de la mosaïque de DELAUNAY d'ordre K .

Percolation et analyse La percolation continue sert ensuite d'outil d'analyse. Elle explique l'inconsistance du Single-Linkage et permet de comparer théoriquement Robust Single-Linkage, (H)DBSCAN et HGP-Clusterer au niveau de leur *fraction* de consistance partielle (fraction d'un cluster récupérable avant fusion parasite).

Applications et extensions Finalement, les différentes hiérarchies que nous construisons sont aussi des espaces de résolution pratique : y injecter des *a priori* permet de résoudre des tâches complexes sans apprentissage (anomalies LiDAR 3D, segmentation d'instance 4D). Surtout, le paradigme couplant « ordre supérieur » et « percolation » s'exporte bien au-delà du cadre euclidien. Sur les graphes signés, il inspire de nouvelles dynamiques bayésiennes de clusters (généralisant SWENDSEN-WANG) qui conduisent à des bornes de recouvrement plus fines. En imagerie, le filtre de FRANGI est étendu en un hypergraphe spatial où la connexité d'ordre supérieur bloque la percolation du bruit, assurant une extraction robuste de réseaux de fissures.

Conclusion La thèse propose ainsi une généralisation naturelle du Single-Linkage qui recourt à des interactions d'ordre supérieur et donne un rôle central à la percolation dans l'analyse des performances. Ces deux idées dépassent largement le cadre euclidien initialement fixé.

Mots-clés : Structuration automatique de données; Clustering hiérarchique; Modèle statistique de HARTIGAN; Percolation; Arbre minimum couvrant; Graphe géométrique; Complexe de Čech; Mosaïque de DELAUNAY d'ordre supérieur; Traitement du signal

Abstract

Problem statement In this thesis, we address the problem of automatic data structuring from local, imperfect, and sometimes noisy observations. The starting point is clustering. We then encountered on multiple occasions—and through entirely different paths—the Single-Linkage algorithm. We focused on three approaches: a heuristic approach (construction of the minimum spanning tree over the data); a geometric approach (persistence of the components of a geometric graph); and a statistical approach (estimation of high-density clusters). The first approach provides an optimized algorithm (especially in Euclidean space); the second helps understand the mathematical mechanism at work (percolation); and the last approach provides a satisfactory mathematical framework to understand Single-Linkage within a non-parametric statistical model.

Limitations of Single-Linkage (and its descendants) Single-Linkage nevertheless lacks a notion of robustness: in dimension $p \geq 2$, noise bridges can prematurely merge distinct clusters (this is the chaining effect). The methods proposed to date, such as Robust Single-Linkage, DBSCAN, and later HDBSCAN, introduce a notion of local density based on the K -nearest neighbors (whereas Single-Linkage only considered the nearest neighbor). However, these algorithms make the mistake of imposing an order- K condition on the points while propagating connectivity at order 1 (binary connectivity via edges).

Main contribution The core contribution of this thesis is the HGP-Clusterer algorithm. The idea is to replace the geometric graph with the Čech complex. For $K \geq 2$, the elementary objects are no longer edges, but $(K - 1)$ -simplices, which encode the simultaneous intersection of K balls. We establish the exact correspondence between the high-density clusters of the K -nearest neighbor estimator—and this at all levels of the hierarchy—and the components identified by our algorithm, the K -polyhedra. Following this generalization of the geometric and statistical approaches, we complete the analogy by identifying the proper structure containing all the information of the K -minimum spanning tree (thus providing a practical algorithm optimized for the Euclidean setting): it is the order- K DELAUNAY mosaic.

Percolation and analysis Continuum percolation then serves as an analytical tool. It explains the inconsistency of Single-Linkage and enables a theoretical comparison of Robust Single-Linkage, (H)DBSCAN, and HGP-Clusterer in terms of their partial consistency *fraction* (the fraction of a cluster recoverable before a spurious merge).

Applications and extensions Finally, the different hierarchies we construct also serve as practical resolution spaces: injecting *priors* into them makes it possible to solve complex tasks without training (3D LiDAR anomalies, 4D instance segmentation). Most importantly, the paradigm coupling “higher order” and “percolation” exports well beyond the Euclidean framework. On signed graphs, it inspires new Bayesian cluster dynamics (generalizing SWENDSEN–WANG) that lead to tighter recovery bounds. In imaging, the FRANGI filter is extended into a spatial hypergraph where higher-order connectivity blocks noise percolation, ensuring a robust extraction of crack networks.

Conclusion The thesis thus proposes a natural generalization of Single-Linkage that leverages higher-order interactions and assigns a central role to percolation in performance analysis. These two ideas extend well beyond the initially established Euclidean framework.

Keywords : Automatic data structuring; Hierarchical clustering; Percolation; HARTIGAN's statistical model; Minimum spanning tree; Geometric graph; Čech complex; Higher-order DELAUNAY mosaic; Signal processing

Résumés < 1000 caractères.

Cette thèse traite de la structuration de données bruitées. Le clustering hiérarchique par Single-Linkage et ses dérivés (HDBSCAN) manquent de robustesse : ils évaluent la densité via les K plus proches voisins mais gardent une connexité binaire (arêtes).

Notre contribution centrale, HGP-Clusterer, corrige cela. En remplaçant les graphes par le complexe de Čech, il utilise des interactions d'ordre supérieur (K -polyèdres) pour retrouver la hiérarchie exacte des clusters denses. En pratique, il s'optimise via la mosaïque de Delaunay d'ordre K .

La théorie de la percolation continue prouve que notre méthode récupère une plus grande fraction de cluster face au bruit. Enfin, ce paradigme couplant « ordre supérieur » et « percolation » dépasse le cadre euclidien : tâches 3D/4D sans apprentissage, dynamiques bayésiennes de communautés sur graphes signés, et extraction de réseaux de fissures en imagerie.

This thesis addresses the structuring of noisy data. Hierarchical clustering via Single-Linkage and its derivatives (HDBSCAN) lacks robustness : they evaluate density using K -nearest neighbors but maintain a binary connectivity (edges).

Our core contribution, HGP-Clusterer, solves this. By replacing graphs with the Čech complex, it uses higher-order interactions (K -polyhedra) to retrieve the exact hierarchy of dense clusters. In practice, it is optimized via the order- K Delaunay mosaic.

Continuum percolation theory proves that our method recovers a larger cluster fraction against noise. Finally, this paradigm coupling "higher order" and "percolation" extends beyond the Euclidean framework : training-free 3D/4D tasks, Bayesian community dynamics on signed graphs, and crack network extraction in imaging.

Introduction générale

1.1 Propos liminaire

Ce manuscrit aborde le problème de la structuration automatique de données. Qu'il s'agisse de nettoyer un nuage de points tridimensionnel acquis par un capteur LiDAR, d'extraire un réseau de fissures dans une image géologique, ou de retrouver des communautés dans un graphe d'interactions, la question générale reste la même : comment extraire, à partir d'observations locales et imparfaites, une structure globale qui soit à la fois robuste, interprétable et mathématiquement contrôlée ?

Notre point de départ sera plus restreint : celui du *clustering*, ou classification non-supervisée, sur un nuage de points fini

$$\mathcal{X} = \{x_1, \dots, x_n\} \subset \mathbb{R}^p.$$

Cette restriction au cadre euclidien peut sembler modeste. Elle est pourtant suffisamment riche pour faire apparaître les principaux phénomènes étudiés dans ce manuscrit : la hiérarchie, la densité, la connexité, le bruit et la percolation.

Historiquement, le clustering a souvent été présenté comme une famille d'heuristiques algorithmiques. Les travaux de HARTIGAN ont donné à ce problème un cadre statistique non paramétrique particulièrement simple : les clusters sont les composantes connexes des ensembles de niveau d'une densité $f : \mathbb{R}^p \rightarrow \mathbb{R}_+$. Pour un niveau $\lambda > 0$, l'on pose

$$L_f(\lambda) = \{x \in \mathbb{R}^p \mid f(x) \geq \lambda\},$$

et les amas de forte densité au niveau λ sont les composantes connexes de $L_f(\lambda)$.

En pratique, la densité f est inconnue. Il faut donc l'estimer. Dans ce manuscrit, l'estimateur qui nous servira de fil conducteur est l'estimateur des K plus proches voisins (ou K -NN pour *Nearest Neighbours* en anglais). En paramétrant les niveaux de densité par un rayon $r > 0$, les ensembles de niveau associés s'écrivent

$$L_K(r) = \{y \in \mathbb{R}^p \mid |B(y, r) \cap \mathcal{X}| \geq K\}.$$

Autrement dit, un point y appartient à $L_K(r)$ si la boule de centre y et de rayon r contient au moins K points du nuage $\mathcal{X}$.

Un phénomène remarquable se produit pour $K = 1$. Les composantes connexes de $L_1(r)$ sont exactement les composantes connexes de l'union de boules fermées

$$L_1(r) = \bigcup_{x \in X} \overline{B}(x, r),$$

et donc celles du graphe géométrique qui relie deux points $x, x' \in X$ dès que $\|x - x'\| \leq 2r$.

Cette hiérarchie est précisément celle produite par l'algorithme du *Single-Linkage* (algorithme dit parfois du « saut minimum » en français). Mieux encore, toute l'information hiérarchique (comprenant tous les niveaux $r \in \mathbb{R}_+$) est contenue dans un unique graphe très parcimonieux : l'arbre minimum couvrant.

Le Single-Linkage fait ainsi le pont entre trois points de vue :

1. Un point de vue **heuristique**, où l'on construit un arbre minimum couvrant sur les données.
2. Un point de vue **géométrique**, où l'on observe la persistance des composantes connexes d'un graphe géométrique lorsque le rayon r varie.
3. Un point de vue **statistique**, où l'on retrouve exactement les amas de forte densité de l'estimateur 1-NN.

Ce constat est le point de départ de la thèse. Si la hiérarchie des niveaux de densité est donnée par un simple graphe lorsque la densité est estimée avec un seul voisin, que devient cette hiérarchie lorsque $K \geq 2$?

La réponse défendue tout au long de ce manuscrit est la suivante : pour $K \geq 2$, les graphes ne suffisent plus. La bonne structure n'est plus une relation binaire entre paires de points, mais une **structure d'ordre supérieur** portée par des hyper-arêtes. Il faut alors remplacer les graphes géométriques par des complexes simpliciaux (une famille d'hypergraphes) et les composantes connexes usuelles par une notion de **connexité d'ordre supérieur**.

Le second phénomène central de ce manuscrit est la **percolation**. En dimension $p \geq 2$, les composantes construites par des graphes géométriques peuvent fusionner par des ponts de “bruit” avant que les amas de forte densité n'aient été correctement recouverts. Ce phénomène explique l'*effet de chaînage* bien connu du Single-Linkage, mais aussi une partie des limites de ses robustifications modernes, comme le Robust Single-Linkage ou HDBSCAN, considéré universellement comme l'« état-de-l'art » pour ce qui touche au clustering hiérarchique fondé sur la densité.

Ainsi, deux idées traversent l'ensemble du manuscrit :

1. Lorsque les relations binaires d'un graphe deviennent insuffisantes ou trop instables, il faut intégrer des **interactions d'ordre supérieur**.
2. La théorie de la **percolation** fournit alors le cadre mathématique permettant de quantifier les performances de ces algorithmes.

Ces deux idées seront d’abord étudiées dans le cadre euclidien des nuages de points, puis reprises dans des cadres plus structurés : les graphes pondérés signés pour la détection de communautés, et les images pour l’extraction de réseaux de fissures.

1.2 Une brève histoire du clustering. L’omniprésence de l’algorithme de Single-Linkage

1.2.1 Les deux grandes familles de clustering

Il existe essentiellement deux paradigmes historiques pour le clustering.

Le premier est celui du k -Means. L’objectif est de partitionner les données en k classes, chacune représentée par un centroïde, de manière à minimiser la variance intra-classe. Dans le cadre euclidien, cet algorithme peut se lire comme un cas particulier très dégénéré d’un modèle de mélange gaussien :

$$f(x) = \sum_{c=1}^k \pi_c \mathcal{N}(x \mid \mu_c, \Sigma_c),$$

lorsque les matrices de covariance Σ_c deviennent petites et que chaque composante se concentre autour de son centre μ_c .

Cette approche est naturelle lorsque l’on accepte de poser des hypothèses fortes sur la distribution des données. Elle cherche, en quelque sorte, à reconstruire un modèle global de la densité. Elle est puissante, mais elle impose souvent une géométrie assez rigide aux clusters attendus.

Le second paradigme est celui des méthodes agglomératives et fondées sur la densité. Le Single-Linkage en est l’exemple le plus élémentaire. L’algorithme ne cherche pas à ajuster explicitement une densité paramétrique ; il se concentre sur les distances locales entre les points, et donc sur les vides qui séparent les structures. Dans le cadre de HARTIGAN, cette approche possède une interprétation statistique précise : pour $K = 1$, le Single-Linkage retrouve exactement les amas de forte densité de l’estimateur 1-NN.

C’est cette seconde famille qui nous intéressera principalement. Elle a l’avantage de ne pas supposer *a priori* que les clusters sont décrits par un nombre fixé de paramètres. Elle est donc plus adaptée à des structures géométriques complexes. Son défaut est tout aussi clair : en reliant les points par des arêtes, elle peut aussi relier ce qui ne devrait pas l’être.

1.2.2 Du partitionnement à la hiérarchie

Définir le clustering comme une unique partition de $\mathcal{X}$ est souvent trop restrictif. La structure pertinente dépend de l’échelle d’observation. Deux objets peuvent être séparés à fine échelle, puis appartenir à une même structure à plus grande échelle. Une partition plate force donc un choix de résolution.

Ce problème apparaît grâce à l’approche axiomatique du clustering : le théorème d’impossibilité de KLEINBERG montre qu’aucune fonction de clustering ne peut satisfaire simultanément trois propriétés naturelles. Une façon de sortir de cette impasse est de demander davantage à la sortie de l’algorithme : non plus une partition unique, mais une hiérarchie de partitions.

Un clustering hiérarchique sur $\mathcal{X}$ peut être vu comme une application

$$\theta : \mathbb{R}_+ \longrightarrow \text{Part}(\mathcal{X}),$$

où $\theta(r)$ est une partition de $\mathcal{X}$ au niveau r , et où les partitions deviennent de moins en moins fines lorsque r augmente. Cette structure est équivalente à la donnée d’une ultramétrique sur $\mathcal{X}$. Dans ce cadre, les travaux de CARLSSON & MÉMOLI montrent que le Single-Linkage apparaît comme une solution canonique : il est l’unique méthode satisfaisant certaines propriétés fonctorielles naturelles.

Ce détour axiomatique – l’approche axiomatique n’est pas au cœur de nos travaux – est instructif : lorsque l’on impose en sortie une hiérarchie de partitions, le Single-Linkage réapparaît. Et lorsque l’on veut aller au-delà du Single-Linkage, une possibilité naturelle consiste à relâcher encore la sortie de l’algorithme. Au lieu d’exiger une partition à chaque niveau, on peut accepter des recouvrements. Cette idée, présente notamment dans les travaux de CULBERTSON, GURALNIK & STILLER, rejoint directement ce que nous observerons pour $K \geq 2$: les objets naturels ne sont plus toujours des partitions des points.

1.3 Problématique : que devient la connexité lorsque $K \geq 2$?

Le Single-Linkage est satisfaisant pour l’estimateur 1-NN, mais il est fragile. Son défaut classique est l’effet de chaînage : une suite de points isolés peut suffire à connecter deux amas qui devraient rester séparés. Du point de vue statistique, cette faiblesse se traduit par l’inconsistance (au sens de HARTIGAN) en dimension $p \geq 2$.

Les robustifications modernes du Single-Linkage cherchent à corriger ce défaut en remplaçant l’estimateur 1-NN par un estimateur K -NN, asymptotiquement consistant. C’est l’idée du Robust Single-Linkage, puis de (H)DBSCAN. Ces méthodes introduisent une notion de densité locale : un point est jugé dense s’il possède au moins K voisins dans une boule de rayon donné.

Cependant, elles conservent une connectivité de graphe, c’est-à-dire binaire au lieu d’être K -naire. Les points sont filtrés à l’ordre K , mais ils restent connectés par des arêtes. Cette asymétrie est le cœur du problème : imposer une condition d’ordre K aux sommets tout en propageant la connexité par des liens d’ordre 1 ne permet pas de reconstruire exactement la topologie des ensembles $L_K(r)$.

Pour voir la structure correcte, il faut repartir de la définition :

$$L_K(r) \triangleq \{y \in \mathbb{R}^p \mid |B(y, r) \cap \mathcal{X}| \geq K\}.$$

Dire que $y \in L_K(r)$ signifie que y est simultanément dans au moins K boules centrées sur des points de $\mathcal{X}$. Les objets élémentaires ne sont donc plus des arêtes, mais des intersections de K boules. Celles-ci sont encodées par les $(K - 1)$ -simplexes du complexe de Čech

$$\check{C}(X, r) \triangleq \left\{ \sigma \subset X \mid \bigcap_{x \in \sigma} B(x, r) \neq \emptyset \right\}.$$

La généralisation proposée dans ce manuscrit consiste alors à construire un graphe auxiliaire $\Gamma_K(\mathcal{X}, r)$ dont les sommets sont les $(K - 1)$ -simplexes de $\check{C}(X, r)$, deux tels simplexes σ et τ étant adjacents lorsque leur union $\sigma \cup \tau$ est encore un simplexe de $\check{C}(X, r)$. Les composantes connexes de ce graphe auxiliaire définissent les K -polyèdres.

Pour $K = 1$, on retrouve exactement les composantes connexes ordinaires du graphe géométrique, donc le Single-Linkage.

Pour $K = 2$, ce ne sont plus les points qui percolent directement, mais les arêtes, recollées entre elles par des triangles.

Plus généralement, la connexité se propage par des interactions d'ordre supérieur.

L'algorithme ainsi défini est baptisé *HGP-Clusterer*, pour *Hypergraphe-Percol*. Le résultat central de la seconde partie peut alors s'écrire sous la forme suivante :

$$\theta_K^{\text{HGP}}(r) = H_{f_K}^{\text{discrets}}(r), \quad r > 0.$$

Autrement dit, les K -polyèdres du complexe de Čech coïncident, niveau par niveau, avec les amas discrets de forte densité associés à l'estimateur K -NN. En particulier,

$$\theta_1^{\text{HGP}} = \theta^{\text{SL}}.$$

Un point important doit être souligné dès l'introduction : pour $K \geq 2$, les amas discrets de forte densité ne forment pas nécessairement une partition de $\mathcal{X}$. Un point peut participer à plusieurs interactions d'ordre supérieur, et donc appartenir à plusieurs K -polyèdres. Ce n'est pas un défaut de la construction ; c'est au contraire l'information géométrique que l'on perd si l'on force trop tôt une assignation unique des points. Une discussion est d'ailleurs consacrée au problème de construire un partitionnement strict, lorsque les données du problème l'impose par exemple.

1.4 La percolation comme mesure de performance

L'exactitude topologique est satisfaisante mathématiquement, mais elle ne suffit pas à décrire les performances d'un algorithme. Même si les K -polyèdres reconstruisent

exactement les amas discrets de forte densité de l'estimateur K -NN, il reste à comprendre ce que l'on peut espérer récupérer lorsque les données sont bruitées et lorsque $n \rightarrow +\infty$.

C'est ici qu'intervient la théorie de la percolation continue. Lorsque l'on fait varier le rayon r , les composantes apparaissent, croissent, puis fusionnent. Dans un fond bruité, une composante géante peut apparaître et relier des régions qui devraient rester distinctes. Le problème n'est donc pas seulement que les graphes "chaînent"; c'est qu'ils percolent trop tôt.

En dimension $p \geq 2$, on ne peut pas espérer, à K fixé, retrouver intégralement deux amas de forte densité avant qu'ils ne fusionnent avec le bruit. L'objectif raisonnable est de quantifier la *fraction* asymptotiquement récupérable. Pour cela, nous introduisons et comparons des probabilités de percolation de la forme

$$\lambda \mapsto \Theta_{K,p}^{\text{cc}}(\lambda), \quad \text{cc} \in \{\text{core}, \text{dbscan}, \text{poly}\},$$

où les trois familles de composantes connexes cc correspondent respectivement au Robust Single-Linkage, à DBSCAN/HDBSCAN et aux K -polyèdres de HGP-Clusterer.

Cette lecture permet de comparer mathématiquement les méthodes. Le Robust Single-Linkage impose une condition trop forte aux points : ils doivent être des points cœurs. DBSCAN corrige partiellement le tir en ajoutant les points accessibles, mais conserve une connectivité par arêtes. HGP-Clusterer modifie la connectivité elle-même : il ne demande pas seulement que les points soient denses, il connecte correctement les régions où la densité K -NN est forte.

La théorie de la percolation permet de mesurer où apparaît un amas dense, à quelle vitesse, et quelle fraction d'un amas peut être récupérée avant fusion parasite.

1.5 Contributions du manuscrit

Les contributions de ce manuscrit peuvent être regroupées autour de quatre axes.

Une vue unifiée du Single-Linkage La première partie propose une synthèse du Single-Linkage selon trois points de vue complémentaires : **heuristique**, **géométrique** et **statistique**. Le Single-Linkage est à la fois l'algorithme de l'arbre minimum couvrant, la persistance des composantes connexes d'un graphe géométrique, et la hiérarchie exacte des amas de forte densité pour l'estimateur 1-NN. Nous digressons aussi en adoptant pour un chapitre le point de vue axiomatique, qui explique pourquoi cet algorithme réapparaît dès que l'on cherche une projection naturelle des espaces métriques vers les espaces ultramétriques.

HGP-Clusterer : la généralisation par l'ordre supérieur Nous définissons une généralisation du Single-Linkage aux estimateurs K -NN. Le graphe géométrique est

remplacé par le complexe de Čech, et les composantes connexes par les K -polyèdres. Le résultat principal est l'identité

$$\theta_K^{\text{HGP}}(r) = H_{\widehat{f_K}}^{\text{discrets}}(r),$$

qui montre que HGP-Clusterer retrouve exactement les amas discrets de forte densité de l'estimateur K -NN. Nous étudions ensuite la question algorithmique : comment éviter de construire tout le complexe de Čech ? Le rôle de l'arbre minimum couvrant est alors joué par une structure plus fine, liée aux simplexes de GABRIEL et à la mosaïque de DELAUNAY d'ordre supérieur.

La percolation comme outil d'analyse théorique Nous montrons que les limites du Single-Linkage, du Robust Single-Linkage et de (H)DBSCAN se comprennent naturellement par le phénomène de percolation. Nous introduisons une *vitesse de percolation* permettant de comparer quantitativement ces familles d'algorithmes. Cette analyse explique pourquoi les interactions d'ordre supérieur retardent la percolation parasite dans le bruit et améliorent la fraction asymptotiquement récupérable des amas de forte densité.

Le passage à des données davantage structurées La dernière partie montre que le couple interactions d'ordre supérieur & percolation ne se limite pas aux nuages de points euclidiens. Sur des graphes pondérés signés, nous construisons un cadre bayésien pour la détection de communautés et généralisons les dynamiques de clusters de type SWENDSEN-WANG à des interactions d'ordre supérieur. En traitement d'image, à partir du filtre de FRANGI, nous proposons d'abord un graphe de FRANGI plus riche en information et permettant une extraction fine de réseaux de fissures. Le passage à l'*hypergraphe* de FRANGI agit comme un filtre contre la percolation du bruit local sur des données plus difficiles.

1.6 Organisation du manuscrit

Le manuscrit est organisé en trois parties.

Première partie : du Single-Linkage à ses fondements Le Chapitre 2 présente le Single-Linkage dans le cadre euclidien selon les trois points de vue qui nous serviront ensuite : arbre minimum couvrant, graphes géométriques persistants, et modèle statistique de Hartigan. Le Chapitre 3 rappelle le point de vue axiomatique, depuis le théorème d'impossibilité de KLEINBERG jusqu'à la caractérisation du Single-Linkage par CARLSSON & MÉMOLI. Le Chapitre 4 étudie les limites du Single-Linkage, en particulier l'effet de chaînage, puis présente ses robustifications modernes : Robust Single-Linkage et (H)DBSCAN. Le Chapitre 5 montre enfin comment exploiter l'arbre hiérarchique comme un espace de recherche, en y injectant des *a priori* géométriques. Deux applications

industrielles illustrent cette approche : la détection d'anomalies dans des nuages LiDAR 3D et la segmentation panoptique 4D sur SemanticKITTI.

Seconde partie : généralisation du Single-Linkage avec des interactions d'ordre supérieur Le Chapitre 6 introduit HGP-Clusterer. Nous y définissons les K -polyèdres du complexe de Čech et démontrons leur correspondance exacte avec les amas discrets de forte densité K -NN. Le Chapitre 7 développe l'analyse par percolation continue et compare les performances théoriques de HGP-Clusterer, du Robust Single-Linkage et de (H)DBSCAN. Le Chapitre 6 cherche l'analogue, à l'ordre K , de l'arbre minimum couvrant : les simplexes utiles aux fusions satisfont une condition de GABRIEL et sont liés à la mosaïque de DELAUNAY d'ordre K . Le Chapitre 9 revient sur la mise en pratique de HGP-Clusterer : partition stricte des points lorsque cela est nécessaire, optimisations pour $K = 2$ (et généralisation à n'importe quel K), approximation par VIETORIS-RIPS en dimension élevée ou dans un cadre métrique général, et ouverture vers la réduction de dimension d'ordre supérieur.

Tierce partie : vers des données davantage structurées Le Chapitre 10 introduit les deux cadres étudiés ensuite : la détection de communautés dans des graphes et l'extraction de structures linéiques dans des images. Le Chapitre 11 propose un cadre bayésien pour la détection de communautés sur graphes pondérés signés. Nous y étudions des dynamiques de clusters généralisant SWENDSEN-WANG et montrons comment les interactions d'ordre supérieur permettent d'obtenir de meilleures bornes de recouvrement. Le Chapitre 12 applique les mêmes idées au traitement d'image avec le graphe de FRANGI pour l'extraction de réseaux de fissures. L'objectif est alors de construire une méthode sans apprentissage, robuste aux changements de domaine, et produisant une sortie géométrique directement "éditable" à fin d'être intégrée à une suite logicielle d'aide à l'annotation experte de vérité terrain.

Enfin, le Chapitre 13 conclut le manuscrit en reprenant ces contributions et en présentant plusieurs perspectives : axiomatique des recouvrements, consistance en dimension $p \geq 2$, réduction de dimension à l'aide d'une analogie sur la mosaïque de Delaunay d'ordre K , etc.

PREMIÈRE PARTIE

Du Single-Linkage à ses fondements

Le cadre euclidien $\mathcal{X} \subset \mathbb{R}^p$ L'algorithme de Single-Linkage [1, 2] peut être défini pour n'importe quel graphe à poids positifs. Dans le premier chapitre de cette partie, le chapitre 2, nous nous plaçons dans le cas très particulier d'un graphe complet sur un nuage de points fini $\mathcal{X} \subset \mathbb{R}^p$ dans l'espace euclidien de dimension $p \in \mathbb{N}^*$, le poids d'une arête $\{x, x'\}$ étant la distance euclidienne $\|x - x'\|$ entre leurs sommets. Cette restriction aux espaces métriques finis $(\mathcal{X}, d)$, avec $d(x, x') = \|x - x'\|$ nous permet de poser un cadre mathématique rigoureux au problème de clustering : l'identification des amas de forte densité (DEF. 6, p. 25), ou modèle de HARTIGAN [3, 4].

Du point de vue statistique, l'algorithme de Single-Linkage est la pierre de fondation du modèle de HARTIGAN : il identifie exactement ces amas denses dans $\mathbb{R}^p$ lorsque la densité de n'importe quel point de l'espace $y \in \mathbb{R}^p$ est estimée au moyen de son plus proche voisin dans le nuage $x \in \mathcal{X}$ (voir la synthèse à la fin du chapitre 2).

En pratique, d'un point de vue heuristique, le Single-Linkage s'obtient en construisant l'arbre minimum couvrant sur les données $\mathcal{X}$.

Un troisième point de vue, qui se montrera très fructueux dans la partie suivante, est d'observer le Single-Linkage du point de vue des graphes géométriques (au sens de PENROSE [4]) : l'échelle r est le rayon du graphe et l'on observe la structure hiérarchique produite en faisant varier r . Cette dernière façon d'appréhender le Single-Linkage nous permettra de le relier à la théorie de la percolation continue [4, 5] (voir le chapitre 7), et ce faisant de mesurer les performances théoriques d'une famille d'algorithmes (comprenant le Single-Linkage) que nous avons baptisés d'*analyse persistante* (par analogie avec l'homologie persistante en analyse topologique des données [6]).

Ce paradigme euclidien nous servira de base pour généraliser naturellement le Single-Linkage au cours de la partie suivante.

Le cadre axiomatique Le chapitre 3 est une digression sur un autre chemin qui aurait pu nous conduire au Single-Linkage. En effet, le Single-Linkage a ceci de fascinant qu'on le rencontre aussi avec une approche tout à fait différente : en essayant de définir une axiomatique minimale à ce que devrait être un "bon" clustering. Le Single-Linkage est l'unique clustering hiérarchique satisfaisant cette axiomatique (FAIT 7, p. 35); on peut alors le voir comme une projection des espaces métriques vers les espaces *ultramétriques*.

Le Single-Linkage aujourd’hui Ces différents points de vue montrent aussi les limites du Single-Linkage ; c’est l’objet de notre chapitre 4. Puisque nous avons abordé le Single-Linkage *via* la théorie des graphes, il est commode pour ce chapitre de le voir comme un algorithme de min max : la distance (ultramétrique) de Single-Linkage d_{SL} entre deux points $x, x' \in \mathcal{X}$ est le minimum sur tous les chemins (toutes les *chaînes*) $\omega : x \rightsquigarrow x'$ reliant ces deux points, du poids maximum d’une arête sur ce chemin :

$$d_{\text{SL}}(x, x') = \min_{\omega=e_1, \dots, e_l} \max_{a \in \{1, \dots, l\}} |e_a|.$$

C’est l’origine de l’effet de chaînage (*chaining effect* en anglais) sur lequel nous revenons en début de chapitre. Les évolutions nécessaires du Single-Linkage ont conduit à HDBSCAN [7, 8], qui est aujourd’hui unanimement considéré comme l’« état-de-l’art » pour le clustering fondé sur la densité [9, 10].

Nous revenons sur ces évolutions et proposons dans le dernier chapitre de cette partie, le chapitre 5, une vue générale sur le clustering hiérarchique avec la possibilité d’ajouter des *a priori*. Ce dernier chapitre est illustré de résultats empiriques pour de la segmentation d’instance de points 3D LiDAR (application visée : la conduite autonome ; *benchmark* : SemanticKITTI).

Le Single-Linkage : trois points de vue (heuristique, géométrique & statistique)

Ainsi que nous l'avons vu dans l'introduction générale au chapitre 1, il y a essentiellement deux paradigmes d'algorithmes de classification non-supervisée, ou *clustering* :

1. Celui du k -Means [11], souvent présenté comme un problème d'optimisation consistant à partitionner l'espace en k cellules, chacune associée à un centroïde, de sorte à minimiser la variance intra-classe (ou maximiser la variance inter-classes).
2. Celui du Single-Linkage, algorithme agglomératif construisant une hiérarchie sur les données [1, 2].

Se placer dans l'espace euclidien nous permet d'avoir naturellement des objets d'intérêt : les amas de forte densité du modèle de HARTIGAN [3] (voir DEF. 6, p. 25).

Dans le domaine de la classification supervisée, l'on distingue habituellement la classification générative de la classification discriminative [12]. Si l'on voulait pousser l'analogie à la classification non-supervisée, l'on pourrait voir deux façons foncièrement différentes pour identifier ces amas (ou clusters) de forte densité :

1. En reconstruisant intégralement la densité en tout point x de l'espace. Cette reconstruction exhaustive permet aussi le cas échéant de générer de nouvelles données, d'où le nom de modèle *génératif*. Le k -Means rentre dans cette catégorie : il suffit d'y voir un cas dégénéré de modèle de mélange gaussien [13]

$$f(x) = \sum_{c=1}^k \pi_c \mathcal{N}(x \mid \mu_c, \Sigma_c)$$

avec $\Sigma_c = \sigma^2 \text{Id}$ (où $\sigma^2 \rightarrow 0$) et $\pi_c = \frac{1}{k}$ pour tout c . *Nota bene* : dans la perspective générative, il est nécessaire de faire une hypothèse forte sur la distribution des

points (ici, un mélange gaussien dégénéré) ; il serait autrement impossible d'avoir un estimateur permettant la génération de nouveaux points *a priori* dans *tout* l'espace $\mathbb{R}^p$.

2. Au contraire, l'algorithme qui nous intéresse, le Single-Linkage, ne fait aucune hypothèse sur la densité des données ; il résout le problème de partitionnement en se concentrant exclusivement sur les frontières (ou les vides) entre les points et *discrimine* les clusters en identifiant les frontières pertinentes. Comme nous le verrons dans la suite (cf. la synthèse en fin de chapitre), le Single-Linkage parvient à identifier exactement les clusters de forte densité d'un estimateur sans pour autant construire cet estimateur. Sa complexité est $\mathcal{O}(n^2)$ dans le pire cas, mais nous verrons qu'il existe d'importantes optimisations tirant parti de la géométrie de $\mathbb{R}^p$.

Contributions Le mérite principal de ce chapitre est de proposer en une synthèse théorique unifiée trois façons fondamentalement différentes d'aborder le Single-Linkage : la géométrie des graphes, l'estimation de densité statistique et l'heuristique agglomérative originelle. Les synthèses proposées jusqu'à aujourd'hui (citons [9, 14] ou la page Wikipedia du Single-Linkage [15]) se concentrant la plupart du temps sur l'aspect heuristique, avec les différentes fonctions d'agglomération (single-link, complete-link, *average/median*, etc.), parfois faisant le lien avec le modèle de HARTIGAN, mais sans saisir le cadre mathématique dans son ensemble.

2.1 Introduction au Single-Linkage

L'algorithme de *Single-Linkage* [1, 2] compte parmi les méthodes de classification hiérarchique (ascendante) les plus anciennes, les plus rapides et les plus populaires [16, 17].

Dès les années 1950, cet algorithme est apparu spontanément pour répondre à des problèmes de taxonomie (puis de phylogénie), formalisé notamment sous le nom de méthode des « dendrites » [1]. L'objectif historique était de regrouper hiérarchiquement des espèces apparentées pour reconstruire l'« arbre de la vie », selon la terminologie de DARWIN (voir le croquis en FIG. 2.1).

DÉFINITION 1 : L'ARBRE HIÉRARCHIQUE DU SINGLE-LINKAGE [1, 2]

Étant donné un espace métrique fini $(\mathcal{X}, d)$ de n points (dont on supposera les distances deux à deux distinctes), l'algorithme construit un dendrogramme (un arbre hiérarchique indexé par un niveau r) de la façon suivante :

- **Initialisation** ($t = 0$, niveau $r_0 \triangleq 0$). On part de la partition triviale en singletons, $\mathcal{C}^{r_0} \triangleq \{\{x_i\}\}_{i=1}^n$.
- **Itération** (étape t , niveau r_t). On fusionne les deux clusters C et C' présents




FIGURE 2.1 : « Arbre de la vie » de DARWIN (*On the Origin of Species*, 1859). Les lettres représentent des espèces distinctes. Chaque ligne représente 1000 générations.

dans le clustering $\mathcal{C}^{r_{t-1}}$ de l'étape précédente qui minimisent la distance de *single linkage* :

$$d_{\text{SL}}(C, C') = \min_{x \in C, x' \in C'} d(x, x').$$

On obtient alors un nouveau clustering $\mathcal{C}^{r_t}$ constitué de $n - t$ clusters associé au niveau $r_t \triangleq \frac{1}{2}d_{\text{SL}}(C, C')$.

- **Arrêt.** L'algorithme se termine à l'étape $n - 1$, lorsque tous les points sont réunis dans un unique cluster global (la racine de l'arbre) associé au niveau $r_{\text{connect}} \triangleq r_{n-1}$.

Remarque Le Single-Linkage est souvent défini comme renvoyant une partition et non l'arbre hiérarchique complet. Dans sa version originale, il reçoit en effet k le nombre de clusters à retourner et renvoie le clustering correspondant à l'étape $n - k$. On peut aussi rencontrer le Single-Linkage dans sa version seuillée à ε ; c'est-à-dire qu'il renvoie le clustering correspondant à l'étape $t \in \{0; \dots; n - 1\}$, où t est l'unique entier vérifiant $r_t \leq \varepsilon < r_{t+1}$ (étant entendu, par convention, que $r_n \triangleq +\infty$).

Cette définition incrémentale trouve un écho en théorie des graphes avec l'*arbre minimum couvrant*.

2.2 Le Single-Linkage en pratique : l'arbre minimum couvrant

2.2.1 Différents algorithmes pour l'arbre minimum couvrant

Il y a équivalence algorithmique entre le Single-Linkage et la recherche de l'arbre minimum couvrant (*minimum spanning tree*, ou MST en anglais), comme l'illustre la version BORŮVKA de construction de l'arbre minimum couvrant (voir ci-dessous).

Il existe trois algorithmes historiques pour extraire l'arbre minimum couvrant d'un graphe (connexe) à n nœuds et m arêtes.

- **“Single-Linkage parallèle” : BORŮVKA** (1926) [18]. À chaque itération, chaque composante connexe identifie et contracte son arête sortante la plus courte. Le nombre de composantes diminue de moitié à chaque passe, garantissant une complexité en $\mathcal{O}(m \log n)$. Il s'agit d'un Single-Linkage massivement parallélisé.
- **Approche gloutonne : KRUSKAL** (1956) [19]. Les arêtes sont triées par poids croissant, puis insérées séquentiellement sous réserve de ne former aucun cycleⁱ⁾. L'étape limitante est le tri des arêtes, de complexité $\mathcal{O}(\text{Tri}(m))$ (citons le QuickSort [20] en complexité moyenne $\mathcal{O}(m \log m)$ de HOAREⁱⁱ⁾). C'est en pratique la méthode la plus utilisée, tant pour sa simplicité que pour la complexité mémoire optimale en $\mathcal{O}(n)$ de la structure auxiliaire d'ensembles disjoints (Union-Find) [21] utilisée une fois le tri des arêtes effectué.
- **Croissance locale : JARNÍK-PRIM-DIJKSTRA** (1930/1957/1959). Cet algorithme fait croître un *unique* arbre en y rattachant itérativement le sommet non visité le plus proche. Sur un espace géométrique dense, son exécution en $\mathcal{O}(n^2)$ est asymptotiquement optimale.

Améliorations (théoriques) et avancée récente Il existe des raffinements théoriques pour améliorer le facteur $\log n$ de la complexité [22]. Il a d'ailleurs été montré que la complexité optimale, quoique non calculée explicitement, est celle associée à un certain arbre de décision (*decision tree*) [23]. Il existe aussi des algorithmes aléatoires pour retrouver l'arbre minimum couvrant [24]. Citons enfin une avancée récente en intelligence artificielle dans le cas d'espaces métriques : VELDT *et al.* [25] ont présenté un algorithme de complétion de forêts par apprentissage (*learning-augmented algorithms*) en temps sous-quadratique (esquivant ainsi le parcours exhaustif de la matrice des distances).

ⁱ⁾Rappelons qu'un arbre est par définition un graphe connexe acyclique.

ⁱⁱ⁾Tony HOARE (1934 – †2026), décédé alors que j'allais me lancer dans rédaction de ce manuscrit.

2.2.2 Graphe de GABRIEL et triangulation de DELAUNAY

Le cas de la basse dimension euclidienne ($p = 2, 3, 4, \dots$) Dans le cas particulier où les données $\mathcal{X} \subset \mathbb{R}^p$ sont dans l'espace euclidien, on peut exploiter la géométrie de cet espace et restreindre la recherche de l'arbre minimum couvrant à des graphes géométriques beaucoup plus parcimonieux que le graphe complet. Ces méthodes sont particulièrement efficaces lorsque la dimension p est suffisamment faible (cf. par exemple la discussion *infra* dans le cas du plan $p = 2$).

Les arêtes de ces graphes reposent sur une condition de vacuité d'une région entre les deux sommets (voir FIG. 2.2 pour une illustration).

DÉFINITION 2 : GRAPHE DE VOISINAGE RELATIF [26]

Le graphe de voisinage relatif (*relative neighborhood graph*, ou RNG en anglais) relie deux points $x, x' \in \mathcal{X}$ si l'intersection de leurs boules ouvertes de rayon $\|x - x'\|$ est vide de tout point de $\mathcal{X}$:

$$\forall z \in \mathcal{X} \setminus \{x, x'\}, \quad \max(\|x - z\|, \|x' - z\|) \geq \|x - x'\|.$$

DÉFINITION 3 : GRAPHE DE GABRIEL [27]

Le graphe de GABRIEL relie deux points $x, x' \in \mathcal{X}$ si la boule ouverte de diamètre $[x, x']$ ne contient aucun point de $\mathcal{X}$:

$$\forall z \in \mathcal{X} \setminus \{x, x'\}, \quad \|x - z\|^2 + \|x' - z\|^2 \geq \|x - x'\|^2.$$

DÉFINITION 4 : TRIANGULATION DE DELAUNAY [28, 29]

Le graphe de DELAUNAY (le 1-squelette de la triangulation de DELAUNAY) relie deux points $x, x' \in \mathcal{X}$ s'il existe au moins une boule ouverte, vide de tout point de $\mathcal{X}$, dont la frontière contient simultanément x et x' .




FIGURE 2.2 : L'arête (x, x') appartient au graphe de **GABRIEL** si aucun autre point de $\mathcal{X}$ ne tombe dans le disque de diamètre $[x, x']$ (en gris). Elle appartient au graphe de voisinage relatif (*relative neighborhood graph*, **RNG**) si aucun point ne tombe dans l'intersection des deux disques de rayon $\|x - x'\|$ centrés en x et x' (en bleu foncé).

FAIT (CONNU) 1 : L'ARBRE MINIMUM COUVRANT (EUCLIDIEN) EST UN SOUS-GRAPHE DE GRAPHES GÉOMÉTRIQUES [29]

L'arbre minimum couvrant euclidien est un sous-graphe du graphe de voisinage relatif (RNG), lui-même inclus dans le graphe de GABRIEL, qui est à son tour un sous-graphe de la triangulation de DELAUNAY [29] :

$$\text{MST} \subseteq \text{RNG} \subseteq \text{GABRIEL} \subseteq \text{DELAUNAY}.$$

Le cas du plan $p = 2$ Dans le plan $\mathbb{R}^2$, la triangulation de DELAUNAY possède un nombre d'arêtes linéaire (au plus $3n - 6$) et se calcule en $\mathcal{O}(n \log n)$ [29]. L'algorithme du Single-Linkage hérite par conséquent de cette même complexité.

2.3 Le Single-Linkage en théorie : persistance de graphes géométriques

Une autre façon très féconde d'aborder le Single-Linkage est de le voir comme un processus d'*analyse persistante* (terme forgé par analogie avec l'*homologie persistante* [6]), consistant à observer la naissance et la fusion de composantes lorsque l'on fait varier un paramètre d'échelle r .

DÉFINITION 5 : GRAPHE GÉOMÉTRIQUE (AU SENS DE GILBERT-PENROSE [4, 30])

Soit $(\mathcal{X}, d)$ un espace métrique. Étant donné un rayon $r \geq 0$, le graphe géométrique $\mathcal{G}(\mathcal{X}, r)$ est le graphe dont les sommets sont les points $\mathcal{X}$, et où deux points $x, x' \in \mathcal{X}$ sont reliés par une arête si et seulement si

$$\|x - x'\| \leq 2r.$$

L'équivalence fondamentale entre l'arbre minimum couvrant et l'évolution des graphes géométriques s'énonce avec le joli résultat suivant (FAIT 2 & son corollaire, le THÉORÈME 1) qui, quoique fondamental, n'est que très rarement explicitement mentionné ; PENROSE [4] l'utilise implicitement. L'on est contraint d'adopter le formalisme de l'analyse topologique de données (*topological data analysis*, TDA) pour le voir écrit noir sur blanc (voir [31], Theorem 3.18 et la remarque « Connection to minimum spanning tree »).

FAIT (CONNU) 2 : ARBRE MINIMUM COUVRANT ET SOUS-NIVEAUX D'UN GRAPHE PONDÉRÉ [19, 32]

Soit $G = (V, E, w)$ un graphe fini pondéré, et soit T une forêt minimum couvrante de G (un arbre minimum couvrant si G est connexe). Alors, pour tout $r \geq 0$, les composantes connexes de

$$T_{\leq r} = (V, \{e \in T : w(e) \leq r\})$$

sont exactement les mêmes que celles de

$$G_{\leq r} = (V, \{e \in E : w(e) \leq r\}).$$

Remarque Par abus de langage, nous parlons de “composante connexe” pour désigner l'ensemble des nœuds du sous-graphe induit (et non le sous-graphe lui-même).

Preuve du FAIT 2. Soit $r \geq 0$. L'inclusion $T_{\leq r} \subseteq G_{\leq r}$ est immédiate. Pour l'autre sens, supposons que deux sommets u, v soient connectés dans $G_{\leq r}$ mais pas dans $T_{\leq r}$. Sur l'unique chemin de T reliant u à v , il existe donc une arête e de poids strictement supérieur à r . Retirer e de T définit une coupe $(A, V \setminus A)$. Comme u et v sont connectés dans $G_{\leq r}$, il existe une arête e' de $G_{\leq r}$ qui traverse cette coupe (voir le FAIT 3 ci-après). Alors

$$w(e') \leq r < w(e),$$

et remplacer e par e' donnerait une forêt couvrante de poids strictement plus petit, en contradiction avec la minimalité de T . $\square$

FAIT (CONNU) 3 : COUPE ET ARBRE MINIMUM COUVRANT [32]

En reprenant les notations du FAIT 2, soit $V = V_1 \dot{\cup} V_2$ une partition de l'ensemble des sommets, alors il existe une arête $e \in E$ de poids minimum reliant V_1 à V_2 qui soit aussi dans T .

Le THÉORÈME 1 suivant est un corollaire du FAIT 2.

THÉORÈME 1 : GRAPHE GÉOMÉTRIQUE $\equiv$ ARBRE MINIMUM COUVRANT ÉLAGUÉ

(Pour avoir l'unicité de l'arbre minimum couvrant, l'on suppose que les points de $\mathcal{X}$ sont en position générale.) Pour tout rayon $r \geq 0$, les ensembles de sommets des composantes connexes de l'arbre minimum couvrant élagué de ses arêtes de longueur strictement supérieure à $2r$ (noté $\text{MST}_{\leq r}$) coïncident exactement avec ceux du graphe géométrique $\mathcal{G}(\mathcal{X}, r)$.

Remarque Pour un graphe sur $\mathcal{X} \subset \mathbb{R}^p$, avoir ses sommets *en position générale* signifie que les distances entre paires de points sont distinctes deux à deux, assurant

l'unicité de l'arbre minimum couvrant. Nous reviendrons plus tard sur la notion de *position générale* pour un nuage de points lorsqu'il s'agira de généraliser aux hypergraphes (voir DEF. 26, p. 88).

Le THÉORÈME 1 est illustré avec la FIG. 2.3.




FIGURE 2.3 : Illustration du THÉORÈME 1 : le graphe géométrique (à gauche) et l'arbre minimum couvrant élagué au même rayon (à droite) partagent rigoureusement les mêmes composantes connexes.

Ce résultat est précieux car il relie intimement le Single-Linkage à la théorie de la percolation continue [4, 5, 33]. Nous reviendrons sur ce mécanisme, la percolation, au cœur du Single-Linkage et de tous les algorithmes de la même famille au chapitre 7.

Utilisé dans l'autre sens (si l'on souhaite construire le clustering produit par le Single-Linkage pour un petit seuil ε), le THÉORÈME 1 montre qu'il suffit d'identifier les composantes connexes du "petit" graphe géométrique de rayon $r \leftarrow \varepsilon$; il n'y a pas besoin de reconstruire tout l'arbre minimum couvrant.

2.4 Le modèle statistique du Single-Linkage : HARTIGAN et les amas de forte densité

2.4.1 Amas de forte densité (*high-density clusters*)

C'est sous l'impulsion de HARTIGAN [34] que le clustering hiérarchique a trouvé un ancrage mathématique rigoureux. Plutôt que de voir le clustering comme une simple heuristique de graphes, on suppose que les données $\mathcal{X} \subset \mathbb{R}^p$ sont des réalisations indépendantes issues d'une certaine densité par rapport à la mesure de LEBESGUE

$$f : \mathbb{R}^p \rightarrow \mathbb{R}_+.$$

DÉFINITION 6 : AMAS DE FORTE DENSITÉ, MODÈLE DE HARTIGAN [34]

Soit $\lambda > 0$. Commençons par définir l'ensemble de niveau supérieur à λ pour la fonction f :

$$L(\lambda) \triangleq \{x \in \mathbb{R}^p \mid f(x) \geq \lambda\}.$$

Les amas de forte densité (*high-density clusters* en anglais) $H_f(\lambda)$ de la densité f au niveau λ sont définis comme les composantes connexes de $L(\lambda)$

$$H_f(\lambda) \triangleq \pi_0(H_f(\lambda)).$$

En faisant varier λ , on observe une hiérarchie stricte d'amas s'emboîtant les uns dans les autres, formalisant mathématiquement le clustering sous forme d'un arbre hiérarchique continu (voir FIG. 2.4).




FIGURE 2.4 : Le modèle de HARTIGAN : correspondance entre $H_f(\lambda)$, les composantes connexes des ensembles de niveau de la densité $L(\lambda)$, (en haut) et la topologie de l'arbre hiérarchique des amas de forte densité (en bas).

2.4.2 L'estimateur de densité des K -Plus Proches Voisins (K -NN)

En pratique, la densité f est inconnue ; l'approche statistique classique consiste à en construire un estimateur $\hat{f}$. L'estimateur des K -Plus Proches Voisins (K -NN pour *K-Nearest Neighbours* en anglais) [35] est le choix non-paramétrique le plus naturel pour ce faire.

DÉFINITION 7 : ESTIMATEUR DE DENSITÉ DES K -PLUS PROCHES VOISINS (K -NN) [35]

Soit $\mathcal{X} \subset \mathbb{R}^p$ un nuage de l'espace euclidien contenant $n \in \mathbb{N}^*$ points et $K \in \mathbb{N}^*$ un entier avec tel que $K \leq n$. L'estimateur de densité des K -Plus Proches Voisins $\hat{f}_K$

(noté plus simplement $\hat{\lambda}$) est défini pour tout point $y \in \mathbb{R}^p$ par

$$\hat{\lambda} = \hat{f}_K(y) \triangleq \frac{K}{n} \frac{1}{\omega_p r_K(y)^p}$$

où $r_K(y) = \inf\{r \geq 0 \mid |B(y, r) \cap \mathcal{X}| \geq K\}$ représente la distance de y à son K -ième plus proche voisin, et ω_p le volume de la boule unité dans $\mathbb{R}^p$.

On définit aussi les niveaux supérieurs associés à cet estimateur pour $\lambda > 0$

$$L_K(\lambda) \triangleq \{y \in \mathbb{R}^p \mid \hat{f}_K(y) \geq \lambda\}.$$

Remarques

1. Dans le cas particulier $K = 1$ et $y \in \mathcal{X}$, on pose $\hat{f}_1(y) = +\infty$.
2. Au facteur $\frac{K}{n}$ de normalisation près, $\hat{\lambda}$ est l'inverse du volume de la plus petite boule centrée en y englobant K points de $\mathcal{X}$.
3. La condition d'être au-dessus d'un certain seuil de densité estimée, $\hat{f}_K(y) \geq \lambda$, est strictement équivalente à se trouver à une distance $r_K(y) \leq r$ d'un point du nuage, avec le changement de variable

$$\lambda = \frac{K}{n \omega_p r^p}.$$

Dans la suite, on manipulera indifféremment les variables λ ou r , étant sous-entendu ce changement de variable.

2.4.3 Lien entre le Single-Linkage et la hiérarchie de HARTIGAN 1-NN

Le lien fondamental avec le Single-Linkage apparaît dans le cas très particulier où $K = 1$: l'ensemble de niveau se réduit alors au *modèle booléen* d'union de boules [5] :

$$L_1(r) \triangleq \{y \in \mathbb{R}^p \mid r_1(y) \leq r\} = \bigcup_{x \in \mathcal{X}} \overline{B}(x, r).$$

Les composantes connexes de cette union de boules correspondent aux composantes connexes du graphe géométrique $\mathcal{G}(\mathcal{X}, r)$ qui sont elles-mêmes en correspondance avec l'arbre minimum couvrant élagué à r (d'après le THÉORÈME 1). *Confer* la synthèse en fin de chapitre.

2.4.4 Amas de forte densité *discrets*

Pour tout entier $K \leq n$, on dispose d'un estimateur de densité $\hat{f}_K: \mathbb{R}^p \rightarrow \mathbb{R}_+$. Appliquer directement la définition des amas de forte densité (DEF. 6, p. 25) pour construire $H_f(\cdot)$ en assignant $f \leftarrow \hat{f}_K$ produit un arbre hiérarchique dont les éléments sont des sous-ensembles de $\mathbb{R}^p$; l'on souhaiterait des sous-ensembles de nos données $\mathcal{X}$. Introduisons pour cela la notion d'amas de forte densité *discret*.

DÉFINITION 8 : AMAS DE FORTE DENSITÉ DISCRETS

Soit $\mathcal{X} \subset \mathbb{R}^p$ un nuage fini de taille n et $K \leq n$ un entier. Soit $\hat{f}_K$ l'estimateur de densité K -NN associé et

$$H_{\hat{f}_K}: r > 0 \mapsto \pi_0(L_K(r))$$

les amas de forte densité de f_K , c'est-à-dire la fonction qui à un niveau $r > 0$ associe les composantes du niveau supérieur $L_K(r)$.

L'on dira que $x \in \mathcal{X}$ est *couvert* par un certain cluster $C \in H_{\hat{f}_K}(r)$ s'il se trouve à moins de r de ce même cluster. Le cluster C^{discret} associé à C est alors l'ensemble des points $x \in \mathcal{X}$ qui sont couverts par C . Finalement, on définit les amas de forte densité *discrets* pour f_K au niveau $r > 0$ par

$$H_{\hat{f}_K}^{\text{discrets}}(r) \triangleq \left\{ C^{\text{discret}} \mid C \in H_{\hat{f}_K}(r) \right\}.$$

Remarques

1. L'idée derrière cette définition de C^{discret} est de bien prendre en compte tous les points qui participent à la formation de l'amas de forte densité associé. Poser $C^{\text{discret}} = C \cap \mathcal{X}$ aurait été une erreur. (Erreur que l'on quantifiera exactement dans le chapitre 7 consacré au phénomène de percolation.) Cette distinction est d'ailleurs la différence essentielle entre le Robust Single-Linkage et DBSCAN (voir *infra* DEF. 18, p. 43) – et qui explique d'ailleurs la supériorité de DBSCAN sur le Robust Single-Linkage.
2. L'on a défini l'amas discret C^{discret} associé à $C \in H_{\hat{f}_K}(r)$ comme l'ensemble des points $x \in \mathcal{X}$ à une distance de C inférieure à r . Cela équivaut à poser

$$C^{\text{discret}} = \mathcal{X} \cap \delta_r(C)$$

où $\delta_r(C)$ désigne la dilatation de l'ensemble C de rayon r .

3. Sauf dans le cas particulier $K = 1$, les amas discrets de forte densité ne forment pas une partition de $\mathcal{X}$; pour un certain niveau $r > 0$ fixé, certains points $x \in \mathcal{X}$ peuvent n'être couverts par aucun cluster, d'autres points peuvent être couverts par plusieurs clusters.

Synthèse Finalement, le clustering hiérarchique produit par l'algorithme du Single-Linkage peut être calculé de trois façons différentes. Soit $t \in \{0; \dots; n - 1\}$ l'étape à laquelle on s'arrête et r_t le rayon de coupure associé (voir *supra* DEF. ??, p. ??). Soit $\lambda_t = \frac{1}{n \omega_p r_t^p}$ la variable de densité associée au rayon. La partition $\mathcal{C}^{r_t}$ peut être obtenue de trois façons différentes :

$$\begin{aligned} \mathcal{C}^{r_t} &= \text{Composantes connexes du graphe géométrique } \mathcal{G}(\mathcal{X}, r_t); \\ &= \text{Composantes connexes de l'arbre minimum couvrant élagué } \text{MST}_{\leq r_t}; \\ &= \text{Amas discrets de forte densité } H_{f_1}^{\text{discrets}}(\lambda_t). \end{aligned}$$

Cette synthèse intègre le Single-Linkage dans la famille de clusterings *density-based* [36] et trace la voie naturelle pour sa généralisation aux estimateurs d'ordre supérieur avec $K \geq 2$.

Le Single-Linkage : un point de vue axiomatique

Au début des années 2000, sous l’impulsion de KLEINBERG [37], l’on commence à emprunter la piste axiomatique pour définir “proprement” le clustering (*c.f.* § 3.2). D’abord aporétique (théorème d’impossibilité de KLEINBERG [37]), cette piste présentait des difficultés qui ont pu être surmontées grâce à CARLSSON & MÉMOLI [38] : la bonne approche est *hiérarchique* : une structure d’arbre sur les données est plus riche qu’une simple partition et peut répondre à des critères impossibles pour un clustering classique (§ 3.3).

Le formalisme des catégories s’empare alors du clustering *hiérarchique*, vu comme une application de la catégorie des espaces métriques vers les espaces *ultramétriques* (FAIT 6, p. 34). On peut réclamer à de tels algorithmes de bonnes qualités *fonctorielles*, celui de préserver le caractère 1-lipshitzien par exemple. Une axiomatique “naturelle” caractérise *uniquement* le Single-Linkage (FAIT 7, p. 35).

Nous n’explorerons pas davantage ici cette voie axiomatique qui pourrait nous égarer dans notre cheminement ; que le lecteur sache néanmoins que CULBERTSON, GURALNIK & STILLER [39] sont allés encore plus loin que CARLSSON & MÉMOLI : ils ont relâché la contrainte du partitionnement, remplacé par des *recouvrements*. L’objet hiérarchique passe alors du dendrogramme au *crible* catégoriel. Ce faisant, cela leur permet de voir le clustering hiérarchique comme une projection dont le choix de la catégorie cible, le *domain clustering*, est crucial.

Contributions Ce chapitre est une revue de ce qui s’est fait à propos de clustering depuis les années 2000 avec une approche axiomatique. Notre approche, toute différente, a été géométrique et statistique ; ce chapitre est donc une légère digression. Il a pour but de montrer au lecteur l’omniprésence du Single-Linkage ainsi que la diversité mathématique avec lequel on peut aborder cet algorithme. Il a aussi l’avantage d’illustrer que la généralisation que nous proposerons du Single-Linkage, conforme à notre approche géométrique et statistique, se retrouve dans les idées proposées par CULBERTSON, GURALNIK & STILLER [39] : il faut relâcher la contrainte (trop forte) du clustering vu comme un *partitionnement* des données.

3.1 Rappels : partitions, relations d'équivalence

Partitions $\mathcal{P}_{\text{art}}(\mathcal{X})$ Rappelons qu'une partition P de $\mathcal{X}$ est un ensemble de sous-ensembles $A \subseteq \mathcal{X}$ vérifiant :

- (i) **Aucun sous-ensemble n'est vide.** $\forall A \in P, A \neq \emptyset$.
- (ii) **Les sous-ensembles sont disjoints deux à deux.** $\forall A, B \in P$, si $A \neq B$ alors $A \cap B = \emptyset$.
- (iii) **Les sous-ensembles recouvrent $\mathcal{X}$.** $\bigcup_{A \in P} A = \mathcal{X}$.

Nous noterons $\mathcal{P}_{\text{art}}(\mathcal{X})$ l'ensemble des partitions de $\mathcal{X}$.

Relation d'équivalence $\sim$ Une relation binaire sur $\mathcal{X}$ (généralement notée en notation infixée $\sim$ ou $\mathcal{R}$) est une relation d'équivalence si elle vérifie les trois propriétés ci-dessous.

- (i) **Réflexive.** $\forall x \in \mathcal{X}, x \sim x$.
- (ii) **Symétrique.** $\forall x, y \in \mathcal{X}$, si $x \sim y$ alors $y \sim x$.
- (iii) **Transitive.** $\forall x, y, z \in \mathcal{X}$, si $x \sim y$ et $y \sim z$ alors $x \sim z$.

La donnée d'une relation d'équivalence $\sim$ sur $\mathcal{X}$ fournit une partition canonique : il suffit de prendre la clôture transitive de chaque singleton $\{x\}$ quand x parcourt $\mathcal{X}$. Et réciproquement, de toute partition l'on peut tirer une relation d'équivalence dont les classes d'équivalence soient les éléments de la partitions originale.

Remarque Nous nous permettons tout au long de ce manuscrit de substituer les termes de partition et de relation d'équivalence.

3.1.1 Le clustering, ou *partitionnement*

Le clustering est souvent défini comme un *partitionnement*ⁱ⁾ de l'espace des données $\mathcal{X}$.

DÉFINITION 9 : CLUSTERING SUR UN ESPACE MÉTRIQUE $(\mathcal{X}, d)$.

Un clustering $\mathcal{C}$ est une fonction qui prend en entrée un espace métrique fini $(\mathcal{X}, d)$

$$\mathcal{C} : (\mathcal{X}, d) \mapsto \sim \in \mathcal{P}_{\text{art}}(\mathcal{X})$$

et retourne une *partition* de l'ensemble $\mathcal{X}$, c'est-à-dire la donnée d'une *relation d'équivalence* $\sim \in \mathcal{P}_{\text{art}}(\mathcal{X})$ sur cet ensemble $\mathcal{X}$.

ⁱ⁾Ce n'est pas notre point de vue, la contrainte de partition étant trop forte comme nous le verrons dans la partie suivante. C'est toutefois le point de vue que nous adoptons pour ce début de chapitre.

3.2 Le théorème d'impossibilité de KLEINBERG

Pour comprendre la nécessité de généraliser à un clustering qui soit *hiérarchique*, il faut remonter à l'impasse logique identifiée au début des années 2000 par KLEINBERG. Le théorème d'impossibilité de KLEINBERG [37] a agi comme un séisme théorique en démontrant que :

FAIT (CONNU) 4 : THÉORÈME D'IMPOSSIBILITÉ DE KLEINBERG [37]

Aucune fonction de clustering $\mathcal{C}$ (DEF. 9, p. 30) sur un espace métrique $(\mathcal{X}, d)$ ne peut satisfaire simultanément ces trois axiomes :

- (i) **Invariance d'échelle.** $\forall \lambda > 0, \mathcal{C}(\mathcal{X}, d) = \mathcal{C}(\mathcal{X}, \lambda d)$.
- (ii) **Richesse.** Capacité à générer toutes les partitions possibles : $\forall P \in \mathcal{P}art(\mathcal{X})$, il existe une distance d sur $\mathcal{X}$ telle que $\mathcal{C}(\mathcal{X}, d) = P$.
- (iii) **Cohérence.** Réduire les distances intra-cluster ou augmenter les distances inter-clusters ne doit pas changer le résultat du clustering $\mathcal{C}$: si $P = \mathcal{C}(\mathcal{X}, d)$ et que d' est telle que pour toute paire $x, x' \in \mathcal{X}$ appartenant respectivement aux clusters $C, C' \in P$, alors $d'(x, x') \leq d(x, x')$ si $C = C'$ et $d'(x, x') \geq d(x, x')$, alors $P = \mathcal{C}(\mathcal{X}, d')$.

Remarque L'axiome le plus contestable est de notre point de vue la cohérence.

Fait remarquable (et qui sera certainement le point de départ des articles de CARLSSON & MÉMOLI, c.f. § 3.3) : pour chacune des trois combinaisons de deux des trois propriétés sus-citées, KLEINBERG donne un exemple de clustering qui les satisfait ; dans les trois cas, il s'agit d'une variante de l'algorithme de Single-Linkage.

3.3 Le besoin d'ajouter une vue hiérarchique

Le Single-Linkage (voir DEF. 1, p. 18) est un algorithme de clustering *hiérarchique*, c'est-à-dire qu'il construit un *dendrogramme* θ (voir DEF. 10 ci-dessous) sur les données $\mathcal{X}$.

DÉFINITION 10 : CLUSTERING HIÉRARCHIQUE = DENDROGRAMME [38]

Un *clustering hiérarchique* sur $\mathcal{X}$ est la donnée d'une application

$$\theta : \mathbb{R}_+ \rightarrow \mathcal{P}art(\mathcal{X})$$

telle que :

- (i) **Croissance.** Si $0 \leq r \leq r'$, alors $\theta(r) \preceq \theta(r')$.
- (ii) **Continuité à droite.** Pour tout $r \geq 0$, il existe $\varepsilon > 0$ tel que $\theta(r) = \theta(r')$ pour tout $r' \in [r; r + \varepsilon[$.

- (iii) $\theta(0)$ est la partition en singletons $\{\{x_i\}\}_{i=1}^n$.
- (iv) Il existe r_{connect} tel que $\theta(r) = \{\mathcal{X}\}$ pour tout $r \geq r_{\text{connect}}$.

Remarque $\preceq$ désigne l'ordre (partiel) habituel sur les partitions $(\mathcal{P}(\mathcal{X}), \preceq)$: soient $P, P' \in \mathcal{P}(\mathcal{X})$, on dit que P *raffine* P' (et l'on note $P \preceq P'$) si pour tout $C \in P$, il existe $C' \in P'$ tel que $C \subseteq C'$.

Le Single-Linkage tel que défini précédemment (DEF. 1, p. 18) rentre bien-sûr dans cette définition, il suffit de poser :

- À l'étape $t = 0$ (associé au rayon $r_0 = 0$), on initialise avec la partition triviale en singletons :

$$\theta^{\text{SL}}(0) = \{\{x_i\}\}_{i=1}^n.$$

- $\theta^{\text{SL}}(r)$ est stable jusqu'au niveau r_{t+1} , associé à la fusion des deux clusters C, C' de l'étape t les plus proches pour la distance $d_{\text{SL}}(C, C') = \frac{1}{2} \min_{x \in C, x' \in C'} d(x, x')$, et

$$\theta^{\text{SL}}(r_{t+1}) = \{C \dot{\cup} C'\} \dot{\cup} \{C''\}_{C'' \in \theta^{\text{SL}}(r_t), C'' \notin \{C, C'\}}.$$

- $r_{\text{connect}} = r_{n-1}$.

Si aucun clustering ne répond aux trois axiomes de KLEINBERG (FAIT ??, p. ??), le Single-Linkage, selon la variante choisie (le(s) niveau(x) auquel(s) on “coupe” dans l'arbre hiérarchique), permet de retrouver les trois combinaisons vérifiant deux des trois axiomes [37].

Remarque D'après la synthèse du chapitre 2, l'on aurait pu – de façon équivalente – définir le dendrogramme du Single-Linkage à l'aide des graphes géométriques, dont les composantes connexes sont vues comme des partitions d'équivalence (voir ci-dessous DEF. 11 & FAIT 5).

DÉFINITION 11 : DENDROGRAMME DE PERSISTANCE DES GRAPHES GÉOMÉTRIQUES $\theta^\sim$

Soit $(\mathcal{X}, d)$ un espace métrique fini, soit $r \geq 0$. L'on définit la relation de voisinage $\leftrightarrow_r$ par

$$x \leftrightarrow_r x' \text{ si } d(x, x') \leq 2r.$$

La relation d'équivalence $\sim_r$ est définie comme la clôture transitive de cette relation de voisinage. Le *dendrogramme de persistance des graphes géométriques* (noté $\theta^\sim$) est alors défini par

$$\theta^\sim: \begin{array}{ccc} \mathbb{R}_+ & \rightarrow & \mathcal{P}(\mathcal{X}) \\ r & \mapsto & \sim_r \end{array}$$

FAIT (CONNU) 5 : DENDROGRAMME DU SINGLE-LINKAGE $\equiv$ DENDROGRAMME DE PERSISTANCE DES GRAPHES GÉOMÉTRIQUES

Soit $(\mathcal{X}, d)$ un espace métrique fini. Le dendrogramme θ^{SL} produit par le Single-Linkage sur $\mathcal{X}$ et $\theta^\sim$ celui de persistance des graphes géométriques sur $\mathcal{X}$ (voir DEF. 11) sont identiques :

$$\theta^{\text{SL}} \equiv \theta^\sim.$$

3.3.1 Équivalence entre les dendrogrammes et les ultramétriques

Le FAIT 6, p. 34, explicite l'équivalence entre les dendrogrammes et les espaces ultramétriques (DEF. 12 ci-dessous). Nous ne rentrerons pas dans les détails, mais il est parfois plus pratique de manipuler des espaces ultramétriques (finis dans notre cas) que des dendrogrammes ; cela permet un certain formalisme que CARLSSON & MÉMOLI ont utilisé (voir ci-dessous, et notamment le FAIT 7, p. 35).

DÉFINITION 12 : ULTRAMÉTRIQUE

Ultramétrique (u) : Une application $u : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}_+$ est une ultramétrique si u est une distance (métrique) sur $\mathcal{X}$ vérifiant l'inégalité triangulaire forte : pour tous $x, y, z \in \mathcal{X}$:

$$u(x, y) \leq \max\{u(x, z), u(z, y)\}.$$

Remarque Tous les triangles dans un espace ultramétrique sont isocèles (en la plus longue arête).

FAIT (CONNU) 6 : HIÉRARCHIE $\equiv$ ULTRAMÉTRIQUE [40]

Il existe une bijection canonique entre l'ensemble des ultramétriques u et l'ensemble des dendrogrammes θ sur $\mathcal{X}$.

1. De l'ultramétrique vers le dendrogramme ($u \mapsto \theta$). La partition $\theta(r)$ est définie par la relation d'équivalence $\sim_r$ suivante :

$$x \sim_r y \iff u(x, y) \leq 2r.$$

2. Du dendrogramme vers l'ultramétrique ($\theta \mapsto u$). La distance ultramétrique est le seuil d'apparition du premier cluster contenant le couple :

$$u(x, y) = 2 \inf\{r \geq 0 \mid \exists C \in \theta(r), x \in C \text{ et } y \in C\} \quad (3.1)$$

Remarque Dans l'Eq. (3.1), le cluster C associé à $u(x, y)$ est défini comme le *plus petit ancêtre commun* à x et y .

Pour sortir de l'aporie mise en avant par KLEINBERG, CARLSSON & MÉMOLI [38] reformulent le clustering comme une transformation qui prend un espace métrique et renvoie un espace ultramétrique, équivalent à la donnée d'un dendrogramme (voir FAIT 6 ci-dessus).

DÉFINITION 13 : CLUSTERING HIÉRARCHIQUE [38]

Soit $\mathbf{X}$ la collection de tous les espaces métriques finis et $\mathbf{U}$ la collection de tous les espaces ultramétriques finis. Un *clustering hiérarchique* T est une application qui à un espace métrique $(\mathcal{X}, d)$ associe une ultramétrique sur le même ensemble fini $(\mathcal{X}, u)$.

$$\begin{array}{ccc} T: & \mathbf{X} & \rightarrow \mathbf{U} \\ & (\mathcal{X}, d) & \mapsto (\mathcal{X}, u) \end{array}$$

Remarque Vu ainsi, le Single-Linkage u^{SL} est en fait la plus grande ultramétrique sur $\mathcal{X}$ *sous-dominante*, c'est-à-dire sous la contrainte $u \leq d$.

CARLSSON & MÉMOLI [38] obtiennent surtout les deux résultats suivants :

1. **Axiomatisation.** En adaptant l'axiomatique "à la KLEINBERG" pour le clustering hiérarchique, ils prouvent que le Single-Linkage est l'unique algorithme de clustering hiérarchique à répondre à leurs axiomes. C'est le FAIT 7 énoncé ci-dessous.
2. **Régularité.** CARLSSON & MÉMOLI montrent que le Single-Linkage, vu comme une application $T^{\text{SL}} : \mathbf{X} \rightarrow \mathbf{U}$, est 1-lipschitzien pour la distance de GROMOV-HAUSDORFF.

FAIT (CONNU) 7 : SINGLE-LINKAGE, UNIQUE SOLUTION FONCTORIELLE [38]

Soit T une méthode de clustering hiérarchique qui à tout espace métrique fini $(\mathcal{X}, d)$ associe une ultramétrique $T : (\mathcal{X}, d) \mapsto (\mathcal{X}, u)$, et supposons que T vérifie :

1. **Normalisation à deux points.** Si $|\mathcal{X}| = 2$ et $d(x, x') = \delta$, alors $u(x, x') = \delta$.
2. **Fonctorialité.** Pour toute application 1-lipschitz $\phi : (\mathcal{X}, d_{\mathcal{X}}) \rightarrow (\mathcal{Y}, d_{\mathcal{Y}})$, on a $u_{\mathcal{Y}}(\phi(x), \phi(x')) \leq u_{\mathcal{X}}(x, x')$ pour tous $x, x' \in \mathcal{X}$;
3. **Séparation.** pour tout $(\mathcal{X}, d)$, et tous $x \neq x' \in \mathcal{X}$,

$$u(x, x') \geq \text{sep}(\mathcal{X}, d) \triangleq \min_{a \neq b \in \mathcal{X}} d(a, b).$$

Alors T coïncide nécessairement avec le Single-Linkage hiérarchique

$$T = T^{\text{SL}}.$$

Synthèse Ce chapitre a montré que le Single-Linkage se rencontre tout aussi naturellement lorsqu'on aborde le clustering *via* l'informatique théorique et la recherche d'une axiomatique minimale. La nécessité d'une hiérarchie, plus riche qu'une simple partition, apparaît alors pour répondre au théorème d'impossibilité de KLEINBERG (FAIT 4, p. 31). Le formalisme de ce chapitre nous permet de manipuler aussi bien des dendrogrammes que des ultramétriques, qui sont en bijection canonique (FAIT 6, p. 34). L'intérêt de voir le clustering hiérarchique comme une projection des espaces métriques vers les ultramétriques est que l'on peut alors appliquer tout un arsenal géométrique et topologique, et montrer par exemple la stabilité du Single-Linkage pour la distance de GROMOV-HAUSDORFF [38].

Nous mentionnons en guise d'ouverture la proposition de CULBERTSON, GURALNIK & STILLER [39] consistant à relâcher la condition de partitionnement pour chaque niveau de la hiérarchie, et de simplement exiger un recouvrement. Ces idées font écho à la généralisation du Single-Linkage que nous proposons dans la seconde partie de ce manuscrit.

CHAPITRE 4

Les limites du Single-Linkage

Les deux chapitres précédents confèrent au Single-Linkage une justification précise : dans le cadre euclidien, il reconstruit exactement la hiérarchie des amas de forte densité (pour l'estimateur 1-NN ; voir § 2.4.3) ; c'est aussi le seul clustering hiérarchique à répondre à une axiomatique minimale (FAIT 7, p. 35).

Mais ces justifications fixent en même temps les limites : dans l'espace euclidien, toute la notion de densité est portée par un unique voisin ; si l'on voit le Single-Linkage comme une application $d \mapsto u$ qui transforme une métrique d en une ultramétrique u , il y a la double contrainte imposée par l'ultramétrie et la sous-dominance $u \leq d$.

Des versions du Single-Linkage tentant d'intégrer une densité à K voisins ont été proposées. Nous verrons ainsi la filiation du Single-Linkage au *Robust* Single-Linkage (nouvelle distance : la distance de cœur, ou *core distance* en anglais), puis à DBSCAN (ajoutant la bonne idée d'intégrer la frontière des clusters), et enfin à HDBSCAN (qui permet d'obtenir un clustering multi-échelle grâce à la notion d'*excès de masse* ; HDBSCAN procède de plus à un élagage de l'arbre hiérarchique pour une meilleure gestion du bruit).

Contributions Ce chapitre constitue encore une revue : le point de départ en est les limites du Single-Linkage ; le point d'arrivée les réponses qui ont été apportées, avec une description plus précise de ce qui est unanimement considéré aujourd'hui comme l'« état-de-l'art » [9, 10] pour le clustering fondé sur la densité : HDBSCAN [7, 8].

Les simples changements de fonction de liaison (remplacer le *Single-* par le *Complete-* ou *Average-Linkage*) apportent plus d'instabilité qu'elles ne règlent de problème (FAIT 9, p. 40).

Cette revue est critique et, comme nous le verrons dans la partie suivante, HDBSCAN ne répond pas aux objectifs qu'il s'était fixé, savoir : remplacer l'estimateur de densité 1-NN du Single-Linkage par un K -NN. Les utilisateurs réguliers de HDBSCAN savent d'ailleurs que le paramètre correspondant à ce K , `min_samples`, produit de mauvais résultats lorsqu'il est trop grand et recommandent souvent en pratique de ne pas excéder une dizaine (même pour des données dépassant les milliers de points). La raison n'en est pas que l'estimateur K -NN lisserait trop les clusters, elle est fondamentalement liée à l'approximation de HDBSCAN : la recherche min max sur le graphe de voisinage muni

de la distance de cœur ne représente plus rien pour $K \gtrsim 10$, et certainement par les véritables amas discrets de forte densité K -NN.

4.1 Quand la notion de densité manque : l'effet de chaînage

L'incapacité du Single-Linkage à séparer correctement certains amas a été relevée très tôt et constitue l'un de ses défauts majeurs en pratique. L'estimation de densité par le plus proche voisin (1-NN) étant, par nature, extrêmement sensible aux variations locales ; la présence d'une fine chaîne de points aberrants (*outliers* en anglais) entre deux amas denses et distincts suffit à les agglomérer prématurément dans le dendrogramme. Il manque fondamentalement au Single-Linkage une notion robuste de *densité locale*.

Cette faiblesse est connue sous le nom d'effet de chaînage (ou *chaining effect* en anglais). L'article de CARLSSON & MÉMOLI [38] l'illustre en comparant deux topologies diamétralement opposées.




FIGURE 4.1 : (a) Trois points alignés espacés de 2δ . (b) Le dendrogramme résultant pour le Single-Linkage (fusion simultanée à δ). (c) Trois points en triangle équilatéral à distance 2δ .

Pour modéliser ce phénomène sur des nuages de taille n , prenons deux ensembles $\mathcal{X} = \{x_1, \dots, x_n\}$ et $\mathcal{Y} = \{y_1, \dots, y_n\}$ munis de deux métriques radicalement différentes (le cas $n = 3$ est illustré en FIG. 4.1) :

1. **La chaîne** (sur $\mathcal{X}$). La distance est définie par $d_{\mathcal{X}}(x_i, x_j) = 2\delta|i - j|$. Géométriquement, cela correspond à des points alignés sur une droite et espacés uniformément de 2δ .
2. **La clique dense** (sur $\mathcal{Y}$). La distance est définie par $d_{\mathcal{Y}}(y_i, y_j) = 2\delta$ pour toute paire $i \neq j$. Géométriquement, cela correspond aux sommets d'un $(n-1)$ -simplexe régulier. C'est la structure la plus dense et compacte possible, où tous les nœuds sont équidistants.

Or, le dendrogramme produit sur $\mathcal{X}$ et sur $\mathcal{Y}$ par le Single-Linkage est rigoureusement identique : il y a fusion simultanée de tous les points au niveau δ . Un algorithme de clustering pertinent devrait pourtant considérer $\mathcal{Y}$ comme un cluster bien plus significatif et structuré que la chaîne éparse $\mathcal{X}$.

4.1.1 Consistance et inconsistance du Single-Linkage

C’est HARTIGAN [3] qui a montré mathématiquement les conséquences de cet effet de chaînage : la possibilité de formation d’un “pont” entre deux clusters rend le Single-Linkage inconsistant en toute dimension $p \geq 2$.

DÉFINITION 14 : (HARTIGAN)-CONSISTANCE D’UN ALGORITHME DE CLUSTERING HIÉRARCHIQUE [3]

Un algorithme de clustering hiérarchique θ (DEF. 10, p. 32) est dit *consistant* (au sens de HARTIGAN) si, quels que soient f une fonction de densité suffisamment régulière sur $\mathbb{R}^p$, $\lambda > 0$, et A, B deux amas disjoints de forte densité de f au niveau λ (et de mesure strictement positive), alors θ sépare asymptotiquement parfaitement A et B ; c’est-à-dire qu’avec probabilité tendant vers 1 lorsque $n \rightarrow \infty$, si $\mathcal{X}_n$ est un nuage de n points tirés i.i.d. selon f , il existe $r_n > 0$ tel que $A_n, B_n \in \theta(r_n)$ et $A_n \subset A, B_n \subset B$.

FAIT (CONNU) 8 : CONSISTANCE ET INCONSISTANCE DU SINGLE-LINKAGE [3]

- En dimension $p = 1$, l’algorithme de Single-Linkage est un estimateur (HARTIGAN)-consistant des amas de forte densité.
- En dimension $p \geq 2$, l’algorithme de Single-Linkage est (HARTIGAN)-inconsistant pour recouvrir les amas de forte densité. Il n’est que *fractionnellement consistant*.

L’explication de cette inconsistance réside dans le phénomène mathématique de la percolation continue [4, 5]. En dimension $p \geq 2$, à mesure que le rayon de connexion augmente, des composantes géantes apparaissent presque sûrement. Cependant, avant qu’une composante géante ne parvienne à absorber l’intégralité des points appartenant à son amas de densité, elle *percole* (fusionne) inévitablement avec les composantes géantes voisines *via* des ponts de bruit (= *chaining effect* ; voir *supra* la FIG. 2.3, p. 24, avec un amas de forte densité central). On ne peut alors espérer recouvrir qu’une *fraction* des points du cluster.

En dimension $p = 1$, ce phénomène de percolation n’existe pas (pour un modèle de Poisson à : l’espace vide maximum sépare toujours parfaitement les modes de la densité.

Nous reviendrons plus amplement sur ce phénomène de percolation dans la partie suivante de ce manuscrit (et notamment au chapitre 7), où nous montrerons comment la théorie nous permet de mesurer la vitesse de percolation (*percolation rate* [33, 41]) des algorithmes pour quantifier théoriquement cette inconsistance.

4.2 Les liaisons dangereuses : Complete- et Average-Linkage

Pour pallier le défaut structurel du Single-Linkage (le critère très laxiste du « voisin le plus proche » entre deux ensembles), l'on pourrait être tenté de recourir à d'autres critères de liaison (*linkage*) lors de l'étape d'agglomération. Citons les deux alternatives historiques les plus célèbres :

DÉFINITION 15 : COMPLETE-LINKAGE [42] ET AVERAGE-LINKAGE [43]

Soient C et C' deux clusters d'un espace métrique $(\mathcal{X}, d)$.

- **Complete-Linkage** (liaison complète). La distance entre deux clusters est définie par la distance maximale entre leurs éléments :

$$d_{\text{CL}}(C, C') = \max_{x \in C, y \in C'} d(x, y).$$

- **Average-Linkage** (liaison moyenne). La distance est définie par la moyenne des distances entre toutes les paires inter-clusters :

$$d_{\text{AL}}(C, C') = \frac{1}{|C||C'|} \sum_{x \in C} \sum_{y \in C'} d(x, y).$$

Empiriquement, ces méthodes tendent à produire des clusters plus compacts (plus « sphériques ») et évitent l'effet de chaînage. Cependant, elles souffrent d'un défaut théorique rédhibitoire qui les disqualifie pour une analyse topologique rigoureuse.

FAIT (CONNU) 9 : INSTABILITÉ DES COMPLETE- ET AVERAGE-LINKAGE [38]

Contrairement au Single-Linkage, les algorithmes de *Complete Linkage* et d'*Average Linkage* sont *instables*. Ils ne satisfont pas la propriété de continuité 1-lipschitzienne au sens de la distance de GROMOV-HAUSDORFF. Une infime perturbation de l'espace métrique initial peut engendrer des dendrogrammes radicalement différents.

La solution au *chaining effect* ne réside donc pas dans la modification de la fonction de liaison entre ensembles (qui détruit les garanties de stabilité métrique).

4.3 Introduire la densité locale : le Robuſt Single-Linkage

Pour introduire une notion de densité au Single-Linkage, l'idée naturelle est de substituer l'estimateur de densité du plus proche voisin (1-NN, responsable de la sensibilité au bruit) par l'estimateur des K -Plus Proches Voisins (K -NN), cet estimateur ayant de bonnes propriétés de consistance lorsque $K \rightarrow \infty$ [35].

Cette approche, initialement pressentie par WISHART [44], a été rigoureusement théorisée par CHAUDHURI & DASGUPTA [45] sous le nom de *Robuſt Single-Linkage*.

DÉFINITION 16 : DISTANCE DE CŒUR (CORE DISTANCE) [46]

Soit $\mathcal{X} \subset \mathbb{R}^p$ un nuage de points de taille n et $K \leq n$. La distance de cœur d'un point $x \in \mathcal{X}$, notée $r_K(x)$, est la distance de x à son K -ième plus proche voisin dans le nuage :

$$r_K(x) = \min\{r \geq 0 \mid |B(x, r) \cap \mathcal{X}| \geq K\}.$$

La distance de cœur est (à un exposant dimensionnel près) inversement proportionnelle à l'estimateur de densité K -NN évalué au point x . Pour forcer les points à se regrouper *uniquement* s'ils se trouvent mutuellement dans une région suffisamment dense, CHAUDHURI & DASGUPTA [45] définissent une nouvelle métrique sur $\mathcal{X}$.

DÉFINITION 17 : DISTANCE D'ATTEIGNABILITÉ MUTUELLE (MUTUAL REACHABILITY DISTANCE) [45]

La distance d'atteignabilité mutuelle entre deux points $x, x' \in \mathcal{X}$ pour un paramètre K est définie par :

$$d_{\text{mreach},K}(x, x') = \max\{r_K(x), r_K(x'), d(x, x')\}.$$

L'algorithme du Robuſt Single-Linkage consiste alors simplement à appliquer le Single-Linkage classique (l'extraction de l'arbre minimum couvrant), mais en calculant les poids des arêtes avec la distance $d_{\text{mreach},K}$ au lieu de la distance d originelle de l'espace métrique.

L'ultramétrique u^{RSL} induite par le Robuſt Single-Linkage pouvant, de la même façon que précédemment avec le Single-Linkage, s'exprimer à l'aide d'un min max [47] (FAIT 10 ci-dessous).

FAIT (CONNU) 10 : ULTRAMÉTRIQUE u^{RSL} DU ROBUST SINGLE-LINKAGE EXPRIMÉE COMME UN min max [47]

Soit $\mathcal{X} \subset \mathbb{R}^p$ un nuage n de points, et $K \in \mathbb{N}^*$, $K \leq n$ un entier. Soit $d_{\text{mreach},K}$ la distance d'atteignabilité mutuelle sur $\mathcal{X}$. Alors l'ultramétrique u^{RSL_K} induite par le

Robuſt Single-Linkage sur $\mathcal{X}$ peut s'exprimer ainsi :

$$\forall x, x' \in \mathcal{X}, u^{\text{RSL}_K}(x, x') = \min_{\omega: x \rightsquigarrow x'} \max_{(u, v) \in \omega} d_{\text{mreach}, K}(u, v)$$

où le minimum est pris sur l'ensemble des chemins ω de x à x' .

Remarque Le mécanisme sous-jacent au Robuſt Single-Linkage est astucieux : pour que deux points soient connectés à un niveau de résolution r , il faut non seulement qu'ils soient géométriquement proches, mais également que *chacun d'eux* réside dans une région de haute densité (avoir au moins K voisins dans un rayon r , c'est-à-dire $r_K(x) \leq r$ et $r_K(y) \leq r$).

4.3.1 Critique du Robuſt Single-Linkage

Si cette méthode garantit la consistance asymptotique lorsque $K \rightarrow \infty$ [45], à K fixé elle ne permet absolument pas de retrouver les amas de forte densité pour le K -NN. Nous reviendrons beaucoup plus longuement sur ce point dans la partie suivante, et notamment au chapitre 6. La façon la plus simple de s'en rendre compte est de prendre la définition min max du Robuſt Single-Linkage : pour un niveau $r > 0$ donné, elle garantit que chacun des sommets du meilleur chemin ω reliant x à x' sont dans des amas de forte densité K -NN, mais non pas que le chemin ω lui-même soit entièrement compris dans un amas de forte densité. Nous verrons dans la partie suivante que la bonne façon d'introduire l'estimateur K -NN, sans briser la topologie des ensembles de niveau, consiste à utiliser des hypergraphes (les complexes de Čech) et à étendre la notion de connectivité via les K -polyèdres (DEF. 21, p. 62).

4.4 L'état de l'art : HDBSCAN

4.4.1 La gestion explicite de la frontière des clusters : DBSCAN

Le Robuſt Single-Linkage est trop exigeant vis-à-vis d'un point $x \in \mathcal{X}$ pour qu'il apparaisse dans un cluster (au niveau r) : être dans un niveau de forte densité $x \in L_K(r)$.

Or, comme cela apparaît dans la définition que nous avons posée des amas *discrets* de forte densité (DEF. 8, p. 27), un point peut participer à un cluster C (être *couvert* par C), sans pour autant appartenir lui-même à C . C'est toute la gestion délicate de la frontière des clusters et du passage du continu au discret qui apparaît. Nous verrons dans la partie suivante (au chapitre 7) en comparant les différentes vitesses de percolation que le critère trop fort du Robuſt Single-Linkage ruine complètement ses performances théoriques.

Il convient de mentionner un algorithme qui a fortement amélioré le Robuſt Single-Linkage sur ce point précis : DBSCAN, proposé par ESTER *et al.* en 1996 [48]. Par voie de

conséquence, DBSCAN a fortement amélioré la gestion du bruit au niveau des frontières, de là son nom : *Density-Based Spatial Clustering of Applications with Noise*.

DBSCAN catégorise, pour un certain niveau r , les points de $\mathcal{X}$ en trois types :

DÉFINITION 18 : CATÉGORISATION DES POINTS DANS DBSCAN [48]

1. **Points cœurs** (*core points*). Points possédant au moins K voisins dans leur r -voisinage ($r_K(x) \leq r$).
2. **Points accessibles** (*reachable points* ou *border points*). Points n'étant pas des cœurs, mais situés dans le r -voisinage d'un point cœur. Ils forment la frontière du cluster.
3. **Bruit** (*noise / outliers*). Tous les autres points, considérés comme isolés.

Remarque la faiblesse du Robust Single-Linkage consistait à ne pas tenir compte de ce que les auteurs de DBSCAN appellent les points *accessibles*. À un certain niveau r , ces points ne font pas partie d'un cœur (ils n'ont pas K voisins), pour autant ils ont participé à la formation d'un amas de forte densité K -NN. Ne pas en tenir compte est une erreur. (Erreur qu'on pourra d'ailleurs mesurer dans le chapitre 7 grâce à la vitesse de percolation.) Ces points correspondent à ce que nous avons appelés des points *couverts* par un amas, sans pour autant faire partie d'un amas (voir DEF. 8, p. 27).

L'algorithme connecte ensuite les points cœurs entre eux s'ils sont à une distance mutuelle inférieure à r , formant ainsi l'ossature des clusters, auxquels on rattache finalement les points accessibles.

4.4.2 HDBSCAN

Nous avons déjà mentionné qu'en pratique, le paramètre K du Robust Single-Linkage ne doit pas être pris trop important (et ce pour des raisons profondes d'inexactitude par rapport au modèle des amas de forte densité K -NN). La gestion de la sensibilité du Robust Single-Linkage au bruit n'en est que plus fragile. Cette faiblesse reste en partie vraie pour DBSCAN. De plus, DBSCAN requiert un paramètre de résolution global r . Si les données présentent des clusters de densités très variables, aucun rayon r unique ne pourra les extraire simultanément de manière satisfaisante.

HDBSCAN (*Hierarchical DBSCAN*) répond (partiellement) à ces deux limites. CAMPELLO, MOULAVI & SANDER [7], puis MCINNES & HEALY [8], ont conçu HDBSCAN, algorithme qui est aujourd'hui la référence [9, 10].

4.4.3 Le seuil de percolation (`min_cluster_size`) pour une meilleure gestion du bruit

La première innovation de HDBSCAN est un élagage systématique de l'arbre hiérarchique. L'algorithme supprime tous les clusters dont la taille est strictement inférieure à un paramètre `min_cluster_size`. Lorsqu'un cluster parent se scinde en deux sous-clusters, on évalue la taille de chaque branche :

- Si une seule des deux branches possède suffisamment de points, on considère qu'il ne s'agit pas d'une véritable scission, mais simplement de points de bruit qui se détachent du cluster principal. La branche survivante conserve l'identité de son parent.
- Si les deux branches ont une taille supérieure à `min_cluster_size`, la scission est validée et deux nouveaux clusters indépendants naissent.

Remarque En effectuant cet élagage, les auteurs de HDBSCAN ont introduit un véritable *seuil de percolation* (et ce, sans le formuler explicitement en ces termes). Seules les composantes “macroscopiques” sont conservées, éliminant ainsi le bruit des micro-composantes qui apparaissent de manière éphémère.

4.4.4 Un clustering multi-échelle : le critère d'excès de masse (*excess of mass*)

Plutôt que de couper le dendrogramme à une hauteur fixe comme le fait DBSCAN, HDBSCAN introduit un critère de stabilité inspiré des statistiques non paramétriques [49] pour sélectionner automatiquement les clusters à des échelles variables.

DÉFINITION 19 : EXCÈS DE MASSE (*EXCESS OF MASS*) [7]

Pour une fonction de densité continue f , l'excès de masse d'un cluster C apparu à un niveau de densité de base λ est défini par :

$$E(C) = \int_C (f(x) - \lambda) \mathbb{1}_{\{f(x) \geq \lambda\}} dx.$$

La FIG. 4.2 illustre les excès de masse des différents clusters d'intérêt pour une certaine fonction.

En pratique, cet excès de masse *relatif* (propre à chaque cluster) est très simple à estimer. Si le cluster C commence à exister à partir du seuil de densité $\hat{\lambda}_{\min}$ (moment où il se sépare de son parent) et qu'un point $x \in \mathcal{X}$ quitte le cluster (devient du bruit ou forme un sous-cluster) à la densité $\hat{\lambda}_x$, l'excès de masse cumulé de C est estimé par :

$$\hat{E}(C) \propto \sum_{x \in C} (\hat{\lambda}_x - \hat{\lambda}_{\min}).$$

HDBSCAN estime la densité en un point x simplement avec l'inverse de la distance à laquelle le point se détache : $\hat{\lambda}_x = 1/r_x$.




FIGURE 4.2 : Illustration du critère d'excès de masse de l'algorithme HDBSCAN. À gauche : l'arbre hiérarchique. À droite : les composantes connexes des ensembles de niveau de la densité délimitant l'excès de masse *relatif*, c'est-à-dire propre à chaque amas C_i .

Pour extraire le partitionnement final, l'algorithme parcourt l'arbre condensé de bas en haut. À chaque nœud parent divisé en plusieurs enfants, on compare son excès de masse empirique $\hat{E}(C)$ avec la somme des stabilités de ses enfants. On définit ainsi récursivement la *stabilité* $\tilde{E}(C)$ d'un cluster par :

$$\tilde{E}(C) = \begin{cases} \hat{E}(C) & \text{si } C \text{ est une feuille,} \\ \max \left(\hat{E}(C), \sum_{C_i \in \text{Fils}(C)} \tilde{E}(C_i) \right) & \text{sinon.} \end{cases}$$

Si la stabilité des enfants est supérieure, la scission est validée et on parcourt les nœuds enfants. Sinon, le parent est sélectionné comme un cluster unique et robuste ($\tilde{E}(C) = \hat{E}(C)$). Cette optimisation permet à HDBSCAN d'extraire des clusters à des niveaux de densité très différents.

La Figure 4.2 illustre ce processus, où l'excès de masse relatif $\hat{E}$ correspond à l'aire des régions colorées. L'algorithme initialise les feuilles avec leurs aires respectives : $\hat{E}(C_1)$, $\hat{E}(C_2)$ et $\hat{E}(C_3)$. En remontant au nœud parent C_4 , la somme des aires **verte** et **rouge** s'avère supérieure à l'aire **violette** du parent : la scission est donc conservée. Le processus s'achève à la racine C_5 , où la somme des stabilités consolidées des branches ($\tilde{E}(C_4) + \tilde{E}(C_3)$) dépasse l'aire **bleue** de la base. Le partitionnement final renvoyé par HDBSCAN sur cet exemple est donc : C_1 , C_2 et C_3 .

4.4.5 Les limites de l'approche : le paradoxe du choix de K

Puisque HDBSCAN vise à utiliser l'estimateur K -NN, la logique statistique dicterait que plus K est grand, plus l'estimation de densité est consistante et lisse, et meilleurs devraient être les résultats.

Or, en pratique, choisir un K (*via* le paramètre `min_samples`) supérieur à une dizaine dégrade rapidement les performances géométriques de l'algorithme, noyant les structures dans le bruit. Nous expliquerons théoriquement ce phénomène dans la partie suivante.

Synthèse L'évolution historique du Single-Linkage vers le Robust Single-Linkage et HDBSCAN illustre le besoin d'intégrer une densité des K plus proches voisins, indispensable pour lutter contre l'inconsistance du modèle (l'effet de chaînage dû à la percolation) et isoler efficacement le bruit.

Toutefois, en dépit de ses bonnes heuristiques d'extraction (condensation de l'arbre hiérarchique *via* `min_cluster_size` et excès de masse), HDBSCAN repose fondamentalement sur le Robust Single-Linkage. Cet algorithme n'évalue que ponctuellement la densité (en les points $x \in \mathcal{X}$) et construit un graphe sur $\mathcal{X}$ qui n'a pas de raison de refléter les amas de forte densité lorsque $K \geq 2$. C'est pourquoi, en pratique, augmenter le paramètre K (`min_samples`) dégrade rapidement les performances géométriques de l'algorithme (un compromis faible comme $K = 10$ est souvent privilégié).

Comme nous le démontrerons dans la partie suivante, la manière mathématiquement exacte d'introduire l'estimateur K -NN exige de généraliser la notion même de connexité. En passant aux hypergraphes (*via* les complexes de Čech) et en introduisant des interactions d'ordre supérieur avec les K -polyèdres, nous rétablirons l'exactitude topologique perdue, tout en fournissant un cadre rigoureux pour analyser théoriquement les performances de ces algorithmes en recourant à la théorie de la percolation.

Une vue générale sur le clustering hiérarchique. Ou comment introduire des *a priori*.

Ce chapitre ne présente ni nouveaux concepts théoriques fondamentaux, ni nouvelles preuves mathématiques ; il s’adresse plutôt aux ingénieurs et chercheurs curieux, désireux de décortiquer la mécanique de HDBSCAN pour l’adapter, par exemple, à des problèmes industriels spécifiques.

Comme nous l’avons vu au chapitre précédent, le succès de HDBSCAN réside dans sa capacité à extraire un clustering qui soit à la fois multi-échelle et qui gère (relativement) bien le bruit.

Nous montrons d’abord dans ce chapitre que la structure d’arbre (l’ultramétrie) est un cadre mathématique puissant qui permet d’unifier et de résoudre de manière quasi-triviale des problèmes d’optimisation (comme le k -Means), autrement NP-complets dans un cadre plus général. Il est possible de “hacker” l’étape d’extraction de HDBSCAN en substituant à sa fonction de coût statistique des *a priori*. Nous illustrons cette démarche avec notre généralisation du Single-Linkage, HGP-Clusterer (HGP pour Hypergraphe-Percol’), qui sera théorisé dans la partie suivante. Nous proposons deux cas d’usage réels : la détection d’anomalies par rapport à un modèle 3D théorique (©Naval Group) et la segmentation d’instance 4D sur des nuages de points LiDAR (sur le jeu de données SemanticKITTI [50]).

Contributions Nous adoptons une vue unificatrice du clustering hiérarchique (en intégrant le formalisme de l’analyse convexe). Nous nous appuyons ensuite sur les récents travaux de DRAGANOV *et al.* [47] pour rappeler qu’un arbre ultramétrique simplifie drastiquement les algorithmes de clustering : le k -Means, NP-complet dans $\mathbb{R}^p$, y est résolu optimalement en temps de tri. Nous montrons comment remplacer la fonction de coût de HDBSCAN, l’excès de masse, par une fonction de coût intégrant des *a priori* géométriques. Nous montrons l’efficacité de cette approche sur des nuages 3D et 4D

avec notre algorithme HGP-Clusterer pour deux applications industrielles (détection d'anomalies sur un chantier naval et *tracking* par transport optimal sur SemanticKITTI).

5.1 L'arbre comme espace de résolution : unifier le clustering

Il existe une dichotomie historique entre les algorithmes de clustering cherchant des centroïdes (comme le k -Means) et les algorithmes agglomératifs (comme le Single-Linkage). Néanmoins, ces deux visions peuvent être unifiées sous le prisme de l'optimisation convexe.

5.1.1 Formalisation convexe du problème de clustering

Le *convex clustering* [51, 52] reformule le clustering comme un problème d'optimisation convexe global. Soit $X \in \mathbb{R}^{n \times p}$ la matrice des données observées. L'idée centrale est de relâcher la contrainte d'appartenance discrète en associant à chaque observation x_i un centroïde $u_i \in \mathbb{R}^p$. Le clustering émerge par la coalescence de ces centroïdes en minimisant :

$$\min_{U \in \mathbb{R}^{n \times p}} \underbrace{\frac{1}{2} \sum_{i=1}^n \|x_i - u_i\|^2}_{\text{Fidélité (Attache aux données)}} + \gamma \underbrace{\sum_{i < j} w_{ij} \|u_i - u_j\|}_{\text{Pénalité de fusion (Régularisation)}}$$

où $\gamma \geq 0$ est un paramètre de régularisation et w_{ij} des poids positifs encodant la géométrie locale.

L'analyse de ce problème [53] offre une perspective mécanique éclairante. En introduisant les variables duales v_{ij} associées aux contraintes de différence, on obtient des conditions de capacité $\|v_{ij}\| \leq \gamma w_{ij}$. Les variables v_{ij} s'interprètent comme des *forces de tension* s'exerçant entre les points. Deux clusters ne fusionnent ($u_i = u_j$) que lorsque l'équilibre des forces nécessite de saturer la capacité du lien γw_{ij} . Cette structure duale révèle que le *convex clustering* est en réalité une relaxation robuste du Single-Linkage¹⁾, où la fusion ne dépend plus d'un unique point (susceptible de créer un effet de chaînage) mais d'un ensemble de tensions.

En faisant varier γ , la séquence temporelle de coalescence des centroïdes permet de reconstruire un arbre hiérarchique (voir l'illustration en FIG. 5.1).

5.1.2 Quand les problèmes NP-complets deviennent triviaux

Si la recherche de centroïdes optimaux (comme dans le k -Means ou le k -Median) est connue pour être un problème NP-complet dans l'espace euclidien $\mathbb{R}^p$ pour $k \geq 2$, la

¹⁾Le Single-Linkage pouvant se formuler comme un cas très particulier de ce problème [53].




FIGURE 5.1 : Illustration du principe du Convex Clustering. (a) Dans l’espace des données, l’augmentation de la pénalité γ force les centroïdes à se déplacer physiquement (*shrinkage*) vers les zones de densité locale. (b) La séquence temporelle de ces coalescences permet de reconstruire l’arbre hiérarchique.

situation change radicalement dès lors que la métrique est une ultramétrique, c’est-à-dire que l’on dispose d’une structure d’arbre.

En théorie des graphes, de nombreux algorithmes NP-complets sur des graphes généraux deviennent de complexité quasi-linéaire lorsque le graphe est un arbre. Il en va de même pour le clustering, comme l’ont montré DRAGANOV *et al.* dans leur récent papier [47].

FAIT (CONNU) 11 : RÉOLUTION OPTIMALE DU k -MEANS SUR LES HIÉRARCHIES ULTRAMÉTRIQUES [47]

Pour n’importe quelle hiérarchie, les objectifs de clustering recourant aux centres (tels que le k -Means, k -Median, ou k -Centre) peuvent être résolus *de manière optimale*. Mieux encore, l’ensemble complet des solutions optimales pour tout $k \in \llbracket 1; n \rrbracket$ peut être trouvé en un temps équivalent à celui d’un tri, soit $\mathcal{O}(n \log n)$.

Ce résultat est une excellente nouvelle : une fois que nous disposons d’un bon arbre hiérarchique, il n’y a plus à s’en remettre à une heuristique : la hiérarchie elle-même devient un espace dans lequel chercher *très rapidement* la solution qui nous intéresse (qu’il s’agisse d’un k -Means optimal ou de toute autre exploration guidée selon le problème).

5.2 « Hacker » HDBSCAN : l’exploration de l’arbre hiérarchique

Revenons à HDBSCAN. Pour extraire un clustering “à plat” depuis la hiérarchie, l’algorithme calcule l’excès de masse (DEF. 19, p. 44) de chaque nœud, puis propage cette valeur de bas en haut.




FIGURE 5.2 : Le mécanisme de sélection d'un cluster. L'architecture de HDBSCAN compare la perte (*loss*) d'un nœud parent à la somme de celles de ses enfants. En jouant sur la fonction de coût, l'on peut introduire des *a priori*.

La décision prise au niveau du nœud parent $C_{\text{Père}}$ s'écrit de manière générique :

Si $\text{loss}(C_{\text{Père}}) < \sum_i \text{loss}(C_{\text{Fils},i}) \implies$ Conserver le nœud parent, sinon continuer d'explorer.

Dans le cas de l'excès de masse de HDBSCAN, il suffit de poser $\text{loss}(C) = -\tilde{E}(C)$. L'excès de masse est un critère purement statistique, aveugle à la géométrie. Si nous substituons cette fonction de coût par une évaluation personnalisée au problème rencontré (l'alignement d'une structure, le volume maximal attendu d'un objet, ou la conformité à un modèle 3D), l'algorithme se transforme en un extracteur guidé géométriquement.

Nous illustrons cette approche sur deux applications pratiques, en utilisant HGP-Clusterer (notre généralisation du Single-Linkage aux interactions d'ordre supérieur, qui sera définie formellement dans la partie suivante, voir DEF. 22, p. 62) pour générer l'arbre hiérarchique de base.

5.3 Application I : Détection d'anomalies 3D guidée par un modèle théorique (©Naval Group)

La première application concerne un problème de structuration de données industrielles : le nettoyage d'un nuage de points LiDAR dans un chantier naval (travail réalisé sur une partie du projet Inria Startup Studio de Marie ASPRO, en collaboration avec elle).

5.3.1 Le problème

Nous disposons en entrée :

1. D’un modèle 3D théorique du chantier naval (les boîtes englobantes des infrastructures attendues).
2. D’un nuage de points 3D brut, fortement bruité, acquis par un capteur LiDAR (la réalité du chantier).

L’objectif est d’isoler les objets physiques présents dans le nuage mais absents du modèle théorique (ex. : des casques, des tuteurs, des câbles ou des outils).

5.3.2 L’exploration guidée

Nous construisons la hiérarchie du nuage LiDAR avec HGP-Clusterer. Lors de la navigation dans l’arbre, notre fonction de coût n’évalue plus la densité, mais utilise le modèle 3D théorique comme *a priori*.

Pour un nœud donné de l’arbre, la fonction calcule sa “pureté” géométrique (par exemple à l’aide de l’index de GINI [54]) : on vérifie la proportion de ses points qui tombent à l’intérieur ou à l’extérieur des limites du modèle théorique.

- Si un nœud parent est hybride (il contient à la fois des points de la structure valide du navire et une anomalie qui y est accolée), la fonction de coût force la scission de l’arbre pour isoler la composante étrangère.
- Dès qu’une branche atteint un seuil adéquat de pureté (la grande majorité de ses points sont situés ou bien hors du modèle théorique, ou bien peuvent être rattachés au modèle), l’algorithme valide le cluster (en tant qu’anomalie ou en tant qu’objet conforme au modèle 3D).

5.3.3 Le post-traitement

Les occultations inhérentes aux acquisitions LiDAR ont la fâcheuse tendance à fragmenter un objet réel (un câble caché par un poteau par exemple) en plusieurs sous-clusters. Nous ne cherchons pas à forcer une partition parfaite absolue au moment de l’exploration de l’arbre. À la place, un post-traitement très simple est appliqué : nous calculons les boîtes englobantes des anomalies extraites, et en parcourant leur matrice d’adjacence on fusionne les fragments d’un même objet. Les points de bruits résiduels piégés dans ces boîtes sont ensuite absorbés.

Cette approche montre que l’injection d’une supervision géométrique faible (la simple indication spatiale du modèle 3D théorique) directement dans la fonction de coût de l’arbre hiérarchique offre une solution robuste, interprétable, et qui s’affranchit totalement des coûteuses méthodes d’apprentissage profond (*training-free*).

Nota bene : Le test montré en FIG. 5.3 est un “petit” nuage *synthétique* de 2 000 000 de points. Pour des raisons de confidentialité, nous ne pouvons pas montrer les résultats sur des données réelles (avec des nuages de l’ordre de 10 000 000 de points), situations




FIGURE 5.3 : Détection d’anomalies sur un *benchmark* synthétique (©Naval Group) de 2 000 000 de points. L’injection du modèle 3D théorique (bien identifié en rouge) comme *a priori* géométrique dans la fonction de coût lors de l’exploration de la hiérarchie produite par HGP-Clusterer permet d’isoler parfaitement les objets étrangers (trois tuteurs, deux cubes ; chacun avec sa couleur). Le « hors-champ » apparaît en gris.

autrement plus difficiles, mais où notre algorithme s’en tire bien mieux que toutes les autres méthodes essayées par Marie ASPRO ainsi que la même *baseline* où HDBSCAN est substitué à notre HGP-Clusterer.

5.4 Application II : Segmentation d’instance 4D sur SemanticKITTI

La seconde application s’attaque à la segmentation d’instance (ou segmentation panoptique) « 4D » (c’est-à-dire avec suivi des objets d’intérêt, des *instances*, au cours du temps), évaluée sur le jeu de données SemanticKITTI [50]. L’objectif est de détecter (segmenter) spatialement et suivre temporellement des objets dynamiques (véhicules, piétons, *etc.*).

Nous reprenons ici les idées récentes de la littérature scientifique qui montrent qu’il est possible d’obtenir l’« état-de-l’art » une fois la sémantique du nuage connue, et sans apprentissage additionnel. Comme le soulignent SAUTIER *et al.* [55], une approche de clustering pur permet d’obtenir une très bonne segmentation d’instance sur chaque trame (*frame* en anglais).

De plus, pour le suivi au cours du temps (*tracking* en anglais), OH *et al.* [56] ont montré plus récemment encore qu’une association géométrique globale est extrêmement efficace.

5.4.1 La méthode

Notre processus de *streaming* se divise en deux étapes (voir un exemple en FIG. 5.4 et le résultat sur les 200 premières trames la séquence 08 de SemanticKITTI en FIG. 5.5) :

1. **Segmentation spatiale 3D.** Pour chaque trame et pour chaque classe d'intérêt, nous générons une hiérarchie avec HGP-Clusterer. Lors de l'exploration de cette hiérarchie, notre fonction de coût est guidée par la sémantique (*a priori* sur les dimensions attendues selon la classe de l'objet). Si, par exemple, un nœud décrit un amas de la taille de deux véhicules fusionnés par la densité, le volume physique aberrant force l'algorithme à scinder le nœud. Cette première passe, assez proche dans l'idée du travail de SAUTIER *et al.* [55], fournit non pas un clustering du nuage de points mais une forêt hiérarchique, un ensemble d'arbres hiérarchiques dont la racine représente le cluster qu'aurait choisi l'algorithme sur une unique trame. Cette forêt est ensuite passée au *tracker*.
2. **Suivi temporel (*tracking 4D*).** Le suivi d'une trame à l'autre est assuré par l'utilisation du transport optimal [57]. L'état cinématique des objets (centroïdes et dimensions) est lissé au cours du temps par un filtre de KALMAN [58]. Pour associer les prédictions de la trame $t - 1$ aux détections géométriques de la trame t , nous calculons un plan de transport optimal entre les pistes de la trame $t - 1$ extrapolées au temps t et le nuage correspondant au temps t . Nous reprenons alors l'exploration de la forêt obtenue à l'étape précédente pour obtenir un appariement optimal entre les pistes extrapolées et les clusters potentiels au temps t . Tout arbre n'ayant aucun de ses nœuds associé à une piste déjà confirmée crée une nouvelle piste potentielle. Le problème de transport optimal est déséquilibré [59] (*unbalanced* ; d'une trame à l'autre, une instance n'a pas forcément le même nombre de points) et régularisé par l'entropie, convexifiant ainsi le problème et permettant le recours à des algorithmes hautement parallélisables de type Sinkhorn [60].




FIGURE 5.4 : Résultat de notre méthode sur la trame 60, séquence 08, de SemanticKITTI. Chaque piste est repérée par sa boîte englobante (une couleur par classe d'objets). Noter les deux cyclistes (boîtes roses) en bas, bien séparés quoique proches (et ce grâce au suivi par transport optimal, quand le clustering avec *a priori* géométriques les avait fusionnés).




FIGURE 5.5 : Segmentation panoptique 4D sur les 200 premières trames de la séquence 08 de SemanticKITTI. Les instances spatiales sont projetées en 2D (*Bird-Eye-View*), le temps t est repéré sur le troisième axe. Chaque piste suivie reçoit une couleur et produit donc comme une traînée avec le temps. À gauche, la vérité terrain. À droite, le résultat de notre méthode (clustering hiérarchique guidé par la géométrie + transport optimal déséquilibré régularisé par l'entropie).

Les résultats (FIG. 5.5) montrent que les pistes principales sont bien détectées et suivies au cours du temps. L'algorithme présente encore quelques faiblesses pour un transfert vers l'industrie : la gestion du bruit, des petites pistes lointaines, et des occlusions, rendant certaines pistes "clignotantes" notamment. Le temps de réponse est aussi un problème : de l'ordre de la seconde pour l'instant lorsqu'une version industrielle impose de pouvoir traiter plusieurs trames à la seconde (dix trames par seconde avec les capteurs qui ont servi à l'établissement de SemanticKITTI) .

Synthèse Ce chapitre illustre la puissance et la flexibilité du clustering hiérarchique. L'arbre ultramétrique est un espace dans lequel des problèmes NP-complets complexes peuvent être résolus très rapidement de manière optimale (comme le k -Means [47]).

Lors de l'exploration de l'arbre hiérarchique, nous avons montré qu'il est possible d'injecter des *a priori* géométriques (le modèle 3D théorique, les dimensions physiques). Les résultats obtenus avec notre algorithme HGP-Clusterer sur la détection d'anomalies LiDAR et la segmentation panoptique 4D valident cette approche pragmatique et *training-free*.

Cependant, la robustesse de ces applications s'appuie fondamentalement sur la qualité de l'arbre généré. Or, comme souligné précédemment, le Robust Single-Linkage (moteur de HDBSCAN) ne reflète pas la topologie des densités K -NN lorsque $K \geq 2$. Il est donc impératif de pallier ces faiblesses. C'est l'objet de la partie suivante, où l'on y définit notre méthode HGP-Clusterer.

DEUXIÈME PARTIE

La généralisation du Single-Linkage avec des interactions d'ordre supérieur

Le cadre euclidien $\mathcal{X} \subset \mathbb{R}^p$ Dans la partie précédente, nous avons dressé une cartographie complète et unifiée de l'algorithme du Single-Linkage. Cette exploration s'est principalement déployée au cœur de l'espace euclidien, terrain d'étude qui offre au Single-Linkage à la fois :

1. Un modèle statistique satisfaisant, celui proposé par HARTIGAN [3], avec l'extraction de la hiérarchie des amas de forte densité (le Single-Linkage correspond au cas où l'estimateur de densité est celui du plus proche voisin).
2. Un cadre théorique intéressant : celui de l'analyse persistante de graphes géométriques sur les données.
3. Des optimisations géométriques : l'arbre minimum couvrant qui contient toute l'information de la hiérarchie peut se construire rapidement (en petite dimension) en tant que sous-graphe de la triangulation de DELAUNAY.

Au sein de ce même cadre euclidien, nous nous proposons dans cette partie de généraliser le Single-Linkage ; généralisation qui prolonge naturellement les trois axes précédents :

1. Construire une hiérarchie qui corresponde exactement au modèle (discret) de HARTIGAN lorsque l'estimateur de densité est $\hat{f}_{K\text{-NN}}$ celui des K plus proches voisins.
2. Disposer d'un cadre théorique (celui de la percolation continue [4, 5]) où l'analyse persistante se fait non plus sur des graphes, mais des hypergraphes géométriques. Dans ce cadre, nous pouvons quantifier précisément les performances théoriques d'un algorithme.
3. Obtenir le même genre d'optimisation géométrique (identifier un K -arbre minimum couvrant) en travaillant avec la *mosaïque* de DELAUNAY d'ordre K [61].

Plan de la seconde partie Cette partie se déroulera selon le plan suivant :

1. **Chapitre 6. Généralisation du Single-Linkage : HGP-Clusterer.** Retour sur les problèmes du Single-Linkage (identifiés mais non résolus par HDBSCAN). Proposition d'un nouvel algorithme de clustering hiérarchique conforme au modèle de HARTIGAN des amas de forte densité avec l'estimateur de densité $\hat{f}_{K\text{-NN}}$ des K plus proches voisins. Cet algorithme faisant de l'analyse persistante (*clique-percolation*) sur un complexe de Čech (généralisation du graphe géométrique), nous l'avons baptisé HGP-Clusterer, HGP signifiant « Hypergraphe-Percol' ».
2. **Chapitre 7. Percolation.** Le phénomène mathématique au cœur de l'analyse persistante est la percolation. C'est dans ce chapitre que manipuler (théoriquement) des (hyper)graphes géométriques plutôt que des arbres couvrants s'avère fructueux : cela permet de connecter toute cette famille d'algorithmes (Robust Single-Linkage, HDBSCAN, HGP-Clusterer) à la théorie de la percolation continue. Ce phénomène – et notamment la vitesse à laquelle il s'opère – permet de mesurer les performances théoriques de l'algorithme.
3. **Chapitre 8. Généralisation des optimisations : le K -arbre couvrant minimal et la mosaïque de DELAUNAY d'ordre K .** Jusqu'alors, la présentation de HGP-Clusterer aura été plus théorique qu'autre chose (de même que le Single-Linkage peut se définir à l'aide d'analyse persistante sur des graphes géométriques, il n'est en pratique jamais calculé de la sorte). Ce chapitre est donc l'occasion de revenir sur la généralisation des optimisations géométriques qui font que le Single-Linkage marche si bien en petite dimension : l'arbre minimum couvrant est un sous-graphe de la triangulation de DELAUNAY. De même, le K -arbre minimum couvrant (qui possède toute l'information hiérarchique nécessaire à HGP-Clusterer) est un sous-complexe de la mosaïque de DELAUNAY d'ordre K .
4. **Chapitre 9. Conclusion pratique.** Nous consacrons tout un pan du dernier chapitre à des considérations pratiques : si l'on veut par exemple imposer un clustering qui soit une stricte partition des données $\mathcal{X}$ (et non pas un recouvrement de $\mathcal{X}$), que faire ? si les données ne sont pas dans l'espace euclidien, ou bien qu'on est en dimension trop grande et sujet au fléau de la dimension, que faire ?

Le dernier chapitre de cette partie est aussi l'occasion de revenir sur la richesse de l'information contenue dans la mosaïque de DELAUNAY d'ordre K . Nous l'avons utilisée pour l'extraction d'un clustering hiérarchique ; nous esquissons en guise de conclusion quelque autre intérêt de cet objet, notamment pour la réduction de dimension.

HGP-Clusterer : la généralisation du Single-Linkage dans l'espace euclidien

Ce chapitre commence par revenir sur le problème fondamental du Single-Linkage : l'effet de chaînage, ou la non prise en compte de la densité locale. Si l'on voit – ainsi que nous l'avons fait dans la partie précédente – le Single-Linkage dans l'espace euclidien comme l'algorithme qui construit la hiérarchie exacte des amas de forte densité (modèle de HARTIGAN, voir DEF. 6 & DEF. 8, p. 27) pour l'estimateur de densité du 1-NN, l'amélioration à apporter au Single-Linkage est claire :

Il faut identifier la hiérarchie exacte des amas de forte densité pour l'estimateur de densité des K plus proches voisins (K -NN).

Nous verrons dans un premier temps (§ 6.1), sur un exemple simple, pourquoi les généralisations proposées au problème dans la partie précédente ne marchent pas. Comme nous l'avons déjà fait remarquer, le problème vient de ce que le Robust Single-Linkage [45] ou (H)DBSCAN [7, 8] imposent à un nœud d'avoir K voisins (ou au moins d'être à la frontière de l'un de ces K -cœurs) pour apparaître au sein d'un cluster. Dans le même temps, une simple arête suffit pour connecter deux nœuds. C'est cette asymétrie entre les contraintes (fortes) imposées aux points et celles (lâches) vis-à-vis des arêtes que nous allons réparer dans le présent chapitre. Nous verrons alors toujours sur le même exemple la véritable solution au problème.

Nous passons alors à la formalisation de cette bonne réponse à apporter (§ 6.2). Des contraintes plus fortes (d'ordre supérieur) imposées aux liens peuvent être encodées en recourant aux hypergraphes, et plus particulièrement aux complexes simpliciaux [62]. La réparation naturelle consiste à renforcer aussi la notion de "connectivité". Le bon objet à construire n'est plus le graphe géométrique, mais le complexe de Čech [6, 63] ; et la bonne notion de composante connexe n'est plus une composante de sommets reliés par

des arêtes, mais une composante de $(K - 1)$ -simplexes reliés par des interactions d'ordre supérieur (ce que nous avons appelé des K -polyèdres).

En § 6.3, nous démontrons la correspondance exacte entre les K -polyèdres et les amas discrets de forte densité K -NN (THÉORÈME 2, p. 64).

Nous ne chercherons pas ici à forcer une partition à chaque niveau. Pour $K \geq 2$, les amas discrets de forte densité (DEF. 8, p. 27) peuvent se recouvrir (*cf.* l'exemple introductif en § 6.1); la généralisation correcte du Single-Linkage doit donc produire, elle aussi, une hiérarchie de recouvrements (nous verrons au chapitre 9 comment faire pour obtenir une hiérarchie qui respecte strictement à tous niveaux la contrainte de partition).

À l'instar de la définition du Single-Linkage (*via* l'analyse persistante de graphes géométriques, *cf.* DEF. 11, p. 33), la généralisation du Single-Linkage, que nous avons baptisée HGP-Clusterer (DEF. 22, p. 62), est pour l'instant toute théorique. Nous verrons au cours des chapitres suivants (dédiés à la généralisation et à la construction de l'arbre minimum couvrant) comment extraire cette hiérarchie en pratique.

Contributions Ce chapitre fait la transition entre la revue complète du Single-Linkage de la partie précédente, et la généralisation mathématiquement satisfaisante proposée. Nous espérons fournir au lecteur, *via* la première section illustrative, la bonne intuition pour que cette généralisation lui paraisse effectivement naturelle. Les résultats présentés dans la suite du chapitre reprennent et reformulent [64]. La reformulation adoptée dans ce manuscrit, plus naturelle et plus simple, a été permise grâce à notre définition d'un amas de forte densité K -NN *discret* (DEF. 8, p. 27). Le résultat principal de ce chapitre est le THÉORÈME 2, p. 64, qui se montre sans difficulté une fois tous les bons outils introduits (amas discrets, régions témoins, graphe d'intersection, *etc.*).

6.1 Retour sur la non prise en compte de la densité

6.1.1 L'échec du Robust Single-Linkage et de (H)DBSCAN sur le modèle de HARTIGAN

Appelons $K \in \mathbb{N}^*$ la variable représentant le nombre de voisins pris en compte dans l'algorithme de Robust Single-Linkage [45] et de (H)DBSCAN [7, 8]. Pour $K = 1$, l'on a vu que le Single-Linkage fournissait exactement la hiérarchie des amas de forte densité dans le modèle de HARTIGAN (voir la synthèse du chapitre 2).

En revanche, pour $K \geq 2$, il n'y a plus correspondance entre la hiérarchie produite par ces algorithmes et celle du modèle (discret) de HARTIGAN.

Nous l'allons voir sur un exemple simple. Soit $\mathcal{X} = \{A; B; C; D; E; F\} \subset \mathbb{R}^2$ un nuage composé de six points disposés comme illustré en FIG. 6.1a : deux triangles équilatéraux (de côté $2r$) parfaitement opposés et à distance $2r$ l'un de l'autre.

Chaque point a son plus proche voisin à distance $2r$. Mieux : pour ce seuil $2r$, chaque point a même au moins $K = 2$ voisins. De plus, le graphe engendré par les connexions




FIGURE 6.1 : (Gauche) Nuage de six points $\mathcal{X} = \{A; B; C; D; E; F\}$. (Droite) Dendrogramme produit par le Single-Linkage avec en entrée $\mathcal{X}$. Le même dendrogramme est produit par le Robust Single-Linkage et (H)DBSCAN pour $K = 2$.

au seuil $2r$ connecte les six points de $\mathcal{X}$ entre eux. Il en résulte que le dendrogramme produit par le Robust Single-Linkage ou (H)DBSCAN avec $K = 2$ est un arbre constitué de six feuilles (les six points de $\mathcal{X}$) qui fusionnent toutes au seuil r (voir FIG. 6.1b)¹⁾.

6.1.2 La hiérarchie exacte de HARTIGAN lorsque $K = 2$

Calculons maintenant la hiérarchie (discrète) produite par le modèle de HARTIGAN lorsque $K = 2$. Rappelons (DEF. 8, p. 27) qu'un point $x \in \mathcal{X}$ est *couvert* au niveau r par un amas de forte densité $C \in H_{f_K}^\wedge(r)$ si x est à moins de r de C . On note $C^{\text{discret}} \subseteq \mathcal{X}$ le cluster discret correspondant.




FIGURE 6.2 : (Gauche) Nuage $\mathcal{X}$ repris de la FIG. 6.1a avec les amas (en bleu) de forte densité 2-NN au niveau $r' \gtrsim r$. (Droite) Dendrogramme en construction. Par convention, le multi-ensemble des feuilles apparaît au niveau 0.

Pour $K = 2$, les premiers amas de forte densité apparaissent au niveau r (cf. la FIG. 6.2a). Ils sont au nombre de sept et en correspondance avec les sept segments de longueur $2r$ (FIG. 6.2b).

¹⁾Ainsi d'ailleurs que le dendrogramme de (H)DBSCAN avec $K = 3$, et aussi celui du Single-Linkage standard.




FIGURE 6.3 : (Gauche) Évolution des amas de forte densité 2-NN au niveau $r' = \frac{2\sqrt{3}}{3}r$: on voit apparaître des fusions de 2-intersections de boules au moyen de 3-intersections (le point de contact de la fusion est repéré en rouge). (Droite) : Évolution du dendrogramme avec les fusions opérées au niveau r' .

Au niveau $r' = \frac{2\sqrt{3}}{3}r$, des 3-intersections de boules apparaissent, fusionnant certains amas de forte densité. Voir la FIG. 6.3 pour plus de détails.




FIGURE 6.4 : Clôture de la hiérarchie 2-NN au niveau $r'' = AD/2$. À ce rayon critique, l'apparition simultanée des quatre points de tangence (points rouges) relie les trois amas de forte densité.

Enfin, au niveau $r'' = \frac{AD}{2}$, des jonctions apparaissent entre les trois amas de forte densité du niveau r' , clôturant ainsi le dendrogramme. Voir la FIG. 6.4.

Comme déjà esquissé dans la première partie, l'on s'aperçoit que pour rendre compte des $K \geq 2$ plus proches voisins, il va être nécessaire de relâcher l'hypothèse d'un clustering vu comme une *partition* sur les données $\mathcal{X}$. Les interactions d'ordre supérieur (ici des arêtes connectées entre elles au moyen de triangles¹⁾) s'avèrent nécessaires.

¹⁾C'est pourquoi le seuil de connexion global sur notre exemple est $r'' = AD/2$: à ce niveau, le triangle ACD apparaît connectant les arêtes AC et CD.

6.2 Du graphe géométrique au complexe de Čech : les K -polyèdres

Pour généraliser correctement le Single-Linkage, nous prenons comme point de départ l’axe (développé dans la partie I) d’analyse persistante sur des *graphes géométriques* (DEF. 11, p. 33). La généralisation naturelle consiste à remplacer les graphes par des hypergraphesⁱⁱ⁾. Plus précisément, une sous-famille des hypergraphes va nous servir au cours de ce manuscrit : les complexes simpliciaux [62]. Un complexe simplicial est un hypergraphe pour lequel la présence d’une hyper-arête entraîne la présence de toutes les sous-hyper-arêtes. Par exemple, la présence d’un tétraèdre entraîne la présence de ses quatre “facettes” (triangles), de ses quatre arêtes (et bien-sûr des quatre sommets, que l’on peut voir comme des hyper-arêtes d’ordre 0).

Il devient alors possible de remplacer les composantes connexes ordinaires par une “connectivité” d’ordre supérieur.

6.2.1 Le complexe de Čech

DÉFINITION 20 : COMPLEXE DE ČECH [29, 62, 63]

Soit $\mathcal{X} \subset \mathbb{R}^p$ un nuage fini et $r \geq 0$. Le *complexe de Čech* de rayon r est le complexe simplicial

$$\check{C}(\mathcal{X}, r) \triangleq \left\{ \sigma \subseteq \mathcal{X} \mid \bigcap_{x \in \sigma} \overline{B}(x, r) \neq \emptyset \right\}.$$

Autrement dit, un ensemble fini $\sigma \subseteq \mathcal{X}$ est un simplexe de $\check{C}(\mathcal{X}, r)$ si et seulement s’il existe un point $y \in \mathbb{R}^p$ situé à distance au plus r de tous les sommets de σ , *i.e.*

$$\sigma \subset \overline{B}(y, r).$$

Remarque Le 1-squelette de $\check{C}(\mathcal{X}, r)$ n’est autre que le graphe géométrique $\mathcal{G}(\mathcal{X}, r)$ introduit au chapitre 2 : une arête $\{x, x'\}$ apparaît exactement lorsque $\overline{B}(x, r) \cap \overline{B}(x', r) \neq \emptyset$, c’est-à-dire lorsque $\|x - x'\| \leq 2r$.

Plus généralement, un K -simplexe de $\check{C}(\mathcal{X}, r)$ encode une interaction entre $K + 1$ points qui peuvent être simultanément vus depuis une même boule de rayon r . C’est précisément ce type d’information sur la densité locale qui manque au Single-Linkage et qui est la source de l’effet de chaînage.

ⁱⁱ⁾Un graphe est la donnée d’un ensemble de sommets noté V (pour *vertices* en anglais) et d’un ensemble de relation binaires entre ces sommets, les arêtes E (*edges* en anglais). Dans le cas d’un *hypergraphe*, les arêtes deviennent des hyper-arêtes, c’est-à-dire qu’elles ne sont plus nécessairement binaires mais peuvent encoder des relation d’ordre supérieur : des triangles, des tétraèdres, *etc.*

6.2.2 Les K -polyèdres

DÉFINITION 21 : GRAPHE DES $(K - 1)$ -SIMPLEXES ET K -POLYÈDRES

Soit $K \in \llbracket 1, |\mathcal{X}| \rrbracket$ et $r \geq 0$. On note $\check{C}_{K-1}(\mathcal{X}, r)$ l'ensemble des simplexes de dimension $K - 1$ du complexe de Čech $\check{C}(\mathcal{X}, r)$.

On leur associe le graphe

$$\Gamma_K(\mathcal{X}, r)$$

dont les sommets sont les éléments de $\check{C}_{K-1}(\mathcal{X}, r)$, deux sommets σ et τ étant reliés dès que $\sigma \cup \tau$ est encore un simplexe de $\check{C}(\mathcal{X}, r)$.

Un K -polyèdre de $\check{C}(\mathcal{X}, r)$ est alors l'ensemble des points de $\mathcal{X}$ apparaissant dans une composante connexe de $\Gamma_K(\mathcal{X}, r)$.

Remarque Cette définition prolonge la notion usuelle de composante connexe, qu'on retrouve pour $K = 1$: les sommets de $\Gamma_1(\mathcal{X}, r)$ sont les points de $\mathcal{X}$ et ses arêtes sont celles telles que $\|x - x'\| \leq 2r$; les 1-polyèdres sont donc les composantes connexes ordinaires du graphe géométrique $\mathcal{G}(\mathcal{X}, r) = \Gamma_1(\mathcal{X}, r)$. Pour $K = 2$, les sommets de $\Gamma_2(\mathcal{X}, r)$ sont les arêtes de $\check{C}(\mathcal{X}, r)$ et deux arêtes partageant un sommet deviennent adjacentes dès que le triangle qu'elles forment apparaît. Cette façon de connecter entre eux des simplexes (vu comme des cliques sur un graphe) au moyen d'une clique plus grande est appelée *clique percolation* [65]. Pour le cas plus général des complexes simpliciaux, ATKIN avait déjà défini en 1972 ce qu'il nommait la *q-connectivity* [66]. Aujourd'hui, l'usage serait plutôt d'employer le terme (*up*) *face percolation* [67].

DÉFINITION 22 : HGP-CLUSTERER (HGP POUR HYPERGRAPHE-PERCOL')

Pour $K \in \llbracket 1, |\mathcal{X}| \rrbracket$, on définit *Hypergraphe-Percol'* (acronyme : HGP) par

$$\theta_K^{\text{HGP}}(r) \triangleq \left\{ K\text{-polyèdres de } \check{C}(\mathcal{X}, r) \right\}, \quad \text{pour tout } r \geq 0.$$

Autrement dit, HGP-Clusterer observe l'évolution des K -polyèdres au fil de la filtration du complexe de Čech.

Remarque La filtration $r \mapsto \check{C}(\mathcal{X}, r)$ est croissante, donc le graphe $\Gamma_K(\mathcal{X}, r)$ l'est aussi. Les K -polyèdres ne peuvent ainsi que croître et fusionner lorsque r augmente. Pour $K = 1$, on retrouve exactement le Single-Linkage de la partie I.

La FIG. 6.5 illustre la différence de nature entre la connexité ordinaire et la connexité d'ordre supérieur. Dans le cas $K = 2$, ce ne sont plus les points qui percolent directement, mais les arêtes, recollées entre elles par des triangles.




FIGURE 6.5 : Exemple de 2-polyèdres sur la configuration à six points de l'exemple en § 6.1. Au rayon $r' = \frac{2\sqrt{3}}{3}r$, le complexe de Čech contient deux triangles ABC et DEF ainsi que l'arête CD . Les composantes connexes du graphe $\Gamma_2(\mathcal{X}, r')$ donnent alors trois 2-polyèdres, à savoir $\{A, B, C\}$, $\{C, D\}$ et $\{D, E, F\}$. On voit déjà apparaître le phénomène essentiel : pour $K \geq 2$, les polyèdres peuvent se recouvrir.

6.3 K -polyèdres de Čech et amas discrets de forte densité K -NN

Au cours de la première partie, nous avons introduit l'estimateur K -NN de densité des K plus proches voisins (DEF. 7, p. 26) et les amas *discrets* de forte densité qui lui sont associés (DEF. 8, p. 27). Rappelons qu'à rayon $r > 0$ fixé, le niveau supérieur s'écrit

$$L_K(r) \triangleq \{y \in \mathbb{R}^p \mid |\overline{B}(y, r) \cap \mathcal{X}| \geq K\},$$

et que les clusters (continus) sont les composantes connexes de $L_K(r)$. Les clusters *discrets* sont les ensembles de points *couverts* (c'est-à-dire à moins de r) par ces clusters continus (ils participent *via* K -NN à l'existence du cluster continu).

Le résultat central de ce chapitre (THÉORÈME 2 ci-dessous) est le suivant : les K -polyèdres du complexe de Čech identifient exactement les amas discrets de forte densité K -NN.

6.3.1 Les régions témoins d'un simplexe

Pour tout $(K-1)$ -simplexe $\sigma \in \check{C}_{K-1}(\mathcal{X}, r)$, introduisons l'ensemble

$$T_r(\sigma) \triangleq \bigcap_{x \in \sigma} \overline{B}(x, r).$$

Nous l'appellerons la *région témoin* du simplexe σ au niveau r . Par construction, $T_r(\sigma)$ est une intersection finie de boules fermées : c'est donc un compact convexe, en particulier connexe. L'idée de la preuve du THÉORÈME 2 est simple : le niveau supérieur $L_K(r)$ est exactement l'union de ces régions témoins pour tous les $(K-1)$ -simplexes de $\check{C}(\mathcal{X}, r)$, et le graphe $\Gamma_K(\mathcal{X}, r)$ n'est rien d'autre que leur graphe d'intersection.

**THÉORÈME 2 : K -POLYÈDRES DE ČECH $\equiv$ AMAS DISCRETS DE FORTE DENSITÉ
 K -NN**

Soit $\mathcal{X} \subset \mathbb{R}^p$ un nuage fini de taille n , $K \in \llbracket 1, n \rrbracket$ et $r > 0$. Alors les K -polyèdres du complexe de Čech $\check{C}(\mathcal{X}, r)$ sont en correspondance avec les amas discrets de forte densité

$$H_{f_K}^{\text{discrets}}(r).$$

Plus précisément, si C est une composante connexe de

$$L_K(r) = \{y \in \mathbb{R}^p \mid |\overline{B}(y, r) \cap \mathcal{X}| \geq K\}$$

et si P_C désigne le K -polyèdre correspondant, alors

$$P_C = C^{\text{discret}} = \{x \in \mathcal{X} \mid \exists y \in C, \|x - y\| \leq r\}.$$

En particulier,

$$\theta_K^{\text{HGP}}(r) = H_{f_K}^{\text{discrets}}(r) \quad \text{pour tout } r \geq 0,$$

et θ_1^{HGP} coïncide avec le Single-Linkage ($\theta_1^{\text{HGP}} = \theta^\sim$, voir DEF. 11, p. 33).

Preuve du THÉORÈME 2. Le niveau supérieur $L_K(r)$ est recouvert par les régions témoins : on a l'égalité

$$L_K(r) = \bigcup_{\sigma \in \check{C}_{K-1}(\mathcal{X}, r)} T_r(\sigma).$$

En effet, si $y \in L_K(r)$, alors la boule $\overline{B}(y, r)$ contient au moins K points de $\mathcal{X}$. Si l'on en choisit K , on obtient un $(K - 1)$ -simplexe σ tel que $y \in T_r(\sigma)$. Réciproquement, si $y \in T_r(\sigma)$ pour un simplexe σ de cardinal K , alors $\overline{B}(y, r)$ contient les K sommets de σ , donc $y \in L_K(r)$.

Le graphe $\Gamma_K(\mathcal{X}, r)$ est le graphe d'intersection de ce recouvrement. Pour deux $(K - 1)$ -simplexes σ et τ , on a

$$T_r(\sigma) \cap T_r(\tau) \neq \emptyset \iff \bigcap_{x \in \sigma \cup \tau} \overline{B}(x, r) \neq \emptyset \iff \sigma \cup \tau \in \check{C}(\mathcal{X}, r).$$

Ce qui est précisément la règle d'adjacence qui définit $\Gamma_K(\mathcal{X}, r)$.

Comme la famille $\{T_r(\sigma)\}_{\sigma \in \check{C}_{K-1}(\mathcal{X}, r)}$ est finie et formée de compacts connexes, les composantes connexes de son union correspondent exactement aux unions des régions témoins de chacune des composantes connexes du graphe d'intersection. Il existe ainsi une bijection naturelle entre les composantes connexes de $L_K(r)$ et les K -polyèdres de $\check{C}(\mathcal{X}, r)$.

Scrutons à présent le cluster discret associé à une région connexe. Soit C une composante connexe de $L_K(r)$, P_C le K -polyèdre qui lui correspond et C^{discret} le cluster discret associé.

Montrons d'abord l'inclusion $P_C \subseteq C^{\text{discret}}$. Si $x \in P_C$, alors x appartient à un $(K - 1)$ -simplex σ tel que $T_r(\sigma) \subseteq C$. Choisissons $y \in T_r(\sigma)$. Comme x est l'un des sommets de σ , on a $\|x - y\| \leq r$. Le point x est donc couvert par C , d'où $x \in C^{\text{discret}}$.

Réciproquement, soit $x \in C^{\text{discret}}$. Par définition, il existe $y \in C$ tel que $\|x - y\| \leq r$. Puisque $y \in L_K(r)$, l'ensemble $\overline{B}(y, r) \cap \mathcal{X}$ contient au moins K points et il contient en particulier x . On peut donc choisir $K - 1$ autres points $x_2, \dots, x_K \in \overline{B}(y, r) \cap \mathcal{X}$ et former le simplexe

$$\sigma = \{x, x_2, \dots, x_K\} \in \check{C}_{K-1}(\mathcal{X}, r).$$

Comme $y \in T_r(\sigma) \subseteq C$, le simplexe σ appartient à la composante de $\Gamma_K(\mathcal{X}, r)$ associée à C . L'un de ses sommets étant x , on obtient $x \in P_C$.

On a donc bien $P_C = C^{\text{discret}}$, ce qui conclut la preuve. $\square$

Remarques Dans le cas $K = 1$, les régions témoins sont simplement les boules $\overline{B}(x, r)$ centrées sur les données. Le graphe d'intersection redevient alors le graphe géométrique, et le THÉORÈME 2 retrouve exactement la synthèse obtenue à la fin du chapitre 2. $K = 2$

Synthèse Ce chapitre a d'abord permis, au travers d'un exemple, de montrer les limites des algorithmes actuels comme le Robust Single-Linkage et (H)DBSCAN¹⁾ et de donner l'intuition de l'algorithme que nous proposons.

Il généralise ensuite exactement les deux premières vues du Single-Linkage :

1. **Modèle géométrique d'analyse persistante.** Le graphe géométrique est remplacé par le complexe de Čech et la composante connexe par un K -polyèdre.
2. **Modèle statistique de HARTIGAN.** Le THÉORÈME 2 montre que cette construction coïncide niveau par niveau avec les amas discrets de forte densité $H_{f_K}^{\text{discrets}}(r)$.

La définition proposée dans ce chapitre de HGP-Clusterer (DEF. 22, p. 62) reste bien-sûr toute théorique (comme l'était la définition du Single-Linkage en DEF. 11, p. 33, recourant à des graphes géométriques).

Il reste au cours des chapitres suivants à retrouver le troisième volet du triptyque : définir HGP-Clusterer au moyen d'un objet combinatoire (beaucoup) plus mince jouant le rôle de l'**arbre minimum couvrant**. C'est sur cet arbre couvrant généralisé qu'est calculée en pratique la hiérarchie K -NN des amas de forte densité.

¹⁾L'on aurait pu aussi citer les auteurs de [68], qui construisent un graphe géométrique sur les données puis échantillonnent la densité le long de ses arêtes.

Le phénomène de percolation au cœur des performances

Nous avons montré au chapitre précédent que les K -polyèdres donnent exactement, niveau par niveau, les amas discrets de forte densité du modèle de HARTIGAN lorsque la densité est estimée par les K plus proches voisins (DEF. 8 et THÉORÈME 2, p. 64).

La question se pose alors : cela apporte-t-il quelque chose aux performances théoriques de l'algorithme ? La réponse est oui ! et le mécanisme à l'œuvre est la *percolation*.

C'est dans ce chapitre que tout l'intérêt de ce que nous avons appelé l'*analyse persistante* apparaît : faire varier un rayon r pour observer des composantes apparaître, croître puis disparaître en fusionnant, cela revient à observer un phénomène de percolation. Certaines statistiques sur cette composante géante permettent de quantifier ce que l'on peut espérer récupérer d'un amas de forte densité.

L'algorithme de Single-Linkage n'est pas consistant en dimension $p \geq 2$ à cause de ce phénomène de percolation ; il l'est seulement dans le cas très particulier de la dimension $p = 1$, où ce phénomène de seuil n'a pas lieu. En dimension $p \geq 2$, on ne peut plus espérer retrouver intégralement tous les points de deux amas disjoints de forte densité avant que leur cluster associé ne fusionne, seulement une *fraction*. L'importance (asymptotique) de cette fraction se lit dans la fonction de probabilité de percolation

$$\lambda \longmapsto \Theta_{K,p}^{\text{fam}}(\lambda)$$

algo à la place de fam ? ou cc ? où $\text{fam} \in \{\text{core}; \text{dbscan}; \text{poly}\}$ est l'algorithme de clustering hiérarchique considéré (respectivement : Robust Single-Linkage, (H)DBSCAN et HGP-Clusterer).

En partant de la densité de génération f , l'on peut savoir à quoi va ressembler la hiérarchie asymptotique *via* cette probabilité de percolation. Dans le cas où f est constante par morceaux et où deux amas denses sont séparés par un fond moins dense, cette lecture devient très simple grâce à un indice que nous avons baptisé la *vitesse de percolation*. La vitesse de percolation dépend de l'algorithme de clustering hiérarchique fam utilisé ; nous estimons donc cette vitesse en petite dimension pour comparer les K -polyèdres, le

K -Robust Single-Linkage et K -DBSCAN. Avantage certain à nos K -polyèdres ! Enfin, lorsque $K \rightarrow +\infty$, la bonne fenêtre d'intensité normalisée est

$$\mu = K + a\sqrt{K}.$$

Dans cette fenêtre, les niveaux de forte densité K -NN sont remplacés par les excursions

$$E_a = \{x \in \mathbb{R}^p \mid G_p(x) \geq -a\}$$

d'un champ gaussien stationnaire. Cette formulation "à la limite" nous permet de reformuler la différence entre ces méthodes.

Contributions Ce chapitre reprend [33] et le généralise au cadre continu. Nous définissons la probabilité de percolation associée aux K -polyèdres, au K -Robust Single-Linkage et à (H)DBSCAN ; nous montrons comment cette fonction contrôle la fraction asymptotiquement récupérable dans le modèle de HARTIGAN ; nous introduisons une vitesse de percolation que nous mesurons effectivement en petite dimension pour quelques valeurs de K ; enfin, nous identifions la fenêtre gaussienne $\mu = K + a\sqrt{K}$ lorsque $K \rightarrow +\infty$ et nous réduisons le développement de la vitesse de percolation à des constantes de percolation d'excursions gaussiennes. Nous isolons ainsi le problème topologique du haut rappel : obstruction ponctuelle pour les cœurs, obstruction de rayon fini pour (H)DBSCAN, obstruction géométrique de connexion pour les K -polyèdres. Les résultats concordent : les polyèdres percolent plus vite dans les amas denses, et sont donc *fractionnellement* plus consistants.

Remarque Tout au long de ce chapitre, et sauf mention contraire, le rayon

$$r = \frac{1}{2}$$

est fixé à $1/2$; l'analyse persistante pouvant se faire (au choix) au moyen du rayon ou de l'intensité λ , il nous a paru à la fois plus pertinent et plus standard de jouer sur l'intensité, à rayon fixé.

7.1 Introduction à la percolation

Le terme latin *percōlātiō* signifie une « filtration » (GAFFIOT). De l'eau *percole* à travers une roche lorsqu'elle s'y infiltre et la traverse par un réseau géant formé de petits pores. Le modèle mathématique de la percolation fut introduit par BROADBENT & HAMMERSLEY [69] en 1957 pour répondre à la question suivante : à quel moment l'eau peut-elle traverser de part en part une roche ? DUMINIL-COPIN [70] a consacré à l'occasion des soixante ans de l'article de 1957 une longue revue à laquelle nous renvoyons le lecteur.

La percolation est un phénomène qui, sous des contraintes locales, s’observe de façon macroscopique. C’est le moment précis où une macro-structure apparaît. Souvent étudiée de façon discrète sur $\mathbb{Z}^p$ [71, 72], la situation qui nous intéresse ici est celle de la *percolation continue* [4, 5]. Point de départ : les graphes géométriques (au sens de PENROSE [4, 73] ; modèle derrière le Single-Linkage) construits sur des processus ponctuels de POISSONⁱ⁾.

7.1.1 Le cadre mathématique

Soit $\mathcal{X}_\lambda$ un processus ponctuel de POISSON [74] homogène d’intensité $\lambda > 0$ sur $\mathbb{R}^p$. On note

$$\mathcal{X}_\lambda^0 \triangleq \mathcal{X}_\lambda \cup \{0\}$$

le processus de PALMⁱⁱ⁾, c’est-à-dire le processus auquel on a ajouté un point en 0. Cette notation est commode pour mesurer la proportion asymptotique de points appartenant à une composante géante.

DÉFINITION 23 : PROBABILITÉ DE PERCOLATION Θ

Soient $K \in \mathbb{N}^*$ et

$$\text{fam} \in \{\text{poly}, \text{core}, \text{dbscan}, \dots\}$$

une famille de composantes croissante en une variable rayon r .

1. poly désigne les polyèdres.
2. core désigne les cœurs (au sens du Robust Single-Linkage).
3. dbscan désigne les composantes connexes de DBSCAN [48].

Remarque Les *cœurs* du Robust Single-Linkage ne sont pas les mêmes objets que les cœurs au sens usuel de la théorie des graphes, définis comme les plus grands sous-graphes induits pour que chaque sommet ait un degré $\geq K$. Ces cœurs correspondent à une procédure d’élagage récursif sur les nœuds ayant un degré strictement plus petit que K , jusqu’à stabilisation. Tandis que les cœurs au sens du Robust Single-Linkage n’ont qu’un seul tour d’élagage.

On définit la probabilité de percolation par

$$\Theta_{K,p,r}^{\text{fam}}(\lambda) \triangleq \mathbb{P}[0 \in \text{une composante connexe infinie de fam construite sur } \mathcal{X}_\lambda^0].$$

Lorsque la composante infinie existe et est unique, cette quantité est la probabilité (de PALM) qu’un point typique appartienne à la composante géante.

ⁱ⁾Le choix poissonien pour le processus ponctuel vient directement du modèle statistique choisi, où l’on suppose les n données tirées i.i.d. selon f (et de l’approximation POISSON/Binomiale).

ⁱⁱ⁾Rappelons rapidement la théorie de PALM [74] : la loi d’un processus ponctuel de POISSON $\mathcal{X}$ conditionnée à $0 \in \mathcal{X}$ est égale à la loi de $\mathcal{X} \cup \{0\}$. La formule de CAMPBELL–PALM utilisée ci-dessous permet d’intégrer une fonction en utilisant cette loi conditionnelle.

Le changement d'échelle donne, pour tout $r > 0$,

$$\Theta_{K,p,r}^{\text{fam}}(\lambda) = \Theta_{K,p,1/2}^{\text{fam}}(\lambda(2r)^p).$$

Nous travaillerons donc avec $r = 1/2$. Lorsque nous aurons besoin du nombre moyen de points dans une boule de rayon $1/2$, nous utiliserons l'intensité normalisée

$$\mu \triangleq \lambda \omega_p 2^{-p},$$

où $\omega_p \triangleq |B(0, 1)|$ est le volume de la boule unité de $\mathbb{R}^p$.

Les K -polyèdres Rappelons (DEF. 7, p. 26) que les ensembles de niveau de l'estimateur K -NN sont

$$L_K^\lambda \triangleq \{y \in \mathbb{R}^p \mid |\overline{B}(y, 1/2) \cap \mathcal{X}_\lambda^0| \geq K\}.$$

Les K -polyèdres du complexe de Čech correspondent exactement aux composantes connexes de ces ensembles de niveau (THÉORÈME 2, p. 64), puis aux points de $\mathcal{X}_\lambda^0$ situés à distance moins de $1/2$ de ces composantes. Si C_∞ désigne la composante non bornée de L_K^λ , alors

$$\Theta_{K,p,1/2}^{\text{poly}}(\lambda) = \mathbb{P}[0 \in \delta_{1/2}(C_\infty)],$$

avec la convention que l'événement est faux lorsqu'aucune composante non bornée n'existe. Le point important est celui-ci : le point 0 n'a pas besoin d'être lui-même dans L_K^λ ; il suffit qu'il soit *couvert* par la composante de forte densité (au moyen de la dilatation $\delta_{1/2}$).

Les cœurs du K -Robust Single-Linkage Les points cœurs sont

$$\mathcal{X}_\lambda^{\text{core}} \triangleq \{x \in \mathcal{X}_\lambda^0 \mid |\overline{B}(x, 1) \cap \mathcal{X}_\lambda^0| \geq K\} = L_K^\lambda \cap \mathcal{X}_\lambda^0.$$

C'est ensuite sur $\mathcal{X}_\lambda^{\text{core}}$ que le Robust Single-Linkage applique une dilatation $\delta_{1/2}$ et identifie les composantes connexes de

$$\delta_{1/2}(\mathcal{X}_\lambda^{\text{core}}),$$

là où les polyèdres n'appliquent de dilatation qu'une fois les composantes de L_K^λ correctement identifiées.

C'est l'asymétrie identifiée au chapitre précédent : le Robust Single-Linkage impose une contrainte de densité forte pour exister comme sommet, puis utilise une connectivité par arêtes ordinaires.

DBSCAN (H)DBSCAN ajoute aux composantes de cœurs les points accessibles, c'est-à-dire les points situés à distance au plus $1/2$ d'un cœur. Ainsi (H)DBSCAN et le K -Robust Single-Linkage ont la même structure de cœurs et donc le même seuil critique de percolation (voir le PROP. 2 ci-dessous), mais pas la même fonction de rappel au niveau $1 - \varepsilon$: (H)DBSCAN réajoute une partie des points à la frontière que le K -Robust Single-Linkage avait jetés.

PROPOSITION 1 : EXISTENCE D'UN SEUIL CRITIQUE (ET ABSENCE DE RÉGIME FANTÔME)

Pour tout $p \geq 2$, $K \in \mathbb{N}^*$ et

$$\text{fam} \in \{\text{poly}, \text{core}, \text{dbscan}\},$$

la fonction

$$\lambda \mapsto \Theta_{K,p,1/2}^{\text{fam}}(\lambda)$$

est croissante. On définit le seuil critique par

$$\lambda_c^{\text{fam}}(K, p) \triangleq \inf \left\{ \lambda > 0 : \Theta_{K,p,1/2}^{\text{fam}}(\lambda) > 0 \right\}.$$

Alors

$$0 < \lambda_c^{\text{fam}}(K, p) < +\infty,$$

et

$$\Theta_{K,p,1/2}^{\text{fam}}(\lambda) = 0 \quad \text{si } \lambda < \lambda_c^{\text{fam}}(K, p),$$

tandis que

$$\Theta_{K,p,1/2}^{\text{fam}}(\lambda) > 0 \quad \text{si } \lambda > \lambda_c^{\text{fam}}(K, p).$$

De plus, ce seuil coïncide avec le seuil d'existence d'une composante infinie. Soit

$$\lambda_{\exists}^{\text{fam}}(K, p) \triangleq \inf \left\{ \lambda > 0 : \mathbb{P}_{\lambda}(\exists \text{ une composante infinie de type fam}) > 0 \right\},$$

alors

$$\lambda_{\exists}^{\text{fam}}(K, p) = \lambda_c^{\text{fam}}(K, p).$$

(Il n'existe pas d'intervalle non vide d'intensités λ pour lesquelles il existerait presque-sûrement une composante infinie qui soit de taille négligeable.)

Preuve de PROP. 1. La croissance s'obtient par couplage de processus de POISSON. Si $\lambda' \geq \lambda$, on peut construire

$$\mathcal{X}_{\lambda'} = \mathcal{X}_{\lambda} \cup \mathcal{X}_{\lambda' - \lambda},$$

où les deux processus du membre de droite sont indépendants. Ajouter des points ne supprime ni simplexe de Čech, ni point cœur, ni point accessible. Les composantes considérées ne peuvent donc que croître ou fusionner. Ainsi $\lambda \mapsto \Theta_{K,p,1/2}^{\text{fam}}(\lambda)$ est croissante.

Pour une configuration (localement finie) ξ , notons $\mathcal{I}_{\infty}^{\text{fam}}(\xi)$ l'ensemble des points de ξ rattachés à une composante infinie du modèle considéré. Plus précisément :

- pour **core**, ce sont les points appartenant à une composante infinie du graphe des cœurs;

- pour dbscan, ce sont les points appartenant à une composante DBSCAN infinie ;
- pour poly, un point $x \in \xi$ est dans $\mathcal{I}_\infty^{\text{poly}}(\xi)$ s'il existe une composante non bornée C de

$$L_K(\xi) \triangleq \{y \in \mathbb{R}^p \mid |B(y, 1/2) \cap \xi| \geq K\}$$

telle que $d(x, C) \leq 1/2$.

Avec cette notation,

$$\Theta_{K,p,1/2}^{\text{fam}}(\lambda) = \mathbb{P}\left(0 \in \mathcal{I}_\infty^{\text{fam}}(\mathcal{X}_\lambda \cup \{0\})\right).$$

Pour le cube unité $Q = [0, 1]^p$, posons

$$N_\infty^{\text{fam}}(Q) \triangleq |\mathcal{I}_\infty^{\text{fam}}(\mathcal{X}_\lambda) \cap Q|.$$

La formule de CAMPBELL–PALM donne

$$\mathbb{E}[N_\infty^{\text{fam}}(Q)] = \lambda|Q| \Theta_{K,p,1/2}^{\text{fam}}(\lambda) = \lambda \Theta_{K,p,1/2}^{\text{fam}}(\lambda).$$

Si $\Theta_{K,p,1/2}^{\text{fam}}(\lambda) = 0$, alors $N_\infty^{\text{fam}}(z + Q) = 0$ presque sûrement pour tout $z \in \mathbb{Z}^p$. Par réunion dénombrable, il n'existe donc presque-sûrement aucun point rattaché à une composante infinie, et donc pas de composante infinie.

Réciproquement, si une composante infinie existe avec probabilité strictement positive, alors elle fournit au moins un point de $\mathcal{I}_\infty^{\text{fam}}(\mathcal{X}_\lambda)$ dans l'un des cubes $z + Q$, $z \in \mathbb{Z}^p$. Par stationnarité, et de nouveau par la formule de CAMPBELL–PALM, on obtient

$$\Theta_{K,p,1/2}^{\text{fam}}(\lambda) > 0.$$

Ainsi, pour tout $\lambda > 0$,

$$\mathbb{P}_\lambda(\exists \text{ une composante infinie de type fam}) > 0 \iff \Theta_{K,p,1/2}^{\text{fam}}(\lambda) > 0.$$

Comme l'événement d'existence d'une composante infinie est invariant par translation, il est de probabilité 0 ou 1 par ergodicité du processus de POISSON et

$$\lambda_\exists^{\text{fam}}(K, p) = \lambda_c^{\text{fam}}(K, p).$$

Montrons à présent que ces seuils sont non dégénérés (dans $]0; +\infty[$). La stricte positivité vient de la comparaison avec le modèle booléen classique. En effet, dans les trois cas considérés, l'existence d'une composante infinie de type fam entraîne l'existence d'une composante infinie dans le modèle booléen. Par conséquent, pour $p \geq 2$

$$\lambda_c^{\text{fam}}(K, p) \geq \lambda_c^{\text{bool}}(p),$$

et l'on conclue grâce à l'inégalité stricte $\lambda_c^{\text{bool}}(p) > 0$ (voir par exemple [4, 5]).

La finitude du seuil s'obtient par domination d'une percolation de sites [72] sur une grille discrète $a\mathbb{Z}^p$. On pave $\mathbb{R}^p$ par des cubes de côté a suffisamment petit et l'on déclare un cube "ouvert" s'il est inclus dans L_K^λ . En faisant tendre $\lambda \rightarrow +\infty$, la probabilité d'ouverture dépasse le seuil critique de percolation de sites sur $\mathbb{Z}^p$, les sites ouverts percolent, et donc L_K^λ aussi.

Remarque Dans le cas des K -polyèdres, cette transition est même *abrupte* (*sharp* en anglais) au sens de la percolation : il y a décroissance exponentielle des tailles de composantes en régime sous-critique (cf. [75], voir aussi [67]). $\square$

PROPOSITION 2 : DBSCAN ET K -ROBUST SINGLE-LINKAGE ONT LE MÊME SEUIL CRITIQUE

Pour tout $K \geq 1$ et $p \geq 2$,

$$\lambda_c^{\text{dbscan}}(K, p) = \lambda_c^{\text{core}}(K, p),$$

où les deux seuils sont ceux définis en PROP. 1. De plus, pour tout $\lambda > 0$,

$$\Theta_{K,p,1/2}^{\text{dbscan}}(\lambda) \geq \Theta_{K,p,1/2}^{\text{core}}(\lambda).$$

Preuve. Une composante DBSCAN est obtenue à partir d’une composante de cœurs en lui ajoutant les points situés à moins de $1/2$ d’un cœur. Si la composante de cœurs est finie, sa dilatation contient presque sûrement un nombre fini de points du processus de POISSON. Une composante DBSCAN est donc infinie si et seulement si la composante de cœurs dont elle provient est infinie. Les deux modèles ont donc le même seuil critique (rappelons qu’en PROP. 1, nous avons défini le seuil critique par la condition $\Theta > 0$ et montré qu’il était le même que celui de l’existence d’une composante non bornée).

L’inégalité sur les fonctions de percolation est claire : tout point cœur appartenant à une composante K -Robust appartient aussi à la composante DBSCAN correspondante ; DBSCAN peut seulement ajouter des points accessibles. $\square$

7.2 Percolation et non-consistance

Le lien entre percolation et clustering apparaît déjà chez HARTIGAN [3], puis de manière plus explicite dans les travaux de PENROSE sur le Single-Linkage et la percolation continue [4, 73].

Le mécanisme est simple (voir la FIG. 7.1 pour une illustration) : deux amas de forte densité vont nécessairement fusionner (du fait de la composante géante qui apparaît dans la vallée de faible densité les séparant) avant d’avoir pu “récupérer” tous les points des deux amas.

7.2.1 Lecture générale avec la densité f

Soit $\mathcal{X}$ un n -échantillon i.i.d. de densité f dans $\mathbb{R}^p$, et soit $r_n \rightarrow 0$ une échelle locale. Par rapport à notre normalisation $r = 1/2$, autour d’un point x où f est régulière, le nuage vu à l’échelle r_n ressemble à un processus de POISSON homogène d’intensité

$$\lambda_n(x) \simeq n(2r_n)^p f(x),$$




FIGURE 7.1 : Inconsistance du Single-Linkage en dimension $p \geq 2$. Les deux amas de forte densité (carrés) sont fusionnés (droite, niveau r_2) avant que tous les points en faisant partie soient récupérés par les deux composantes géantes (gauche, niveau r_1).

Autrement dit, la fonction

$$\Theta_{K,p,1/2}^{\text{fam}}(\lambda_n(x))$$

donne la probabilité asymptotique qu'un point situé dans une région de densité $f(x)$ appartienne à la composante géante observée à cette échelle.

Pour une densité générale, la séparation entre deux amas dépend alors de la géométrie des cols et des vallées de f . Soit C un amas de forte densité, c'est-à-dire une composante connexe de $H_f(\lambda)$ et $\tau < \lambda$ une densité plus faible pour laquelle une vallée de plus faible densité, si elle devenait supercritique et percolait, ferait "disparaître" C par fusion. Juste avant cette fusion, la proportion récupérable de l'amas C est heuristiquement donnée par la moyenne pondérée

$$\frac{\int_C \Theta_{K,p,1/2}^{\text{fam}} \left(\lambda_c^{\text{fam}}(K, p) \frac{f(x)}{\tau} \right) f(x) dx}{\int_C f(x) dx}. \quad (7.1)$$

Le cas constant par morceaux ci-dessous est la version plus lisible de cette idée et qui permet de calculer un indice concret, la *vitesse de percolation* (DEF. 24, p. 76).

7.2.2 Le cas simple des niveaux de densité constants

Considérons deux domaines $A, B \subset \mathbb{R}^p$ compacts convexes de mesures de LEBESGUE strictement positives, séparés par un domaine de fond $F \supset A \cup B$ contenant un corridor macroscopique (la dilatation d'un chemin lisse) reliant A à B . Par souci de simplicité du modèle, on supposera que les données sont tirées selon une densité constante par morceaux :

$$f(x) = \rho \mathbf{1}_{A \cup B}(x) + \rho_0 \mathbf{1}_F(x),$$

où $\rho, \rho_0 > 0$. Posons

$$\rho_1 \triangleq \rho + \rho_0.$$

Les ensembles A et B ont donc densité $\rho_1 > \rho_0$; ce sont des amas de forte densité par rapport à la vallée de faible densité les reliant, à savoir $F \setminus (A \cup B)$. Voir la FIG. 7.1 pour une illustration : A et B sont les deux carrés inclus dans un long rectangle, le fond F .

PROPOSITION 3 : FUSION ASYMPTOTIQUE LORSQUE LE FOND DEVIENT SUPER-CRITIQUE

Soit fam une famille de composantes parmi celles considérées ci-dessus, et soit $\lambda_c^{\text{fam}}(K, p)$ son seuil critique. Supposons que le rayon r_n soit choisi de sorte que le fond soit strictement supercritique :

$$n(2r_n)^p \rho_0 > \lambda_c^{\text{fam}}(K, p) + \eta$$

pour un $\eta > 0$ fixé. Alors, les deux composantes géantes présentes dans A et B fusionnent avec probabilité tendant vers 1 lorsque $n \rightarrow +\infty$.

Preuve. Après changement d'échelle par r_n , le corridor contenu dans F devient une boîte dont les dimensions tendent vers l'infini. Dans cette boîte, le processus de points converge localement vers un processus de POISSON homogène d'intensité normalisée strictement supérieure au seuil critique. Les résultats standards de percolation continue supercritique donnent alors l'existence, avec probabilité tendant vers 1, d'une composante traversante reliant les deux faces opposées du corridor [4, 5].

□

THÉORÈME 3 : FRACTION RÉCUPÉRABLE AVANT FUSION PARASITE

Soit fam une méthode de clustering persistant, de probabilité de percolation Θ^{fam} et de seuil critique λ_c^{fam} . Dans le modèle à deux densités ci-dessus, la fraction asymptotiquement récupérable dans A et B juste avant la percolation du fond est

$$\Theta_{K,p,1/2}^{\text{fam}} \left(\lambda_c^{\text{fam}}(K, p) \frac{\rho_1}{\rho_0} \right).$$

En particulier, un rappel asymptotique d'au moins $1 - \varepsilon$ avant fusion parasite est possible si et seulement si

$$\frac{\rho_0}{\rho_1} \leq \frac{\lambda_c^{\text{fam}}(K, p)}{\lambda_{1-\varepsilon}^{\text{fam}}(K, p)},$$

où

$$\lambda_{1-\varepsilon}^{\text{fam}}(K, p) \triangleq \inf \left\{ \lambda > 0 : \Theta_{K,p,1/2}^{\text{fam}}(\lambda) \geq 1 - \varepsilon \right\}.$$

Preuve du THÉOREME 3. À la limite où le fond devient critique (lorsque son intensité normalisée tend vers $\lambda_c^{\text{fam}}(K, p)$ par valeurs supérieures), l'intensité normalisée dans F vaut $\lambda_c^{\text{fam}}(K, p)$. À cette même échelle, l'intensité normalisée dans A et B vaut

$$\lambda_c^{\text{fam}}(K, p) \frac{\rho_1}{\rho_0}.$$

La proportion de points appartenant à la composante géante dans un domaine homogène de cette intensité converge vers la probabilité de PALM correspondante (en supposant la continuité en ce point de la fonction), c'est-à-dire vers

$$\Theta_{K,p,1/2}^{\text{fam}} \left(\lambda_c^{\text{fam}}(K, p) \frac{\rho_1}{\rho_0} \right).$$

Pour que cette quantité soit au moins $1 - \varepsilon$, il faut et il suffit que

$$\frac{\rho_0}{\rho_1} \leq \frac{\lambda_c^{\text{fam}}(K, p)}{\lambda_{1-\varepsilon}^{\text{fam}}(K, p)},$$

ce qui donne exactement l'inégalité annoncée. □

7.3 La vitesse de percolation

Le THÉOREME 3 précédent motive la définition suivante.

DÉFINITION 24 : VITESSE CRITIQUE DE PERCOLATION

Pour une famille fam , on définit le quantile de rappel au niveau $\alpha \in [0; 1]$

$$\lambda_\alpha^{\text{fam}}(K, p) \triangleq \inf \left\{ \lambda > 0 \mid \Theta_{K,p,1/2}^{\text{fam}}(\lambda) \geq \alpha \right\}.$$

La *vitesse critique de percolation* est le rapport

$$v_{\text{crit},K,p}^{\text{fam}}(\varepsilon) \triangleq \frac{\lambda_c^{\text{fam}}(K, p)}{\lambda_{1-\varepsilon}^{\text{fam}}(K, p)}.$$

Remarque Plus cette quantité est proche de 1, plus la méthode récupère rapidement une grande fraction d'un amas dense avant que le fond ne percole. C'est donc un indice de performance directement lisible sur la courbe Θ .

Le seuil critique λ_c est en pratique difficile à estimer ; aussi l'avions-nous remplacé dans [33] par le quantile de niveau ε :

$$v_{K,p}^{\text{fam}}(\varepsilon) \triangleq \frac{\lambda_\varepsilon^{\text{fam}}(K, p)}{\lambda_{1-\varepsilon}^{\text{fam}}(K, p)}. \tag{7.2}$$

Remarque Si l'on préfère raisonner en rayons plutôt qu'en intensités, alors il suffit de remplacer dans la formule les quantiles des intensités par ceux des rayons

$$\frac{\lambda_\varepsilon^{\text{fam}}(K, p)}{\lambda_{1-\varepsilon}^{\text{fam}}(K, p)} = \left(\frac{r_\varepsilon^{\text{fam}}(K, p)}{r_{1-\varepsilon}^{\text{fam}}(K, p)} \right)^p.$$

7.4 Comparaison empirique entre K -polyèdres, K -Robuſt Single-Linkage et DBSCAN

Les expériences de ce chapitre suivent le protocole suivant :

1. Fixer K_list une liste de K possibles, la dimension $p \in \mathbb{N}^*$, $T \leftarrow 100$ le nombre de tests, $n \leftarrow 100\,000$ le nombre de points ($n \leftarrow 10\,000$ en dimension $p = 4$) et $\varepsilon \leftarrow 3\%$.
2. Pour $t \in \{1; \dots; T\}$:
 - (a) L'on génère $\mathcal{X}$ contenant n points uniformément tirés dans l'hypercube $[0, n^{1/p}]^p$ (approximation POISSON/binomiale).
 - (b) Pour $\text{fam} \in \{\text{poly}, \text{core}, \text{dbscan}\}$, générer de façon efficace (voir chapitre suivant pour les K -polyèdres) la hiérarchie produite par fam sur $\mathcal{X}$ en repérant les rayons de fusion et la proportion de points se trouvant alors dans la plus grande composante connexe.
3. En déduire un estimateur $\hat{\Theta}^{\text{fam}}$ de Θ^{fam} ainsi que de la vitesse de percolation

$$\hat{v}^{\text{fam}} \triangleq \frac{\hat{\lambda}_\varepsilon^{\text{fam}}}{\hat{\lambda}_{1-\varepsilon}^{\text{fam}}}.$$

Remarques

1. Lorsque $K = 1$, les trois familles coïncident : les 1-polyèdres sont les composantes du graphe géométrique, les points cœurs du 1-Robuſt Single-Linkage sont tous les points qui apparaissent dans le modèle booléen, et DBSCAN ne fait qu'ajouter une frontière déjà présente. Les différences ne commencent donc qu'à partir de $K \geq 2$.
2. Pour $K = 2$, le K -Robuſt Single-Linkage retire les feuilles des graphes géométriques mais n'identifie pas pour autant de structures plus fines. Cet élagage non nécessaire entraîne comme nous allons le voir des résultats pires que ceux pour $K = 1$. DBSCAN réajoute ensuite ces points accessibles (qui correspondent exactement aux feuilles élaguées); $K = 2$ donne donc les mêmes résultats pour DBSCAN que $K = 1$.

Les résultats des estimations de $\hat{\Theta}^{\text{fam}}$ (pour $p = 2$, $K \in \{1; 2; 3; 4; 5\}$) sont montrés en FIG. 7.2 pour $\text{fam} = \text{poly}$, en FIG. 7.3 pour $\text{fam} = \text{core}$ et en FIG. 7.4 pour $\text{fam} = \text{dbscan}$.

Pour le calcul des vitesses de percolation $\hat{v}^{\text{fam}}$ (en dimension $p = 2$, $p = 3$ et $p = 4$), se reporter au TAB. 7.1.




FIGURE 7.2 : Estimation de la fonction de probabilité $\lambda \mapsto \hat{\Theta}_{K,2}^{\text{poly}}(\lambda)$ pour $K \in \{1, 2, 3, 4, 5\}$ des K -polyèdres en dimension 2. À noter que pour $K = 1$, le seuil critique en 2D est $\lambda_c \approx 1.44$ [76, 77].




FIGURE 7.3 : Estimation de la fonction de probabilité $\lambda \mapsto \hat{\Theta}_{K,2}^{\text{core}}(\lambda)$ pour $K \in \{1, 2, 3, 4, 5\}$ des K -composantes du Robust Single-Linkage en dimension 2.

Remarque Ces simulations, quoique faisant intervenir $n = 100\,000$ points, montrent des fonctions $\lambda \mapsto \Theta(\lambda)$ “démarrant” au-dessus de 0 avec une pente nulle. Pourtant, au moins pour le Single-Linkage ($K = 1$), il a été montré que la pente au niveau du seuil λ_c est strictement positive [78-80] :

$$\exists C > 0, \forall \lambda \geq \lambda_c, \quad \Theta(\lambda) \geq C (\lambda - \lambda_c).$$

Les K -polyèdres améliorent systématiquement la vitesse de percolation dès que $K \geq 2$ et surpassent les K -cœurs du Robust Single-Linkage et les K -composantes DBSCAN.




FIGURE 7.4 : Estimation de la fonction de probabilité $\lambda \mapsto \hat{\Theta}_{K,2}^{\text{dbscan}}(\lambda)$ pour $K \in \{1, 2, 3, 4, 5\}$ des K -composantes de DBSCAN en dimension 2.

TABLE 7.1 – Vitesse de percolation v en fonction de K pour les dimensions $p = 2$, $p = 3$ et $p = 4$. Les meilleurs résultats sont indiqués en gras.

K	$p = 2$			$p = 3$			$p = 4$		
	HGP	Robuſt SL	DBSCAN	HGP	Robuſt SL	DBSCAN	HGP	Robuſt SL	DBSCAN
1	0,735	0,735	0,735	0,563	0,563	0,563	0,362	0,362	0,362
2	0,779	0,689	0,735	0,646	0,462	0,563	0,451	0,271	0,362
3	0,800	0,632	0,753	0,690	0,412	0,582	0,497	0,247	0,378
4	0,817	0,598	0,767	0,714	0,400	0,605	0,500	0,246	0,409
5	0,826	0,584	0,779	0,732	0,399	0,625	0,534	0,236	0,415

L'on s'attendait à ce que le K -Robuſt Single-Linkage soit moins bon que DBSCAN et que, pour $K = 2$, il donne de moins bons résultats que $K = 1$. En fait, c'est pis que cela : pour $K \geq 3$, le Robuſt Single-Linkage continue de dégrader considérablement les résultats par rapport au Single-Linkage. La raison à cela se lit en FIG. 7.3 : l'algorithme peine à rassembler les derniers points ; sa probabilité de percolation Θ^{core} converge trop lentement vers 1. L'erreur de ne pas prendre en compte les points à la frontière des amas est rédhibitoire.

DBSCAN répare partiellement cette erreur en réintégrant les points accessibles ; ses résultats sont donc meilleurs que ceux du Robuſt Single-Linkage (et progressent à partir de $K \geq 3$), ils restent toutefois bien inférieurs à ceux des K -polyèdres ; la connectivité reste celle des cœurs, qui percolent bien trop vite ($\hat{\lambda}_c^{\text{core}} < \hat{\lambda}_c^{\text{poly}}$) par rapport aux véritables niveaux L_K^λ .

7.5 Et lorsque $K \rightarrow +\infty$?

À K et ε (rappel, ou *recall* en anglais) fixés, il y a peu d'espoir d'obtenir des résultats comparatifs entre les vitesses de percolation des différents algorithmes $\text{fam} \in \{\text{poly}, \text{dbscan}, \text{core}\}$ autrement qu'avec des simulations sur de grands nuages de points.

Il en va autrement lorsque $K \rightarrow +\infty$.

7.5.1 Le champ gaussien limite

Commençons par travailler en intensité normalisée

$$\mu \triangleq \lambda |B(0; 1/2)| = \lambda 2^{-p} \omega_p.$$

Ainsi, pour $x \in \mathbb{R}^p$, si l'on pose

$$N_\mu(x) \triangleq |\mathcal{X}_{\mu/|B(0,1/2)|} \cap B(x, 1/2)|$$

le nombre de voisins de x à intensité (normalisée) μ , alors $N_\mu(x)$ suit une loi de POISSON de paramètre μ , et notamment

$$\mathbb{E}[N_\mu(x)] = \mu, \quad \mathbb{V}[N_\mu(x)] = \mu.$$

De plus, les vitesses étant des rapports d'intensités, passer de λ à μ ne change rien :

$$\frac{\lambda_c}{\lambda_{1-\varepsilon}} = \frac{\mu_c}{\mu_{1-\varepsilon}}.$$

On introduit le *champ de comptage* (centré réduit)

$$Z_\mu(x) \triangleq \frac{N_\mu(x) - \mu}{\sqrt{\mu}}.$$

PROPOSITION 4 : THÉORÈME CENTRAL LIMITE LOCAL DU CHAMP DE COMPTAGE

Pour tous $x_1, \dots, x_m \in \mathbb{R}^p$, le vecteur

$$(Z_\mu(x_1), \dots, Z_\mu(x_m))$$

converge en loi, lorsque $\mu \rightarrow +\infty$, vers un vecteur gaussien centré

$$(G_p(x_1), \dots, G_p(x_m))$$

de covariance

$$\mathbb{E}[G_p(x_i)G_p(x_j)] = \rho_p(x_i - x_j) \triangleq \frac{|B(x_i, 1/2) \cap B(x_j, 1/2)|}{|B(0, 1/2)|}.$$

G_p désigne le champ gaussien stationnaire centré de covariance ρ_p . En particulier,

$$\rho_p(z) = 0 \quad \text{dès que } \|z\| \geq 1.$$

Preuve. Notons

$$B_i \triangleq B(x_i, 1/2), \quad i \in \{1, \dots, m\}.$$

On partitionne $\bigcup_i B_i$ en les atomes

$$A_J \triangleq \left(\bigcap_{j \in J} B_j \right) \setminus \left(\bigcup_{j \notin J} B_j \right), \quad \emptyset \neq J \subseteq \{1, \dots, m\}.$$

(Un point $x \in \bigcup_i B_i$ apparaissant *exactement* dans les boules B_j pour $j \in J \subseteq \{1; \dots; m\}$ sera placé dans l'ensemble A_J .) Les variables

$$Y_J \triangleq \mathcal{X}_{\mu/|B(0,1/2)|}(A_J)$$

sont des POISSON indépendantes qui permettent d'écrire (en les combinant linéairement) le vecteur

$$(Z_\mu(x_1), \dots, Z_\mu(x_m)).$$

L'approximation POISSON–Normale permet de conclure quant à la convergence. La covariance, elle, vaut : **MEtre trois lignes de calcul**

$$\begin{aligned} \text{Cov}(Z_\mu(x_i), Z_\mu(x_j)) &= \frac{1}{\mu} \text{Cov}(N_\mu(x_i), N_\mu(x_j)) \\ &= \frac{1}{\mu} \mathbb{V}(\mathcal{X}_{\mu/|B(0,1/2)|}(B_i \cap B_j)) \\ &= \frac{|B_i \cap B_j|}{|B(0, 1/2)|}. \end{aligned}$$

□

Les ensembles K -NN sont définis par $N_\mu(x) \geq K$. La transition se produit quand μ est proche de K , avec des fluctuations d'ordre $\sqrt{K}$. La fenêtre d'intérêt pour μ est donc

$$\mu = K + a\sqrt{K}.$$

Pour finir, en remarquant que

$$\{x \mid N_\mu(x) \geq K\} = \left\{ x \mid Z_\mu(x) \geq \frac{K - \mu}{\sqrt{\mu}} \right\},$$

et avec la convergence $\frac{K - \mu}{\sqrt{\mu}} \rightarrow -a$, les amas de forte densité K -NN (pour le rayon $r = 1/2$ fixé) peuvent se modéliser (à la limite) par l'ensemble d'excursion gaussien [81, 82]

$$E_a \triangleq \{x \in \mathbb{R}^p \mid G_p(x) \geq -a\}.$$

L'évaluation de la vitesse de percolation se réduit dès lors à l'étude de ces excursions.

7.5.2 Comportements sur le champ gaussien de HGP-Clusterer, (H)DBSCAN et Robust Single-Linkage

À la limite, la différence de résultats entre les algorithmes s'explique formellement par la manière dont chacun interagit avec l'excursion E_a .

Pour rappel, $\delta_r(A) \triangleq \{x \in \mathbb{R}^p \mid d(x, A) \leq r\}$ désigne la *dilatation* d'un ensemble A , et $\mathcal{C}_\infty(\cdot)$ la réunion de ses composantes connexes non bornées.

En s'appuyant sur PROP. 5 (admis) ci-dessous, la récupération d'un point typique (l'origine 0) s'écrit asymptotiquement :

- **Cœurs (Robust Single-Linkage).** L'origine 0 doit appartenir à l'excursion E_a (pour faire partie d'un cœur) *et*, une fois dilatés les cœurs de $r = 1/2$ (liaison par arête), 0 doit se trouver dans une composante géante :

$$A_a^{\text{core}} = \{0 \in E_a \cap \mathcal{C}_\infty(\delta_{1/2}(E_a))\}.$$

- **DBSCAN.** L'appartenance à l'excursion E_a stricte n'est plus exigée ; il suffit d'être couvert par la composante géante *dilatée* :

$$A_a^{\text{dbscan}} = \{0 \in \mathcal{C}_\infty(\delta_{1/2}(E_a))\}.$$

- **HGP-Clusterer.** Il n'y a pas de dilatation préalable à l'identification d'une composante géante de l'excursion E_a . C'est l'origine 0 qui est dilatée en une boule, $B(0; 1/2) = \delta_{1/2}(0)$, et l'on regarde si cette boule intersecte $\mathcal{C}_\infty(E_a)$, cela revient à observer l'événement :

$$A_a^{\text{poly}} = \{0 \in \delta_{1/2}(\mathcal{C}_\infty(E_a))\}.$$

Enlever le cadre

PROPOSITION 5 : LEMME DE STABILITÉ DE LA FENÊTRE GAUSSIENNE

Soient $p \geq 2$ et

$$\text{fam} \in \{\text{poly}, \text{core}, \text{dbscan}\}.$$

On pose

$$\mu_K(a) := K + a\sqrt{K}, \quad \lambda_K(a) \triangleq \frac{\mu_K(a)}{|B(0; 1/2)|}.$$

Soit

$$F_K^{\text{fam}}(a) \triangleq \Theta_{K,p,1/2}^{\text{fam}} \left(\frac{K + a\sqrt{K}}{|B(0; 1/2)|} \right).$$

On note G_p le champ gaussien stationnaire centré de covariance

$$\mathbb{E}[G_p(x)G_p(y)] = \frac{|B(x; 1/2) \cap B(y; 1/2)|}{|B(0; 1/2)|},$$

et

$$E_a \triangleq \{x \in \mathbb{R}^p \mid G_p(x) \geq -a\}.$$

Enfin, on définit

$$A_a^{\text{core}} \triangleq \{0 \in E_a \cap C_\infty(\delta_{1/2}(E_a))\},$$

$$A_a^{\text{dbscan}} \triangleq \{0 \in C_\infty(\delta_{1/2}(E_a))\},$$

et

$$A_a^{\text{poly}} \triangleq \{0 \in \delta_{1/2}(C_\infty(E_a))\}.$$

Alors, en tout point de continuité de

$$a \mapsto \mathbb{P}(A_a^{\text{fam}}),$$

on a

$$\Theta_{K,p,1/2}^{\text{fam}} \left(\frac{K + a\sqrt{K}}{|B(0; 1/2)|} \right) \xrightarrow{K \rightarrow +\infty} \mathbb{P}(A_a^{\text{fam}}).$$

Preuve. Admis. □

L'on voit avec cette formulation réapparaître les deux défauts du Robust Single-Linkage par rapport à HGP-Clusterer :

1. La dilatation $\delta_{1/2}$ est appliquée avant l'identification des composantes géantes $\mathcal{C}_\infty$, provoquant une percolation précoce ($a_c^{\text{core}} = a_c^{\text{dbscan}} \leq a_c^{\text{poly}}$).
2. La condition d'être un point cœur, c'est-à-dire (en terme de champ gaussien) d'appartenir à l'excursion E_a est beaucoup trop restrictive.

DBSCAN évite l'erreur du second point (en permettant à un point d'être seulement *accessible*), mais pas du premier : la percolation de ses composantes a lieu trop tôt (comparer FIG. 7.2 avec les FIG. 7.3 & 7.4).

7.5.3 Et à haut rappel $\varepsilon \rightarrow 0$

À rappel $\varepsilon > 0$ fixé, il est assez aisé de voir [83] que quel que soit l'algorithme $\text{fam} \in \{\text{poly}; \text{dbscan}; \text{poly}\}$, la vitesse de percolation est asymptotiquement

$$1 - \mathcal{O}\left(\frac{1}{\sqrt{K}}\right).$$

Cela vient de la nature du processus ponctuel choisi pour $\mathcal{X}$, savoir : un processus de POISSON, dont les variations sont telles qu'il nous suffit de l'observer sur une fenêtre d'intensité (normalisée)

$$\mu = K + a\sqrt{K}.$$

Dans le cas d'un rappel asymptotiquement parfait $\varepsilon \rightarrow 0$, c'est-à-dire que la fenêtre se déplace $a \rightarrow \infty$ (et $a = o(\sqrt{K})$), on voit alors assez nettement quelles sont les obstructions aux événements A_a^{core} et A_a^{poly} :

1. **Cœurs (Robust Single-Linkage).** Dans $\overline{A_a^{\text{core}}}$, c'est l'événement $0 \notin E_a$ qui devient prépondérantⁱ⁾.
2. **Polyèdres (HGP-Clusterer).** L'obstruction est beaucoup plus coûteuse : il faut que *toute* la boule $B(0; 1/2)$ (et non simplement le point à l'origine) soit hors de la composante infinie de l'excursion $\mathcal{C}_\infty(E_a)$. (L'on conjecture que le coût de la réduction de l'excursion à sa composante infinie est négligeable devant celui de la dilatation $\delta_{1/2}$ appliquée.)

Montrer rigoureusement ces résultats nous emmènerait trop loin ; la percolation étant une digression et non le cœur de ce travail.

Sous réserve toutefois que ces intuitions soient justes, les quantiles (asymptotiques) de rappel $a_{1-\varepsilon}^{\text{fam}}(p)$ seraient alors donnés par

$$a_{1-\varepsilon}^{\text{poly}}(p) \sim \sqrt{2U_p \log(1/\varepsilon)} \quad < \quad a_{1-\varepsilon}^{\text{core}}(p) \sim \sqrt{2 \log(1/\varepsilon)}$$

où $U_p < 1$ est le coût de lié à l'obstruction

$$\forall x \in B(0, 1/2), \quad G_p(x) \geq -1.$$

Ajouté à cela que $a_c^{\text{poly}} \geq a_c^{\text{core}}$ et vous obtenez une meilleure vitesse de percolation asymptotique pour HGP-Clusterer.

Remarque Ces résultats, qui ne sont qu'à l'ébauche d'intuitions, mériteraient pour être rigoureusement développés d'introduire l'espace de CAMERON–MARTIN [86, 87], qui est l'espace de HILBERT à noyau reproduisant [88] (RKHS pour *Reproducible Kernel HILBERT Space* en anglais) adapté à l'étude des processus gaussiens. Pour ce qui est du coût de l'obstruction, c'est une conséquence du théorème de SCHILDER [89, 90].

Synthèse Ce chapitre permet de quantifier les défauts du Single-Linkage et de ses robustifications standards. En dimension $p \geq 2$, le problème n'est pas seulement que les graphes chaînent ; c'est qu'ils percolent avant d'avoir bien récupéré tous les points des amas de forte densité.

La fonction de probabilité de percolation $\Theta_{K,p,r}^{\text{fam}}$ contient alors l'information qui nous intéresse : connaissant la densité f , on peut lire localement la fraction asymptotiquement

ⁱ⁾Cette assertion – à elle seule !.. – mériterait d'être plus amplement justifiée ; c'est l'analogue continu des résultats de PENROSE indiquant qu'en régime supercritique, lorsque $\lambda \rightarrow +\infty$, seules des composantes de taille plus en plus petites ne sont pas rattachées à la composante géante [4, 84, 85].

recupérable à partir de l'intensité effective $n(2r_n)^p f(x)$. Dans le cas élémentaire de deux niveaux de densité, la fraction récupérable avant fusion parasite vaut

$$\Theta_{K,p,1/2}^{\text{fam}} \left(\lambda_c^{\text{fam}}(K, p) \frac{\rho_1}{\rho_0} \right).$$

Formule qui nous a poussé à définir la vitesse de percolation

$$v_{\text{crit}}^{\text{fam}}(\varepsilon) = \frac{\lambda_c^{\text{fam}}}{\lambda_{1-\varepsilon}^{\text{fam}}},$$

un indice pratique pour mesurer la performance de l'algorithme : plus il est proche de 1, plus l'algorithme récupère vite un amas dense avant que le fond ne percole.

Les simulations en petites dimensions montrent que HGP-Clusterer (c'est-à-dire notre algorithme identifiant les K -polyèdres) possède une meilleure vitesse de percolation que le K -Robust Single-Linkage et K -DBSCAN. L'analyse lorsque $K \rightarrow +\infty$ explique ce phénomène : les niveaux K -NN convergent vers des excursions d'un champ gaussien, et l'échec des polyèdres exige un séparateur spatial autour d'une boule, là où l'échec des cœurs peut déjà venir d'une fluctuation ponctuelle. C'est la conséquence de notre idée de départ : il ne faut pas seulement demander aux points d'être denses ; il faut connecter correctement les régions où la densité K -NN est forte.

À la recherche de la généralisation de l'arbre minimum couvrant

Au cours du chapitre 6 précédent, nous avons montré que les K -polyèdres de Čech constituent la bonne généralisation du Single-Linkage : niveau par niveau, la hiérarchie qu'ils produisent coïncide avec les amas discrets de forte densité de l'estimateur K -NN (THÉORÈME 2, p. 64). Cette réponse est satisfaisante mathématiquement, mais quelque peu brutale algorithmiquement. Construire le complexe de Čech complet revient à manipuler tous les K -simplexes sur $\mathcal{X}$, au nombre de $\binom{n}{K+1}$.

Pour $K = 1$, cette explosion n'a pas lieu en pratique dans l'espace euclidien (de petite dimension) : on ne calcule pas toute la filtration des graphes géométriques, on extrait l'arbre minimum couvrant. Cet arbre est lui-même contenu dans le graphe de GABRIEL, lui-même sous-graphe de la triangulation de DELAUNAY (FAIT 1, p. 21).

L'objectif de ce chapitre est de reconstruire cette chaîne d'idées à l'ordre K :

Complexes de Čech $\rightsquigarrow$ Simplexes responsables des fusions
 $\rightsquigarrow$ K -Graphe de GABRIEL $\rightsquigarrow$ Mosaïque de DELAUNAY d'ordre K

Contributions Ce chapitre reprend et développe les optimisations géométriques introduites dans [64]. Nous commençons par montrer que l'on peut retrouver les K -polyèdres comme composantes connexes d'un graphe pondéré *élémentaire* sur les $(K - 1)$ -simplexes, c'est-à-dire en restreignant les arêtes aux K -simplexes. Cette reformulation permet de définir précisément les simplexes K -séparant (DEF. 27, p. 90) : les simplexes qui provoquent effectivement une fusion dans la hiérarchie. Le premier résultat central est le THÉORÈME 4 : tout simplexe K -séparant est nécessairement de GABRIEL. On en déduit que le graphe de GABRIEL contient toutes les fusions utiles et qu'un arbre couvrant minimum construit sur ce graphe préserve, à chaque échelle, les K -polyèdres (THÉORÈME 5, p. 94).

Enfin, nous expliquons comment construire en pratique la hiérarchie K -NN : la structure géométrique naturelle derrière cette construction est la mosaïque de DELAUNAY d'ordre K .

8.1 L'approche persistante : les simplexes K -séparants

Fixons un nuage fini $\mathcal{X} \subset \mathbb{R}^p$ et un entier

$$K \in \llbracket 1, |\mathcal{X}| - 1 \rrbracket.$$

DÉFINITION 25 : RAYON DE NAISSANCE D'UN SIMPLEXE

Pour tout sous-ensemble fini non vide $\sigma \subseteq \mathcal{X}$, on note

$$\rho(\sigma) \triangleq \inf \left\{ r \geq 0 \mid \sigma \in \check{C}(\mathcal{X}, r) \right\}.$$

Autrement dit,

$$\rho(\sigma) = \inf_{y \in \mathbb{R}^p} \max_{x \in \sigma} \|y - x\|.$$

La boule fermée réalisant cet infimum sera notée

$$B_\sigma = \overline{B}(c_\sigma, \rho(\sigma)),$$

avec c_σ son centre.

Remarque En anglais, on appelle cette plus petite boule englobante la *miniball* de σ . La méthode standard pour calculer le rayon $\rho(\sigma)$ ainsi que d'identifier le centre c_σ de la boule B_σ est l'algorithme de WELZL [91].

Le rayon de naissance $\rho(\sigma)$ est exactement le niveau d'apparition de σ dans la filtration de Čech. Pour $K = 1$, si $\sigma = \{x, x'\}$, alors

$$\rho(\sigma) = \frac{1}{2} \|x - x'\|.$$

Dans toute la suite du chapitre, nous utiliserons l'hypothèse suivante à propos des données $\mathcal{X}$.

DÉFINITION 26 : POSITION GÉNÉRALE POUR LA FILTRATION DE ČECH

On dit qu'un nuage $\mathcal{X} \subset \mathbb{R}^p$ localement fini est en *position générale pour la filtration de Čech* si, pour tout simplexe non vide $\sigma \subseteq \mathcal{X}$, aucun point de $\mathcal{X} \setminus \sigma$ n'appartient à la frontière de sa plus petite boule englobante,

$$\partial B_\sigma \cap (\mathcal{X} \setminus \sigma) = \emptyset.$$

Autrement dit, aucun point du nuage extérieur à σ ne se trouve sur la frontière de la plus petite boule englobante de σ .

L'on supposera de plus (pour éviter toute ambiguïté lors des scissions/fusions), l'unicité des rayons : deux simplexes σ et σ' ayant des supports $\sigma \cap \partial B_\sigma$ et $\sigma' \cap \partial B_{\sigma'}$ distincts ont nécessairement un rayon différent :

$$\rho(\sigma) \neq \rho(\sigma').$$

Remarques

1. Noter que notre définition d'un nuage en position générale est plus contraignante que la DEF. 4.2 de [29]
2. Sous cette hypothèse, les points de $\sigma \cap \partial B_\sigma$ forment exactement l'ensemble de support de la boule minimale B_σ (voir FAIT 12 ci-dessous). En particulier, ils sont affinement indépendants et c_σ appartient à l'intérieur (relatif) de $\text{conv}(\sigma \cap \partial B_\sigma)$.

FAIT (CONNU) 12 : BOULE MINIMALE ET ENSEMBLE DE SUPPORT [29, 91]

Soit $A \subset \mathbb{R}^p$ fini non vide. Il existe une unique plus petite boule fermée contenant A . Son centre appartient à l'enveloppe convexe d'un sous-ensemble


$$S(A) \subseteq A \cap \partial B_A$$

de cardinal au plus $p+1$. Sous l'hypothèse de position générale (DEF. 26), cet ensemble de support est exactement l'ensemble des points de A situés sur la frontière de B_A . En particulier, si $s \in S(A)$, alors

$$\rho(A \setminus \{s\}) < \rho(A).$$

8.1.1 Le graphe élémentaire des facettes

Il nous a été plus commode en DEF. 21, p. 62 de définir les K -polyèdres comme les composantes connexes d'un graphe $\Gamma_K(\mathcal{X}, r)$ dont les sommets sont les $(K-1)$ -simplexes de $\check{C}(\mathcal{X}, r)$ et dont deux sommets sont adjacents lorsque leur union est encore un simplexe de $\check{C}(\mathcal{X}, r)$, et ce sans restriction sur la taille de cette union. L'objet de PROP. 6 est d'observer que l'on aurait pu se restreindre aux adjacence *élémentaires*, c'est-à-dire aux seuls K -simplexes pour créer des liaisons entre les sommets.



(a) Triangle aigu. Le centre c_σ se trouve à l'intérieur de l'enveloppe convexe. Tous les sommets définissent la boule minimale, donc $S = \sigma$.

(b) Triangle obtus : le centre c_σ appartient à une arête. L'ensemble de support est strictement inclus dans le simplexe : $S = \{x_1, x_2\} \subsetneq \sigma$.

FIGURE 8.1 : Illustration de la plus petite boule englobante B_σ , de son centre c_σ , de son rayon de naissance $\rho(\sigma)$ et de son ensemble de support à la frontière $S = \sigma \cap \partial B_\sigma$ pour un 2-simplexe $\sigma = \{x_1, x_2, x_3\}$.

PROPOSITION 6 : LES ADJACENCES ÉLÉMENTAIRES SUFFISENT

Pour tout $r \geq 0$, retirer de $\Gamma_K(\mathcal{X}, r)$ les liens entre deux sommets τ et τ' dès que $|\tau \cup \tau'| > K + 1$ laisse inchangées les composantes connexes. Elles correspondent donc toujours aux K -polyèdres du complexe de Čech $\check{C}(\mathcal{X}, r)$ définis en DEF. 21.

Preuve. Supposons que deux $(K - 1)$ -simplexes τ et τ' soient adjacents dans $\Gamma_K(\mathcal{X}, r)$, c'est-à-dire que $\tau \cup \tau' \in \check{C}(\mathcal{X}, r)$, soit

$$\rho(\tau \cup \tau') \leq r.$$

Si $|\tau \cup \tau'| = K + 1$, l'adjacence est déjà élémentaire. Si $|\tau \cup \tau'| > K + 1$, alors on peut relier τ à τ' au moyen d'un chemin de K -sous-simplexes de $\tau \cup \tau'$, différant à chaque fois d'un seul élément. Ces liaisons sont toutes présentes dans le graphe $\Gamma_K(\mathcal{X}, r)$ élagué des simplexes de dimension $> K$. $\square$

Notation À partir de maintenant, $\Gamma_K(\mathcal{X}, r)$ désignera uniquement la version élaguée du graphe, réduit aux adjacences élémentaires. Nous noterons ce graphe indifféremment $\Gamma_K(\mathcal{X})_{\leq r}$ et $\Gamma_K(\mathcal{X})$, sans indice, quand nous prenons $r = +\infty$. Nous noterons aussi $\Gamma_K(\mathcal{X})_{< r}$ le sous-graphe de $\Gamma_K(\mathcal{X})_{\leq r}$ privés de tous les simplexes σ (sommets et arêtes) ayant un rayon $\rho(\sigma)$ exactement égal à r .

DÉFINITION 27 : SIMPLEXE K -SÉPARANT

Soit $\sigma \subseteq \mathcal{X}$ un K -simplexe, et posons $r_\sigma = \rho(\sigma)$. On dit que σ est K -séparant si les K -polyèdres de $\Gamma_K(\mathcal{X})_{< r_\sigma}$ et $\Gamma_K(\mathcal{X})_{\leq r_\sigma}$ ne sont pas égaux.

Autrement dit, un simplexe K -séparant est un simplexe qui change réellement la connectivité persistante des K -polyèdres. Pour $K = 1$, les 1-simplexes séparant sont

exactement les arêtes qui relient deux composantes distinctes du graphe géométrique au moment où elles apparaissent ; ce sont les arêtes de l'arbre minimum couvrant.

Le FAIT 2 appliqué à $\Gamma_K(\mathcal{X})$ dit que si l'on savait construire un arbre couvrant minimum de $\Gamma_K(\mathcal{X})$, alors son élagage à l'échelle r redonnerait les K -polyèdres de $\check{C}(\mathcal{X}, r)$. Mais ce graphe contient encore tous les sommets induits par les $\binom{n}{K}$ simplexes d'ordre $K - 1$. Il faut donc identifier un sous-graphe beaucoup plus mince ; c'est l'objet de la section suivante.

8.2 Une condition nécessaire pour un simplexe séparant : être de GABRIEL

Le cas $K = 1$ fournit l'intuition géométrique décisive : une arête de l'arbre minimum couvrant euclidien est nécessairement une arête de GABRIEL (DEF. 3 & FAIT 1, p. 21), c'est-à-dire que la plus petite boule englobante, celle ayant pour diamètre l'arête, est vide de tout autre point du nuage. La condition se généralise en remplaçant la boule diamétrale par la plus petite boule englobante du simplexe.

DÉFINITION 28 : SIMPLEXE DE GABRIEL

Un K -simplexe $\sigma \subseteq \mathcal{X}$ est dit de GABRIEL si l'intérieur de sa plus petite boule englobante ne contient aucun point de $\mathcal{X}$ extérieur à σ :

$$\mathring{B}_\sigma \cap (\mathcal{X} \setminus \sigma) = \emptyset.$$

Remarque Noter que notre généralisation de la notion de simplexe de GABRIEL à l'aide de la *miniball* diffère de celle de [29], où l'on impose une condition de sphère circonscrite vide (la *circumball*). Pour $K = 1$, les deux notions coïncident avec l'arête de GABRIEL classique.

Cette condition de vacuité est nécessaire pour qu'un K -simplexe provoque une fusion.

THÉORÈME 4 : CONDITION NÉCESSAIRE POUR QUE σ SOIT K -SÉPARANT : σ DOIT ÊTRE DE GABRIEL

Supposons $\mathcal{X}$ en position générale pour la filtration de Čech. Tout simplexe K -séparant est de GABRIEL.

PREUVE DU THÉORÈME 4. Soit σ un K -simplexe, et posons

$$r = \rho(\sigma), \quad B_\sigma = \overline{B}(c, r).$$


Raisonnons par contraposée. Supposons que σ ne soit pas de GABRIEL. Il existe donc un point

$$z \in \mathcal{X} \setminus \sigma \quad \text{tel que} \quad z \in \mathring{B}_\sigma.$$

Notons

$$S \triangleq \sigma \cap \partial B_\sigma$$

l'ensemble des sommets de σ situés sur la frontière de la boule minimale. Par la DEF. 26 et le FAIT 12, S est l'ensemble de support de B_σ ; en particulier $|S| \geq 2$, le centre c appartient à l'intérieur relatif de $\text{conv}(S)$, et retirer n'importe quel point de S diminue strictement le rayon de naissance.



(a) Un triangle $\sigma = \{x_1, x_2, x_3\}$. B_σ a pour diamètre $[x_1, x_2]$. L'ensemble de support est $S = \{x_1, x_2\}$. σ n'est pas de GABRIEL, donc il existe un "intrus" $z \in \dot{B}_\sigma$.

(b) Les K -simplexes σ_2^z et σ_1^z ont des rayons $< r$. Le chemin $\tau_1 \xrightarrow{\sigma_1^z} \eta_{1,2}^z \xrightarrow{\sigma_2^z} \tau_2$ connecte les facettes actives dans $\Gamma_K(\mathcal{X})_{<r}$.

FIGURE 8.2 : Illustration de la preuve du THÉORÈME 4 ($K = 2$) pour un triangle $\sigma = \{x_1, x_2, x_3\}$ obtus en x_3 , c'est-à-dire que $S = \{x_1, x_2\}$. Si le simplexe n'est pas de GABRIEL, B_σ (de rayon r) contient donc un "intrus" z . Les facettes τ_1 et τ_2 , actives pour une filtration $< r$, sont connectées au moyen de z (les 2-simplexes σ_s^z et σ_t^z).

Les seules facettes de σ qui existent strictement avant le niveau r sont les facettes

$$\tau_s \triangleq \sigma \setminus \{s\}, \quad s \in S.$$

En effet, si l'on retire un point de support $s \in S$, le rayon diminue strictement :

$$\rho(\tau_s) < r.$$

À l'inverse, si l'on retire un sommet intérieur $u \in \sigma \setminus S$, la boule minimale reste B_σ , donc la facette correspondante naît au même niveau r .

Montrons maintenant que toutes les facettes actives τ_s , $s \in S$, sont déjà dans la même composante de $\Gamma_K(\mathcal{X})_{<r}$. Soient $s, t \in S$, $s \neq t$. Considérons les deux K -simplexes

$$\sigma_s^z \triangleq (\sigma \setminus \{s\}) \cup \{z\}, \quad \sigma_t^z \triangleq (\sigma \setminus \{t\}) \cup \{z\}.$$

Ils contiennent respectivement les facettes

$$\tau_s = \sigma \setminus \{s\}, \quad \eta_{s,t}^z \triangleq (\sigma \setminus \{s, t\}) \cup \{z\},$$

et

$$\eta_{s,t}^z, \quad \tau_t = \sigma \setminus \{t\}.$$

Il suffit donc de vérifier que

$$\rho(\sigma_s^z) < r \quad \text{et} \quad \rho(\sigma_t^z) < r.$$

(Voir la FIG. 8.2 pour une illustration.) Or σ_s^z est contenu dans B_σ , et ses points situés sur la frontière de B_σ sont contenus dans $S \setminus \{s\}$. D'après le FAIT 12, on a bien

$$\rho(\sigma_s^z) < r.$$

Même raisonnement pour σ_t^z .

Ainsi, pour tout couple $s, t \in S$, les facettes τ_s et τ_t sont reliées dans $\Gamma_K(\mathcal{X})_{<r}$ par le chemin

$$\tau_s \xleftrightarrow[\tau_s]{\sigma_s^z} \eta_{s,t}^z \xleftrightarrow[\tau_t]{\sigma_t^z} \tau_t$$

Le simplexe σ n'a donc aucune influence sur les K -polyèdres (les $(K-1)$ -simplexes déjà existant étant de la même composante connexe ; ceux apparaissant ayant déjà tous leurs points dans cette même composante préexistante) ; il n'est pas K -séparant. $\square$

DÉFINITION 29 : GRAPHE DE GABRIEL

Le *graphe de GABRIEL* de $\mathcal{X}$, noté

$$\mathcal{G}_K^{\text{Gab}}(\mathcal{X}),$$

est le sous-graphe pondéré de $\Gamma_K(\mathcal{X})$ défini ainsi.

- Ses sommets sont les $(K-1)$ -simplexes de $\mathcal{X}$ qui sont facettes d'au moins un K -simplexe de GABRIEL.
- Pour chaque K -simplexe de GABRIEL σ , on relie entre elles toutes les facettes de σ (formant une clique).
- Toutes les arêtes induites par σ reçoivent le poids $\rho(\sigma)$.

Pour $K = 1$, ce graphe n'est autre que le graphe de GABRIEL classique, pondéré par la moitié de la longueur des arêtes. Pour $K \geq 2$, ce n'est plus un graphe sur les points, mais un graphe sur les $(K-1)$ -simplexes.

PROPOSITION 7 : LE GRAPHE DE GABRIEL CONTIENT TOUTES LES FUSIONS UTILES

Pour tout $r \geq 0$, les ensembles de points associés aux composantes connexes non réduites à un sommet isolé de

$$\mathcal{G}_K^{\text{Gab}}(\mathcal{X})_{\leq r}$$

coïncident avec les K -polyèdres de $\check{C}(\mathcal{X}, r)$ non réduits à un $(K - 1)$ -simplexe isolé.

Preuve. Notons d'abord l'inclusion triviale

$$\mathcal{G}_K^{\text{Gab}}(\mathcal{X})_{\leq r} \subseteq \Gamma_K(\mathcal{X})_{\leq r}.$$

Supposons (preuve par induction avec rayon r croissant) que jusqu'à un niveau critique r , les composantes non triviales (vues comme des ensembles de points) du graphe de GABRIEL et du graphe de Čech des facettes définissent les mêmes ensembles de points. Ajoutons maintenant les K -simplexes de naissance r .

Si un simplexe σ ajouté à ce niveau est de GABRIEL, il est ajouté dans les deux graphes. S'il ne l'est pas, la preuve du THÉORÈME 4 montre que toutes ses facettes nées strictement avant r sont déjà reliées entre elles par des chemins de poids strictement plus petits que r . **Revoir la preuve.** Les autres facettes de σ naissent au niveau r lui-même ; elles peuvent être ajoutées comme sommets, mais elles ne changent pas l'ensemble de points de la composante, car l'union des facettes actives

$$\{\sigma \setminus \{s\} \mid s \in \sigma \cap \partial B_\sigma\}$$

contient déjà tous les sommets de σ . Ajouter σ ne crée donc aucune fusion nouvelle entre ensembles de points.

Par induction sur les valeurs critiques, les simplexes qui ne sont pas de GABRIEL peuvent être supprimés sans modifier les K -polyèdres non triviaux. $\square$

Nous pouvons maintenant définir l'analogue de l'arbre minimum couvrant.

DÉFINITION 30 : K -ARBRE MINIMUM COUVRANT

Un K -arbre minimum couvrant, noté K -MST, est un arbre minimum couvrant du graphe pondéré $\mathcal{G}_K^{\text{Gab}}(\mathcal{X})$. Pour $r \geq 0$, on note

$$K\text{-MST}_{\leq r}$$

le sous-graphe obtenu en supprimant les arêtes de poids strictement supérieur à r .

THÉORÈME 5 : COMPLEXE DE ČECH $\equiv K$ -ARBRE MINIMUM COUVRANT ÉLAGUÉ

Supposons $\mathcal{X} \subset \mathbb{R}^p$ en position générale pour la filtration de Čech. Pour tout $r \geq 0$, les ensembles de points associés aux composantes connexes de

$$K\text{-MST}_{\leq r}$$

qui ne sont pas réduites à un sommet isolé coïncident avec les K -polyèdres de $\check{C}(\mathcal{X}, r)$ qui ne sont pas réduits à un $(K - 1)$ -simplexe isolé.

Preuve du THÉORÈME 5. On applique le FAIT 2 au graphe pondéré

$$\mathcal{G}_K^{\text{Gab}}(\mathcal{X}).$$

Il donne, pour tout $r \geq 0$, l'égalité des composantes connexes de

$$K\text{-MST}_{\leq r} \quad \text{et} \quad \mathcal{G}_K^{\text{Gab}}(\mathcal{X})_{\leq r}.$$

Le PROP. 7 identifie ensuite les composantes non triviales de ce dernier graphe avec les K -polyèdres non triviaux de $\check{C}(\mathcal{X}, r)$. $\square$

8.3 La bonne structure à observer : la mosaïque de DELAUNAY d'ordre K

Le THÉORÈME 5 remplace le complexe de Čech complet par un arbre couvrant construit sur le K -graphe de GABRIEL. Il reste encore à savoir : comment trouver les simplexes de GABRIEL sans tester les $\binom{n}{K+1}$ candidats ?

Pour $K = 1$, la réponse dans l'espace euclidien $\mathbb{R}^p$ est la triangulation de DELAUNAY (FAIT 1).

Pour $K \geq 2$, la réponse est la mosaïque de DELAUNAY d'ordre K [61, 92].

DÉFINITION 31 : CELLULES DE VORONOÏ D'ORDRE SUPÉRIEUR ET MOSAÏQUE DE DELAUNAY DUALE [61, 92]

Soit $\mathcal{X} \subseteq \mathbb{R}^p$ un ensemble fini, et soit $k \in \{1, \dots, |\mathcal{X}| - 1\}$. Pour tout sous-ensemble $Q \subset \mathcal{X}$ de cardinal k , on définit sa cellule de VORONOÏ d'ordre k par

$$\text{Vor}_k(Q) \triangleq \left\{ y \in \mathbb{R}^p \mid \max_{q \in Q} \|y - q\| \leq \min_{x \in \mathcal{X} \setminus Q} \|y - x\| \right\}.$$

Autrement dit, $\text{Vor}_k(Q)$ est l'ensemble des points de l'espace pour lesquels les points de Q sont les k plus proches voisins dans $\mathcal{X}$.

La *mosaïque de DELAUNAY d'ordre k* , notée $\text{Del}_k(\mathcal{X})$, est le complexe dual du diagramme de VORONOÏ d'ordre k : ses sommets sont les k -uplets $Q \subset \mathcal{X}$ tels que $\text{Vor}_k(Q) \neq \emptyset$, et plus généralement

$$\{Q_0, \dots, Q_m\} \in \text{Del}_k(\mathcal{X}) \iff \bigcap_{i=0}^m \text{Vor}_k(Q_i) \neq \emptyset.$$

En particulier, deux sommets Q, Q' de $\text{Del}_k(\mathcal{X})$ sont adjacents dès qu'il existe un point $y \in \mathbb{R}^p$ pour lequel Q et Q' sont deux choix possibles de k plus proches voisins. Nous dirons qu'un k -simplexe $\sigma \subset \mathcal{X}$ est *porté par la mosaïque de DELAUNAY d'ordre k* s'il existe deux sommets adjacents Q, Q' de $\text{Del}_k(\mathcal{X})$ tels que

$$Q \cup Q' = \sigma.$$

8.3.1 Un K -simplexe de GABRIEL est nécessairement dans la mosaïque de DELAUNAY d'ordre K

THÉORÈME 6 : LES K -SIMPLEXES DE GABRIEL SONT PORTÉS PAR LA MOSAÏQUE DE DELAUNAY D'ORDRE K

Soit $\mathcal{X} \subset \mathbb{R}^p$ un nuage fini en position générale. Tout K -simplexe de GABRIEL $\sigma \subseteq \mathcal{X}$ est porté par la mosaïque de DELAUNAY d'ordre K , au sens de la DEF. 31.

Preuve du THÉORÈME 6. Notons

$$B_\sigma = \overline{B}(c_\sigma, r_\sigma)$$

la plus petite boule fermée contenant σ . Comme σ est de GABRIEL, aucun point de $\mathcal{X} \setminus \sigma$ n'appartient à l'intérieur de cette boule :

$$\overset{\circ}{B}_\sigma \cap (\mathcal{X} \setminus \sigma) = \emptyset.$$

En position générale, on peut de plus supposer qu'aucun point de $\mathcal{X} \setminus \sigma$ n'appartient à la sphère ∂B_σ . L'on décompose alors les sommets de σ en deux familles :

$$I \triangleq \sigma \cap \overset{\circ}{B}_\sigma, \quad S \triangleq \sigma \cap \partial \overset{\circ}{B}_\sigma.$$

Les points de I sont strictement plus proches du centre c_σ que les points de S , tandis que tous les points de S sont à distance exactement r_σ de c_σ . La boule B_σ étant minimale, l'ensemble S contient au moins deux points. Choisissons donc deux sommets distincts $s, t \in S$. Considérons les deux K -uplets

$$Q_s \triangleq \sigma \setminus \{s\}, \quad Q_t \triangleq \sigma \setminus \{t\}.$$

Au point c_σ , tous les points de I sont strictement plus proches que les points de S , et aucun point extérieur à σ n'est plus proche que les points de S . Ainsi, Q_s et Q_t sont deux choix possibles de K plus proches voisins de c_σ . Autrement dit,

$$c_\sigma \in \text{Vor}_K(Q_s) \cap \text{Vor}_K(Q_t).$$

Par définition de la mosaïque de DELAUNAY d'ordre K , les deux sommets Q_s et Q_t sont donc adjacents dans $\text{Del}_K(\mathcal{X})$. Enfin,

$$Q_s \cup Q_t = (\sigma \setminus \{a\}) \cup (\sigma \setminus \{b\}) = \sigma,$$

ce qui prouve que σ est porté par la mosaïque de DELAUNAY d'ordre K . □

Nous avons à présent tous les résultats nécessaires pour aborder dès le chapitre suivant les aspects pratiques.

Synthèse Le rôle de l'arbre minimum couvrant dans le Single-Linkage repose sur un principe plus général : dans une filtration, seules les cellules qui changent effectivement la connectivité doivent être conservées pour reconstruire les composantes à toutes les échelles.

Pour les K -polyèdres, ces cellules sont les simplexes K -séparant. Le THÉORÈME 4 montre qu'ils satisfont nécessairement une condition de vacuité : ils sont de GABRIEL. On peut donc remplacer le graphe complet des facettes de Čech par le graphe beaucoup plus mince des simplexes de GABRIEL, puis calculer un K -arbre minimum couvrant. L'élagage de cet arbre redonne exactement les mêmes K -polyèdres non triviaux que la hiérarchie complète sur le complexe de Čech (THÉORÈME 5).

La structure géométrique qui organise ces simplexes est la mosaïque de DELAUNAY d'ordre K (THÉORÈME 6).

CHAPITRE 9

HGP-Clusterer en pratique

Ce chapitre achève la deuxième partie consacrée à la généralisation du Single-Linkage dans l'espace euclidien, avec un certain nombre de considérations où la pratique diffère de la pure théorie.

Premier problème rencontré en pratique (§ 9.1) : il est parfois nécessaire d'avoir une partition stricte des données $\mathcal{X}$ (et non un recouvrement comme les K -polyèdres produits par HGP-Clusterer θ^{HGP}).

Nous décrivons ensuite (§ 9.2) la mise en œuvre optimisée pour $K = 2$ ne nécessitant que le calcul de la triangulation de DELAUNAY standard et qui nous a permis d'obtenir des résultats empiriques à la fois sur des données synthétiques 2D et des données réelles 8D (les huiles d'olive italiennes) pour illustrer la supériorité de HGP-Clusterer face à HDBSCAN [64].

Il arrive aussi parfois que les données $\mathcal{X}$ soient de trop grande dimension pour pouvoir calculer la triangulation de DELAUNAY (phénomène dit du « fléau de la dimension », *curse of dimensionality* [93] en anglais). Ou bien les données peuvent tout simplement ne pas provenir de l'espace euclidien. (Supposons qu'on ait une matrice de distance, éventuellement creuse, représentant des données dans un espace métrique quelconque.) En ce cas, nous pouvons recourir à un autre complexe que celui de Čech : le complexe de VIETORIS-RIPS (§ 9.3).

Pour terminer ce chapitre, nous revenons en § 9.4 sur l'objet mathématique au cœur de HGP-Clusterer, et qui contient toute l'information de la hiérarchie K -NN : la mosaïque de DELAUNAY d'ordre K . Nous l'avons utilisée à des fins de clustering, alors nous avons montré qu'il suffisait d'extraire un arbre minimum couvrant sur certaines de ses cellules. Mais on aurait pu l'utiliser pour d'autres fins de structuration automatique de données ! Nous esquissons une direction de travail encore ouverte : utiliser la mosaïque comme support d'une réduction de dimension de type UMAP, mais en recourant à des interactions d'ordre supérieur.

9.1 Et lorsqu'on impose une partition stricte des données ?

Jusqu'ici, HGP-Clusterer a été présenté comme une hiérarchie exacte de K -polyèdres. Ce point est fondamental : pour $K \geq 2$, l'objet naturel n'est pas une partition de $\mathcal{X}$, mais un recouvrement de $\mathcal{X}$ (ou bien une partition des $(K - 1)$ -simplexes).

Un point peut appartenir à plusieurs K -polyèdres, parce qu'il peut apparaître dans plusieurs $(K - 1)$ -simplexes situés dans des composantes différentes du graphe $\Gamma_K(\mathcal{X})_r$; c'est précisément l'information géométrique portée par les intersections d'ordre supérieur.

En revanche, la plupart des bibliothèques de clustering, des métriques usuelles, des tableaux de résultats et surtout des problèmes concrets posés à la fois par les mondes académique & industriel veulent une assignation unique d'un cluster à chaque point. Il va nous falloir "réparer" cela. Pour ce faire, nous proposons un post-traitement qui conserve telle quelle la première étape de la construction de la hiérarchie des K -polyèdres.

Soit $\mathcal{F}_K$ l'ensemble des $(K - 1)$ -simplexes effectivement construits par l'algorithme (ce sont les sommets du graphe dual utilisé par HGP-Clusterer ; dans la version standard de l'algorithme, $\mathcal{F}_K$ correspond aux simplexes de GABRIEL). Après traitement de cette hiérarchie (*exempli gratia*, condensation de l'arbre et sélection des clusters pertinents par excès de masse comme HDBSCAN [8] le fait), chaque face $\tau \in \mathcal{F}_K$ reçoit soit une étiquette de cluster

$$\ell(\tau) \in \{0, \dots, q_{\text{clust}} - 1\},$$

soit l'étiquette -1 si la face n'appartient à aucun cluster sélectionné (considérée comme du bruit).

L'implémentation associe à chaque face $\tau \in \mathcal{F}_K$ un score local positif. Dans la version par défaut, ce score est

$$S_\tau \triangleq \sum_{\substack{\sigma \supset \tau \\ |\sigma|=K+1}} \psi(\rho(\sigma)), \quad \psi(t) = \frac{1}{t^p},$$

où $\rho(\sigma)$ désigne le rayon de naissance du K -simplexe σ dans la filtration. Plus généralement, ψ peut être remplacée par toute fonction de poids décroissante. Le choix uniforme $\psi \equiv 1$ est possible, mais le choix $1/t^p$ reflète plus exactement la densité locale, qui est au cœur du modèle mathématique derrière HGP-Clusterer.

Pour éviter qu'un point incident à beaucoup de faces soit artificiellement surpondéré, chaque point $x \in \mathcal{X}$ normalise la masse de ses faces incidentes par

$$T_x \triangleq \sum_{\substack{\tau \in \mathcal{F}_K \\ x \in \tau}} S_\tau.$$

La masse d'une face dans l'arbre condensé est alors

$$m_\tau \triangleq S_\tau \sum_{x \in \tau} \frac{1}{T_x},$$

avec la convention $1/T_x = 0$ lorsque $T_x = 0$. Ainsi, lorsqu'un point appartient à au moins une face, il distribue une masse totale égale à 1 entre les faces qui le contiennent. C'est ce poids m_τ , et non le simple comptage des faces, qui est utilisé par le seuil `min_cluster_size` dans l'arbre condensé (même idées algorithmiques que HDBSCAN).

La conversion en partition stricte se fait ensuite par vote pondéré. Pour tout point $x \in \mathcal{X}$ et tout cluster c , on définit

$$V_x(c) \triangleq \sum_{\substack{\tau \in \mathcal{F}_K \\ x \in \tau \\ \ell(\tau)=c}} \frac{S_\tau}{T_x}.$$

Le point reçoit alors l'étiquette

$$\hat{\ell}(x) \in \operatorname{argmax}_c V_x(c)$$

PROPOSITION 8 : PARTITION STRICTE INDUITE PAR LE VOTE PONDÉRÉ

Fixons une sélection de clusters sur les faces de $\mathcal{F}_K$ et une règle déterministe de départage des égalités. La procédure précédente définit une partition disjointe

$$\mathcal{X} = \hat{C}_{-1} \dot{\cup} \hat{C}_0 \dot{\cup} \dots \dot{\cup} \hat{C}_{q_{\text{clust}}-1}, \quad \hat{C}_c \triangleq \{x \in \mathcal{X} \mid \hat{\ell}(x) = c\},$$

où $\hat{C}_{-1}$ est l'ensemble des points non classés.

Pour $K = 1$, les faces sont les points eux-mêmes ; le vote est donc trivial et restitue exactement les étiquettes du Single-Linkage après sélection des composantes. Pour $K \geq 2$, il joue un rôle réel : il remplace l'appartenance multiple aux K -polyèdres par une décision locale, pondérée par la densité de naissance des faces incidentes.

9.2 Optimisations pour $K = 2$ avec des résultats empiriques

9.2.1 Les propriétés géométriques du 2-graphe de GABRIEL

Lorsque $K = 2$, les sommets du graphe dual sont les arêtes de la filtration, et les fusions sont portées par des triangles. Deux arêtes deviennent adjacentes lorsqu'elles sont facettes d'un même triangle de Čech.

PROPOSITION 9 : LE 2-GRAPHE DE GABRIEL SE LIT DANS LA TRIANGULATION DE DELAUNAY [64]

Les triangles aigus de GABRIEL sont des triangles de DELAUNAY, puisque leur sphère minimale est leur sphère circonscrite. Les triangles obtus de GABRIEL ont pour boule

minimale le disque de diamètre leur plus long côté; dans ce cas, les deux petites arêtes appartiennent à la triangulation de DELAUNAY, ce qui suffit pour énumérer les triangles de GABRIEL (aigus et obtus) sans parcourir tous les triplets de points.

Preuve. Il suffit de jongler avec les notions de GABRIEL et de DELAUNAY comme l'illustre la FIG. 9.1 ci-dessous. La boule de diamètre le plus grand côté ne contient qu'un seul point (le troisième sommet du triangle obtus). Il existe donc des boules contenant les plus petites arêtes et vides d'autres points du nuage $\mathcal{X}$; par conséquent ces arêtes sont de DELAUNAY. □




FIGURE 9.1 : Illustration de la preuve de PROP. 9. Si un triangle obtus $\sigma = \{x_1, x_2, x_3\}$ est de GABRIEL, sa boule minimale B_σ de diamètre $[x_2, x_3]$ est vide de tout “intrus”. L’on peut alors y inscrire deux disques D_{x_3} et D_{x_2} inclus dans B_σ (et donc également vides de tout point de $\mathcal{X}$). Ces disques vides attestent que $[x_1, x_2]$ et $[x_1, x_3]$ sont bien de DELAUNAY.

9.2.2 Digression au cas $K \geq 2$

Ces idées (PROP. 9 et la preuve) se généralisent très bien pour $K \geq 2$.

La mosaïque de DELAUNAY $\text{Del}_{K-1}(\mathcal{X})$ d’ordre $K - 1$ a pour sommets les sous-ensembles $Q \subset \mathcal{X}$ de cardinal $K - 1$ associés à une cellule de VORONOI d’ordre $K - 1$ non vide. Les arêtes élémentaires de cette mosaïque (reliant deux sommets Q, Q' tels que $|Q \cup Q'| = K$), portent donc un $(K - 1)$ -simplexe $\tau = Q \cup Q'$.

Autrement dit, les arêtes élémentaires de $\text{Del}_{K-1}(\mathcal{X})$ fournissent des candidats pour les sommets de $\Gamma_K(\mathcal{X})$.

Regardons à présent les arêtes de $\Gamma_K(\mathcal{X})$: soit $\sigma \subseteq \mathcal{X}$ un K -simplexe de GABRIEL, $|\sigma| = K + 1$. Notons comme à l’accoutumée $B_\sigma = B(c_\sigma, \rho(\sigma))$ sa plus petite boule englobante, et $S = \sigma \cap \partial B_\sigma$ son ensemble de support. Comme B_σ est minimale, on a $|S| \geq 2$. Pour tout $s \in S$, on pose $\tau_s = \sigma \setminus \{s\}$. Alors chaque facette active τ_s est portée par la mosaïque $\text{Del}_{K-1}(\mathcal{X})$: par les arguments maintenant habituels (FAIT 12), il existe deux sommets adjacents Q, Q' de $\text{Del}_{K-1}(\mathcal{X})$ tels que $Q \cup Q' = \tau_s$.

Comme $|S| \geq 2$, en choisissant deux points distincts $s, t \in S$, on obtient deux facettes actives

$$\tau_s = \sigma \setminus \{s\}, \quad \tau_t = \sigma \setminus \{t\},$$

et leur union redonne le simplexe entier :

$$\tau_s \cup \tau_t = \sigma.$$

Par conséquent, on obtient le résultat suivant généralisant PROP. 9 à $K \geq 2$.

THÉORÈME 7 : LE K -GRAPHE DE GABRIEL SE LIT DANS LA MOSAÏQUE DE DELAUNAY Del_{K-1} D'ORDRE $K - 1$

Tout K -simplexe de GABRIEL peut être identifié à partir de deux $(K - 1)$ -simplexes portés par des arêtes élémentaires de $\text{Del}_{K-1}(X)$.

Ce THÉORÈME 7 permet le résultat algorithmique suivant : pour retrouver la hiérarchie complète des niveaux K -NN, il suffit¹⁾ de construire la mosaïque $\text{Del}_{K-1}(X)$ d'ordre $K - 1$.

9.2.3 L'algorithme pour $K = 2$

PROP. 9 permet d'obtenir PROP. 10 ainsi que l'ALG. 1 utilisé dans la suite de ce chapitre sur les données expérimentales.

PROPOSITION 10 : EXTRACTION PLANAIRE DU 2-GRAPHE DE GABRIEL [64]

Soit $\mathcal{X} \subset \mathbb{R}^2$ un nuage fini en position générale. Tous les triangles de GABRIEL de $\mathcal{X}$ peuvent être extraits à partir de la triangulation de DELAUNAY ordinaire de $\mathcal{X}$. En particulier, le graphe dual des arêtes reliées par les triangles de GABRIEL peut être construit en temps $\mathcal{O}(n \log n)$ dans le plan.

Remarque En dimension plus grande, la mise en œuvre exacte devient rapidement limitée par la construction de la mosaïque de DELAUNAY d'ordre K . Des approximations de type RIPS, une réduction préalable de dimension, un sous-échantillonnage suivi d'une propagation par k -plus proches voisins, ou encore une recherche restreinte à des listes de voisins sont des options praticables. Elles doivent toutefois être distinguées de la construction géométrique exacte : dès qu'une approximation remplace la mosaïque exacte, les garanties d'équivalence avec les K -polyèdres exacts ne valent plus sans hypothèses supplémentaires.

¹⁾Il y a tout de même un coût supplémentaire non négligeable en grande dimension : trouver le rayon de filtration r_σ des simplexes σ candidats, par exemple au moyen de l'algorithme de WELZL [91] (et éventuellement tester qu'ils sont bien de GABRIEL).

Algorithm 1 HGP-CLUSTERER pour $K = 2$ avec sortie en partition stricte

Entrée : Nuage de points $\mathcal{X} \subset \mathbb{R}^p$, seuil `min_cluster_size`, choix de poids ψ

Sortie : Clustering sur $\mathcal{X}$

- 1 : Construire la triangulation de DELAUNAY $\text{Del}(\mathcal{X})$.
 - 2 : Extraire les triangles de GABRIEL : triangles aigus de $\text{Del}(\mathcal{X})$ satisfaisant le test de vacuité, puis triangles obtus énumérés à partir des couples d'arêtes de DELAUNAY incidentes (voir PROP. 9).
 - 3 : Construire le graphe dual G_2 dont les sommets sont les arêtes $\tau = \{x_i, x_j\}$ apparaissant comme facettes d'au moins un triangle de GABRIEL.
 - 4 : Pour chaque triangle $\sigma = \{x_i, x_j, x_k\}$, relier (deux de) ses trois arêtes-facettes dans G_2 avec une fusion de poids $\rho(\sigma)$.
 - 5 : Calculer les scores de faces $S_\tau = \sum_{\sigma \supset \tau} \psi(\rho(\sigma))$ et les masses $m_\tau = S_\tau \sum_{x \in \tau} T_x^{-1}$.
 - 6 : Extraire un arbre couvrant minimal T_2 de G_2 par KRUSKAL.
 - 7 : Condenser T_2 avec le seuil `min_cluster_size` [8] et sélectionner les clusters par excès de masse.
 - 8 : Propager les étiquettes des clusters aux points par le vote pondéré (voir la section précédente).
 - 9 : Optionnellement, réaffecter les points non classés par 1-plus proche voisin parmi les points déjà étiquetés.
-

9.2.4 Résultats sur les huiles d'olive italiennes

Le jeu de données des huiles d'olive italiennes [94] contient 572 échantillons, chacun décrit par huit concentrations en acides gras. Ainsi le nuage $\mathcal{X} \subset \mathbb{R}^8$ est représenté par une matrice de taille 572×8 . Comme dans [17], nous avons centré puis normalisé (en norme ℓ^2) les colonnes de la matrice. Les données ont été mises à disposition publiquement par [95]. Les échantillons proviennent de neuf provinces italiennes, regroupées en trois macro-régions : Italie du Sud, Sardaigne, puis Centre-Nord.

HDBSCAN retrouve correctement les trois macro-régions, mais ne sépare pas les neuf provinces fines. La méthode PERSISTABLE de [17] est l'état-de-l'art pour l'identification des plus petites provinces : elle retrouve huit des neuf provinces (la Sicile n'est pas identifiée), mais ne classe directement que 279 points, soit environ 49% des données. Notre méthode [64] avec $K = 2$ retrouve également huit groupes interprétables (et c'est encore la Sicile qui échappe à l'identification, absorbée par les groupes de Calabre et de Pouilles du Nord), mais elle classe directement 412 points, soit environ 72% des données, avec $396/412 \approx 96.1\%$ d'étiquettes correctes.

Dans les deux tableaux suivants (TAB. 9.1 & TAB. 9.2), chaque case contient le résultat de PERSISTABLE, puis celui de HGP-Clusterer. La colonne 4 correspond à la Sicile, non identifiée.

L'extension exhaustive par 1-plus proche voisin des points non classés donne

TABLE 9.1 – Résultats partiels de PERSISTABLE et de HGP-Clusterer sur le jeu de données des huiles d’olive italiennes. La notation a/b indique PERSISTABLE/HGP-Clusterer.

PERS./HGP	1	2	3	4	5	6	7	8	9	Non classés
N. Apulia	12/24	0/0	0/0	–	0/0	0/0	0/0	0/0	0/0	13/1
Calabria	0/0	7/25	1/2	–	0/0	0/0	0/0	0/0	0/0	48/29
S. Apulia	0/0	0/0	100/145	–	0/0	0/0	0/0	0/0	0/0	106/61
Sicilia	3/6	0/2	0/1	–	0/0	0/0	0/0	0/0	0/0	33/27
Inl. Sard.	0/0	0/0	0/0	–	51/62	0/0	0/0	0/0	0/0	14/3
Coast S.	0/0	0/0	0/0	–	0/2	19/29	0/0	0/0	0/0	14/2
E. Ligur.	0/0	0/0	0/0	–	0/0	0/0	14/32	1/2	0/1	35/15
W. Ligur.	0/0	0/0	0/0	–	0/0	0/0	0/0	29/33	0/0	21/17
Umbria	0/0	0/0	0/0	–	0/0	0/0	0/0	0/0	42/46	9/5

521/572 $\approx$ 91,1% d’étiquettes correctes et un indice de RAND ajusté [96] (*Adjusted Rand Index*, ARI, en anglais) égal à 0,890. La version exhaustive de PERSISTABLE atteint 499/572 $\approx$ 87,2% et un ARI égal à 0,848.

9.2.5 Résultats sur SIPU

Le *benchmark* public SIPU [97], utilisé ici *via* CLUSTBENCH [98], regroupe des jeux de données synthétiques de formes et de tailles très variées. Les jeux admettant une vérité terrain multiple – et donc sujette à ambiguïté –, comme compound, flame, pathbased et r15, n’ont pas été retenus; worms_64 est également écarté à cause de sa dimension 64 (du fait du fléau de la dimension, la triangulation de DELAUNAY n’est pas calculable).

La comparaison avec HDBSCAN [8] est rigoureusement faite : on garde le même seuil minimal de percolation, $\text{min_cluster_size} = \sqrt{n}$, le même estimateur de densité $\hat{\rho} = 1/r$, et le même critère d’excès de masse ($\psi(t) = \frac{1}{t}$). Toutes choses égales par ailleurs, la seule différence est donc le type de connexité : connexité standard de graphe géométrique pour HDBSCAN, connexité par triangles de Čech pour HGP-Clusterer avec $K = 2$ [64].

Les résultats sont en TAB. 9.3. HGP-Clusterer améliore nettement l’ARI sur la plupart des jeux difficiles, en particulier a2, a3, d31, s2 et s3. Il classe aussi une proportion plus grande de points dans la plupart des cas, parce que la connexité triangulaire évite de construire des filaments instables (créant des “trous” dont les points à l’intérieur sont “perdus”). Une exception cependant : birch2, où HDBSCAN est presque parfait et où HGP-Clusterer fusionne intempestivement certains clusters. La raison en est que les clusters sont essentiellement filiformes et sont donc mieux identifiés avec de simples graphes. À

TABLE 9.2 – Résultats exhaustifs de PERSISTABLE et de HGP-Clusterer sur le jeu de données des huiles d’olive italiennes, après propagation aux points non classés. La notation a/b indique PERSISTABLE/HGP-Clusterer.

PERS./HGP	1	2	3	4	5	6	7	8	9	Non classés
N. Apulia	21/24	2/1	0/0	–	0/0	0/0	0/0	0/0	0/0	2/0
Calabria	0/1	50/52	3/2	–	0/0	0/0	1/1	0/0	0/0	2/0
S. Apulia	0/2	1/0	196/204	–	0/0	0/0	0/0	0/0	0/0	9/0
Sicilia	6/10	20/16	7/10	–	0/0	0/0	0/0	0/0	0/0	3/0
Inl. Sard.	0/0	0/0	0/0	–	65/65	0/0	0/0	0/0	0/0	0/0
Coast S.	0/0	0/0	0/0	–	2/2	31/31	0/0	0/0	0/0	0/0
E. Ligur.	0/0	0/0	0/0	–	0/0	0/0	41/44	2/5	0/1	7/0
W. Ligur.	0/0	0/0	0/0	–	0/0	0/0	0/0	47/50	0/0	3/0
Umbria	0/0	0/0	0/0	–	0/0	0/0	2/0	0/0	48/51	1/0

TABLE 9.3 – Résultats de HDBSCAN et de HGP-Clusterer sur les jeux de données SIPU. n désigne la taille du jeu de données, k le nombre de clusters, ARI l’indice de RAND ajusté, et “classés” la proportion de points affectés à un cluster.

Jeu	Vérité terrain		HDBSCAN			HGP-Clusterer		
	n	k	k	ARI	Classés	k	ARI	Classés
a1	3 000	20	17	0.745	94.9%	17	0.778	97.7%
a2	5 250	35	33	0.762	92.1%	32	0.834	96.2%
a3	7 500	50	43	0.696	95.0%	45	0.831	97.1%
aggregation	788	7	5	0.809	100.0%	5	0.809	100.0%
birch1	100 000	100	98	0.215	79.7%	100	0.298	83.1%
birch2	100 000	100	100	0.996	99.7%	84	0.441	83.9%
d31	3 100	31	27	0.659	90.0%	30	0.835	94.5%
jain	373	2	3	0.935	98.4%	3	0.935	98.7%
s1	5 000	15	15	0.961	97.6%	15	0.976	99.0%
s2	5 000	15	15	0.783	88.9%	15	0.842	91.9%
s3	5 000	15	15	0.251	65.9%	15	0.418	77.2%
s4	5 000	15	15	0.258	67.4%	15	0.284	69.6%
spiral	312	3	3	1.000	100.0%	3	1.000	100.0%
unbalance	6 500	8	8	1.000	99.9%	8	1.000	100.0%
worms_2	105 600	35	15	0.055	74.2%	33	0.076	66.4%

noter que poser le bon estimateur $\hat{\rho} = 1/r^2$ résout le problème et HGP-Clusterer devient alors quasi-parfait pour identifier le bon nombre de clusters.

9.3 Lorsque la mosaïque de DELAUNAY n'est plus disponible : le complexe de VIETORIS–RIPS

La construction exacte des chapitres précédents repose sur le complexe de Čech, puis sur son amincissement par la mosaïque de DELAUNAY d'ordre K et le K -graphe de GABRIEL. C'est la bonne voie – tant théorique que pratique – lorsque les données sont effectivement un nuage euclidien de dimension modérée (et que le modèle de HARTIGAN est pertinent). Mais il existe des situations où cette voie n'est plus possible.

D'abord, lorsque les données ne sont pas dans l'espace euclidien $\mathbb{R}^p$. L'on peut, *exempli gratia*, ne disposer que d'une matrice de distances, éventuellement creuse (ou *sparse* en anglais). Dans ces cas, toutes les notions de boules minimales, de cellule de VORONOÏ ou de mosaïque de DELAUNAY tombent.

Une seconde raison est algorithmique : même lorsque les données sont euclidiennes, la grande dimension rend la mosaïque de DELAUNAY rapidement incalculable en pratique. La triangulation de DELAUNAY ordinaire peut déjà avoir une complexité au pire cas $\mathcal{O}(n^{\lceil p/2 \rceil})$ dans $\mathbb{R}^p$ [29]. Il faut donc faire appel à des constructions de remplacement qui permettent de faire tourner l'algorithme dans des cadres moins favorables. Le complexe de VIETORIS–RIPS est une possibilité assez naturelle.

DÉFINITION 32 : COMPLEXE DE VIETORIS–RIPS [29, 62]

Soit $(\mathcal{X}, d)$ un espace métrique fini et soit $r \geq 0$. Le complexe de VIETORIS–RIPS de rayon r est le complexe simplicial

$$\text{VR}(\mathcal{X}, r) \triangleq \{\sigma \subseteq \mathcal{X} \mid \forall x, x' \in \sigma, d(x, x') \leq 2r\}.$$

Autrement dit, σ est un simplexe de $\text{VR}(\mathcal{X}, r)$ si et seulement si tous ses sommets sont deux à deux reliés dans le graphe seuil

$$G_r = (\mathcal{X}, E_r), \quad E_r \triangleq \{\{x, x'\} \subseteq \mathcal{X} \mid d(x, x') \leq 2r\}.$$

Remarque Les complexes de Čech et VIETORIS–RIPS ont même 1-squelette (graphe sous-jacent) : le graphe géométrique seuil. De plus, le complexe de VIETORIS–RIPS est le plus grand complexe constructible sur ce graphe seuil (dès qu'une clique est présente, le simplexe associé apparaît); on dit qu'il est le complexe de drapeau (ou *flag complex* en anglais) du graphe géométrique G_r .

L'on pourrait tout à fait définir de façon plus générale le complexe de VIETORIS–RIPS

sur un graphe pondéré en considérant que les arêtes absentes ont un poids $+\infty$ pour pouvoir ainsi travailler avec des matrices de distance creuses.

FAIT (CONNU) 13 : ENCADREMENT ČECH–RIPS DANS $\mathbb{R}^p$ [29]

Soit $\mathcal{X} \subset \mathbb{R}^p$ un nuage localement fini. Pour tout $r \geq 0$,

$$\boxed{\check{C}(\mathcal{X}, r) \subseteq \text{VR}(\mathcal{X}, r) \subseteq \check{C}(\mathcal{X}, \alpha_p r)}, \quad \alpha_p \triangleq \sqrt{\frac{2p}{p+1}} \leq \sqrt{2}.$$

En particulier, tout K -polyèdre de $\check{C}(\mathcal{X}, r)$ est contenu dans un K -polyèdre de $\text{VR}(\mathcal{X}, r)$, et tout K -polyèdre de $\text{VR}(\mathcal{X}, r)$ est contenu dans un K -polyèdre de $\check{C}(\mathcal{X}, \alpha_p r)$.

Preuve. La première inclusion est immédiate : les complexes ont même 1-squelette, et le complexe de VIETORIS–RIPS est le plus grand possible (*flag complex*). La seconde inclusion est une conséquence du théorème de JUNG [99] : un ensemble de diamètre au plus $2r$ dans $\mathbb{R}^p$ est contenu dans une boule de rayon au plus $\alpha_p r$. $\square$

Le FAIT 13 permet de voir en le complexe de VIETORIS–RIPS une approximation contrôlée du complexe de Čech dans le cas euclidien. À noter que cette approximation devient cependant de plus en plus mauvaise au fur et à mesure que la dimension p croît.

Le complexe de VIETORIS–RIPS fournit aussi une extension naturelle pour le cas métrique général.

PROPOSITION 11 : LES K -POLYÈDRES DE RIPS COMME PERCOLATION DE CLIQUES

Fixons $r \geq 0$ et notons G_r le graphe seuil associé à $\text{VR}(\mathcal{X}, r)$. Les K -simplexes de $\text{VR}(\mathcal{X}, r)$ sont exactement les cliques de taille $K + 1$ de G_r . Les K -polyèdres non triviaux de $\text{VR}(\mathcal{X}, r)$ correspondent donc aux usuelles composantes de *clique percolation* [65].

L'intérêt pratique majeur de VIETORIS–RIPS est qu'il ouvre la porte à des implémentations massivement parallèles, en particulier sur GPU. La géométrie euclidienne exacte disparaît au profit de quatre opérations de graphes, dont les trois premières (qui représentent le coût véritable de l'algorithme) sont massivement parallélisables.

1. **Construction du graphe de voisinage.** Si les données sont euclidiennes mais de grande dimension, on peut construire un graphe (approché) de voisinages. Cette étape se parallélise naturellement. Si l'entrée est déjà une matrice creuse (*sparse* en anglais), cette étape est simplement sautée.
2. **Énumération des cliques.** Pour $K = 2$, il suffit d'énumérer les triangles du graphe. C'est le cas le plus favorable : les triangles se calculent par intersections de listes

d'adjacence triées. Pour K fixé plus grand, on peut énumérer les $(K + 1)$ -cliques par intersections récursives de voisinages. La complexité dépend alors du nombre réel de cliques du graphe parcimonieux (*sparse* en anglais), non de $\binom{n}{K+1}$.

3. **Construction du graphe dual.** Chaque $(K + 1)$ -clique génère $K + 1$ faces de taille K . L'opération consiste à produire ces faces, les trier ou les hacher, agréger leurs poids S_τ , puis écrire les arêtes du graphe dual.
4. **Percolation, arbre couvrant et condensation.** Une fois le graphe dual construit, l'arbre couvrant minimum peut être identifié *via* une simple structure UNION-FIND [21] couplée à un algorithme de KRUSKAL [19]. Ou de façon plus élaborée (et parallélisable) avec un algorithme de type BORŮVKA.

Illustrer Vietoris–Rips / Čech.

9.4 La richesse structurelle de la mosaïque d'ordre K : vers la réduction de dimension ?

Au cours du chapitre 8 précédent, la mosaïque de DELAUNAY d'ordre K a été introduite pour des raisons algorithmiques : elle permet d'extraire un K -graphe de GABRIEL, puis un K -arbre couvrant minimal, sans avoir à parcourir le complexe de Čech complet.

Ainsi, pour la tâche qu'est le clustering hiérarchique, une "compression" au moyen d'un arbre couvrant suffit à reconstruire toutes les fusions successives des K -polyèdres, et finalement la hiérarchie des amas discrets de forte densité K -NN dans le modèle de HARTIGAN.

Mais cet objet est bien plus riche et contient beaucoup plus d'information quant à la structure des données $\mathcal{X}$ que la simple hiérarchie des amas de forte densité.

La question qui touche à la structuration automatique de données, champ plus vaste que le simple clustering, est la suivante :

La mosaïque de DELAUNAY d'ordre K permettrait-elle aussi d'obtenir un algorithme de réduction de dimension ?

Plusieurs analogies avec le travail déjà établi seraient à faire :

- **le cadre mathématique.** De même que le modèle de HARTIGAN nous fournissait un cadre statistique satisfaisant pour le problème de clustering hiérarchique, il nous faudrait un cadre mathématique tout aussi rigoureux pour le problème de réduction de dimension. L'"adversaire" du point suivant nous semble proposer un début de réponse.
- **L'"adversaire" état-de-l'art.** De même que HDBSCAN, lointain descendant du Single-Linkage, fut l'algorithme concurrent naturel (puisque état-de-l'art) auquel se comparer ; pour la réduction de dimension, la place est occupée par UMAP [100]. Le cadre mathématique dans lequel se placent les auteurs de UMAP donne un début

de réponse au point précédent : ils supposent les données de $\mathbb{R}^p$ se répartissant le long d'une sous-variété de dimension $q < p$, et uniformément (pour la métrique riemannienne induite).

Cette observation suggère une direction naturelle : ne plus utiliser la mosaïque seulement pour extraire une hiérarchie, mais comme support pour une réduction de dimension. L'idée n'est pas d'annoncer ici un algorithme fini – ce travail est en cours – mais de préciser le programme. Il s'agirait de construire une sorte de UMAP d'ordre supérieur : remplacer le graphe flou des voisins par une structure issue de la mosaïque de DELAUNAY d'ordre K , puis chercher une représentation en basse dimension qui préserve non seulement des proximités binaires, mais aussi des relations locales portées par des simplexes.

9.4.1 UMAP : *Uniform Manifold Approximation and Projection for Dimension Reduction*

Rappelons d'abord le fonctionnement d'UMAP, dans la version utile pour cette analogie.

FAIT (CONNU) 14 : PRINCIPE ALGORITHMIQUE D'UMAP [100]

UMAP construit d'abord un graphe orienté des k_{nn} plus proches voisins. Pour chaque point x_i , il choisit une distance locale minimale ρ_i et une échelle $\sigma_i > 0$, puis définit, pour x_j voisin de x_i ,

$$p_{j|i} = \exp\left(-\frac{\max\{0, d(x_i, x_j) - \rho_i\}}{\sigma_i}\right).$$

Les poids orientés sont ensuite symétrisés par union floue :

$$w_{ij} = p_{j|i} + p_{i|j} - p_{j|i}p_{i|j}.$$

Dans l'espace latent, on cherche des points $y_i \in \mathbb{R}^q$ et l'on pose typiquement

$$\tilde{w}_{ij}(Y) = \frac{1}{1 + a\|y_i - y_j\|^{2b}},$$

où $a, b > 0$ sont choisis à partir des paramètres de l'algorithme. L'optimisation minimise alors l'entropie croisée entre les poids w_{ij} du graphe de haute dimension et les poids $\tilde{w}_{ij}$ du plongement :

$$\mathcal{L}_{\text{UMAP}}(Y) = -\sum_{i < j} [w_{ij} \log \tilde{w}_{ij}(Y) + (1 - w_{ij}) \log(1 - \tilde{w}_{ij}(Y))].$$

Les faiblesses de UMAP Le point important est le suivant : malgré son recours à un vocabulaire topologique, UMAP exploite essentiellement un graphe. Le complexe simplicial flou qu’il construit est gouverné par son 1-squelette, c’est-à-dire par des relations binaires. Les interactions d’ordre supérieur n’y apparaissent qu’indirectement *via* des relations de voisinage deux à deux. La mosaïque d’ordre K , elle, encode nativement des configurations de $K + 1$ points, leurs rayons de naissance, leurs cellules duales et leurs adjacences. Elle donne donc un candidat naturel plus riche que le graphe d’UMAP.

On voit ainsi apparaître deux difficultés

1. **Le réducteur.** Supposons que l’on dispose de la mosaïque de DELAUNAY d’ordre K sur $\mathcal{X}$... comment construire proprement le réducteur ? Pour répondre proprement à cette question, il est d’abord nécessaire d’identifier exactement le bon cadre mathématique de travail.
2. La seconde difficulté est algorithmique : en grande dimension, il est déraisonnable de vouloir calculer exactement la mosaïque de DELAUNAY d’ordre K . UMAP doit une bonne partie de son efficacité au fait qu’il approxime rapidement un graphe k -NN. Un analogue d’ordre supérieur devra donc approximer la mosaïque.

Synthèse Ce chapitre vient clore la deuxième partie de ce manuscrit en apportant les réponses pratiques nécessaires à l’utilisation concrète de la généralisation du Single-Linkage, baptisée HGP-Clusterer.

D’une part, l’algorithme a été rendu compatible avec les protocoles et demandes usuels pour le clustering : avoir une partition stricte (système de vote pondéré en post-traitement). D’autre part, l’implémentation géométrique exacte pour $K = 2$, qui repose sur la seule triangulation de DELAUNAY (et non la mosaïque d’ordre 2), valide empiriquement la supériorité de notre approche sur des jeux de données réels et synthétiques face à des méthodes de l’état-de-l’art telles que HDBSCAN et PERSISTABLE.

Lorsque le calcul géométrique exact devient prohibitif en raison du fléau de la dimension, ou lorsque les données évoluent dans des espaces non euclidiens, nous avons vu que le complexe de VIETORIS-RIPS (et la percolation de cliques associée) offre une alternative d’approximation robuste et massivement parallélisable à la filtration de Čech.

Enfin, au-delà du partitionnement, la richesse structurelle de la mosaïque de DELAUNAY d’ordre K invite à repenser la réduction de dimension à l’aune de cet objet. En transposant les principes d’UMAP aux interactions d’ordre supérieur, cette direction de recherche nous semble prometteuse.

TROISIÈME PARTIE

Vers des données davantage structurées

Après les nuages de points Lors des deux premières parties de ce manuscrit, nous nous sommes concentrés volontairement sur un cadre assez minimal où les données étaient des points de l'espace euclidien pour lesquels nous cherchions à retrouver la hiérarchie géométrique de la distribution. Ce minimalisme nous a permis de faire émerger naturellement l'algorithme du Single-Linkage, de cerner précisément ses atouts & ses limites, avant de le généraliser proprement au moyen d'interactions d'ordre supérieur.

En pratique, beaucoup de jeux de données possèdent une structure plus riche. Nous avons déjà esquissé quelques possibilités lorsque les données sont dans un espace métrique général en § 9.3.

Tout n'est cependant pas perdu : au moyen de deux cas d'étude pratiques, très différents de nature et apparemment bien éloignés de notre modèle de départ, nous montrerons que les idées principales développées dans la partie II demeurent, à savoir :

1. Les interactions d'ordre supérieur sont la voie naturelle pour gagner en robustesse ⁱ⁾.
2. C'est le phénomène de percolation qui est au cœur des performances théoriques de ces algorithmes.

ⁱ⁾Le terme de robustesse s'entend à chaque fois dans un sens propre au contexte : robustesse face au phénomène de frustration pour les dynamiques de clusters ; robustesse de l'algorithme face à des images présentant une granularité locale très forte dans le cas du traitement d'image.

Deux formes de structure La partie III commence avec le **Chapitre 10**, qui est une brève introduction pour donner au lecteur le contexte de chacun des deux problèmes abordés et lui rappeler quelques bases dans chacun des deux domaines. Les deux situations étudiées dans cette troisième partie sont les suivantes :

1. **Chapitre 11.** La première situation est celle des graphes. Conformément à l’usage en théorie des graphes, l’on appellera *détection de communautés* le clustering de nœuds (les bons clusters à identifier étant les communautés, données par exemple par un modèle génératif comme celui de SANKARARAMAN–BACCELLI [101]). Nous définissons un cadre bayésien propre pour une certaine famille de graphes (non-orientés, pondérés, signés, avec éventuellement des attributs attachés aux nœuds). Dans ce cadre statistique, l’observation des données permet de définir une loi de probabilité *a posteriori* sur la “véritable” configuration de communautés. Nous introduisons alors des dynamiques de clusters de type méthodes de Monte-Carlo par chaînes de MARKOV [102] (*MARKOV Chain Monte Carlo*, ou MCMC en anglais). La classe de dynamiques introduite généralise SWENDSEN–WANG [103] en prenant en compte des interactions d’ordre supérieur. À ce point du chapitre, une analogie troublante avec notre chapitre 7 apparaît : c’est encore le phénomène de percolation (au cœur de la dynamique de clusters) qui nous permet d’obtenir des résultats théoriques sur la détectabilité des communautés.
2. **Chapitre 12.** La seconde situation est celle du traitement d’image [104-106]. En traitement, le clustering des pixels possède aussi son nom propre : on parle de *segmentation* (et de *segmentation sémantique* lorsqu’on fait de la classification, c’est-à-dire qu’on différencie les étiquettes). Les approches bayésiennes par champ de MARKOV ont d’ailleurs joué un rôle important en segmentation d’image [107]. Plus précisément, nous nous intéresserons à la détection de fissures sur image. Notre approche consiste à construire un graphe sur les sommets du graphe (les pixels candidats) et le réseau de fissures à extraire est un sous-graphe. Nous reprenons les idées du filtre de FRANGI [108], vu comme une fonction des pixels V vers $[0; 1]$ indiquant la vraisemblance d’appartenance dudit pixel à une structure tubulaire. Si les méthodes d’apprentissage profond dominent aujourd’hui la segmentation de fissures, elles restent dépendantes des annotations et peuvent se dégrader lors de changements de domaine ou lorsque les données ne correspondent pas à la distribution sur laquelle l’apprentissage s’est fait. L’on observe aujourd’hui un changement sensible de paradigme marqué par un retour à des méthodes plus géométriques [109]. Nous suivons cette voie complémentaire en généralisant le filtre de FRANGI à un graphe de similarité entre pixels [110, 111]. L’extraction se fait au moyen d’une méthode comparable à celle du Single-Linkage. L’intégration d’interactions d’ordre supérieur *via* un *hypergraphe* de FRANGI permet d’obtenir des résultats meilleurs et plus stables sur des images particulièrement difficiles.

CHAPITRE 10

Introduction

Lors des deux premières parties de ce manuscrit, nous avons un cadre géométrique où les données étaient principalement des nuages de points plongés dans l'espace euclidien $\mathbb{R}^p$ de dimension p . L'objectif de cette troisième partie est de montrer que les idées de ce cadre minimaliste peuvent se transposer à des données bien davantage structurées que par leur seule géométrie. Nous nous intéressons à deux cas pratiques : des graphes (pondérés et signés) et des images (multimodales).

Ce changement de nature des données justifie l'emploi de méthodes spécifiques, issues de la physique statistique et du traitement du signal, et qui feront l'objet des deux chapitres suivants 11 & 12.

10.1 Détection de communautés et méthodes de Monte-Carlo

Les graphes sont des objets naturels pour modéliser de très nombreux problèmes ; il est donc nécessaire de pouvoir les analyser convenablement [112]. Une des premières tâches d'analyse que l'on peut demander est de regrouper des nœuds V présentant des comportements communs ; ces clusters sont appelés *communautés* en théorie des graphes. Ainsi est apparu le terme de détection de communautés sur graphe [113]. Dit autrement, on cherche à faire du clustering sur l'ensemble des sommets V . L'on supposera tout au long de ce chapitre et du suivant que le nombre de communautés $K \in \mathbb{N}^*$ est donné à l'avance.

10.1.1 De l'optimisation à l'échantillonnage de GIBBS

Pour faire de la détection de communautés sur graphe, des méthodes dont les idées sont issues de la physique statistique ont été proposées [114, 115]. Elles ont l'avantage d'être intuitives, élégantes mathématiquement, ainsi que de pouvoir être analysées théoriquement. Ces méthodes formulent l'inférence des communautés non pas comme une simple optimisation (où il s'agirait de trouver la “meilleure” configuration de communautés), mais comme un problème d'échantillonnage d'une certaine distribution de probabilité sur l'espace des configurations

$$\mathcal{S}_K \triangleq \{1; \dots; K\}^V.$$

La loi cible, notée μ , prend souvent la forme d'une mesure de (BOLTZMANN-)GIBBS [116] :

$$\mu(\sigma) = \frac{1}{Z} \exp(-H(\sigma)),$$

où $H(\sigma)$ désigne l'énergie (ou le coût) de la configuration σ , pénalisant les configurations à forte énergie en leur attribuant une faible probabilité. Le terme de normalisation $Z \triangleq \sum_{\sigma \in \mathcal{S}_K} \exp(-H(\sigma))$ est appelé *fonction de partition*.

La taille de l'espace des configurations ($K^{|V|}$) croît de façon exponentielle avec le nombre de nœuds ; l'exploration complète de $\mathcal{S}_K$ devient impossible en pratique.

Il s'agit donc de pouvoir convenablement échantillonner selon la mesure de GIBBS, c'est-à-dire d'avoir un algorithme qui tire des configurations σ selon leur probabilité $\mu(\sigma)$ de GIBBS (*i.e.* un *GIBBS sampler* en anglais).

10.1.2 Le théorème ergodique et les chaînes de MARKOV

Pour échantillonner de la sorte, l'on recourt souvent à des méthodes de Monte-Carlo par chaînes de MARKOV (*MARKOV Chain Monte Carlo*, ou MCMC en anglais) [102, 117].

Le principe consiste à construire une chaîne de MARKOV $(\Sigma_t)_{t \in \mathbb{N}}$ définie par un noyau de transition P , telle que sa distribution stationnaire soit exactement la mesure cible μ . Cette invariance est souvent obtenue en imposant une condition de réversibilité locale (*detailed balance* en anglais).

Soit ϕ une fonction d'intérêt sur les configurations dont on cherche à évaluer l'espérance $\mathbb{E}_{\Sigma \sim \mu}[\phi(\Sigma)]$. Grâce au théorème ergodique [117], si la chaîne simulée est irréductible et apériodique, cette espérance peut être estimée par la moyenne empirique sur les visites de (Σ_t) . En effet, presque sûrement

$$\lim_{T \rightarrow \infty} \frac{1}{T} \sum_{t=1}^T \phi(\Sigma_t) = \sum_{\sigma \in \mathcal{S}_K} \phi(\sigma) \mu(\sigma).$$

Pour revenir plus spécifiquement à la détection de communautés, parmi les méthodes MCMC, les plus simples ont une dynamique locale : à chaque pas, elles choisissent un nœud au hasard, puis changent son étiquette (transition de σ vers σ' , différant de σ seulement sur le nœud choisi). Cette transition se fait aléatoirement, selon une distribution qui permet de respecter la réversibilité locale. On dit en anglais de telles dynamiques qu'elles opèrent par *single-spin update*. Ainsi font les dynamiques de METROPOLIS-HASTINGS et de GLAUBER [118].

Un algorithme fameux de détection de communautés, dit de LOUVAIN [119]ⁱ⁾, consiste à maximiser une certaine *modularité*, qui n'est autre que l'opposé d'une énergie sur les configurations. L'efficacité de l'algorithme de LOUVAIN vient du fait qu'il applique

ⁱ⁾Pour une approche plus physique statistique, voir le *Constant POTTS Model* [115], intégré à un raffinement de l'algorithme de LOUVAIN : l'algorithme de LEIDEN [120].

d’abord des changements locaux de type *single-spin update*, puis une fois un minimum local d’énergie trouvé, il procède à de macro-changements en regroupant ensemble tous les nœuds d’un même cluster.

10.1.3 Dynamiques de clusters face à la frustration

Le théorème ergodique garantit la convergence presque sûre. Le problème en pratique vient de la vitesse à laquelle cette convergence se produit [102] (le temps de mélange de la chaîne de MARKOV, ou *mixing time* en anglais).

Lorsque le système présente de fortes corrélations spatiales, les dynamiques locales classiques peinent à explorer l’espace des configurations et se retrouvent piégées dans des *minima* locaux d’énergie (souvent très médiocres par rapport au minimum global) [121]. L’algorithme de SWENDSEN–WANG [103], généralisé par EDWARDS & SOKAL [122], s’appuie sur le modèle de percolation des amas aléatoires (*random-cluster model*) [123, 124] pour créer des dynamiques de clusters.

Toutefois lorsque le réseau comporte des interactions concurrentes, *e.g.* dans le cas que nous allons étudier : des arêtes tant attractives (ferromagnétiques) que répulsives (anti-ferromagnétiques), le phénomène dit de *frustration* apparaît [125, 126]. Ces informations locales contradictoires bloquent la construction de clusters pertinents et gèlent la dynamique. Pour surmonter cet obstacle, inspirés par les travaux de KANDEL, BEN-AV ET DOMANY [127], nous proposerons d’étendre la dynamique de SWENDSEN–WANG en y intégrant des interactions d’ordre supérieur.

10.1.4 La percolation comme garantie théorique pour le recouvrement des communautés

C’est ici que le lien avec les deux parties précédentes du manuscrit apparaît plus clairement : les interactions d’ordre supérieur *via* une dynamique triangulaire permettent de réduire la frustration.

Mieux encore : au sein du cadre bayésien que nous aurons rigoureusement construit, la détection des communautés n’est théoriquement possible qu’à la condition que la dynamique de clusters percole. De même qu’en § 7, le phénomène de percolation dépend du type d’interaction. Avantage une nouvelle fois aux interactions d’ordre supérieur !

10.2 Extraction de réseaux de fissures au sein d’images : le retour vers des modèles géométriques plus explicites ?

Le second domaine abordé dans cette partie concerne le traitement d’image [104-106], motivé par l’extraction automatique de réseaux de fissures.

Il y a notamment deux raisons qui font que l'établissement d'une cartographie fiable de ces structures linéiques est crucial : pour l'inspection des infrastructures civiles (e.g. des piles de pont sur lesquelles le réseau de fissures représenterait un risque [128]) et la surveillance des aléas géologiques (évacuation d'une zone en cas de risque de glissement de terrain) [129, 130].

10.2.1 Les limites de l'apprentissage profond en extraction de réseaux

Actuellement, l'apprentissage profond (*deep learning* en anglais) domine la vision par ordinateur, avec des architectures éprouvées comme le U-Net [131], DeepCrack [132], les *transformers* [133] ou les modèles de diffusion [134]. Toutefois, leur utilisation se heurte à des limites pratiques sévères, récemment soulignées par ZHANG *et al.* [109] :

1. Un coût prohibitif pour la constitution de bases de données annotées par des experts [135].
2. Plus fâcheux encore : une capacité de généralisation qui s'effondre fréquemment face à des changements de domaine [109] (*domain shifts* en anglais).

Le second point peut être dû à de multiples causes allant de la variation des capteurs à celle des matériaux observés, en passant par les différences de conditions d'observation [109].

10.2.2 Le retour à des modèles physiques? Du pixel au graphe spatial

Ces contraintes justifient une voie complémentaire : le retour (au moins partiellement) à des modèles géométriques explicites (*model-based*), s'affranchissant de (ou limitant) la phase d'entraînement (le modèle est dit alors *training-free* en anglais).

Historiquement, avant l'avènement du *deep learning*, ce sont ces modèles qui prévalaient. Ainsi sont apparus des filtres (c'est-à-dire des fonctions de l'ensemble des pixels dans $[0; 1]$) fondés sur l'analyse de la matrice hessienne de l'image. Citons *exempli gratia* le filtre de SATO [136]. Le plus fameux est peut-être le filtre de FRANGI [108] qui analyse de façon multi-échelle les valeurs propres de la matrice hessienne ; le filtre de FRANGI est un standard pour rehausser (puis détecter) les structures tubulaires.

Le § 12 propose de généraliser ce filtre en déplaçant la réponse, de pixélique qu'elle était, vers un (hyper-)graphe spatial de similarité entre paires/triplets de pixels.

L'information contenue dans une paire/un triplet de pixels est beaucoup plus riche que la simple réponse pixélique ; par exemple, si deux pixels sont chacun dans une structure tubulaire, rien n'indique que ce soit la même structure si l'on ne regarde le bon alignement des deux structures.

Une fois cette information bien encodée dans un graphe de similarité, baptisé graphe de FRANGI, nous avons développé un algorithme – lointain cousin de HGP-Clusterer

– pour l'extraction du réseau de fissures. Cet algorithme s'appuie ainsi sur le calcul d'un arbre minimum couvrant élagué par une mesure de centralité d'intermédiarité (*betweenness centrality* en anglais) [112, 137].

Un grand avantage de cette méthode est sa flexibilité : elle intègre très naturellement la multi-modalité au niveau des opérateurs différentiels (images optiques ou radar ; reconstruction photogrammétrique pour ajouter une modalité de profondeur, *etc.*).

Une nouvelle fois, nous montrons que nous pouvons utilement tirer parti des interactions d'ordre supérieur (composantes triangle-connexes) pour filtrer les artefacts sur des images fortement texturées.

Un cadre bayésien pour la détection de communautés sur graphes

Ce chapitre s'intéresse au cas où les données possèdent une structure de graphe (non orienté, pondéré signé, avec potentiellement des attributs sur les sommets). Dans le domaine des graphes, on ne parle plus alors de clustering (sur les nœuds) mais de *détection de communautés sur graphes* [113]. L'objectif général est de partitionner les sommets en groupes/clusters, appelés communautés, de sorte que les sommets d'un même groupe aient des profils d'interaction similaires (e.g. fortement reliés entre eux : cas *assortatif*).

Pour analyser correctement les graphes, l'on a besoin de modèles génératifs probabilistes [112]. Le modèle le plus simple présentant des structures de communautés est peut-être le modèle à blocs stochastiques [138-141] : les communautés sont des étiquettes cachées qui influencent la loi des arêtes du graphe observé. Dans les graphes spatiaux (les sommets portent en attribut une position), l'information disponible est alors à la fois combinatoire et géométrique, rendant la détection de communauté beaucoup plus difficile [101, 142].

L'objectif de ce chapitre est triple.

1. Toute la première partie consiste à donner un cadre bayésien rigoureux au problème de détection de communautés sur graphes : *a priori*, canal d'observation, postérieure, algorithmes, tirages au hasard (*random guess* en anglais), recouvrement partiel (*weak/partial recovery* en anglais).
2. La seconde partie introduit une famille de dynamiques de clusters généralisant SWENDSEN-WANG [103, 122]. Ces dynamiques laissent invariante la postérieure (lorsqu'elle s'écrit comme une mesure de GIBBS) et fournissent donc des couplages exploitables en pratique et en théorie.
3. La troisième partie applique notre cadre bayésien au cas particulier du modèle de SANKARARAMAN-BACCELLI [101] et montre qu'on peut ainsi très simplement

retrouver leurs résultats. Vu depuis notre cadre bayésien, leur théorème principal est retrouvé en appliquant un simple couplage SWENDSEN–WANG classique. Nous expliquons ensuite comment une dynamique triangulaire permet d’obtenir des bornes plus fines (que nous calculons exactement dans le cas particulier de la grille triangulaire).

Contributions Ce chapitre reprend et affine un premier travail préparatoire consacré aux dynamiques de clusters d’ordre supérieur pour la détection de communautés dans des graphes euclidiens [143]. Ce travail fera l’objet d’une soumission à un journal [144].

Remarques

1. Pour alléger les notations, la dépendance en n (le nombre de sommets du graphe) sera parfois omise. Ainsi, l’on écrira parfois $V, E, \Sigma, W, \mu_0, \mu_{X,W}$ au lieu de $V_n, E_n, \Sigma_n, W_n, \mu_{0,n}, \mu_{n,X_n,W_n}$. Les résultats asymptotiques seront toujours entendus lorsque $|V_n| \rightarrow \infty$.
2. Nous reprendrons dans ce chapitre l’usage courant en statistiques d’écrire les variables aléatoires en majuscules et leur réalisation en minuscule; il en va ainsi des attributs (X et x), des configurations (Σ et σ) ou encore des poids des arêtes (W et w).
3. L’on supposera que tous les espaces introduits ($W_n, \mathcal{X}_n, \text{etc.}$) sont boréliens.

11.1 Cadre bayésien général

11.1.1 Modèle probabiliste, postérieure et algorithmes

11.1.1.1 L’espace produit probabilisé

Soit $n \geq 1$ un entier représentant le nombre de sommets d’un graphe et

$$V_n = \{1, \dots, n\}$$

son ensemble de sommets. On fixe aussi un ensemble d’arêtes potentielles (non orientées)

$$E_n \subseteq \binom{V_n}{2},$$

et un ensemble de communautés (on parle de l’*étiquette* d’un sommet pour désigner sa communauté; *label* en anglais)

$$S_K = \{1, \dots, K\}, \quad K \geq 2.$$

L’espace des configurations est

$$\mathcal{S}_n = (S_K)^{V_n}$$

et une configuration $\sigma = (\sigma_i)_{i \in V_n} \in \mathcal{S}_n$ peut être vue comme une fonction $V_n \rightarrow S_K$ des sommets vers les communautés.

L'on se restreindra au cours de ce chapitre à des poids d'arêtes prenant leur valeur dans $W \subseteq \mathbb{R} \cup \{\pm\infty\}$ mais les résultats pourraient tout aussi bien s'appliquer pour n'importe quel espace mesurable.

Signification du poids $w \in W$ d'une arête Un poids positif indique une tendance à avoir la même étiquette, un poids négatif indique une tendance à avoir des étiquettes différentes.

DÉFINITION 33 : MODÈLE BAYÉSIEN DE DÉTECTION DE COMMUNAUTÉS

Un modèle bayésien de détection de communautés est la donnée, pour chaque n , des objets suivants :

1. Un espace mesurable d'attributs sur les sommets $\mathcal{X}_n$ (*features* en anglais) et une variable

$$X_n \in \mathcal{X}_n$$

de loi ν_n .

2. Un *a priori* sur les configurations, éventuellement dépendant des attributs,

$$\mu_{0,n}(\mathrm{d}\sigma \mid x), \quad \sigma \in \mathcal{S}_n.$$

Lorsque l'*a priori* ne dépend pas de x , on écrit simplement $\mu_{0,n}$.

3. Un canal d'observation

$$Q_n(\mathrm{d}w \mid x, \sigma)$$

de $\mathcal{X}_n \times \mathcal{S}_n$ vers W^{E_n} .

La loi jointe de (X_n, Σ_n, W_n) est

$$\mathbb{P}_n(\mathrm{d}x, \mathrm{d}\sigma, \mathrm{d}w) = \nu_n(\mathrm{d}x) \mu_{0,n}(\mathrm{d}\sigma \mid x) Q_n(\mathrm{d}w \mid x, \sigma). \quad (11.1)$$

L'observation disponible est

$$\mathcal{O}_n = (X_n, W_n)$$

et les communautés à recouvrer sont données par

$$\Sigma_n.$$

C'est cette "vérité cachée" Σ_n qui est l'objectif à retrouver en détection de communautés.

Dans les modèles où les arêtes sont conditionnellement indépendantes, le canal se

factorise sous la forme

$$Q_n(dw \mid x, \sigma) = \prod_{e=\{i,j\} \in E_n} Q_{e,n}(dw_e \mid x_i, x_j, \sigma_i, \sigma_j). \quad (11.2)$$

C'est ce genre de modèles que nous allons voir en pratique, et que l'on peut écrire de façon équivalente

$$W_e = f_e(X_i, X_j, \Sigma_i, \Sigma_j, U_e),$$

où le "hasard" est donné par des variables auxiliaires $(U_e)_{e \in E_n}$, indépendantes du reste.

Postérieure Il existe alors une loi conditionnelle régulière de Σ_n sachant l'observation. On la note

$$\mu_{n,x,w}(d\sigma) = \mathbb{P}_n[\Sigma_n \in d\sigma \mid X_n = x, W_n = w]. \quad (11.3)$$

Lorsque Q_n admet une densité $q_n(w \mid x, \sigma)$ par rapport à une mesure de référence, on obtient

$$\mu_{n,x,w}(\sigma) = \frac{1}{Z_n(x, w)} \mu_{0,n}(\sigma \mid x) q_n(w \mid x, \sigma). \quad (11.4)$$

Où la constante $Z_n(x, w)$ normalise la mesure (dans le cas des mesures de GIBBS, on parle de fonction de partition).

L'architecture de notre modèle bayésien est résumée en FIG. 11.1 ci-dessous.




FIGURE 11.1 : Modèle bayésien général : l'*a priori* et le canal d'observation induisent une loi jointe, puis une postérieure. La détection consiste à produire une configuration à partir de l'observation.

11.1.2 Algorithmes et tirages au hasard

Dans le cadre bayésien que l'on vient de voir, il est alors possible de définir un algorithme τ , vu comme une fonction mesurable des observations X_n, W_n et d'un hasard interne U .

DÉFINITION 34 : ALGORITHME POUR LA DÉTECTION DE COMMUNAUTÉS

Un algorithme de détection de communautés est un noyau de MARKOV

$$A_n : \mathcal{O}_n \mapsto A_n(\mathcal{O}_n) \in \mathcal{M}_1(\mathcal{S}_n).$$

La sortie τ_n de l'algorithme vérifie donc

$$\mathcal{L}(\tau_n \mid X_n, W_n) = A_n(X_n, W_n).$$

De manière équivalente, il existe une variable auxiliaire $U \sim \text{Unif}[0; 1]$, indépendante de (X_n, Σ_n, W_n) , et une fonction mesurable g_n telles que

$$\tau_n = g_n(X_n, W_n, U).$$

La définition usuelle d'un système faiblement/partiellement recouvrable (*weakly/partially recoverable* en anglais) [101] est qu'il est possible (au sens : il existe un algorithme) de faire strictement mieux (dans un sens que nous verrons plus bas) qu'un tirage aléatoire/au hasard (*random guess* en anglais).

Notre cadre bayésien nous permet de définir rigoureusement ce qu'est un tirage aléatoire dans ce contexte général : c'est un algorithme qui ignore la réalisation de X_n, W_n (voir DEF. 35 ci-dessous et l'illustration en FIG. 11.2).

DÉFINITION 35 : TIRAGE AU HASARD (*RANDOM GUESS*)

Un tirage au hasard, ou *random guess*, est un algorithme dont le noyau ne dépend pas de la réalisation observée. Il existe donc une mesure de probabilité $\rho_n \in M_1(\mathcal{S}_n)$ telle que

$$\mathcal{L}(\tau'_n \mid X_n, W_n) = \rho_n.$$

Ainsi, τ'_n est indépendant de l'observation (X_n, W_n) . La loi ρ_n peut dépendre du modèle (connu) et de n , mais pas de la réalisation.




FIGURE 11.2 : Un algorithme voit la réalisation observée ; un tirage au hasard connaît seulement le modèle.

Soit Φ_n un score borné, mesurable, de la forme

$$\Phi_n : \mathcal{X}_n \times \mathcal{W}^{E_n} \times \mathcal{S}_n \times \mathcal{S}_n \longrightarrow \mathbb{R}.$$

Par exemple, comme pour le cas du recouvrement partiel (DEF. 37, p. 129), le score peut

être l'indicatrice d'un recouvrement des communautés supérieur au seuil s

$$\Phi_n = \mathbb{1}_{\{\text{ov}_n(\Sigma_n, \tau) \geq s\}}.$$

La performance moyenne d'un algorithme τ_n est

$$G_\Phi(\tau) = \mathbb{E} [\Phi(X, W, \Sigma, \tau)]. \quad (11.5)$$

L'on a introduit en toute généralité des algorithmes qui pouvaient contenir une composante aléatoire ; toutefois, ceux maximisant la performance moyenne auraient pu être choisis parmi les algorithmes déterministes (en se restreignant à de tels algorithmes, l'on retombe sur la DEF. 2.2 de SANKARARAMAN–BACCELLI [101]). Ce résultat est l'objet de la PROP. 12 suivante.

PROPOSITION 12 : LE MEILLEUR TIRAGE AU HASARD EST DÉTERMINISTE

Pour tout score borné Φ_n ,

$$\sup_{\tau'_n \text{ random guess}} G_{\Phi, n}(\tau'_n) = \max_{a \in \mathcal{S}_n} \mathbb{E} [\Phi_n(X_n, W_n, \Sigma_n, a)]. \quad (11.6)$$

Preuve. Si $\tau'_n \sim \rho_n$ est indépendant de l'observation, alors

$$G_{\Phi, n}(\tau'_n) = \sum_{a \in \mathcal{S}_n} \rho_n(a) \mathbb{E} [\Phi_n(X_n, W_n, \Sigma_n, a)].$$

Cette quantité est affine en ρ_n ; son supremum sur le simplexe des probabilités sur $\mathcal{S}_n$ (compact) est donc atteint en une masse de DIRAC. $\square$

11.1.3 Recouvrement de communautés

Le calcul du recouvrement (DEF. 36) se fait modulo permutation $\pi \in \mathfrak{S}_K$ des étiquettes (convention standard en détection de communautés [140]) : les indices des étiquettes sont arbitraires, seule la partition induite compte (voir FIG. 11.3).

DÉFINITION 36 : RECOUVREMENT DE COMMUNAUTÉS (COMMUNITY OVERLAP)
[101, 140]

Pour $\sigma, \tau \in \mathcal{S}_n$, on pose

$$\text{ov}_n(\sigma, \tau) = \max_{\pi \in \mathfrak{S}_K} \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{\{\tau_i = \pi(\sigma_i)\}}. \quad (11.7)$$

Remarque Lorsque $K = 2$ et $\mathcal{S}_2 = \{-1, +1\}$,

$$\text{ov}_n(\sigma, \tau) = \frac{1}{2} \left(1 + \left| \frac{1}{n} \sum_{i=1}^n \sigma_i \tau_i \right| \right). \quad (11.8)$$

La quantité utilisée par SANKARARAMAN–BACCELLI [101] est le recouvrement signé absolu

$$O_n(\sigma, \tau) = \left| \frac{1}{n} \sum_{i=1}^n \sigma_i \tau_i \right|,$$

et l'on a simplement $ov_n = (1 + O_n)/2$.




FIGURE 11.3 : Le recouvrement ignore les *labels* arbitraires des communautés; c'est la partition induite qui compte.

On dira plus tard que les communautés sont recouvrables (DEF. 38) s'il existe un algorithme faisant mieux que le meilleur *random guess*. Introduisons donc la fonction de succès du meilleur tirage au hasard (pour un certain seuil $s \in [0; 1]$).

DÉFINITION 37 : MEILLEUR TIRAGE AU HASARD AU SEUIL s

Pour $s \in [0; 1]$, on définit

$$RG_n(s) = \sup_{\tau'_n \text{ random guess}} \mathbb{P} [ov_n(\Sigma_n, \tau'_n) \geq s]. \quad (11.9)$$

COROLLAIRE 1 : PROP. 12 APPLIQUÉE AU RECOUVREMENT ALÉATOIRE DE COMMUNAUTÉS

Pour tout seuil $s \in [0; 1]$,

$$RG_n(s) = \max_{a \in \mathcal{S}_n} \mathbb{P} [ov_n(\Sigma_n, a) \geq s]. \quad (11.10)$$

Preuve. Le corollaire s'obtient à partir de PROP. 12 en prenant comme score l'indicatrice de l'événement $\{ov_n(\Sigma_n, \tau) \geq s\}$. $\square$

La fonction $s \mapsto RG_n(s)$ dépend uniquement de l'*a priori* sur les *labels*, puisque le tirage au hasard ne voit pas l'observation.

DÉFINITION 38 : RECOUVREMENT PARTIEL DANS LE CADRE BAYÉSIEN GÉNÉRAL [101]

On dit qu'une suite de modèles bayésiens admet un recouvrement de communautés *partiel* (ou *weak/partial recovery* en anglais), s'il existe un seuil $s \in [0; 1]$, une constante

$\eta > 0$ et une suite d'algorithmes $(\tau_n)_n$ tels que

$$\liminf_{n \rightarrow \infty} (\mathbb{P}[\text{ov}_n(\Sigma_n, \tau_n) \geq s] - \text{RG}_n(s)) \geq \eta. \quad (11.11)$$

On dit que le recouvrement partiel est obtenu *avec haute probabilité* au niveau s si, de plus,

$$\mathbb{P}[\text{ov}_n(\Sigma_n, \tau_n) \geq s] \longrightarrow 1 \quad \text{et} \quad \limsup_{n \rightarrow \infty} \text{RG}_n(s) < 1. \quad (11.12)$$

La seconde forme est celle qu'on utilisera conformément à la DEF. 2.2 de SANKARARAMAN–BACCELLI [101] (cas uniforme équilibré avec $K = 2$, voir PROP. 13 ci-dessous).

PROPOSITION 13 : CAS UNIFORME : RETOUR AU SEUIL $1/K$

Supposons que $\mu_{0,n}$ soit uniforme sur les configurations à K classes, ou plus généralement que les proportions des classes convergent vers $(1/K; \dots; 1/K)$ et que l'*a priori* soit invariant par permutation des étiquettes. Alors, pour tout $\varepsilon > 0$,

$$\text{RG}_n\left(\frac{1}{K} + \varepsilon\right) \longrightarrow 0.$$

$$\text{RG}_n\left(\frac{1}{K} - \varepsilon\right) \longrightarrow 1.$$

En particulier, dans ce cas, obtenir avec haute probabilité un recouvrement au moins $1/K + \varepsilon$ est exactement battre tout tirage au hasard au sens de la DEF. 38, p. 130.

Preuve. Par le Fait 12, il suffit de considérer une configuration déterministe $a \in \mathcal{S}_n$. Pour une permutation fixée des étiquettes, l'accord moyen entre a et une configuration tirée au hasard se concentre autour de $1/K$. Le nombre de permutations ($K!$) étant fixé, l'on obtient que la probabilité de dépasser $1/K + \varepsilon$ (ou d'être en-dessous $1/K - \varepsilon$) converge vers 0. $\square$

PROPOSITION 14 : CONCORDANCE AVEC LA DEF. 2.2 DE SANKARARAMAN–BACCELLI [101]

Dans le modèle de SANKARARAMAN–BACCELLI à deux communautés, l'*a priori* est uniforme sur $\{-1, +1\}^{V_n}$, et leur définition de “solvabilité” demande l'existence d'un algorithme τ_n et d'une constante $\varepsilon > 0$ tels que

$$\mathbb{P}\left[\left|\frac{1}{|V_n|} \sum_{i \in V_n} \tau_{n,i} \Sigma_{n,i}\right| \geq \varepsilon\right] \longrightarrow 1. \quad (11.13)$$

Cette condition est équivalente à

$$\mathbb{P} \left[\text{ov}_n(\Sigma_n, \tau_n) \geq \frac{1}{2} + \frac{\varepsilon}{2} \right] \longrightarrow 1. \quad (11.14)$$

De plus,

$$\text{RG}_n \left(\frac{1}{2} + \frac{\varepsilon}{2} \right) \longrightarrow 0. \quad (11.15)$$

Ainsi, la DEF. 38 coïncide avec la DEF. 2.2 de SANKARARAMAN–BACCELLI dans leur cadre.

A priori non uniforme Si la mesure *a priori* impose des communautés de proportions limites $(p_1, \dots, p_K)$ non uniformes (en étant toutefois invariante par permutation), le meilleur tirage au hasard consiste à prendre une configuration composée uniquement de l'étiquette la plus présente et le seuil de recouvrement aléatoire est $\max_k p_k \geq \frac{1}{K}$.

11.1.4 Recouvrement de communautés partiel, presque parfait et parfait

On distingue habituellement plusieurs niveaux de récupération dans les modèles à communautés cachées [101, 140].

1. Le recouvrement partiel (*weak/partial recovery*) demande seulement un gain strict au-dessus du meilleur tirage au hasard (*random guess*), au sens probabiliste de la DEF. 38.
2. Le recouvrement presque parfait (*almost perfect recovery* en anglais) demande $\text{ov}_n(\Sigma_n, \tau_n) \rightarrow 1$ en probabilité.
3. Le recouvrement parfait (*perfect recovery* en anglais) demande l'égalité exacte $\text{ov}_n(\Sigma_n, \tau_n) = 1$ avec une probabilité tendant vers 1.

Voir la FIG. 11.4 pour une illustration de ces trois régimes.

Dans notre cadre, le régime qui présente l'intérêt principal est le recouvrement partiel. Le régime (presque) parfait correspond à une postérieure presque concentrée sur une seule orbite (modulo permutation) : celle de Σ . Ce régime n'est pas pertinent pour comprendre une mesure de GIBBS [114] un tant soit peu générale, où plusieurs configurations (macroscopiquement différentes) peuvent rester plausibles.




FIGURE 11.4 : Les trois régimes de recouvrement de communautés. Dans ce chapitre, le recouvrement partiel est le régime pertinent (il détecte une information globale sans exiger une postérieure quasi-dégénérée).

11.1.5 Rééchantillonnage postérieur et couplages invariants

Le résultat probabiliste ci-dessous est une forme de l'identité de NISHIMORI [145, 146] : si la postérieure est la vraie loi conditionnelle des étiquettes, alors la vérité cachée Σ et une réplique postérieure $\Sigma^{(1)}$ sont échangeables conditionnellement à l'observation. Utilisés implicitement dans notre travail préparatoire [143], nous explicitons ici ce résultat (THÉORÈME 8, classique en statistiques) qui va nous permettre de coupler la vérité terrain avec un pas de dynamique de clusters (COROLLAIRE 2), en particulier pour savoir si une famille de modèle est partiellement recouvrable (COROLLAIRE 3). Cette idée est illustrée en FIG. 11.5.

THÉORÈME 8 : RÉÉCHANTILLONNAGE POSTÉRIEUR [145, 146]

Soit τ_n un algorithme. Conditionnellement à (X_n, W_n) , soit

$$\Sigma_n^{(1)} \sim \mu_{n, X_n, W_n}$$

un tirage indépendant de τ_n . Alors, pour toute fonction mesurable bornée Ψ_n ,

$$\mathbb{E} [\Psi_n(X_n, W_n, \Sigma_n, \tau_n)] = \mathbb{E} [\Psi_n(X_n, W_n, \Sigma_n^{(1)}, \tau_n)] . \quad (11.16)$$

Preuve. On écrit $\tau_n = g_n(X_n, W_n, U)$ avec U indépendant de (X_n, Σ_n, W_n) . Conditionnellement à (X_n, W_n, U) , la loi de Σ_n est encore μ_{n, X_n, W_n} . C'est aussi la loi conditionnelle de $\Sigma_n^{(1)}$. Les deux espérances conditionnelles sont donc égales, puis l'on intègre. $\square$

COROLLAIRE 2 : COUPLAGE PAR UNE TRANSITION INVARIANTE

Pour chaque observation (x, w) , soit $M_{n, x, w}$ un noyau de MARKOV sur $\mathcal{S}_n$ laissant invariante la postérieure $\mu_{n, x, w}$. Si

$$\Sigma_n^{(1)} \mid (X_n, W_n, \Sigma_n) \sim M_{n, X_n, W_n}(\Sigma_n, \cdot),$$

alors, pour tout algorithme τ_n et toute fonction mesurable bornée Ψ_n ,

$$\mathbb{E} [\Psi_n(X_n, W_n, \Sigma_n, \tau_n)] = \mathbb{E} [\Psi_n(X_n, W_n, \Sigma_n^{(1)}, \tau_n)] . \quad (11.17)$$

Preuve. Conditionnellement à (X_n, W_n) , la variable Σ_n a pour loi μ_{n, X_n, W_n} . Comme M_{n, X_n, W_n} laisse cette mesure invariante, la variable obtenue après un pas a encore pour loi conditionnelle μ_{n, X_n, W_n} . On applique alors le THÉORÈME 8. $\square$

COROLLAIRE 3 : APPLICATION AU RECOUVREMENT

Sous les hypothèses du COROLLAIRE 2, pour tout algorithme τ_n et tout seuil $s \in [0; 1]$,

$$\mathbb{P} [\text{ov}_n(\Sigma_n, \tau_n) \geq s] = \mathbb{P} [\text{ov}_n(\Sigma_n^{(1)}, \tau_n) \geq s]. \quad (11.18)$$




FIGURE 11.5 : La vérité cachée Σ peut être remplacée par une réplique postérieure $\Sigma^{(1)}$. Toute l'astuce de la suite du chapitre consiste à construire $\Sigma^{(1)}$ en faisant un pas d'une dynamique de clusters à partir de Σ .

11.2 Dynamiques de clusters : généralisation de SWENDSEN–WANG aux interactions d'ordre supérieur

11.2.1 Mesures de GIBBS sur graphes pondérés signés

11.2.1.1 Poids sur les arêtes e et potentiels locaux

Les poids sur les arêtes peuvent être vus dans un cadre général comme des observations $w_e \in W$ attachées aux arêtes $e \in E_n$. Pour obtenir une mesure de GIBBS [122] dans sa forme générale, on choisit une famille de potentiels locaux [122] **Est-ce vraiment la peine d'introduire des potentiels ψ ?**

$$\psi_w : S_K \times S_K \longrightarrow \mathbb{R} \cup \{\pm\infty\}, \quad w \in W.$$

L'énergie postérieure prend alors la forme

$$U_{x,w}(\sigma) = -\log \mu_{0,n}(\sigma \mid x) + \sum_{e=\{i,j\} \in E_n} \psi_{w_e}(\sigma_i, \sigma_j), \quad (11.19)$$

et la postérieure est

$$\mu_{n,x,w}(\sigma) = \frac{1}{Z_n(x, w)} e^{-U_{x,w}(\sigma)}. \quad (11.20)$$

Dans ce chapitre, pour $w \in \mathbb{R}$, on pose

$$\psi_w(a, b) = \begin{cases} |w| \mathbb{1}_{\{a \neq b\}}, & w > 0, \\ |w| \mathbb{1}_{\{a = b\}}, & w < 0, \\ 0, & w = 0. \end{cases} \quad (11.21)$$

(Voir FIG. 11.6 pour une illustration.) Ainsi, un poids positif pénalise des étiquettes différentes; un poids négatif pénalise des étiquettes égales. L'intensité de l'interaction est portée par $|w|$.

Comme illustré en FIG. 11.6, on représentera les arêtes positives d'un trait plein et les arêtes négatives en pointillés; un trait plus épais signifie que l'arête est satisfaite.




FIGURE 11.6 : Interprétation d'un poids w réel : le signe indique la contrainte; le module $|w|$ indique la force de cette contrainte. Les arêtes positives sont représentées d'un trait plein et les arêtes négatives en pointillés; un trait plus épais signifie que l'arête est satisfaite.

11.2.2 Frustration

La *frustration* [125] est un phénomène classique dans les modèles d'ISING avec poids signés [147] (qu'on supposera non nuls), et qui explique en grande partie les difficultés des dynamiques de clusters en présence à la fois d'interactions attractives et répulsives [125, 127]. Dans le cas binaire, une configuration satisfait une arête $e = \{i, j\}$ si

$$W_e \geq 0 \text{ et } \sigma_i = \sigma_j, \quad \text{ou} \quad W_e \leq 0 \text{ et } \sigma_i \neq \sigma_j.$$

DÉFINITION 39 : FRUSTRATION

Un graphe pondéré signé (V, E, W) est frustré s'il n'existe aucune configuration $\sigma \in \{-1, +1\}^V$ qui satisfasse simultanément toutes les arêtes (de poids non nul).

PROPOSITION 15 : CARACTÉRISATION DE LA FRUSTRATION BINAIRE

Un graphe pondéré signé n'est pas frustré si et seulement si, pour toute paire de sommets x, y , la parité du nombre d'arêtes de poids négatifs le long d'un chemin reliant x à y ne dépend pas du chemin choisi.

Preuve. Si une configuration σ satisfait toutes les arêtes, le produit des signes des arêtes le long d'un chemin ω de x à y est nécessairement égal à $\sigma_x \cdot \sigma_y$ (et ne dépend pas du choix de ω). Réciproquement, si cette parité est indépendante du chemin, on fixe le spin d'un sommet racine x_0 (on en prend un par composante connexe) et l'on définit le spin d'un sommet y de la même composante connexe par $\sigma_y \triangleq \sigma_{x_0} \cdot (-1)^{\text{parité}(\omega: x_0 \rightarrow y)}$. $\square$




FIGURE 11.7 : La frustration apparaît dès qu'un cycle impose un nombre impair d'arêtes négatives. Le triangle pleinement répulsif est le plus petit exemple.

La frustration apparaît dès qu'un cycle impose un nombre impair d'arêtes négatives. Le triangle pleinement répulsif est le plus petit exemple. Dans notre travail préparatoire, nous avons appelés de tels triangles contradictoires de façon inhérente (*inherently contradictory* dans le texte [143]), contrairement aux autres triangles, seulement potentiellement contradictoires (*potentially contradictory*), et satisfaits ou non selon la configuration σ choisie.

Par invariance de jauge, l'on peut se ramener (comme pour la définition d'une dynamique sur les triangles dans la suite du chapitre) à analyser seulement deux triangles :

1. **Le triangle attractif** (pur). Composé de trois arêtes ferromagnétiques (positives).
2. **Le triangle répulsif** (pur). Composé de trois arêtes anti-ferromagnétiques (négatives).

11.2.3 Dynamiques de clusters

11.2.4 Liens et réversibilité de la dynamique

Supposons que l'énergie soit décomposable en contributions locales

$$U(\sigma) = U_0(\sigma) + \sum_{b \in \mathcal{B}} U_b(\sigma), \quad (11.22)$$

où chaque $b \subseteq V_n$ est un *lien* (*bond* en anglais), c'est-à-dire une hyper-arête (arête simple, triangle, tétraèdre, *etc.*) ou bien un motif local plus général et U_b est une fonction d'énergie associée à un potentiel local $\psi_{w_b}(\{\sigma_i\}_{i \in b})$.

(Cette écriture reprend l'esprit du cadre formel proposé par EDWARDS–SOKAL [122] pour la FK-percolation (FORTUIN–KASTELEYN) [123], ou *random-cluster model* [124].)

Par “dynamique”, nous entendons une application markovienne sur l'ensemble des configurations $\sigma \in \mathcal{S}_n$.

Dans cette famille, nous allons travailler uniquement avec ce que nous appelons les dynamiques de clusters, généralisant la dynamique de SWENDSEN–WANG [103]. Une dynamique de clusters commence par tirer, pour chaque lien $b \in \mathcal{B}$, un sous-lien $\omega_b \subseteq b$ (suivant une loi P_b^σ) que l'on va “geler”. Chaque composante gelée est ensuite “recoloriée” (application d'une permutation des étiquettes sur chaque cluster gelé, selon une certaine loi¹⁾ préservant μ_0).

DÉFINITION 40 : COMPATIBILITÉ ET RÉVERSIBILITÉ LOCALE D'UNE DYNAMIQUE DE CLUSTERS

Pour deux configurations σ, σ' et un lien b , on pose

$$P_b^{\sigma \rightarrow \sigma'}(\omega_b) = \begin{cases} P_b^\sigma(\omega_b), & \text{si } P_b^{\sigma'}(\omega_b) > 0, \\ 0, & \text{sinon.} \end{cases} \quad (11.23)$$

($P_b^{\sigma \rightarrow \sigma'}(\omega_b) > 0$ signifie que la dynamique peut transformer en un pas avec une probabilité non nulle σ en σ' – localement au niveau du lien b en tout cas.)

La règle de gel est dite *réversible* (localement) si, pour tout b , tout ω_b et toutes configurations σ, σ' ,

$$P_b^{\sigma \rightarrow \sigma'}(\omega_b) = \exp[-(U_b(\sigma') - U_b(\sigma))] P_b^{\sigma' \rightarrow \sigma}(\omega_b). \quad (11.24)$$

THÉORÈME 9 : INVARIANCE PAR BALANCE LOCALE

Supposons que les choix de gel des liens soient indépendants, que la règle de gel soit localement réversible (11.24), et que $P_b^\sigma(\emptyset) > 0$ pour tout b et tout σ . Alors la dynamique obtenue après recoloriage des clusters est réversible par rapport à la mesure

$$\mu(\sigma) = Z^{-1} e^{-U(\sigma)}.$$

¹⁾La dynamique de SWENDSEN–WANG standard recolorie chacun des clusters indépendamment et uniformément sur $\mathfrak{S}_K$; ce qui correspond à un *a priori* μ_0 uniforme. Dans le *framework* général de EDWARDS–SOKAL [122], il est tout à fait possible d'intégrer un *a priori* qui ne soit pas uniforme; on peut, par exemple, recourir à une dynamique de type METROPOLIS–HASTINGS/GLAUBER [118] sur les clusters: on sélectionne aléatoirement un cluster et on le recolorie selon une loi sur $\mathfrak{S}_K$ donnée par les variations d'énergie induites.

En particulier, μ est stationnaire.

Preuve. Soit $T(\sigma, \sigma')$ la probabilité de transition. On somme sur les familles de contraintes gelées compatibles avec σ et σ' . Par indépendance des liens et par (11.24), chaque famille compatible apporte le facteur

$$\prod_{b \in \mathcal{B}} \exp[-(U_b(\sigma') - U_b(\sigma))] = \exp[-(U(\sigma') - U(\sigma))].$$

On obtient

$$\mu(\sigma)T(\sigma, \sigma') = \mu(\sigma')T(\sigma', \sigma),$$

ce qui est la réversibilité de la chaîne de MARKOV induite. La condition $P_b^\sigma(\emptyset) > 0$ évite de figer irréversiblement une contrainte (et procure l'irréductibilité de la chaîne de MARKOV). $\square$

11.2.5 Le cas arête par arête : SWENDSEN–WANG signé

Revenons au cas “simple” : lorsque les liens $b \in \mathcal{B}$ ne sont constitués que d'arêtes de poids W_e , $e \in E_n$. L'arête est satisfaite si elle respecte la contrainte de signe de W_e . La dynamique arête par arête est alors :

1. Pour les arêtes non satisfaites, on ne gèle rien (on “gèle” $\emptyset$ avec la probabilité 1).
2. Pour une arête satisfaite e , on gèle e avec la probabilité

$$p_e^{\text{gel}} = 1 - e^{-|W_e|}. \quad (11.25)$$

(Et l'on gèle donc $\emptyset$ avec la probabilité complémentaire $p_\emptyset^{\text{gel}} = 1 - p_e^{\text{gel}} = e^{-|W_e|}$).

3. Chaque cluster gelé est recolorié indépendamment selon une loi préservant la mesure *a priori* μ_0 (associée à l'énergie U_0). Dans le cas standard ($U_0(\sigma) = 0$ et $K = 2$), cela revient à retourner (*flip* en anglais) ou non le cluster avec une probabilité 1/2.

La FIG. 11.8 montre un exemple d'un pas de cette dynamique arête par arête sur un graphe à six nœuds et sept arêtes.




FIGURE 11.8 : Un pas de SWENDSEN–WANG signé : partant d'une configuration $\sigma : V \rightarrow \{+, -\}$, l'on gèle aléatoirement certaines des arêtes satisfaites (en gras), puis on recolorie aléatoirement les clusters ainsi formés ; on obtient de la sorte une nouvelle configuration σ'

FAIT (CONNU) 15 : DYNAMIQUE DE SWENDSEN-WANG SIGNÉE

La dynamique arête par arête décrite ci-dessus est réversible par rapport à la mesure de GIBBS associée à l'énergie (11.19)–(11.21). C'est la dynamique de SWENDSEN-WANG dans le formalisme d'EDWARDS-SOKAL [103, 122].

11.2.6 Dynamiques triangulaire et obstruction par percolation**11.2.6.1 Transfert d'énergie vers les triangles**

Comme nous l'avons décrit en [143], il est tout à fait possible, *via* un jeu de réécriture de “transférer” l'énergie d'un premier ensemble de liens $\mathcal{B}$ donné vers un second (multi-)ensemble $\mathcal{B}'$. Si l'on trouve U'_0 et des $U'_{b'}, b' \in \mathcal{B}$ tels que

$$\forall \sigma \in \mathcal{S}_n, \quad U(\sigma) = U'_0(\sigma) + \sum_{b' \in \mathcal{B}'} U'_{b'}(\sigma),$$

alors la mesure de GIBBS associée reste inchangée.

Les cas simples (traités en [143]) sont :

1. **Les arêtes.** $\mathcal{B}'$ peut tout à fait être un multi-ensemble ; on peut “séparer” le poids d'une arête en plusieurs copies de la même arête. Il suffit pour cela que la somme des poids associés à chaque arête soit préservée. Réciproquement, si par exemple une arête apparaissant à la fois positivement et négativement crée une frustration (inutile donc nuisible), on peut remplacer cette apparition multiple par une unique copie ayant pour poids la somme des deux.
2. **Le cas des triangles isotropes**ⁱ⁾ est particulièrement bien adapté (lorsque $K = 2$) : ils ne possèdent que deux niveaux d'énergie. Il est donc aisé de remplacer leur poids (répartis sur les arêtes) par des poids répartis sur les triangles.

11.2.7 Règles locales sur un triangle isotrope

Dans l'esprit de KANDEL-BEN-AV-DOMANY [127], on remplace certains liens-arêtes par des liens-*plaquettes*, interactions d'ordre supérieur. Nous nous sommes particulièrement intéressés aux liens-triangles.

Pour $K = 2$, les triangles signés se répartissent en deux familles : ceux qui ne portent pas de frustration locale, et ceux qui en portent déjà une.

À retournement local de spins près (invariance de jauge), il suffit d'étudier le triangle pleinement attractif et le triangle pleinement répulsif. Dans le cas isotrope, toutes les arêtes ont même intensité $u > 0$. On pose

$$a_u = 1 - e^{-2u}, \quad b_u = e^{-2u}. \quad (11.26)$$

ⁱ⁾Par triangle *isotrope*, nous entendons un triplet d'arêtes formant un triangle, et toutes de même intensité (valeur absolue du poids).

L'idée de la dynamique triangulaire (toujours dans l'esprit KANDEL–BEN-AV–DOMANY) est d'introduire des corrélations sur le mécanisme de gel des liens pour geler le moins possible (et ainsi prévenir une dynamique complètement bloquée par des gels trop massifs, qui est le problème des dynamiques de clusters sur les systèmes avec frustration).

Distinguons les deux types de triangles :

1. Un triangle t pleinement **attractif** possède deux niveaux d'énergie :
 - Un état de basse énergie $+++$ (ou par symétrie $---$) : $U_t(+++) = U_t(---) = 0$ où toutes les arêtes sont satisfaites. On introduit donc des corrélations sur le mécanisme de gel : soit l'on gèle toutes les arêtes, soit l'on n'en gèle aucune.
 - Tous les autres états sont de haute énergie : $2u$. Seule une arête sur les trois est satisfaite. Dans la dynamique arête par arête, cette arête pourrait être gelée avec une probabilité non nulle. Dans la dynamique de triangle, on ne gèle rien (c'est-à-dire qu'on gèle $\emptyset$ avec la probabilité 1).
2. Un triangle t pleinement **répulsif** possède deux niveaux d'énergie :
 - Un état de haute énergie $+++$ (ou par symétrie $---$) : $U_t(+++) = U_t(---) = 3u$ où aucune arête n'est satisfaite. On gèle $\emptyset$ avec la probabilité 1.
 - Tous les autres états de basse énergie : u . Deux des trois arêtes sont satisfaites. On introduit des corrélations sur le mécanisme de gel pour ne pas geler inutilement le triangle entier : si l'on gèle, on ne gèle *exactement* que l'une des deux arêtes satisfaites, garantissant ainsi (avec un minimum de gel) de rester dans un état de basse énergie.

La dynamique sur ces deux triangles est décrite en TAB. 11.1.

$\triangle$	Triangle attractif isotrope				
Configuration	$\emptyset$	$\{ab\}$	$\{ac\}$	$\{bc\}$	$\{ab, ac, bc\}$
$(+, +, +)$	b_u	0	0	0	a_u
$(+, +, -)$	1	0	0	0	0
$(+, -, +)$	1	0	0	0	0
$(+, -, -)$	1	0	0	0	0

$\triangleleft$	Triangle répulsif isotrope				
Configuration	$\emptyset$	$\{ab\}$	$\{ac\}$	$\{bc\}$	$\{ab, ac, bc\}$
$(+, +, +)$	1	0	0	0	0
$(+, +, -)$	b_u	0	$a_u/2$	$a_u/2$	0
$(+, -, +)$	b_u	$a_u/2$	0	$a_u/2$	0
$(+, -, -)$	b_u	$a_u/2$	$a_u/2$	0	0

TABLE 11.1 – Règles de gel de la dynamique SWENDSEN–WANG triangulaire isotrope. Les lignes indiquent la configuration des spins sur le triangle $t = \{a, b, c\}$ (on fixe le premier spin à + par symétrie). Les colonnes indiquent l'ensemble d'arêtes gelées $\omega \subseteq t$ dans le triangle. Noter que geler deux ou trois arêtes revient au même pour la dynamique.

PROPOSITION 16 : RÉVERSIBILITÉ LOCALE DE LA DYNAMIQUE TRIANGULAIRE

Les règles triangulaires isotropes décrites ci-dessus satisfont la réversibilité locale (11.24). Par produit indépendant sur les triangles, la dynamique globale laisse donc invariante la même mesure de GIBBS que la dynamique arête par arête.

Preuve. Sur un triangle isotrope, il n'y a que deux niveaux d'énergie pertinents dans chacune des deux familles. La différence d'énergie est toujours égale à $2u$; les rapports de probabilités de transition entre les états de basse et de haute énergie sont donc imposés par le facteur e^{-2u} . Les choix $b_u = e^{-2u}$ et $a_u = 1 - e^{-2u}$ donnent exactement ces rapports. Il ne reste plus qu'à appliquer le THÉORÈME 9. $\square$

11.3 Le rôle de la percolation dans les performances théoriques. Application au modèle de SANKARARAMAN–BACCELLI

Cette section nous permet de faire le lien avec le début de ce manuscrit, où les données étaient non des graphes mais des points de l'espace euclidien. Nous avons vu que le phénomène mathématique clef au cœur des performances des différents algorithmes était la percolation.

C'est exactement la même chose ici : nous allons montrer que la percolation est une condition nécessaire pour pouvoir espérer recouvrir partiellement les communautés. Mieux : la taille des composantes macroscopiques donne une borne sur la fraction des étiquettes qu'on peut espérer pouvoir recouvrir.

Évidemment, la dynamique de clusters choisie influe sur la percolation. En appliquant simplement le COROLLAIRE 3 à la dynamique de clusters arête par arête (SWENDSEN–WANG standard), l'on retrouve le THÉORÈME 6.1 de SANKARARAMAN–BACCELLI [101]. En l'appliquant à notre dynamique triangulaire, on obtient de meilleures bornes théoriques pour le recouvrement partiel (sur la grille triangulaire, où ces bornes sont calculables).

11.3.1 Percolation nécessaire

On fixe une suite de modèles et une dynamique de clusters. La notion utilisée ci-dessous est celle de percolation des clusters gelés, dans l'esprit de la théorie de la percolation et des modèles random-cluster [71, 124, 148].

Notons κ_n l'objet gelé produit par un pas de dynamique appliqué à une configuration $\Sigma_n \sim \mu_{n,X,W}$, et $\mathcal{C}(\kappa_n)$ les clusters correspondants (composantes connexes créées par les gels).

DÉFINITION 41 : MASSE PERCOLÉE DES CLUSTERS

Pour $\delta > 0$, on définit

$$\theta_\delta(\kappa_n) = \frac{1}{n} \sum_{C \in \mathcal{C}(\kappa_n)} |C| \mathbf{1}_{\{|C| \geq \delta n\}}. \quad (11.27)$$

On pose ensuite

$$\theta^{\max} = \inf \left\{ \theta \in [0; 1] \mid \lim_{\delta \downarrow 0} \limsup_{n \rightarrow \infty} \mathbb{P} [\theta_\delta(\kappa_n) > \theta] = 0 \right\}. \quad (11.28)$$

Remarque La définition ne suppose pas l'unicité d'un cluster géant : θ_δ mesure la masse totale portée par tous les clusters de taille au moins δn .

THÉORÈME 10 : BORNE SUR LA FRACTION RECOUVRABLE VIA PERCOLATION

Supposons K fixé, et par simplicité l'*a priori* μ_0 uniforme (mettant le seuil de recouvrement d'un tirage aléatoire à $\frac{1}{K}$, c.f. PROP. 13, p. 130), et supposons aussi que les clusters soient recoloriés indépendamment et uniformément (comme dans les dynamiques de type SWENDSEN–WANG). Alors, pour tout $\eta > 0$ et toute suite d'algorithmes τ_n ,

$$\lim_{n \rightarrow \infty} \mathbb{P} \left[\text{ov}_n(\Sigma_n, \tau_n) \geq \frac{1}{K} + \frac{K-1}{K} (\theta^{\max} + \eta) \right] = 0. \quad (11.29)$$

En particulier, si une suite d'algorithmes vérifie, pour un certain $\varepsilon > 0$,

$$\mathbb{P} \left[\text{ov}_n(\Sigma_n, \tau_n) \geq \frac{1}{K} + \frac{K-1}{K} \varepsilon \right] \longrightarrow 1, \quad (11.30)$$

alors $\varepsilon \leq \theta^{\max}$.

Preuve. Par le COROLLAIRE 3, on peut remplacer Σ_n par la configuration $\Sigma_n^{(1)}$ obtenue après un pas de la dynamique. Fixons $\delta > 0$ et séparons les clusters gelés en deux familles :

$$\mathcal{C}_{\text{grand}} = \{C \mid |C| \geq \delta n\}, \quad \mathcal{C}_{\text{petit}} = \{C \mid |C| < \delta n\}.$$

La masse totale des grands clusters vaut $\theta_\delta(\kappa_n)$.

Conditionnellement à la partition gelée, à l'observation et à l'algorithme, les petits clusters sont recoloriés indépendamment et uniformément. Pour une permutation globale $\pi \in \mathfrak{S}_K$ fixée, leur contribution à l'accord avec τ_n est d'espérance

$$\frac{1}{K} (1 - \theta_\delta(\kappa_n)).$$

Or leur nombre $\rightarrow +\infty$ et leur poids relatif $\rightarrow 0$ lorsque $n \rightarrow +\infty$. Une borne de TCHEBYCHEV, puis une union sur les $K!$ permutations, donnent

$$\sum_{C \in \mathcal{C}_{\text{petit}}} \frac{|C|}{n} \frac{1}{|C|} \sum_{i \in C} \mathbb{1}_{\{\tau_{n,i} = \pi(\Sigma_{n,i}^{(1)})\}} \leq \frac{1}{K} (1 - \theta_\delta(\kappa_n)) + o_{\mathbb{P}}(1)$$

uniformément en π .

Les grands clusters, eux, peuvent contribuer au recouvrement au plus par leur masse totale $\theta_\delta(\kappa_n)$. On obtient en sommant

$$\text{ov}_n(\Sigma_n^{(1)}, \tau_n) \leq \frac{1}{K} + \frac{K-1}{K} \theta_\delta(\kappa_n) + o_{\mathbb{P}}(1).$$

Soit $\theta > \theta^{\max}$. Par définition de $\theta^{\max}$, en choisissant δ assez petit, puis n assez grand, l'événement $\{\theta_\delta(\kappa_n) \leq \theta\}$ a une probabilité arbitrairement proche de 1. Ainsi, pour tout $\eta > 0$,

$$\mathbb{P} \left[\text{ov}_n(\Sigma_n^{(1)}, \tau_n) \geq \frac{1}{K} + \frac{K-1}{K} (\theta + \eta) \right] \longrightarrow 0.$$

On fait tendre $\theta \downarrow \theta^{\max}$ et l'on utilise encore le COROLLAIRE 3. □

COROLLAIRE 4 : PERCOLATION NÉCESSAIRE AU RECOUVREMENT PARTIEL ÉQUILIBRÉ

Dans le cadre uniforme équilibré, la masse macroscopique des clusters d'une dynamique invariante contrôle la fraction récupérable :

$$\varepsilon_{\max} \leq \theta^{\max}, \quad (11.31)$$

où $\varepsilon_{\max}$ désigne le plus grand ε pour lequel il existe des algorithmes vérifiant (11.30). En particulier, l'absence de percolation des clusters implique l'absence de recouvrement partiel.

11.3.2 Le modèle de SANKARARAMAN–BACCELLI dans le cadre bayésien

Le but de cette dernière section est d'appliquer les résultats précédents au modèle de SANKARARAMAN–BACCELLI [101].

En particulier, l'on retrouve leur résultat principal, le THÉORÈME 6.1 [101], simplement en appliquant nos résultats à la dynamique arête par arête (SWENDSEN–WANG standard).

Sur la grille triangulaire, où les bornes de percolation sont calculables, l'on montre que notre dynamique triangulaire donne des bornes de recouvrement strictement plus fines.

11.3.2.1 Le canal d'observation

On se donne un graphe potentiel $G = (V, E)$ (géométrique dans le cas d'usage principal de SANKARARAMAN–BACCELLI), et des fonctions de connexion

$$f_{\text{in}}, f_{\text{out}} : \mathbb{R}_+ \rightarrow [0, 1], \quad f_{\text{in}}(r) \geq f_{\text{out}}(r).$$

L'a priori sur Σ est uniforme dans le modèle original. Conditionnellement à Σ , une arête potentielle $e = \{i, j\} \in E$, de longueur $r_e = \|x_i - x_j\|$, est observée dans H avec la probabilité

$$f_{\text{in}}(r_e) \quad \text{si } \Sigma_i = \Sigma_j, \quad f_{\text{out}}(r_e) \quad \text{si } \Sigma_i \neq \Sigma_j.$$

On transforme ensuite l'observation H en poids signés sur toutes les arêtes potentielles :

$$W_e(H) = \begin{cases} \log \left(\frac{f_{\text{in}}(r_e)}{f_{\text{out}}(r_e)} \right), & e \in H, \\ -\log \left(\frac{1 - f_{\text{out}}(r_e)}{1 - f_{\text{in}}(r_e)} \right), & e \notin H. \end{cases} \quad (11.32)$$

Les arêtes présentes dans H (et aussi à la base dans G) sont donc attractives ; les arêtes absentes de H (mais présentes initialement dans G) sont répulsives.

PROPOSITION 17 : LA POSTÉRIEURE DE SANKARARAMAN-BACCELLI EST UNE MESURE DE GIBBS SIGNÉE

Dans le modèle de SANKARARAMAN-BACCELLI avec *a priori* uniforme, la loi conditionnelle de Σ sachant H est exactement la mesure de GIBBS

$$\mu_H(\sigma) = \frac{1}{Z_H} \exp \left[- \sum_{e=\{i,j\} \in E} \psi_{W_e(H)}(\sigma_i, \sigma_j) \right], \quad (11.33)$$

où ψ est le potentiel signé (11.21).

Preuve. La log-vraisemblance de H sachant σ est

$$\sum_{e \in H} \log(f_{\sigma_i, \sigma_j}(r_e)) + \sum_{e \notin H} \log(1 - f_{\sigma_i, \sigma_j}(r_e)),$$

où $f_{a,b} = f_{\text{in}}$ si $a = b$ et $f_{a,b} = f_{\text{out}}$ sinon. Pour une arête présente dans H , le coût relatif d'une paire d'étiquettes différentes est

$$-\log(f_{\text{out}}(r_e)) + \log(f_{\text{in}}(r_e)) = \log\left(\frac{f_{\text{in}}(r_e)}{f_{\text{out}}(r_e)}\right) = W_e(H).$$

Pour une arête absente de H , le coût relatif d'une paire d'étiquettes égales est

$$-\log(1 - f_{\text{in}}(r_e)) + \log(1 - f_{\text{out}}(r_e)) = \log\left(\frac{1 - f_{\text{out}}(r_e)}{1 - f_{\text{in}}(r_e)}\right) = -W_e(H).$$

On obtient donc exactement (11.33). $\square$

11.3.3 Retrouver la borne de SANKARARAMAN-BACCELLI par SWENDSEN-WANG arêtes

Appliquons un pas de SWENDSEN-WANG arête par arête à la configuration Σ . Sous le modèle génératif de SANKARARAMAN-BACCELLI, conditionnellement à la vérité Σ , examinons une arête potentielle $e = \{i, j\}$ de longueur r_e .

Si $\Sigma_i = \Sigma_j$, l'arête est présente avec la probabilité $f_{\text{in}}(r_e)$. Lorsqu'elle est présente, son poids est positif et vaut en module

$$\log\left(\frac{f_{\text{in}}(r_e)}{f_{\text{out}}(r_e)}\right).$$

Elle est donc gelée avec la probabilité

$$1 - \frac{f_{\text{out}}(r_e)}{f_{\text{in}}(r_e)}.$$

La probabilité totale de gel est

$$f_{\text{in}}(r_e) \left(1 - \frac{f_{\text{out}}(r_e)}{f_{\text{in}}(r_e)} \right) = f_{\text{in}}(r_e) - f_{\text{out}}(r_e). \quad (11.34)$$

Si $\Sigma_i \neq \Sigma_j$, l'arête absente est satisfaite comme interaction répulsive. Elle est absente avec la probabilité $1 - f_{\text{out}}(r_e)$, et son poids négatif a pour module

$$\log \left(\frac{1 - f_{\text{out}}(r_e)}{1 - f_{\text{in}}(r_e)} \right).$$

La probabilité totale de gel vaut encore

$$(1 - f_{\text{out}}(r_e)) \left(1 - \frac{1 - f_{\text{in}}(r_e)}{1 - f_{\text{out}}(r_e)} \right) = f_{\text{in}}(r_e) - f_{\text{out}}(r_e). \quad (11.35)$$

COROLLAIRE 5 : RÉDUCTION À LA PERCOLATION $f_{\text{in}} - f_{\text{out}}$

Dans le modèle de SANKARARAMAN–BACCELLI, le graphe gelé produit par un pas de SWENDSEN–WANG arête par arête sur Σ a même loi qu'une percolation indépendante sur le graphe potentiel $G(V, E)$, où l'arête e est conservée avec la probabilité

$$f_{\text{in}}(r_e) - f_{\text{out}}(r_e). \quad (11.36)$$

Si cette percolation ne possède pas de composante géante, le recouvrement partiel est impossible.

Ce COROLLAIRE 5 redonne exactement le THÉORÈME 3.1 de SANKARARAMAN–BACCELLI [101] : la percolation du graphe de paramètre $f_{\text{in}} - f_{\text{out}}$ est une condition nécessaire pour recouvrir les communautés.

11.3.4 La grille triangulaire : une borne strictement meilleure pour la dynamique triangulaire

11.3.4.1 Modèle homogène sur la grille triangulaire

Nous prenons ici un cas simple, où les bornes de percolation sont exactement calculables.

Considérons le cas (homogène) où $G(V, E)$ est la grille triangulaire du plan et

$$f_{\text{in}} \equiv p, \quad f_{\text{out}} \equiv 1 - p, \quad p \in \left[\frac{1}{2}; 1 \right].$$

Tous les poids non nuls ont alors la même valeur absolue

$$u_p = \log \left(\frac{p}{1 - p} \right). \quad (11.37)$$

Le signe du poids dépend seulement de la présence ou de l'absence de l'arête observée.

11.3.4.2 Dynamique par arêtes

Une arête en accord avec la vérité apparaît comme une interaction satisfaite avec la probabilité p . Conditionnellement à cela, la probabilité de gel vaut

$$1 - e^{-u_p} = 1 - \frac{1-p}{p} = \frac{2p-1}{p}.$$

Donc la probabilité effective de conservation d'une arête dans le graphe gelé est

$$p_{\text{lien}} = 2p - 1. \quad (11.38)$$

Le seuil critique de percolation par arêtes de la grille triangulaire vaut $2 \sin(\pi/18)$ [71, 124] ; par suite, les calculs donnent pour le p critique

$$p_c^{\text{edge}} = \frac{1}{2} + \sin\left(\frac{\pi}{18}\right) = 0,673\dots \quad (11.39)$$

Ainsi, la borne obtenue par SWENDSEN-WANG arête par arête (ou, de façon équivalente par SANKARARAMAN-BACCELLI) assure que le recouvrement partiel est impossible pour

$$p < p_c^{\text{edge}}.$$

Au-delà, l'on ne peut pas conclure.

11.3.4.3 Dynamique triangulaire

Sur la grille triangulaire, on choisit une famille de triangles indépendants de sorte que chaque arête appartienne à un unique triangle. Si l'on considère cette grille peinte comme un damier, l'on pourra prendre tous les triangles blancs, orientés vers le haut. À effet de bord négligeable, chaque poids d'arête est transféré son unique triangle blanc adjacent. La dynamique de clusters utilise donc des liens triangulaires corrélés.

Dans le cas d'une percolation corrélée de triangles indépendants [149], le seuil critique est atteint lorsque la probabilité d'avoir un triangle plein (deux ou trois arêtes “ouvertes”, c'est-à-dire gelées) est supérieur à la probabilité d'un triangle vide (aucune arête gelée). Les calculs (voir TAB. 11.1) donnent le seuil critique

$$p_c^{\Delta} = \frac{7}{4} - \frac{\sqrt{17}}{4} = 0,7192\dots \quad (11.40)$$

Remettre un peu plus de lignes de calculs ?

Comme

$$p_c^{\text{edge}} < p_c^{\Delta}, \quad (11.41)$$

la dynamique triangulaire donne une zone de recouvrement plus fine (COROLLAIRE 6).

COROLLAIRE 6 : AMÉLIORATION STRICTE DE LA BORNE SUR LA GRILLE TRIANGULAIRE

Dans le modèle homogène de SANKARARAMAN–BACCELLI sur la grille triangulaire, pour tout

$$p \in \left[\frac{1}{2} + \sin \left(\frac{\pi}{18} \right); \frac{7}{4} - \frac{\sqrt{17}}{4} \right], \quad (11.42)$$

la dynamique SWENDSEN–WANG arête par arête ne permet pas de conclure si le modèle est faiblement/partiellement recouvrable (parce qu’il y a percolation). Au contraire, la dynamique triangulaire ne percole pas ; le recouvrement partiel est donc impossible sur tout cet intervalle.

Preuve. La première borne est obtenue par la percolation indépendante d’arêtes de paramètre $2p - 1$, donc par (11.39). La dynamique triangulaire, elle, produit le modèle de percolation corrélée dont le seuil est décrit en Eq. (11.40). Dans l’intervalle (11.42), les clusters triangulaires restent sous-critiques. Le THÉORÈME 10 assure alors que le recouvrement partiel est impossible. La stricte amélioration vient de (11.41). $\square$

11.4 Ouverture : le modèle de SANKARARAMAN–BACCELLI pour l’assemblage d’haplotypes

Le modèle de SANKARARAMAN–BACCELLI s’applique assez naturellement à l’assemblage d’haplotypes ; ce fut d’ailleurs l’objet de leur collaboration avec VIKALO [150].

L’assemblage d’haplotypes consiste à reconstruire les deux longues chaînes nucléotidiques de deux chromosomes homologues à partir de fragments, ou *lectures* (*reads* en anglais) de ces dernières.

Les sommets du graphe sont les lectures (repérées spatialement sur $\mathbb{Z}$) et les arêtes représentent la vraisemblance que deux lectures (celles d’intersection non vide) soient ou non de la même (*i.e.* issues ou non du même chromosome).




FIGURE 11.9 : Assemblage d’haplotypes (formulé comme un problème de détection de communautés sur graphe). La vérité terrain $\Sigma \in \{+, -\}^V$ répartit les nœuds sur deux chromosomes homologues. Les lectures s’intersectant produisent une arête. Le bruit inhérent au séquençage est modélisé par un *geometric stochastic block model* avec $p = \frac{3}{4}$, introduisant de la frustration.

Retrouver les $K = 2$ communautés revient à attribuer les lectures à chacun de leur chromosome respectif, et par suite à reconstruire leur séquence ADN.

La FIG. 11.9 illustre la correspondance entre le problème d’assemblage d’haplotypes et le recouvrement des $K = 2$ communautés Σ sur un graphe signé.

L’avantage de notre cadre bayésien est qu’il correspond au problème : il est pertinent de représenter le séquençage ADN par un canal bruité. Connaître le taux d’erreur du séquenceur, c’est pouvoir mettre des poids sur les arêtes qui font correspondre exactement notre modèle bayésien avec les données du problème.

Synthèse Nous avons construit dans ce chapitre un cadre bayésien général pour la détection de communautés sur graphes pondérés signés. Dans ce cadre, on a pu définir ce qu’était :

1. **Un algorithme** : un noyau markovien fondé sur l’observation (et les *a priori*).
2. **Un tirage au hasard** (ou *random guess*) : un algorithme agnostique de la réalisation observée (qui ne peut se fonder par conséquent que sur les *a priori*).
3. **Recouvrer faiblement/partiellement/fractionnellement les communautés** : avoir un algorithme qui batte asymptotiquement le meilleur *random guess*.
4. La vérité cachée Σ des modèles génératifs peut être remplacée par une réplique postérieure $\Sigma^{(1)}$. Ce résultat (classique en statistiques) est notre THÉORÈME 8, p. 132.
5. Ainsi, toute dynamique de MARKOV qui laisse la postérieure invariante fournit donc un couplage (COROLLAIRE 2, p. 133).

6. En particulier, les **dynamiques de clusters** permettent d’obtenir des bornes par percolation (bornes qui dépendent du type de dynamique).
7. Si l’on applique nos résultats au modèle de SANKARARAMAN–BACCELLI avec une simple dynamique par arête (SWENDSEN–WANG standard), l’on retrouve leurs résultats : la percolation du graphe avec probabilité $f_{\text{in}} - f_{\text{out}}$ est une condition nécessaire au recouvrement faible. Mieux : la probabilité de percolation donne une borne supérieure à la fraction recouvrable des nœuds.
8. Notre dynamique triangulaire d’ordre supérieur donne de meilleures bornes que SWENDSEN–WANG standard (à tout le moins sur la grille triangulaire, où les bornes exactes sont calculables).

CHAPITRE 12

Extension au traitement du signal : application à la détection des fissures sur des images

Ce chapitre aborde un tout autre type de données : les images. Ici, les sommets de nos (hyper)graphes seront des pixels. Le problème reste de même nature : il faut en extraire des structures d'intérêt, savoir : des réseaux de fissures (et ce à partir de données locales imparfaites).

Ces images pouvant contenir des fissures sont obtenues dans des contextes variés : images de glissements de terrain (prises par un capteur optique dans le domaine visible), données de profondeur (laser 3D profilométrique [151] ou reconstruction photogramétrique) sur des infrastructures civiles, images infra-rouges thermiques de fissures géologiques. L'objectif n'est pas seulement de produire un *masque* binaire (une réponse binaire par pixel), mais d'extraire un réseau (*i.e.* un graphe) qui conserve autant que possible la connectivité, les ramifications et l'orientation générale des fissures.

L'avantage de produire en sortie un graphe (par rapport par exemple à un masque binaire) est que cet objet éditable

Cadre du problème On se donne un domaine discret $\Omega \subset \mathbb{Z}^2$. Les données avec vérité de terrain nous ont manqué jusqu'à présent, mais il n'y a aucun obstacle particulier à ce que l'image soit 3D $\Omega \subset \mathbb{Z}^3$. Une *modalité* est un signal scalaire

$$I : \Omega \longrightarrow \mathbb{R}.$$

Dans le cas multimodal, on dispose d'une famille d'images (recalées)

$$\mathcal{I} = \{I^{(m)}\}_{m \in \mathcal{M}}, \quad I^{(m)} : \Omega \longrightarrow \mathbb{R}.$$

Par exemple, une image visible (en niveau de gris, ou trois modalités différentes Rouge, Vert et Bleu, RGB en anglais), une carte de profondeur, ou encore une image infrarouge thermique. L'hypothèse physique utilisée dans ce chapitre est la suivante : une fissure apparaît comme une vallée sombre (*dark ridge*, en anglais), c'est-à-dire comme une structure dont la courbure principale est positive. (Si une modalité code au contraire les fissures comme des crêtes claires, il suffit d'inverser le contraste avant d'appliquer la méthode.)

La sortie visée est un ensemble de pixels

$$\hat{\Gamma} \subset \Omega$$

qui représente le squelette du réseau. Par squelette, nous entendons ici la projection au niveau des pixels d'un (hyper)graphe. Nous nous sommes limités dans ce manuscrit aux cas $K = 1$ (graphe standard) et $K = 2$ (composantes triangle-connexes). Lorsque $K = 1$, la sortie $\hat{\Gamma}$ est donc une représentation linéique, de largeur un pixel, qui garde le centre géométrique des fissures plutôt que leur épaisseur. Lorsque $K = 2$, $\hat{\Gamma}$ correspond aux pixels des triangles des composantes triangle-connexes sélectionnées. Si l'on souhaite tout de même avoir une représentation linéique, $\hat{\Gamma}$ peut alors faire l'objet d'un amincissement au moyen d'un algorithme de squelettisation comme celui de LEE [152, 153].

En particulier, les métriques d'évaluation devront tenir compte de ce choix.

Le chapitre reprend les travaux menés avec le Cerema, depuis une première version consacrée aux images du glissement de terrain des Vaches Noires [110], jusqu'à une version plus générale intégrant la multimodalité, l'accélération GPU et les interactions d'ordre supérieur (et destinée à être soumise au journal de l'ISPRS [111]).

Positionnement Les méthodes d'apprentissage profond dominent aujourd'hui la détection de fissures : réseaux convolutionnels de type U-Net [131], DeepCrack [132], Transformers [133], puis modèles de diffusion comme CrackSegDiff [134]. Ces méthodes sont souvent excellentes quand les images de test ressemblent aux images d'apprentissage. La revue récente de ZHANG *et al.* [109] insiste cependant sur deux difficultés qui nous concernent directement : le coût d'annotation et la mauvaise généralisation aux changements de domaine.

L'idée défendue ici est complémentaire : revenir à des modèles géométriques explicites. En effet, le prix à payer est une performance parfois plus faible sur des données propres et proches d'un jeu d'entraînement mais il y a un gain attendu : une meilleure stabilité lorsque l'on change de capteur, de texture, de saison ou de type de matériau.

12.1 Un classique : le filtre de FRANGI

Le filtre de FRANGI est un algorithme classique pour rehausser et extraire des structures tubulaires ou curvilignes [108]. Il a d'abord été proposé pour l'imagerie médicale,

notamment pour la détection de vaisseaux sanguins, dans la même famille que les filtres multi-échelle de SATO *et al.* [136]. L'idée s'adapte assez naturellement aux fissures : une fissure est fine, allongée.

Soit $I : \Omega \rightarrow \mathbb{R}$ une image. Pour une échelle gaussienne $\sigma > 0$, on note G_σ le noyau gaussien 2D. La hessienne lissée de I à l'échelle σ est

$$\mathcal{H}_\sigma I(x) = \begin{pmatrix} \partial_{xx}(G_\sigma * I)(x) & \partial_{xy}(G_\sigma * I)(x) \\ \partial_{xy}(G_\sigma * I)(x) & \partial_{yy}(G_\sigma * I)(x) \end{pmatrix}, \quad x \in \Omega. \quad (12.1)$$

En pratique, les dérivées secondes sont calculées par convolution avec les dérivées secondes du noyau gaussien :

$$\partial_{ab}(G_\sigma * I) = (\partial_{ab}G_\sigma) * I, \quad a, b \in \{x, y\}.$$

La matrice en EQ. (12.1) est symétrique réelle. Elle possède donc deux valeurs propres réelles, que l'on ordonne par

$$|\lambda_1^\sigma(x)| \leq |\lambda_2^\sigma(x)|.$$

Le vecteur propre associé à $\lambda_1^\sigma(x)$ donne la direction longitudinale de la fissure, tandis que $\lambda_2^\sigma(x)$ mesure la courbure transverse.

Dans le cas d'une ligne sombre sur fond clair, on attend

$$\lambda_2^\sigma(x) > 0 \quad \text{et} \quad |\lambda_1^\sigma(x)| \ll |\lambda_2^\sigma(x)|.$$

Le premier critère impose le bon signe de *courbure*, le second exprime l'*élongation* (la structure doit ressembler à une ligne, non à une tache ronde, un *blob* en anglais).

La réponse de FRANGI combine typiquement deux termes. Le premier terme mesure l'élongation par le rapport

$$R_{B,\sigma}(x) = \frac{|\lambda_1^\sigma(x)|}{|\lambda_2^\sigma(x)|}. \quad (12.2)$$

Le second terme mesure l'intensité de la réponse de second ordre. Dans notre contexte où l'on suppose que les fissures apparaissent foncées sur fond clair, on peut se contenter de

$$C_\sigma(x) = \lambda_2^\sigma(x) \mathbb{1}_{\lambda_2^\sigma(x) > 0}. \quad (12.3)$$

Remarque Avec l'*a priori* contraire (fissures claires), il suffirait de poser

$$C_\sigma(x) = \lambda_2^\sigma(x) \mathbb{1}_{\lambda_2^\sigma(x) < 0}.$$

Une forme simple de réponse de FRANGI est alors

$$V_\sigma(x) = \exp\left(-\frac{1}{2} \frac{R_{B,\sigma}(x)^2}{\beta^2}\right) \left(1 - \exp\left(-\frac{1}{2} \frac{C_\sigma(x)^2}{c^2}\right)\right), \quad (12.4)$$

où β et c jouent le rôle d'écart-types. Enfin, comme les fissures peuvent avoir des largeurs différentes, l'algorithme est appliqué à plusieurs échelles et l'on conserve la meilleure réponse :

$$V(x) = \max_{\sigma \in \Sigma} V_{\sigma}(x). \quad (12.5)$$

Le filtre de FRANGI a trois qualités : il est rapide, interprétable, et dépend d'un petit nombre de paramètres. Il a aussi une faiblesse importante : il reste essentiellement local. Il dit qu'un pixel ressemble à un morceau de fissure, mais il ne dit pas si ce pixel appartient au même réseau qu'un autre pixel voisin. Cette distinction est cruciale sur des images bruitées, où des ombres, des stries d'asphalte, des cailloux ou des artefacts photogrammétriques peuvent produire des réponses de FRANGI tout à fait crédibles. Le filtre classique identifie un bon candidat local mais ne voit pas de structure globale.

C'est exactement le point où les graphes deviennent utiles.

12.2 Une structure plus riche : le graphe de FRANGI

L'idée originale de notre méthode consiste à remplacer la réponse pixélique du filtre de FRANGI par une similarité entre paires de pixels voisins. Autrement dit, au lieu de se demander seulement « le pixel x appartient-il à une fissure ? », on demande aussi « les pixels x_i et x_j appartiennent-ils à deux morceaux compatibles de la même fissure ? ». Cette seconde approche est beaucoup plus riche en terme d'information sur le réseau de fissures contenu dans l'image.

On construit donc un graphe spatial

$$G = (V, E),$$

où $V \subseteq \Omega$ est un ensemble de pixels candidats et où deux pixels $x_i, x_j \in V$ sont reliés si leur distance euclidienne est inférieure à un rayon R :

$$E_R = \{(i, j) \mid 0 < \|x_i - x_j\| \leq R\}. \quad (12.6)$$

Le choix $R \geq 1$ est important : il permet de franchir de petites discontinuités dues au bruit, à l'ombre ou à une perte locale de contraste. En contrepartie, un rayon trop grand sur-connecte le graphe et permet de faire des "sauts" trop importants.

Pour chaque échelle $\sigma \in \Sigma$, la similarité entre deux pixels x_i et x_j est définie comme le produit de trois termes.

Terme d'élongation Il impose que les deux extrémités de l'arête ressemblent à des structures allongées :

$$S_{\text{shape}}^{\sigma}(x_i, x_j) = \exp \left(-\frac{1}{2} \left(\frac{R_{B,\sigma}(x_i) + R_{B,\sigma}(x_j)}{s_s} \right)^2 \right). \quad (12.7)$$

Si l'un des deux pixels est au centre d'une tache plutôt que d'une ligne, le rapport de FRANGI augmente et l'arête est pénalisée.

Terme d'intensité Il favorise les arêtes dont les deux extrémités ont une forte courbure positive :

$$S_{\text{int}}^{\sigma}(x_i, x_j) = 1 - \exp \left(-\frac{1}{2} \left(\frac{\sqrt{C_{\sigma}(x_i)C_{\sigma}(x_j)}}{s_i} \right)^2 \right). \quad (12.8)$$

Terme d'alignement Ce terme représente le gain le plus important du recours au graphe. Soit $\theta^{\sigma}(x)$ l'angle du vecteur propre associé à $\lambda_1^{\sigma}(x)$, c'est-à-dire la direction locale de la fissure. On pose

$$S_{\text{align}}^{\sigma}(x_i, x_j) = \exp \left(-\frac{1}{2} \left(\frac{\sin(\theta^{\sigma}(x_i) - \theta^{\sigma}(x_j))}{s_a} \right)^2 \right). \quad (12.9)$$

L'utilisation du sinus tient compte du fait qu'une direction de fissure est une droite non orientée : les angles θ et $\theta + \pi$ décrivent la même direction.

La similarité multi-échelle est alors

$$S_{ij} = \max_{\sigma \in \Sigma} (S_{\text{shape}}^{\sigma}(x_i, x_j) S_{\text{int}}^{\sigma}(x_i, x_j) S_{\text{align}}^{\sigma}(x_i, x_j)). \quad (12.10)$$

Cette similarité est finalement transformée en dissimilarité par la formule

$$d_{ij} = (1 - S_{ij}) \|x_i - x_j\|. \quad (12.11)$$

Le facteur $\|x_i - x_j\|$ est une régularisation géométrique essentielle. En effet, deux pixels éloignés peuvent avoir des hessiennes compatibles par accident ; pondérer par la distance empêche l'arbre couvrant minimum de privilégier des sauts longs et instables.

Extraction du squelette Une fois le graphe construit, l'extraction du réseau se fait en quatre étapes :

1. On élimine les pixels dont la courbure maximale est trop faible.
2. On élimine les arêtes dont la similarité S_{ij} est trop faible.
3. Sur chaque composante connexe retenue, on calcule un arbre couvrant minimum pour la dissimilarité d_{ij} .
4. On extrait le centre de cet arbre à l'aide d'une centralité d'intermédierité (*betweenness centrality* en anglais) pondérée.

La centralité d'intermédierité a été introduite par FREEMAN [137], puis calculée efficacement dans les graphes généraux par BRANDES [154]. Dans notre cas, le graphe est ramené à un arbre, ce qui simplifie de beaucoup le calcul.

Soit $\mathcal{T}$ un arbre couvrant minimum. Si l'on retire un sommet v , l'arbre se décompose en branches

$$\text{Branch}(\mathcal{T} \setminus v) = \{b_1, \dots, b_q\}.$$

Au lieu de mesurer la taille d'une branche par son nombre de sommets, on la mesure par la somme des similarités de ses arêtes :

$$\mathcal{M}(b_r) = \sum_{e \in b_r} S_e. \quad (12.12)$$

La centralité pondérée du sommet v est alors

$$C_B(v) = \frac{1}{2} \left[\left(\sum_{r=1}^q \mathcal{M}(b_r) \right)^2 - \sum_{r=1}^q \mathcal{M}(b_r)^2 \right]. \quad (12.13)$$

Les sommets situés sur l'axe central du réseau relient de grandes masses de réponse de FRANGI ; ils accumulent donc une forte centralité. Les pixels périphériques, eux, participent à peu de chemins et sont éliminés par un seuil relatif τ_c [111].

L'algorithme complet ALG. 2 est résumé ci-dessous.

Algorithm 2 Extraction d'un squelette par graphe de FRANGI généralisé

Require : Modalités recalées $\{I^{(m)}\}_{m \in \mathcal{M}}$, poids $\{w_m\}$, échelles Σ , rayon R , paramètres s_s, s_i, s_a , seuils τ, τ_c , ordre $K \in \{1, 2\}$. **return** Squelette de fissures $\hat{\Gamma}$.

- 1 : Calculer la hessienne fusionnée à chaque échelle (c.f. § 12.2.1).
 - 2 : Extraire les valeurs propres $(\lambda_1^\sigma, \lambda_2^\sigma)$ et l'orientation θ^σ .
 - 3 : Construire les arêtes de voisinage E_R et calculer S_{ij} puis d_{ij} .
 - 4 : Élaguer les pixels de faible courbure positive (on en garde une proportion τ).
 - 5 : Élaguer les arêtes de faible similarité (on en garde une proportion τ).
 - 6 : **if** $K = 1$ **then**
 - 7 : Extraire les composantes connexes du graphe.
 - 8 : **else**
 - 9 : Extraire les composantes triangles-connexes du graphe ($K = 2$).
 - 10 : **end if**
 - 11 : Calculer une forêt couvrante minimum pour la dissimilarité d_{ij} .
 - 12 : Ne conserver que les composantes suffisamment grandes.
 - 13 : Calculer la centralité pondérée, cf. EQ. (12.13).
 - 14 : Seuiller la centralité à τ_c pour obtenir le squelette $\hat{\Gamma}$.
-

La dernière mise en œuvre [111] faite lors de les étapes lourdes sont vectorisées avec PyTorch et calculées de sur GPU. Les voisinages sont extraits avec des opérations de type `unfold`, puis les arêtes sont traitées par morceaux pour éviter de saturer la mémoire GPU.

12.2.1 Extension à la multimodalité

La fusion multimodale est souvent traitée en apprentissage profond par concaténation de canaux (par exemple canaux spectraux), fusion de caractéristiques intermédiaires, ou

fusion tardive des prédictions. Ces approches dépendent fortement de l'architecture du réseau et du jeu de modalités vu pendant l'entraînement. Ajouter une modalité demande souvent de réentraîner le modèle, voire de le modifier, ce qui représente un coût non négligeable. Ici, la fusion se fait avant le graphe, directement au niveau des opérateurs différentiels (hessienne). Pour chaque modalité $m \in \mathcal{M}$, on calcule la hessienne

$$\mathcal{H}_\sigma^{(m)}(x).$$

Les modalités n'ont pas les mêmes unités physiques, l'on normalise donc chaque hessienne par sa norme spectrale [112] :

$$\widehat{\mathcal{H}}_\sigma^{(m)}(x) = \frac{\mathcal{H}_\sigma^{(m)}(x)}{\max_{y \in \Omega} \|\mathcal{H}_\sigma^{(m)}(y)\|_2}. \quad (12.14)$$

Pour une matrice symétrique 2×2 , la norme spectrale est

$$\|A\|_2 = \sup_{\|u\|=1} \|Au\| = \max(|\mu_1|, |\mu_2|), \quad (12.15)$$

où μ_1, μ_2 sont les valeurs propres de A . Le choix de cette norme est naturel ici : il normalise l'amplitude maximale de courbure de chaque modalité.

La hessienne fusionnée est ensuite une combinaison convexe :

$$\mathcal{H}_\sigma^{\text{fused}}(x) = \sum_{m \in \mathcal{M}} w_m \widehat{\mathcal{H}}_\sigma^{(m)}(x), \quad w_m \geq 0, \quad \sum_{m \in \mathcal{M}} w_m = 1. \quad (12.16)$$

Toutes les quantités utilisées plus haut, valeurs propres, orientations, courbure positive, sont ensuite calculées sur $\mathcal{H}_\sigma^{\text{fused}}$.

Cette fusion repose sur une hypothèse géométrique : les bruits peuvent être différents d'une modalité à l'autre, mais la fissure physique produit des variations de signal alignées. Si cette hypothèse est vraie, les directions principales des hessiennes se renforcent sur la fissure, alors que les artefacts non corrélés se renforcent beaucoup moins, voire s'annulent.

Un avantage important est que la formule en Eq. (12.16) ne dépend pas du nombre de modalités. Nous avons testé des images visibles, de profondeur et infrarouges thermiques, mais la définition accepte n'importe quel nombre de modalités scalaires recalées. Ajouter ou retirer un capteur revient simplement à modifier l'ensemble $\mathcal{M}$ et les poids w_m associés.

12.2.2 Interactions d'ordre supérieur

Le graphe de FRANGI décrit jusqu'ici reste un graphe ordinaire : une fissure est reconstruite par des chaînes d'arêtes. Or, c'est précisément ce type de mécanisme qui peut être fragile sur des images à forte granularité. Des cailloux, des irrégularités de surface

peuvent produire de nombreuses petites réponses tubulaires. Avec des arêtes simples, ces réponses finissent parfois par se raccorder en branches parasites.

L'idée est alors de reprendre le principe développé dans la Partie II (voir le chapitre 6 et [64]) : renforcer la notion de connexité en faisant intervenir des interactions d'ordre supérieur. Dans ce chapitre, nous n'utilisons que le cas $K = 2$, c'est-à-dire les triangles.

À partir du graphe $G = (V, E)$, on cherche les triangles

$$\{u, v, w\} \quad \text{tels que} \quad (u, v), (v, w), (u, w) \in E.$$

On construit alors un graphe dual G^Δ dont les sommets sont les arêtes de G . Deux arêtes de G sont adjacentes dans G^Δ si elles appartiennent à un même triangle. Les composantes connexes de G^Δ définissent ce que nous appelons les composantes triangles-connexes.

Ce critère est plus exigeant qu'une simple connexité par l'intermédiaire arêtes. Une chaîne fine de bruit peut relier deux zones très éloignées, mais elle forme rarement des triangles cohérents. À l'inverse, une fissure réelle, même si l'on cherche finalement son squelette unidimensionnel, apparaît dans l'image comme un ruban de quelques pixels d'épaisseur ; elle contient donc localement assez de densité pour engendrer des triangles.

L'implémentation GPU procède par intersections de listes de voisins triées, avec des appels vectorisés de type `torch.searchsorted`. Cela évite de parcourir explicitement tous les triplets de pixels.

12.3 Résultats

Les résultats ci-dessous ont trois objectifs distincts : vérifier que la méthode donne des réseaux corrects sur des fissures géologiques visibles ; montrer l'intérêt de la fusion multimodale sur le *benchmark* FIND [151] ; illustrer le rôle des interactions d'ordre supérieur dans un contexte granulaire visible et thermique.

12.3.1 Jeux de données et protocole

Nous utilisons quatre familles de données.

- **Vaches Noires** (©Cerema). Deux images visibles 512×512 issues d'acquisitions drone sur le glissement des Vaches Noires, à Villers-sur-Mer. Le site présente une morphologie de *badland* et des réseaux de fissures multi-échelle [130]. Ces images ont servi à la première version de la méthode [110]. La comparaison se fait avec un U-Net adapté par *transfer learning* [155].
- **FIND**. Le *benchmark* FIND [151] fournit des images alignées d'intensité et de profondeur pour la détection de fissures sur infrastructures (routes). Nous utilisons les premières images du protocole, en retirant les cas où l'annotation ou le contraste est incompatible avec l'hypothèse physique de vallée sombre. Les mêmes exclusions sont appliquées à toutes les méthodes comparées.

- **VT-GraF** (©Cerema). Ce jeu (deux modalités : visible et thermique) vise un cas encore peu couvert par les *benchmarks* publics : des fissures dans un milieu très granulaire, où des cailloux et irrégularités produisent beaucoup de faux candidats. L'intérêt principal est ici qualitatif et méthodologique : tester la robustesse du $K = 2$ dans un contexte où les graphes ordinaires se laissent facilement piéger.
- **CrackForest**. CrackForest [156] est un *benchmark* classique de fissures routières. Comme la vérité terrain est déjà fournie sous forme de squelettes, il est particulièrement utile pour les tests de sensibilité aux paramètres. L'image 042 est écartée car il y a clairement une erreur au niveau de sa vérité terrain.

Métriques Soient A la vérité terrain et B la prédiction, vues comme ensembles de pixels. Nous utilisons l'indice de JACCARD [157] (parfois aussi appelé *Intersection over Union*, IoU)

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|}, \quad (12.17)$$

l'indice de TVERSKY [158]

$$T(A, B) = \frac{|A \cap B|}{|A \cap B| + \alpha|A \setminus B| + \beta|B \setminus A|}, \quad \alpha = 1, \quad \beta = \frac{1}{2}, \quad (12.18)$$

et une distance de WASSERSTEIN entre distributions discrètes portées par les pixels des deux réseaux [159]. Le choix $\alpha = 1, \beta = 1/2$ pénalise davantage les fissures manquées que les sur-détections (en cohérence avec un usage d'inspection).

Dans FIND, les annotations sont des masques épais, tandis que notre méthode produit un squelette. Pour limiter ce biais, les masques de vérité terrain et les sorties denses des méthodes d'apprentissage profond sont squelettisés par l'algorithme de LEE disponible dans `scikit-image` [153]. Pour JACCARD et TVERSKY, les squelettes sont ensuite dilatés de 3 pixels. Ce seuil est empirique ; il sert seulement à tolérer de petits décalages spatiaux.

12.3.2 Images géologiques visibles : Vaches Noires

Sur les deux images des Vaches Noires, nous utilisons une seule modalité visible et plusieurs échelles

$$\Sigma = \{1, 3, 5, 7, 9\}.$$

Les autres paramètres sont fixés de façon *ad hoc*¹⁾ : $R = 3, \tau = 0,3; \tau_c = 0,005; K = 1$. (Voir les différentes étapes de notre méthode illustrés en FIG. 12.1.) Le modèle U-Net de comparaison est adapté par *transfer learning* sur une image annotée de 3760×2058

¹⁾Comme nous le verrons lors de l'analyse de sensibilité en § 12.3.5, le paramètre le plus important à bien régler est l'ensemble d'échelles Σ . Or Σ peut se régler facilement de façon *ad hoc* avec seulement un *a priori* sur la fenêtre de largeur des structures d'intérêt, *i.e.* les fissures.

pixels provenant de la même zone. Cette annotation a demandé environ deux jours de travail à un expert géophysicien [110].




FIGURE 12.1 : Chaîne de traitement sur une image des Vaches Noires. Ligne du haut : image visible, réponse de FRANGI classique, graphe de similarité, composantes retenues. Ligne du bas : centralité, vérité terrain, squelette prédit, superposition finale.

TABLE 12.1 – Comparaison quantitative sur deux images des Vaches Noires. Les valeurs sont calculées entre le squelette expert et le squelette prédit.

Image	Méthode	JACCARD $\uparrow$	TVERSKY $\uparrow$	WASSERSTEIN $\downarrow$
Test1	Graphe de FRANGI	0.47	0.52	34 px
	U-Net + T.L.	0.50	0.60	38 px
Test2	Graphe de FRANGI	0.29	0.32	81 px
	U-Net + T.L.	0.34	0.36	60 px




FIGURE 12.2 : Comparaison qualitative sur les deux images des Vaches Noires. La vérité terrain apparaît en vert, notre méthode en rouge et U-Net + *transfer learning* en bleu.

Les résultats (qualitativement en FIG. 12.2, quantitativement en TAB. 12.1) sont du même ordre que ceux de la méthode supervisée. U-Net obtient légèrement de meilleurs scores de recouvrement sur ces deux images car ce réseau de neurones a été adapté sur une image très proche (*via transfer learning*), annotée dans le même contexte. En revanche, le graphe de FRANGI n'utilise aucune annotation et isole plus directement l'ossature principale du réseau. Sur Test 1, cela donne même une meilleure distance de WASSERSTEIN. Ce résultat montre que notre méthode géométrique simple sans annotation est compétitive sans avoir besoin d'annotation experte coûteuse indispensable en apprentissage profond.

12.3.3 Fusion multimodale : FIND

FIND [151] permet de tester la fusion entre intensité, profondeur et profondeur filtrée. L'image visible peut contenir des stries d'asphalte ou des textures allongées qui ressemblent beaucoup à des fissures. La profondeur apporte une information différente sur le signe de la courbure des stries (voir la FIG. 12.3).




FIGURE 12.3 : Exemple de fusion multimodale sur FIND (image 0001). La similarité de FRANGI généralisée isole la fissure principale malgré les stries visibles dans l'intensité. **Ajouter a) b) c) d) et la fissure (en rouge) dans d)**

Le tableau suivant (TAB. 12.2) montre l'effet des poids de fusion. La modalité filtrée seule est déjà très utile, mais la fusion des trois modalités donne le meilleur compromis.

TABLE 12.2 – Influence des poids de fusion sur FIND. I désigne l'intensité, R la profondeur, F la profondeur filtrée (*Filtered*).

Poids	JACCARD $\uparrow$	TVERSKY $\uparrow$	WASSERSTEIN $\downarrow$
$I = 1$	41%	48%	43 px
$R = 1$	54%	62%	20 px
$F = 1$	60%	68%	12 px
$I = \frac{1}{2}, R = \frac{1}{2}$	60%	68%	18 px
$I = \frac{1}{3}, R = \frac{1}{3}, F = \frac{1}{3}$	63%	71%	11 px

Cependant, sur données propres, CrackSegDiff [134] reste largement supérieur. C'était attendu : le modèle de diffusion est entraîné pour ce type de données et produit des masques très ajustés à la distribution du *benchmark*.

TABLE 12.3 – Comparaison avec CrackSegDiff sur FIND propre.

Méthode	JACCARD $\uparrow$	TVERSKY $\uparrow$	WASSERSTEIN $\downarrow$
Graphe de FRANGI ($I + R + F$)	63%	71%	11 px
CrackSegDiff	87%	90%	5 px

La situation devient différente lorsque l'on ajoute un bruit synthétique hors distribution : bruit multiplicatif de type chatoiement (*speckle* en anglais) sur l'intensité, bruit gaussien additif sur la profondeur. Les courbes de la FIG. 12.4 montrent que notre méthode géométrique se dégrade lentement [111], alors que le modèle de diffusion perd rapidement

la fissure [134]. C'est un résultat important, parce qu'il illustre exactement un compromis évoqué par [109] : spécialisation contre stabilité.




FIGURE 12.4 : Retour des axes Dégradation des performances sur FIND bruité. Le bruit augmente de gauche à droite. L'échelle verticale va de 0% à 100%. La méthode géométrique reste plus stable, tandis que CrackSegDiff se dégrade fortement hors de sa distribution d'entraînement.

12.3.4 Milieu granulaire en imagerie visible-thermique : VT-GraF

Le jeu VT-GraF (Visible, Thermique, Granularité et Fissures, ©Cerema) est particulièrement utile pour tester les interactions d'ordre supérieur. Les images combinent une modalité visible et une modalité infrarouge thermique, avec une surface très granulaire (voir FIG. 12.5 et FIG. 12.6 avec nos résultats). De nombreux cailloux produisent des réponses locales allongées. Un graphe de FRANGI ordinaire, avec $K = 1$, construit alors beaucoup de branches parasites.

Le passage à $K = 2$ impose que les arêtes appartiennent à des triangles. Cette contrainte élimine une grande partie des réponses granulaires isolées. Les deux exemples ci-dessous (FIG. 12.5 et FIG. 12.6) montrent l'effet recherché : la composante retenue suit la fissure principale, alors que le fond produit de nombreuses réponses locales.




FIGURE 12.5 : Exemple VT-GraF. De gauche à droite et de haut en bas : visible, thermique, courbure positive, graphe de similarité, composantes triangles-connexes, centralité, vérité terrain, superposition.




FIGURE 12.6 : Second exemple VT-GraF. Le $K = 2$ agit comme un filtre de densité locale et supprime une grande partie des artefacts granulaires.

12.3.5 Sensibilité aux paramètres : CrackForest

CrackForest [156] permet une étude de sensibilité plus propre, car les vérités terrain sont déjà des squelettes. L'image 001, par exemple, est correctement reconstruite par la méthode avec $K = 2$, comme illustré en FIG. 12.7.




FIGURE 12.7 : Exemple sur CrackForest, image 001. Le squelette prédit est en rouge, la vérité terrain en vert. Sur cette image : JACCARD = 78%, distance de WASSERSTEIN = 5 px.

Les essais de sensibilité donnent les tendances suivantes :

- L'ordre $K = 2$ améliore légèrement les résultats sur CrackForest, mais son intérêt principal apparaît surtout sur les images granulaires de type VT-GraF.
- L'échelle gaussienne σ_0 est le paramètre le plus important dès que les fissures ont une largeur relativement homogène. Sur CrackForest, l'échelle optimale est autour de 4 px.

- Le rayon R interagit avec σ_0 . En pratique, il faut éviter de choisir R trop grand par rapport à l'échelle, sinon des fissures parallèles ou des structures voisines peuvent être reliées artificiellement.
- Les paramètres de similarité s_s, s_i, s_a sont moins sensibles que prévu car les étapes importantes de seuillage sont toutes *relatives* (on garde une proportion τ , voir ALG. 2). Sauf si ces paramètres permutent les réponses de similarité de FRANGI, ils n'ont pas d'influence sur les résultats¹⁾.
- Le bon choix du seuil d'élagage τ est plus délicat. Si fixé trop faible, le graphe se fragmente ; trop élevé, il conserve des arêtes parasites qui peuvent créer des ponts dans l'arbre couvrant minimum.




FIGURE 12.8 : Exemples de courbes de sensibilité sur CrackForest (bleu : JACCARD ; vert : TVERSKY ; rouge : WASSERSTEIN). Les réponses les plus instables apparaissent lorsque le graphe est trop fragmenté ou au contraire trop dense. **À séparer**

Nous avons aussi testé l'interaction entre R et σ_0 par une grille de paramètres. Le test de FISHER [160] obtenu dans cette analyse (voir FIG. 12.9 ; hypothèse nulle : apports additifs indépendants de chacun des paramètres sur la réponse) donne $F = 21.0$ avec $p < 0.001$, ce qui rejette l'hypothèse nulle. Dit plus simplement : ces deux paramètres ne se règlent pas indépendamment.




FIGURE 12.9 : **Refaire et séparer** Interaction entre le rayon du graphe R et l'échelle de base σ_0 sur CrackForest.

¹⁾Nous avons pu nous permettre cela car il y avait toujours au moins une fissure sur les *benchmarks* testés. Pour un passage à l'échelle industrielle, cette faiblesse devrait être corrigée.

12.3.6 Conclusion sur les résultats du graphe de FRANGI

Les expériences montrent que le graphe de FRANGI que nous avons introduit au cours de ce chapitre est une méthode crédible pour extraire des réseaux de fissures sans données annotées d'entraînement. La méthode dépend d'hypothèses explicites : fissures assimilables à des vallées sombres, modalités correctement recalées, existence d'un réseau suffisamment visible, choix d'échelles raisonnable.

Il y a aussi trois limites pratiques.

1. Les seuils τ et τ_c sont relatifs. Ils fonctionnent bien lorsqu'on sait qu'une image contient une fissure, mais une utilisation industrielle demanderait aussi un seuil absolu pour rejeter une image sans fissure.
2. L'arbre couvrant minimum élimine les cycles ; cela peut poser problème pour des réseaux de fractures fermées et demanderait un post-traitement adéquat.
3. Les comparaisons avec l'apprentissage profond doivent encore être élargies : plus de jeux de données, plus de *baselines*, et surtout des *benchmarks* multimodaux mieux annotés. Le manque de données visible-thermique adaptées est actuellement une vraie contrainte expérimentale. Le *benchmark* promis par [109] permettra-t-il de résoudre ce problème dans le futur ?

12.4 Ouverture : vers une réconciliation de l'apprentissage profond et des modèles mathématiques

La conclusion naturelle de ce chapitre n'est pas qu'il faudrait choisir entre apprentissage profond et modèles mathématiques. En réalité, les deux approches présentent chacune des avantages et des inconvénients complémentaires.

L'apprentissage profond est excellent pour apprendre des structures aux apparences complexes. Mais il demande des données annotées, et sa robustesse hors distribution reste fragile, notamment dans les contextes de fissures où les capteurs, les matériaux et les résolutions changent souvent [109]. Les modèles de type FRANGI, eux, généralisent mieux parce qu'ils reposent sur des contraintes géométriques simples, mais ils manquent parfois de souplesse face à des cas visuels ambigus.

Pour continuer ce travail de recherche, une première piste consiste à utiliser les modèles géométriques comme outils d'annotation. Le graphe de FRANGI produit un squelette éditable, souvent proche du réseau principal. Il pourrait servir à générer des pré-annotations, ensuite corrigées par un expert. Cela réduirait le coût de constitution de bases d'apprentissage, qui est l'un des freins majeurs du domaine.

Une deuxième piste consiste à injecter explicitement des opérateurs différentiels dans les réseaux. Des travaux récents autour de neurones ou couches inspirés du filtre de FRANGI montrent que l'on peut intégrer des réponses hessiennes dans une architecture

entraînable [161]. Ce type d'approche est intéressant : le réseau n'a plus à redécouvrir seul que les lignes allongées ont une géométrie de second ordre : on lui donne l'outil.

Une troisième piste concerne les modèles de fondation en vision par ordinateur. SAM [162] et ses adaptations aux fissures, comme CrackSAM [163], montrent l'intérêt de grands modèles pré-entraînés. Mais les fissures posent une difficulté particulière : ce sont des objets fins, discontinus, dont la topologie compte autant que l'apparence. Une contrainte de graphe, ou une pénalisation de connectivité, pourrait servir de post-traitement ou même de module différentiable pour réduire les phénomènes de sur-détection et de sous-détection.

Synthèse Le filtre de FRANGI classique donne une réponse locale. Nous avons introduit un *graphe* de FRANGI, qui ajoute une notion de compatibilité entre pixels. Cette méthode a l'avantage de permettre de faire de la fusion multimodale, en agissant au niveau des hessiennes. Nos expérimentations montrent que les interactions d'ordre supérieur renforcent la connexité dans les milieux granulaires. L'ensemble donne une méthode sans apprentissage, imparfaite mais robuste et dont l'application principale que nous lui voyons serait un logiciel d'aide à l'annotation de vérité terrain (la sortie étant un graphe, elle est facilement éditable).

Conclusion générale

Au cours de cette thèse, nous avons abordé et essayé d’explorer en détail le problème de clustering et de structuration automatique de données. Nous sommes partis d’un cadre minimaliste, lorsque les données $\mathcal{X} \subset \mathbb{R}^p$ sont dans l’espace euclidien. Le modèle statistique le plus courant consiste à supposer que les données $\mathcal{X} = \{x_1, \dots, x_n\}$ sont le résultat de n réalisations indépendantes et identiquement distribuées (i.i.d), selon une certaine loi à densité f par rapport à la mesure de LEBESGUE. Le but est de retrouver la hiérarchie des niveaux de densité (voir la FIG. 2.4, p. 25, ainsi que la FIG. 4.2, p. 45).

Évidemment, une première approche aurait pu consister à faire des hypothèses sur la distribution f et supposer, par exemple, un mélange gaussien. Notre modèle eût alors été paramétrique¹⁾, ce qui nous aurait conduit à la question du choix des ‘bons’ estimateurs pour ces paramètres. Cette approche, qu’on pourrait qualifier de “généraliste”, n’a pas du tout été la nôtre ; la voie que nous avons choisie fut “discriminative” (se reporter à l’introduction du chapitre 2 pour une brève discussion sur ce sujet).

En ne posant aucun *a priori* sur la densité f , il ne nous restait guère que l’estimateur $\hat{f}_{K\text{-NN}}$ des K plus proches voisins pour pouvoir identifier la hiérarchie des niveaux de densité.

C’est alors que se produit un “miracle” pour $K = 1$: les niveaux, ou *amas*, de forte densité sont *exactement* donnés par un objet très simple : un graphe géométrique. Mieux encore : toute l’information hiérarchique – pour tous les niveaux – est comprise dans un seul graphe, le plus petit des graphes : l’arbre minimum couvrant sur les données $\mathcal{X}$.

Ces propriétés font le pont entre le modèle de HARTIGAN, mathématiquement élégant et satisfaisant, à un algorithme heuristique très courant : le Single-Linkage.

Ce constat nous a mis le pied à l’étrier ; la question suivante était naturellement amenée :

Si la hiérarchie des niveaux de densité est donnée par un simple graphe lorsque la densité est estimée à l’aide de $K = 1$ voisin, qu’en est-il lorsque $K \geq 2$?

La réponse à cette question s’est avérée beaucoup plus riche et dépassant le seul cadre euclidien du modèle de HARTIGAN ; elle constitue l’un des deux piliers fondamentaux de cette thèse :

¹⁾De paramètres dans le cas du mélange gaussien : les centres, les matrices de covariances ainsi que les poids associés à chaque gaussienne.

Quand les relations binaires d'un graphe (entre paires de points) se révèlent insuffisantes ou trop instables, il est nécessaire d'intégrer des **interactions d'ordre supérieur** pour garantir une cohérence robuste.

Toutes les propriétés du Single-Linkage, tant théoriques que algorithmiques, se généralisent naturellement lorsque l'on passe ainsi des graphes aux *hypergraphes*.

Le second pilier de notre thèse concerne l'analyse de cette famille d'algorithmes que l'on peut construire à partir de graphes/hypergraphes. L'on pourrait le résumer ainsi :

La théorie de la **percolation** est la clef de voûte théorique pour comprendre et quantifier les performances de tels algorithmes.

Là encore, notre analyse ne s'est pas limitée au cadre euclidien, mais a été poussée jusqu'à des données en entrée autrement plus structurées que de simples nuages de points : graphes (avec des arêtes portant des poids, et les nœuds des attributs) dont il s'agit de retrouver les 'communautés' ou images desquelles il faut extraire automatiquement une information comme un réseau de fissures.

Nous donnons ci-dessous un bilan des contributions plus détaillé et faisons le point, chapitre par chapitre, sur les questions ouvertes et autres perspectives qui pourraient suivre nos travaux.

13.1 Bilan des contributions

Notre cheminement s'est articulé autour de quatre axes majeurs :

1. **Une vue unifiée pour le clustering hiérarchique.** Tout l'intérêt de la première partie est d'avoir proposé un cadre unifié et cohérent pour le Single-Linkage. Nous nous sommes concentrés sur les trois points de vue qui nous intéressaient pour généraliser naturellement cet algorithme, à savoir une vue qui peut être :
 - (a) **Heuristique.** Le Single-Linkage est souvent décrit par une heuristique qui revient à construire l'arbre minimum couvrant sur les données. C'est aussi de cette façon qu'il est mis en œuvre. Pour autant, il possède une grande richesse théorique si l'on ne le restreint pas à ce cadre heuristique.
 - (b) **Geométrique.** Définir le Single-Linkage au moyen de (hyper)graphes géométriques permet de le relier phénomène mathématique de la percolation, point de vue indispensable pour analyser ses performances théoriques.
 - (c) **Statistique.** C'est le modèle de HARTIGAN, qui explique exactement ce que l'on cherche (les amas de forte densité), et à quels estimateurs l'on recourt pour ce faire (l'estimateur des K plus proches voisins).

Fait révélateur qui montre l'importance – et l'omniprésence – du Single-Linkage : on retrouve cet algorithme tout aussi bien en informatique théorique, si l'on souhaite

poser une axiomatique minimale à ce que devrait être un “bon” clusteringⁱ⁾. Ce dernier point permet de voir le problème de clustering comme une application des espaces métriques vers les espaces ultramétriques. Ces espaces ultramétriques sont d’ailleurs des espaces de recherche privilégiés : nous montrons sur des problèmes industriels complexes comment y injecter simplement des *a priori* géométriques et obtenir des réponses rapides et satisfaisantes, et ce sans entraînement. Les deux problèmes qui nous servent à illustrer la conclusion de la première partie sont la détection d’anomalies 3D LiDAR et la segmentation panoptique 4D.

2. **HGP-Clusterer : la généralisation par l’ordre supérieur.** De nombreux algorithmes ont été proposés pour rendre davantage robuste le Single-Linkage, le plus universellement adopté aujourd’hui est HDBSCAN. Ne recourant pas à des interactions d’ordre supérieur (ils continuent de travailler sur des graphes), ces algorithmes créent une asymétrie entre les contraintes fortes qu’ils imposent aux nœuds, tandis qu’ils ne peuvent mettre que des contraintes permissives sur la connexion par arêtes. Notre algorithme, HGP-Clusterer, lui, identifie exactement les amas de forte densité des K plus proches voisins pour n’importe quel entier K . Pour ce faire, nous avons substitué aux graphes géométriques des hypergraphes géométriques, à savoir : les complexes de Čech, et aux composantes connexes les K -polyèdres. Sur le plan algorithmique, nous avons prouvé que les fusions utiles (les simplexes K -séparant) vérifient une condition de vacuité stricte (être un simplexe de GABRIEL) et peuvent être extraites efficacement à partir de la mosaïque de DELAUNAY d’ordre $K - 1$. Nous montrons d’ailleurs sur des données synthétiques 2D et un jeu de données d’huiles d’olive italiennes (représentées par des vecteur de $\mathbb{R}^8$) que prendre $K = 2$ suffit déjà à obtenir de très bons résultats.
3. **La percolation comme mesure de performance théorique.** La limite historique du Single-Linkage en dimension $p \geq 2$ (l’effet de chaînage) n’est autre qu’un phénomène de percolation continue : le bruit de fond percole et fusionne différents amas avant que ceux-ci n’aient pu être intégralement récupérés. Le Single-Linkage est consistant uniquement en dimension $p = 1$ justement parce que le phénomène de percolation n’y a pas lieu. Nous avons formalisé ce mécanisme en introduisant la *vitesse de percolation*. Nous avons ainsi pu quantifier mathématiquement à quel point le Robust Single-Linkage et (H)DBSCAN échouent à recouvrir correctement les amas de forte densité (leur connectivité, lâche, provoque une percolation prématurée et finalement pas assez rapide). À l’inverse, l’exigence d’interactions d’ordre supérieur (K -polyèdres) retarde l’apparition de la composante géante dans le bruit, faisant correspondre exactement l’algorithme avec le modèle statistique de HARTIGAN et permettant de récupérer une fraction théorique bien supérieure des amas.
4. **Passage à des données davantage structurées : le *leitmotiv* percolation/ordre**

ⁱ⁾Ce point de vue ne constitue qu’une digression au cours de nos recherches ; le problème étant qu’il ne nous permet pas de généraliser aussi naturellement qu’avec les autres points de vue. Le choix d’une axiomatique reste en dernière analyse toujours assez arbitraire.

supérieur demeure. La troisième partie du manuscrit a montré que l'on peut aller au-delà du paradigme euclidien et retrouver les mêmes phénomènes à l'œuvre (robustification grâce aux interactions d'ordre supérieur et percolation pour l'analyse théorique) :

- **Sur les graphes signés (détection de communautés).** Nous avons prouvé, dans un cadre bayésien soigneusement établi, que le recouvrement partiel des communautés est strictement conditionné par la percolation d'une dynamique de clusters. En généralisant la dynamique de SWENDSEN–WANG avec des interactions d'ordre supérieur (dynamique triangulaire), nous réduisons la frustration géométrique, retardons la percolation parasite et obtenons des bornes théoriques de recouvrement strictement plus fines.
- **En traitement d'image (extraction de réseaux de fissures).** Face au manque de généralisation de l'apprentissage profond lors de changements de domaine (*domain shifts*), nous avons introduit le graphe de FRANGI multimodal. L'imposition d'une connexité d'ordre supérieur ($K = 2$) agit comme un filtre qui empêche le bruit local de percoler en fausses branches, offrant une extraction robuste des fissures dans des milieux fortement granulaires.

13.2 Ouvertures et perspectives de recherche

Les travaux présentés dans cette thèse ouvrent plusieurs directions de recherche. Nous en proposons quelques-unes en reprenant le fil de la thèse.

- **Chapitre 3.** L'approche axiomatique n'est pas celle que nous avons privilégiée, pourtant elle pourrait servir à chercher et identifier les bons espaces de recherche (*clustering domain*). Par exemple, les métriques d'arbre pourraient être un bon objet à regarder, légèrement plus général que les ultramétriques (qui sont en correspondance avec un type particulier d'arbre : les dendrogrammes). De plus, les outils rencontrés dans ce chapitre, comme la distance de GROMOV–HAUSDORFF, seraient un autre moyen de quantifier la stabilité de notre HGP-Clusterer.
- **Chapitre 4 & 7.** HGP-Cluster n'est pas plus consistant (au sens de HARTIGAN) que le Single-Linkage. Il est seulement *fractionnellement* consistant (et cette fraction se mesure grâce à la théorie de la percolation). La question d'avoir un algorithme qui soit consistant en toute dimension $p \geq 2$ reste ouverte. Pour l'obtenir, il serait nécessaire d'introduire des notions de composantes connexes encore plus restrictives.
- **Chapitre 7.** Le champ gaussien introduit au cours du chapitre, obtenu comme limite du *shot noise* centré réduit, possède certainement de bonnes propriétés mathématiques qui le rendent intéressant pour des problèmes théoriques comme celui du *sphere packing* en grande dimension, pour retrouver le dernier facteur 2 manquant à [164] par rapport à la conjecture de PARISI & ZAMPONI. De manière générale,

notre travail apporte des perspectives à toute démonstration faisant intervenir des graphes géométriques (au sens de PENROSE).

- **Chapitre 8. Réduction de dimension d'ordre supérieur.** La mosaïque de Delaunay d'ordre K contient une information structurelle autrement plus riche qu'un simple graphe de voisinages utilisé par des méthodes comme UMAP. Construire un algorithme de réduction de dimension préservant la géométrie dictée par cet objet (ou une "bonne" approximation) constitue un prolongement naturel de notre étude et notre piste privilégiée.
- **Chapitre 11.** Notre cadre bayésien, créant une réplique postérieure *via* une dynamique de type SWENDSEN-WANG, nous permet d'obtenir une borne théorique sur le recouvrement des communautés. Pour obtenir des résultats exacts, il nous faudrait créer non pas une mais deux répliques postérieures. C'est un sujet de recherche très actif. Puisque nous avons montré que des interactions d'ordre supérieur donnent de meilleures bornes, une autre piste serait d'analyser si oui ou non le passage à des interaction d'ordre plus grand convergerait vers l'objet d'intérêt. Le cas échéant, et pour que cette approche soit utile, il nous faudrait quantifier cette vitesse de convergence.
- **Chapitre 12.** Il nous paraît de plus en plus évident que la méthode "FRANGI-(hyper)graphe" que nous avons développée trouverait toute son utilité au sein d'un logiciel d'aide à l'annotation experte de vérité terrain pour des images de réseaux de fissures. L'avantage de notre méthode est qu'elle rend en sortie un (hyper)graphe, objet aisément "éditable". Le point fort de notre méthode étant que nous avons montré qu'elle peut être appliquée à une très grande variété d'images, et ce sans apprentissage, en réglant simplement de façon *ad hoc* quelques paramètres (comme la taille des fissures que l'expert souhaiterait annoter).

Annexe

ANNEXE **A**

Cartographie des publications




FIGURE A.1 : Cartographie des relations entre la structure du manuscrit et les publications associées.

Bibliographie

- [1] K. FLOREK et al. « Sur la liaison et la division des points d'un ensemble fini ». fre. In : *Colloquium Mathematicum* 2.3-4 (1951), p. 282-285. DOI : 10.4064/cm-2-3-4-282-285.
- [2] J. C. GOWER et G. J. S. ROSS. « Minimum Spanning Trees and Single Linkage Cluster Analysis ». In : *Journal of the Royal Statistical Society. Series C (Applied Statistics)* 18.1 (1969), p. 54-64. DOI : 10.2307/2346439.
- [3] J. A. HARTIGAN. « Consistency of Single Linkage for High-Density Clusters ». In : *J. of the Am. Stat. Ass.* 76.374 (1981), p. 388-394. DOI : 10.1080/01621459.1981.10477658.
- [4] M. PENROSE. *Random Geometric Graphs*. T. 5. Oxford Studies in Probability. Oxford University Press, 2003. DOI : 10.1093/acprof:oso/9780198506263.001.0001.
- [5] R. MEESTER et R. ROY. *Continuum Percolation*. T. 119. Cambridge Tracts in Mathematics. Cambridge University Press, 1996. DOI : 10.1017/CBO9780511895357.
- [6] O. BOBROWSKI et M. KAHLE. « Topology of rand. geom. complexes : a survey ». In : *Journal of Appl. and Comput. Top.* 1 (2018), p. 331-364. DOI : 10.1007/s41468-017-0010-0.
- [7] R. J. G. B. CAMPELLO, D. MOULAVI et J. SANDER. « Density-Based clustering based on hierarchical density estimates ». In : *Advances in Knowledge Discovery and Data Mining*. Springer, 2013, p. 160-172. ISBN : 978-3-642-37456-2. DOI : 10.1007/978-3-642-37456-2_14.
- [8] L. MCINNIS et J. HEALY. « Accelerated Hierarchical Density Based Clustering ». In : *IEEE International Conference on Data Mining Workshops (ICDMW)*. 2017, p. 33-42. DOI : 10.1109/ICDMW.2017.12.
- [9] A. KAYUMOV, S. MAKHAMMADJONOV et J. S. SHIN. « Minimal and Simplified Analysis of Hierarchical Density-Based Spatial Clustering ». In : *IEEE Access* 13 (2025), p. 145191-145199. DOI : 10.1109/ACCESS.2025.3596634.
- [10] D. M. BOT et al. « FLASC : A flare-sensitive clustering algorithm ». In : *PeerJ Computer Science* 11 (2025), e2792. DOI : 10.7717/peerj-cs.2792.
- [11] S. P. LLOYD. « Least squares quantization in PCM ». In : *IEEE Transactions on Information Theory* 28.2 (1982), p. 129-137. DOI : 10.1109/TIT.1982.1056489.

- [12] A. Y. NG et M. I. JORDAN. « On discriminative vs. generative classifiers : A comparison of logistic regression and naive bayes ». In : *Advances in Neural Information Processing Systems (NIPS)*. T. 14. MIT Press, 2001. URL : <https://papers.nips.cc/paper/2020-on-discriminative-vs-generative-classifiers-a-comparison-of-logistic-regression-and-naive-bayes>.
- [13] SCIKIT-LEARN LIBRARY. *Gaussian mixture models*. <https://scikit-learn.org/stable/modules/mixture.html#gmm>. [Online; accessed 14-February-2024].
- [14] F. MURTAGH et P. CONTRERAS. « Algorithms for hierarchical clustering : an overview, II ». In : *WIREs Data Mining and Knowledge Discovery* 7 (2017). DOI : 10.1002/widm.1219.
- [15] WIKIPEDIA CONTRIBUTORS. *Single-linkage clustering — Wikipedia, The Free Encyclopedia*. https://en.wikipedia.org/wiki/Single-linkage_clustering. [En ligne; accédé le 25-mars-2026]. 2026.
- [16] F. NIELSEN. « Hierarchical Clustering ». In : *Introduction to HPC with MPI for Data Science*. Springer International Publishing, 2016, p. 195-211. DOI : 10.1007/978-3-319-21903-5_8.
- [17] A. ROLLE et L. SCOCCOLA. « Stable and Consistent Density-Based Clustering via Multiparameter Persistence ». In : *Journal of Machine Learning Research* 25.258 (2024), p. 1-74. DOI : 10.48550/arXiv.2005.09048. URL : <https://jmlr.org/papers/v25/21-1185.html>.
- [18] O. BORŮVKA. « O jistém problému minimálním (Sur un certain problème minimal) ». In : *Práce Moravské Přírodovědecké Společnosti v Brně* 3 (1926), p. 37-58. DOI : 10.1016/S0012-365X(00)00224-7.
- [19] J. B. KRUSKAL. « On the shortest spanning subtree of a graph and the traveling salesman problem ». In : *Proceedings of the American Mathematical Society* 7.1 (1956), p. 48-50. DOI : 10.1090/S0002-9939-1956-0078686-7.
- [20] C. A. R. HOARE. « Quicksort ». In : *The Computer Journal* 5.1 (1962), p. 10-16. DOI : 10.1093/comjnl/5.1.10.
- [21] R. E. TARJAN. « Efficiency of a Good But Not Linear Set Union Algorithm ». In : *Journal of the ACM* 22.2 (1975), p. 215-225. DOI : 10.1145/321879.321884.
- [22] B. CHAZELLE. « A minimum spanning tree algorithm with inverse-Ackermann type complexity ». In : *Journal of ACM* 47.6 (nov. 2000), p. 1028-1047. DOI : 10.1145/355541.355562.
- [23] S. PETTIE et V. RAMACHANDRAN. « An optimal minimum spanning tree algorithm ». In : *Journal of ACM* 49.1 (jan. 2002), p. 16-34. DOI : 10.1145/505241.505243.
- [24] D. R. KARGER, P. N. KLEIN et R. E. TARJAN. « A randomized linear-time algorithm to find minimum spanning trees ». In : *Journal of ACM* 42.2 (mars 1995), p. 321-328. DOI : 10.1145/201019.201022.

- [25] N. VELDT et al. « Approximate Forest Completion and Learning-Augmented Algorithms for Metric Minimum Spanning Trees ». In : *Proceedings of the 42nd International Conference on Machine Learning (ICML)*. 2025. DOI : 10.48550/arXiv.2502.12993. URL : <https://proceedings.mlr.press/v267/veldt25a.html>.
- [26] G. T. TOUSSAINT. « The relative neighbourhood graph of a finite planar set ». In : *Pattern Recognition* 12.4 (1980), p. 261-268. DOI : 10.1016/0031-3203(80)90066-7.
- [27] K. R. GABRIEL et R. R. SOKAL. « A new statistical approach to geographic variation analysis ». In : *Systematic Zoology* 18.3 (1969), p. 259-278. DOI : 10.2307/2412323.
- [28] B. DELAUNAY. « Sur la sphère vide. A la mémoire de Georges Voronoï ». In : *Bulletin de l'Académie des Sciences de l'URSS. Classe des sciences mathématiques et naturelles* 6 (1934), p. 793-800. URL : <http://mi.mathnet.ru/eng/izv4937>.
- [29] J.-D. BOISSONNAT, F. CHAZAL et M. YVINEC. *Geometric and Topological Inference*. Cambridge Texts in Applied Mathematics. Cambridge University Press, 2018. DOI : 10.1017/9781108297806.
- [30] E. N. GILBERT. « Random Plane Networks ». In : *Journal of the Society for Industrial and Applied Mathematics* 9.4 (1961), p. 533-543. DOI : 10.1137/0109045.
- [31] T. K. DEY et Y. WANG. *Computational Topology for Data Analysis*. Cambridge University Press, 2022. DOI : 10.1017/9781009099950.
- [32] R. C. PRIM. « Shortest connection networks and some generalizations ». In : *The Bell System Technical Journal* 36.6 (1957), p. 1389-1401. DOI : 10.1002/j.1538-7305.1957.tb01515.x.
- [33] L. HAUSEUX, K. AVRACHENKOV et J. ZERUBIA. « Hypergraphs, percolation, and hierarchical clustering ». In : *Proceedings of the 13th International Conference on Complex Networks and their Applications*. Studies in Computational Intelligence. Istanbul, Turkey : Springer, déc. 2024. DOI : 10.1007/978-3-031-82431-9_2.
- [34] J. HARTIGAN. *Clustering Algorithms*. John Wiley & Sons, Inc., 1975. ISBN : 978-0-471-35645-5.
- [35] G. BIAU et L. DEVROYE. *Lectures on the Nearest Neighbor Method*. T. 246. Springer, 2015. ISBN : 978-3-319-25386-2. DOI : 10.1007/978-3-319-25388-6.
- [36] R. J. G. B. CAMPELLO et al. « Density-based clustering ». In : *WIREs Data Mining and Knowledge Discovery* 10.2 (2020), e1343. DOI : 10.1002/widm.1343.
- [37] J. KLEINBERG. « An impossibility theorem for clustering ». In : *Advances in Neural Information Processing Systems (NIPS)* 15 (2002). URL : <https://papers.nips.cc/paper/2002/hash/2291d2ec3b3048d1a6f86c2c4591b7e0-Abstract.html>.

- [38] G. CARLSSON et F. MÉMOLI. « Characterization, Stability and Convergence of Hierarchical Clustering Methods ». In : *Journal of Machine Learning Research* 11.47 (2010), p. 1425-1470. URL : <https://jmlr.org/papers/v11/carlsson10a.html>.
- [39] J. CULBERTSON, D. P. GURALNIK et P. F. STILLER. « Functorial Hierarchical Clustering with Overlaps ». In : *Discrete Applied Mathematics* 236 (2018), p. 108-123. DOI : 10.1016/j.dam.2017.10.015.
- [40] S. C. JOHNSON. « Hierarchical clustering schemes ». In : *Psychometrika* 32.3 (1967), p. 241-254. DOI : 10.1007/BF02289588.
- [41] L. HAUSEUX. « How can we theoretically measure the performance of density-based clustering algorithms? ». In : *ACM SIGMETRICS 2024 Student Research Competition*. Second prize. Venice, Italy, juin 2024. DOI : 10.1145/3725536.3725546.
- [42] T. SØRENSEN. « A method of establishing groups of equal amplitude in plant sociology based on similarity of species and its application to analyses of the vegetation on Danish commons ». In : *Biologiske Skrifter* 5.4 (1948), p. 1-34. URL : <http://publ.royalacademy.dk/books/31/>.
- [43] R. R. SOKAL et C. D. MICHENER. « A statistical method for evaluating systematic relationships ». In : *University of Kansas Science Bulletin* 38.22 (1958), p. 1409-1438. URL : <https://archive.org/details/universityofkans3802univ>.
- [44] D. WISHART. « Mode analysis : a generalization of nearest neighbour which reduces chaining effects (with discussion) ». In : *Numerical taxonomy* (1969), p. 282-311. URL : <https://cir.nii.ac.jp/crid/1571980075067269888>.
- [45] K. CHAUDHURI et S. DASGUPTA. « Rates of convergence for the cluster tree ». In : *Advances in Neural Information Processing Systems*. T. 23. Curran Associates, Inc., 2010, p. 343-351. URL : <https://papers.nips.cc/paper/4068-rates-of-convergence-for-the-cluster-tree>.
- [46] M. ANKERST et al. « OPTICS : Ordering Points To Identify the Clustering Structure ». In : *Proceedings of the 1999 ACM SIGMOD International Conference on Management of Data*. SIGMOD '99. Philadelphia, Pennsylvania, USA : ACM, 1999, p. 49-60. ISBN : 1-58113-084-8. DOI : 10.1145/304182.304187. URL : <https://doi.org/10.1145/304182.304187>.
- [47] A. DRAGANOV et al. « Ultrametric Cluster Hierarchies : I Want 'em All! ». In : *Advances in Neural Information Processing Systems (NeurIPS)*. T. 38. Curran Associates, Inc., 2025. DOI : 10.48550/arXiv.2502.14018. URL : <https://neurips.cc/virtual/2025/poster/119173>.
- [48] M. ESTER et al. « A Density-Based Algorithm for Discovering Clusters in Large Spatial Databases with Noise ». In : *Proceedings of the Second International Conference on Knowledge Discovery and Data Mining*. KDD'96. Portland, Oregon : AAAI Press, 1996, p. 226-231. URL : <https://dl.acm.org/doi/10.5555/3001460.3001507>.

- [49] D. W. MÜLLER et G. SAWITZKI. « Excess Mass Estimates and Tests for Multimodality ». In : *Journal of the American Statistical Association* 86.415 (1991), p. 738-746. DOI : 10.1080/01621459.1991.10475103.
- [50] J. BEHLEY et al. « SemanticKITTI : A Dataset for Semantic Scene Understanding of LiDAR Sequences ». In : *Proc. of the IEEE/CVF International Conf. on Computer Vision (ICCV)*. 2019. DOI : 10.1109/ICCV.2019.00939.
- [51] T. D. HOCKING et al. « Clusterpath : An algorithm for clustering using convex fusion penalties ». In : *Proceedings of the 28th International Conference on Machine Learning (ICML)*. 2011, p. 745-752. URL : <https://hal.science/hal-00591630>.
- [52] E. C. CHI et K. LANGE. « Splitting methods for convex clustering ». In : *Journal of Computational and Graphical Statistics* 24.4 (2015), p. 994-1013. DOI : 10.1080/10618600.2014.948181.
- [53] K. M. TAN et D. WITTEN. « Statistical properties of convex clustering ». In : *Electronic Journal of Statistics* 9.2 (2015), p. 2329-2347. DOI : 10.1214/15-EJS1072.
- [54] C. GINI. « Measurement of Inequality of Incomes ». In : *The Economic Journal* 31.121 (1921), p. 124-126. DOI : 10.2307/2223319.
- [55] C. SAUTIER et al. « Is clustering enough for LiDAR instance segmentation? A state-of-the-art training-free baseline ». In : *arXiv preprint arXiv:2503.13203* (2025). DOI : 10.48550/arXiv.2503.13203.
- [56] G. OH et al. « Training-Free Global Geometric Association for 4D LiDAR Panoptic Segmentation ». In : *arXiv preprint arXiv:2512.18991* (2025). DOI : 10.48550/arXiv.2512.18991.
- [57] G. PEYRÉ et M. CUTURI. « Computational Optimal Transport : With Applications to Data Science ». In : *Foundations and Trends® in Machine Learning* 11.5-6 (2019), p. 355-607. DOI : 10.1561/22000000073.
- [58] R. E. KALMAN. « A New Approach to Linear Filtering and Prediction Problems ». In : *Transactions of the ASME, Journal of Basic Engineering* 82.1 (1960), p. 35-45. DOI : 10.1115/1.3662552.
- [59] L. CHIZAT et al. « Scaling algorithms for unbalanced optimal transport problems ». In : *Mathematics of Computation* 87.314 (2018), p. 2563-2609. DOI : 10.1090/mcom/3303.
- [60] M. CUTURI. « Sinkhorn Distances : Lightspeed Computation of Optimal Transport ». In : *Advances in Neural Information Processing Systems*. T. 26. Curran Associates, Inc., 2013, p. 2292-2300. URL : <https://papers.nips.cc/paper/4927-sinkhorn-distances-lightspeed-computation-of-optimal-transport>.
- [61] G. OSANG et H. EDELSBRUNNER. « A Simple Algorithm for Higher-Order Delaunay Mosaics and Alpha Shapes ». In : *Algorithmica* 85 (2023), p. 277-295. DOI : 10.1007/s00453-022-01027-6.

- [62] J. R. MUNKRES. *Elements of Algebraic Topology*. CRC Press, 1984, p. 468. DOI : 10.1201/9780429493911.
- [63] E. ČECH. « Théorie générale de l'homologie dans un espace quelconque ». In : *Fundamenta Mathematicæ* 19.1 (1932), p. 149-183. DOI : 10.4064/fm-19-1-149-183.
- [64] L. HAUSEUX, K. AVRACHENKOV et J. ZERUBIA. « Generalization of single-linkage with higher-order interactions ». In : *Applied Network Science* 11.1 (2026), p. 9. DOI : 10.1007/s41109-025-00756-1.
- [65] G. PALLA et al. « k -Clique Percolation and Clustering ». In : *Handbook of Large-Scale Random Networks*. Sous la dir. de B. BOLLOBÁS, R. KOZMA et D. MIKLÓS. Berlin, Heidelberg : Springer Berlin Heidelberg, 2008, p. 369-408. DOI : 10.1007/978-3-540-69395-6_9.
- [66] R. ATKIN. « From cohomology in physics to q -connectivity in social science ». In : *International Journal of Man-Machine Studies* 4.2 (1972), p. 139-167. DOI : 10.1016/S0020-7373(72)80029-4.
- [67] C. HIRSCH et D. VALESIN. « Face and cycle percolation ». In : *Journal of Applied and Computational Topology* 9.1 (2025), p. 6. DOI : 10.1007/s41468-025-00202-2.
- [68] W. STUETZLE et R. NUGENT. « A Generalized Single Linkage Method for Estimating the Cluster Tree of a Density ». In : *Journal of Computational and Graphical Statistics* 19.2 (2010), p. 397-418. DOI : 10.1198/jcgs.2009.07049.
- [69] S. R. BROADBENT et J. M. HAMMERSLEY. « Percolation processes. I. Crystals and mazes ». In : *Mathematical Proceedings of the Cambridge Philosophical Society* 53.3 (1957), p. 629-641. DOI : 10.1017/S0305004100032680.
- [70] H. DUMINIL-COPIN. « Sixty years of percolation ». In : *Proceedings of the International Congress of Mathematicians (ICM 2018)*. World Scientific, 2019, p. 2829-2856. DOI : 10.1142/9789813272880_0162.
- [71] G. GRIMMETT. *Percolation*. Springer, 1999. ISBN : 978-3-540-64902-1. DOI : 10.1007/978-3-662-03981-6.
- [72] B. BOLLOBÁS et O. RIORDAN. *Percolation*. Cambridge University Press, 2006. ISBN : 9781139167383. DOI : 10.1017/CBO9781139167383.
- [73] M. D. PENROSE. « Single Linkage Clustering and Continuum Percolation ». In : *Journal of Multivariate Analysis* 53.1 (1995), p. 94-109. DOI : 10.1006/jmva.1995.1026.
- [74] F. BACCELLI et B. BŁASZCZYSZYN. *Stochastic Geometry and Wireless Networks, Volume I - Theory*. T. 1. Foundations and Trends in Networking. NoW Publishers, 2009, p. 150. DOI : 10.1561/13000000006.
- [75] G. LAST, G. PECCATI et D. YOGESHWARAN. « Phase transitions and noise sensitivity on the Poisson space via stopping sets and decision trees ». In : *Random Structures & Algorithms* 63.2 (2023), p. 457-511. DOI : 10.1002/rsa.21136.

- [76] J. QUINTANILLA, S. TORQUATO et R. M. ZIFF. « Efficient measurement of the percolation threshold for fully penetrable discs ». In : *Journal of Physics A : Mathematical and General* 33.42 (2000), p. L399-L407. DOI : 10.1088/0305-4470/33/42/104.
- [77] W. XU et al. « Critical polynomials in the nonplanar and continuum percolation models ». In : *Physical Review E* 103 (2 fév. 2021), p. 1-11. DOI : 10.1103/PhysRevE.103.022127.
- [78] G. LAST, M. PENROSE et S. ZUYEV. « On the capacity functional of the infinite cluster of a Boolean model ». In : *The Annals of Applied Probability* 27.3 (2017), p. 1678-1701. DOI : 10.1214/16-AAP1241.
- [79] G. LAST, M. PENROSE et S. ZUYEV. « Corrections : On the capacity functional of the infinite cluster of a Boolean model ». In : *The Annals of Applied Probability* 34.3 (2024), p. 3370-3374. DOI : 10.1214/23-AAP2043.
- [80] H. DUMINIL-COPIN, A. RAOUFI et V. TASSION. « Subcritical phase of d -dimensional Poisson–Boolean percolation and its vacant set ». In : *Annales Henri Lebesgue* 3 (2020), p. 677-700. DOI : 10.5802/ahl.43.
- [81] J.-M. AZAÏS et M. WSCHEBOR. *Level Sets and Extrema of Random Processes and Fields*. John Wiley & Sons, 2009. DOI : 10.1002/9780470434642.
- [82] R. J. ADLER et J. E. TAYLOR. *Random Fields and Geometry*. Springer Monographs in Mathematics. New York : Springer, 2007. ISBN : 978-0-387-48112-8. DOI : 10.1007/978-0-387-48116-6.
- [83] L. HAUSEUX, K. AVRACHENKOV et J. ZERUBIA. « Graph Based Approach for Galaxy Filament Extraction ». In : *Complex Networks & Their Applications XII*. Springer, 2023, p. 384-396. DOI : 10.1007/978-3-031-53472-0_32.
- [84] M. PENROSE et X. YANG. *On the components of random geometric graphs in the dense limit*. 2025. DOI : 10.48550/arXiv.2501.02676. arXiv : 2501.02676 [math.PR].
- [85] M. PENROSE et X. YANG. « On k -clusters of high-intensity random geometric graphs ». In : *Stochastic Processes and their Applications* 195 (2026), p. 104882. DOI : 10.1016/j.spa.2026.104882.
- [86] R. H. CAMERON et W. T. MARTIN. « Transformations of Wiener Integrals under Translations ». In : *Annals of Mathematics* 45.2 (1944), p. 386-396. DOI : 10.2307/1969276.
- [87] V. I. BOGACHEV. *Gaussian Measures*. T. 62. Mathematical Surveys and Monographs. Providence, RI : American Mathematical Society, 1998. ISBN : 978-0-8218-1054-5.
- [88] A. BERLINET et C. THOMAS-AGNAN. *Reproducing Kernel Hilbert Spaces in Probability and Statistics*. Kluwer Academic Publishers, 2004. DOI : 10.1007/978-1-4419-9096-9.
- [89] M. SCHILDER. « Some Asymptotic Formulas for Wiener Integrals ». In : *Transactions of the American Mathematical Society* 125.1 (1966), p. 63-85. DOI : 10.1090/S0002-9947-1966-0201892-6.

- [90] A. DEMBO et O. ZEITOUNI. *Large Deviations Techniques and Applications*. 2^e éd. T. 38. Stochastic Modelling and Applied Probability. Berlin, Heidelberg : Springer, 2010. ISBN : 978-3-642-03311-7. DOI : 10.1007/978-3-642-03311-7.
- [91] E. WELZL. « Smallest enclosing disks (balls and ellipsoids) ». In : *New Results and New Trends in Computer Science*. Sous la dir. de H. MAURER. Berlin, Heidelberg : Springer Berlin Heidelberg, 1991, p. 359-370. DOI : 10.1007/BFb0038202.
- [92] H. EDELSBRUNNER et G. OSANG. « The Multi-cover Persistence of Euclidean Balls ». In : *Discrete & Computational Geometry* 65.4 (2021), p. 1296-1313. DOI : 10.1007/s00454-021-00281-9.
- [93] V. G. PESTOV. « On the Geometry of Similarity Search : Dimensionality Curse and Concentration of Measure ». In : *Information Processing Letters* 73.1-2 (2000), p. 47-51. DOI : 10.1016/S0020-0190(99)00156-8.
- [94] M. FORINA et al. « Classification of olive oils from their fatty acid composition ». In : *Food research and data analysis : proceedings from the IUFOST Symposium, September 20-23, 1982, Oslo*. London : Applied Science Publishers. 1983.
- [95] H. WICKHAM et al. « tourr : An R Package for Exploring Multivariate Data with Projections ». In : *Journal of Statistical Software* 40.2 (2011), p. 1-18. DOI : 10.18637/jss.v040.i02.
- [96] L. HUBERT et P. ARABIE. « Comparing partitions ». In : *Journal of classification* 2 (1985), p. 193-218. DOI : 10.1007/BF01908075.
- [97] P. FRÄNTI et S. SIERANOJA. « K-means properties on six clustering benchmark datasets ». In : *Applied Intelligence* 48 (2018), p. 4743-4759. DOI : 10.1007/s10489-018-1238-7.
- [98] M. GAGOLEWSKI. « A framework for benchmarking clustering algorithms ». In : *SoftwareX* 20 (2022), p. 101270. DOI : 10.1016/j.softx.2022.101270. URL : <https://clustering-benchmarks.gagolewski.com>.
- [99] H. W. E. JUNG. « Über die kleinste Kugel, die eine räumliche Figur einschließt ». In : *Journal für die reine und angewandte Mathematik* 123 (1901), p. 241-257. DOI : 10.1515/crll.1901.123.241.
- [100] L. MCINNES, J. HEALY et J. MELVILLE. *UMAP : Uniform Manifold Approximation and Projection for Dimension Reduction*. 2020. DOI : 10.48550/arXiv.2109.02508. URL : <https://arxiv.org/abs/1802.03426>.
- [101] A. SANKARARAMAN et F. BACCELLI. « Community Detection on Euclidean Random Graphs ». In : *Proceedings of the Annual ACM-SIAM Symposium on Discrete Algorithms (SODA)* (2018), p. 2181-2200. DOI : 10.1137/1.9781611975031.142.
- [102] C. P. ROBERT. *Méthodes de Monte Carlo par chaînes de Markov*. Statistique mathématique et probabilités. Paris : Economica, 1996.

- [103] R. H. SWENDSEN et J.-S. WANG. « Nonuniversal critical dynamics in Monte Carlo simulations ». In : *Phys. Rev. Lett.* 58 (2 jan. 1987), p. 86-88. DOI : 10.1103/PhysRevLett.58.86.
- [104] A. K. JAIN. *Fundamentals of Digital Image Processing*. Prentice-Hall Information and System Sciences Series. Englewood Cliffs, NJ : Prentice-Hall, Inc., 1989. ISBN : 0-13-336165-9.
- [105] J.-P. COCQUEREZ et al. *Analyse d'images : filtrage et segmentation*. French. Collection Enseignement de la physique. Masson, 1995. ISBN : 2-225-84923-4.
- [106] R. C. GONZALEZ et R. E. WOODS. *Digital Image Processing*. 4th. Pearson, 2018. ISBN : 978-0-13-335672-4.
- [107] Z. KATO et J. ZERUBIA. *Markov Random Fields in Image Segmentation*. T. 5. 1-2. Foundations et Trends® in Signal Processing, 2012, p. 1-155. DOI : 10.1561/20000000035.
- [108] A. F. FRANGI et al. « Multiscale vessel enhancement filtering ». In : *Medical Image Computing and Computer-Assisted Intervention*. Springer, 1998. DOI : 10.1007/BFb0056195.
- [109] X. ZHANG et al. « Deep Learning for Crack Detection : A Review of Learning Paradigms, Generalizability, and Datasets ». In : (2025). preprint arXiv:2508.10256. DOI : 10.48550/arXiv.2508.10256.
- [110] L. HAUSEUX et al. « Généralisation du filtre de Frangi pour l'extraction des réseaux de fissures au sein d'images d'un glissement de terrain. Comparaison avec une méthode d'apprentissage profond ». In : *XXXe Colloque Francophone de Traitement du Signal et des Images (GRETSI)*. Online. Strasbourg, août 2025, p. 389-392.
- [111] L. HAUSEUX et al. *Multi-Modal, Training-Free Crack Extraction via Generalized Frangi Graph*. Journal en préparation. 2026.
- [112] K. AVRACHENKOV et M. DREVETON. *Statistical Analysis of Networks*. Now publishers, 2022. DOI : 10.1561/9781638280514.
- [113] S. FORTUNATO. « Community detection in graphs ». In : *Physics Reports* 486.3 (2010), p. 75-174. ISSN : 0370-1573. DOI : 10.1016/j.physrep.2009.11.002.
- [114] J. REICHARDT et S. BORNHOLDT. « Statistical mechanics of community detection ». In : *Phys. Rev. E* 74 (1 juill. 2006), p. 016110. DOI : 10.1103/PhysRevE.74.016110.
- [115] A. TRAAG, P. VAN DOOREN et Y. NESTEROV. « Narrow scope for resolution-limit-free community detection ». In : *Phys. Rev. E* 84 (1 juill. 2011), p. 016114. DOI : 10.1103/PhysRevE.84.016114.
- [116] G. PARISI. *Statistical field theory*. Frontiers in Physics. Addison-Wesley, 1988, p. 352. ISBN : 0-201-05985-1.

- [117] J. SALEZ. *Modern aspects of Markov chains : entropy, curvature and the cutoff phenomenon*. Saint-Flour lecture notes, submitted. 2025. arXiv : 2508 . 21055 [math.PR].
- [118] P. DIACONIS. « The Markov chain Monte Carlo revolution ». In : *Bulletin of the American Mathematical Society* 46.2 (2009), p. 179-205. DOI : 10.1090/S0273-0979-08-01238-X.
- [119] V. BLONDEL et al. « Fast unfolding of communities in large networks ». In : *Journal of Statistical Mechanics : Theory and Experiment* 2008.10 (oct. 2008), P10008. DOI : 10.1088/1742-5468/2008/10/P10008.
- [120] V. TRAAG, L. WATMAN et N. van ECK. « From Louvain to Leiden : guaranteeing well-connected communities ». In : *Scientific Reports* 9.5233 (2019). DOI : 10.1038/s41598-019-41695-z.
- [121] G. CELEUX, M. HURN et C. P. ROBERT. « Computational and inferential difficulties with mixture posterior distributions ». In : *Journal of the American Statistical Association* 95.451 (2000), p. 957-970.
- [122] R. G. EDWARDS et A. D. SOKAL. « Generalization of the Fortuin-Kasteleyn-Swendsen-Wang representation and Monte Carlo algorithm ». In : *Phys. Rev. D* 38 (6 sept. 1988), p. 2009-2012. DOI : 10.1103/PhysRevD.38.2009.
- [123] C. FORTUIN et P. KASTELEYN. « On the random-cluster model : I. Introduction and relation to other models ». In : *Physica* 57.4 (1972), p. 536-564. ISSN : 0031-8914. DOI : 10.1016/0031-8914(72)90045-6.
- [124] G. GRIMMETT. *The random-cluster model*. T. 333. Springer, 2006. DOI : 10.1007/978-3-540-32891-9.
- [125] V. CATAUDELLA et al. « Critical clusters and efficient dynamics for frustrated spin models ». In : *Physical Review Letters* 72.10 (1994), p. 1541.
- [126] L. MÜNSTER et M. WEIGEL. « Spin glasses and percolation ». In : *Frontiers in Physics* 12 (2024). DOI : 10.3389/fphy.2024.1448175.
- [127] D. KANDEL, R. BEN-AV et E. DOMANY. « Cluster Monte Carlo dynamics for the fully frustrated Ising model ». In : *Phys. Rev. B* 45 (9 mars 1992), p. 4700-4709. DOI : 10.1103/PhysRevB.45.4700.
- [128] CEREMA et SETRA. *Image de la Qualité des Ouvrages d'Art (IQOA) – Les ponts : Pont dalle en béton armé - Catalogue des désordres*. Guide technique. Bagneux, France : Centre d'études et d'expertise sur les risques, l'environnement, la mobilité et l'aménagement (Cerema), 1996. URL : https://doc.cerema.fr/Default/doc/SYRACUSE/16512/iqoa-tablier-du-pont-dalle-en-beton-arme-desordres-catalogue-des-desordres?_lg=fr-FR.
- [129] E. BIRD. *Coastal cliffs : morphology and management*. Springer, 2016.

- [130] C. FAUCHARD et al. « Diachronic UAV study of coastal badlands supported by geophysical imaging in the context of accelerated erosion processes ». In : *Landslides* 20.5 (2023), p. 1065-1082.
- [131] O. RONNEBERGER, P. FISCHER et T. BROX. « U-Net : Convolutional networks for biomedical image segmentation ». In : *MICCAI* (2015).
- [132] Q. ZOU et al. « DeepCrack : Learning hierarchical convolutional features for crack detection ». In : *IEEE Transactions on Image Processing* 28.3 (2019), p. 1498-1512.
- [133] H. LIU et al. « CrackFormer : Transformer Network for Fine-Grained Crack Detection ». In : *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*. Oct. 2021, p. 3783-3792.
- [134] X. JIANG et al. *CrackSegDiff : Diffusion Probability Model-based Multi-modal Crack Segmentation*. preprint arXiv:2410.08100. 2024. DOI : 10.48550/arXiv.2410.08100.
- [135] B. JAFRASTEH, I. MANIGHETTI et J. ZERUBIA. « Generative adversarial networks as a novel approach for tectonic fault and fracture extraction in high resolution satellite and airborne optical images ». In : *XXIV International Society of Photogrammetry and Remote Sensing Congress*. T. XLIII-B3-2020. Nice, France, août 2020, p. 1219-1227. DOI : 10.5194/isprs-archives-XLIII-B3-2020-1219-2020.
- [136] Y. SATO et al. « Three-dimensional multi-scale line filter for segmentation and visualization of curvilinear structures in medical images ». In : *Medical Image Analysis* 2.2 (1998), p. 143-168. DOI : 10.1016/S1361-8415(98)80009-1.
- [137] L. C. FREEMAN. « A set of measures of centrality based on betweenness ». In : *Sociometry* (1977), p. 35-41.
- [138] P. HOLLAND, K. LASKEY et S. LEINHARDT. « Stochastic blockmodels : First steps ». In : *Social Networks* 5.2 (1983), p. 109-137. DOI : 10.1016/0378-8733(83)90021-7.
- [139] A. DECELLE et al. « Asymptotic analysis of the stochastic block model for modular networks and its algorithmic applications ». In : *Phys. Rev. E* 84 (6 déc. 2011), p. 066106. DOI : 10.1103/PhysRevE.84.066106. URL : <https://link.aps.org/doi/10.1103/PhysRevE.84.066106>.
- [140] E. ABBE. « Community Detection and Stochastic Block Models : Recent Developments ». In : *Journal of Machine Learning Research* 18.177 (2018), p. 1-86.
- [141] H. SCHawe et A. K. HARTMANN. « Large deviations of connected components in the stochastic block model ». In : *Phys. Rev. E* 102 (5 nov. 2020), p. 052108. DOI : 10.1103/PhysRevE.102.052108.
- [142] E. ABBE, F. BACCELLI et A. SANKARARAMAN. « Community detection on Euclidean random graphs ». In : *Information and Inference : A Journal of the IMA* 10.1 (mai 2020), p. 109-160.

- [143] L. HAUSEUX, N. SOPRANO-LOTO et K. AVRACHENKOV. « Higher-order Monte Carlo cluster dynamics for community detection in Euclidean graphs ». In : *Asilomar Conference on Signals, Systems, and Computers 2025*. Pacific Grove (CA), United States, oct. 2025. URL : <https://inria.hal.science/hal-05267074>.
- [144] L. HAUSEUX, N. SOPRANO-LOTO et K. AVRACHENKOV. *A Bayesian Framework for Community Detection on Signed Graphs. Tighter Bounds with Higher-Order Interaction Markov Chain Monte Carlo Cluster Dynamics*. Article en cours de rédaction. 2026+.
- [145] H. NISHIMORI. « Exact results and critical properties of the Ising model with competing interactions ». In : *Journal of Physics C : Solid State Physics* 13.21 (1980), p. 4071-4076. DOI : 10.1088/0022-3719/13/21/012.
- [146] H. NISHIMORI. *Statistical Physics of Spin Glasses and Information Processing : An Introduction*. Oxford : Oxford University Press, 2001.
- [147] H. NISHIMORI. *Exact mapping of a spin glass with correlated disorder to the pure Ising model*. 2026. DOI : 10.48550/arXiv.2602.22657. arXiv : 2602.22657 [cond-mat.dis-nn].
- [148] S. BROADBENT et J. HAMMERSLEY. « Percolation processes : I. Crystals and mazes ». In : *Mathematical Proceedings of the Cambridge Philosophical Society* 53.3 (1957), p. 629-641. DOI : 10.1017/S0305004100032680.
- [149] L. CHAYES et H. K. LEI. « Random cluster models on the triangular lattice ». In : *Journal of statistical physics* 122 (2006), p. 647-670. DOI : 10.1007/s10955-005-8078-7.
- [150] A. SANKARARAMAN, H. VIKALO et F. BACCELLI. « ComHapDet : a spatial community detection algorithm for haplotype assembly ». In : *BMC Genomics* (2020). DOI : 10.1186/s12864-020-06935-x.
- [151] S. ZHOU, C. CANCHILA et W. SONG. *Fused Image dataset for convolutional neural Network-based crack Detection (FIND)*. <https://zenodo.org/records/6383044>. Zenodo, mars 2022. DOI : 10.5281/zenodo.6383044.
- [152] T.-C. LEE, R. L. KASHYAP et C.-N. CHU. « Building Skeleton Models via 3-D Medial Surface/Axis Thinning Algorithms ». In : *Computer Vision, Graphics, and Image Processing : Graphical Models and Image Processing* 56.6 (1994), p. 462-478. DOI : 10.1006/cgip.1994.1042.
- [153] S. VAN DER WALT et al. « Scikit-image : image processing in Python ». In : *PeerJ* 2 (2014). Online, e453.
- [154] U. BRANDES. « A faster algorithm for betweenness centrality ». In : *Journal of Mathematical Sociology* 25.2 (2001), p. 163-177.
- [155] Y. SHI et al. « Semi-universal geo-crack detection by machine learning ». In : *Frontiers in Earth Science* 11 (2023), p. 1073211. DOI : 10.3389/feart.2023.1073211.

- [156] Y. SHI et al. « Automatic road crack detection using random structured forests ». In : *IEEE Transactions on Intelligent Transportation Systems* 17.12 (2016), p. 3434-3445.
- [157] P. JACCARD. « Distribution de la flore alpine dans le bassin des Dranses et dans quelques régions voisines ». In : *Bulletin De La Société Vaudoise Des Sciences Naturelles* (1901). DOI : 10.5169/seals-266440.
- [158] A. TVERSKY. « Features of similarity ». In : *Psychological Review* 84.4 (1977), p. 327-352. DOI : 10.1037/0033-295X.84.4.327.
- [159] L. N. VASERSTEIN. « Markov processes over denumerable products of spaces, describing large systems of automata ». In : *Problemy Peredači Informacii* 5.3 (1969), p. 64-72.
- [160] D. C. MONTGOMERY. *Design and Analysis of Experiments*. 9th. Hoboken, NJ : John Wiley & Sons, 2017. ISBN : 978-1-119-11347-8.
- [161] T. HACHAJ et M. PIEKARCZYK. « High-Level Hessian-Based Image Processing with the Frangi Neuron ». In : *Electronics* 12.19 (2023). ISSN : 2079-9292. DOI : 10.3390/electronics12194159.
- [162] A. KIRILLOV et al. « Segment anything ». In : *Proceedings of the IEEE/CVF International Conference on Computer Vision*. 2023, p. 4015-4026.
- [163] K. GE et al. « Fine-tuning vision foundation model for crack segmentation in civil infrastructures ». In : *Construction and Building Materials* 431 (2024), p. 136573. DOI : 10.1016/j.conbuildmat.2024.136573.
- [164] M. CAMPOS et al. *A new lower bound for sphere packing*. 2023. arXiv : 2312.10026 [math.MG]. URL : <https://arxiv.org/abs/2312.10026>.
- [165] L. HAUSEUX, K. AVRACHENKOV et J. ZERUBIA. « Benefits of hypergraphs for density-based clustering ». In : *32nd European Signal Processing Conference (EUSIPCO)*. Lyon, France, août 2024. DOI : 10.23919/EUSIPCO63174.2024.10715271.
- [166] L. HAUSEUX et B. BLASZCZYSZYN. *Un classificateur non-supervisé utilisant les complexes simpliciaux (avec une application à la stylométrie)*. Research Report. INRIA Paris, sept. 2017.
- [167] L. HAUSEUX. *K-centroïdes dans un arbre*. Google Colaboratory Python Notebook. 2024. URL : https://colab.research.google.com/drive/1r74-Di0e0K_CXPHqn06m4x9PIzbEJmmM?usp=sharing.
- [168] L. HAUSEUX et al. *Graphical generalization of Frangi filter. An illustration on crack extraction from images*. Soumis. Palermo, Italy, sept. 2025.
- [169] L. HAUSEUX et al. *Multi-Modal, Training-Free Crack Extraction via Generalized Frangi Graph*. soumis. Luxembourg, oct. 2026.
- [170] L. HAUSEUX et al. « Multi-Modal, Training-Free Crack Extraction via Generalized Frangi Graph ». In : *34th European Signal Processing Conference (EUSIPCO)*. submitted. Bruges, Belgium, août 2026.

Table des figures

2.1	« Arbre de la vie » de DARWIN (<i>On the Origin of Species</i> , 1859). Les lettres représentent des espèces distinctes. Chaque ligne représente 1000 générations.	19
2.2	L'arête (x, x') appartient au graphe de GABRIEL si aucun autre point de $\mathcal{X}$ ne tombe dans le disque de diamètre $[x, x']$ (en gris). Elle appartient au graphe de voisinage relatif (<i>relative neighborhood graph</i> , RNG) si aucun point ne tombe dans l'intersection des deux disques de rayon $\ x - x'\ $ centrés en x et x' (en bleu foncé).	22
2.3	Illustration du THÉORÈME 1 : le graphe géométrique (à gauche) et l'arbre minimum couvrant élagué au même rayon (à droite) partagent rigoureusement les mêmes composantes connexes.	24
2.4	Le modèle de HARTIGAN : correspondance entre $H_f(\lambda)$, les composantes connexes des ensembles de niveau de la densité $L(\lambda)$, (en haut) et la topologie de l'arbre hiérarchique des amas de forte densité (en bas). . . .	25
4.1	(a) Trois points alignés espacés de 2δ . (b) Le dendrogramme résultant pour le Single-Linkage (fusion simultanée à δ). (c) Trois points en triangle équilatéral à distance 2δ	38
4.2	Illustration du critère d'excès de masse de l'algorithme HDBSCAN. À gauche : l'arbre hiérarchique. À droite : les composantes connexes des ensembles de niveau de la densité délimitant l'excès de masse <i>relatif</i> , c'est-à-dire propre à chaque amas C_i	45
5.1	Illustration du principe du Convex Clustering. (a) Dans l'espace des données, l'augmentation de la pénalité γ force les centroïdes à se déplacer physiquement (<i>shrinkage</i>) vers les zones de densité locale. (b) La séquence temporelle de ces coalescences permet de reconstruire l'arbre hiérarchique.	49
5.2	Le mécanisme de sélection d'un cluster. L'architecture de HDBSCAN compare la perte (<i>loss</i>) d'un nœud parent à la somme de celles de ses enfants. En jouant sur la fonction de coût, l'on peut introduire des <i>a priori</i>	50
5.3	Détection d'anomalies sur un <i>benchmark</i> synthétique (©Naval Group) de 2 000 000 de points. L'injection du modèle 3D théorique (bien identifié en rouge) comme <i>a priori</i> géométrique dans la fonction de coût lors de l'exploration de la hiérarchie produite par HGP-Clusterer permet d'isoler parfaitement les objets étrangers (trois tuteurs, deux cubes; chacun avec sa couleur). Le « hors-champ » apparaît en gris.	52

5.4	Résultat de notre méthode sur la trame 60, séquence 08, de SemanticKITTI. Chaque piste est repérée par sa boîte englobante (une couleur par classe d'objets). Noter les deux cyclistes (boîtes roses) en bas, bien séparés quoique proches (et ce grâce au suivi par transport optimal, quand le clustering avec <i>a priori</i> géométriques les avait fusionnés).	54
5.5	Segmentation panoptique 4D sur les 200 premières trames de la séquence 08 de SemanticKITTI. Les instances spatiales sont projetées en 2D (<i>Bird-Eye-View</i>), le temps t est repéré sur le troisième axe. Chaque piste suivie reçoit une couleur et produit donc comme une traînée avec le temps. À gauche, la vérité terrain. À droite, le résultat de notre méthode (clustering hiérarchique guidé par la géométrie + transport optimal déséquilibré régularisé par l'entropie).	54
6.1	(Gauche) Nuage de six points $\mathcal{X} = \{A; B; C; D; E; F\}$. (Droite) Dendrogramme produit par le Single-Linkage avec en entrée $\mathcal{X}$. Le même dendrogramme est produit par le Robust Single-Linkage et (H)DBSCAN pour $K = 2$	59
6.2	(Gauche) Nuage $\mathcal{X}$ repris de la FIG. 6.1a avec les amas (en bleu) de forte densité 2-NN au niveau $r' \gtrsim r$. (Droite) Dendrogramme en construction. Par convention, le multi-ensemble des feuilles apparaît au niveau 0. . . .	60
6.3	(Gauche) Évolution des amas de forte densité 2-NN au niveau $r' = \frac{2\sqrt{3}}{3}r$: on voit apparaître des fusions de 2-intersections de boules au moyen de 3-intersections (le point de contact de la fusion est repéré en rouge). (Droite) : Évolution du dendrogramme avec les fusions opérées au niveau r'	60
6.4	Clôture de la hiérarchie 2-NN au niveau $r'' = AD/2$. À ce rayon critique, l'apparition simultanée des quatre points de tangence (points rouges) relie les trois amas de forte densité.	60
6.5	Exemple de 2-polyèdres sur la configuration à six points de l'exemple en § 6.1. Au rayon $r' = \frac{2\sqrt{3}}{3}r$, le complexe de Čech contient deux triangles ABC et DEF ainsi que l'arête CD . Les composantes connexes du graphe $\Gamma_2(\mathcal{X}, r')$ donnent alors trois 2-polyèdres, à savoir $\{A, B, C\}$, $\{C, D\}$ et $\{D, E, F\}$. On voit déjà apparaître le phénomène essentiel : pour $K \geq 2$, les polyèdres peuvent se recouvrir.	63
7.1	Inconsistance du Single-Linkage en dimension $p \geq 2$. Les deux amas de forte densité (carrés) sont fusionnés (droite, niveau r_2) avant que tous les points en faisant partie soient récupérés par les deux composantes géantes (gauche, niveau r_1).	74
7.2	Estimation de la fonction de probabilité $\lambda \mapsto \hat{\Theta}_{K,2}^{\text{poly}}(\lambda)$ pour $K \in \{1, 2, 3, 4, 5\}$ des K -polyèdres en dimension 2. À noter que pour $K = 1$, le seuil critique en 2D est $\lambda_c \approx 1.44$ [76, 77].	78

7.3	Estimation de la fonction de probabilité $\lambda \mapsto \hat{\Theta}_{K,2}^{\text{core}}(\lambda)$ pour $K \in \{1, 2, 3, 4, 5\}$ des K -composantes du Robust Single-Linkage en dimension 2.	78
7.4	Estimation de la fonction de probabilité $\lambda \mapsto \hat{\Theta}_{K,2}^{\text{dbscan}}(\lambda)$ pour $K \in \{1, 2, 3, 4, 5\}$ des K -composantes de DBSCAN en dimension 2.	79
8.1	Illustration de la plus petite boule englobante B_σ , de son centre c_σ , de son rayon de naissance $\rho(\sigma)$ et de son ensemble de support à la frontière $S = \sigma \cap \partial B_\sigma$ pour un 2-simplexe $\sigma = \{x_1, x_2, x_3\}$	90
8.2	Illustration de la preuve du THÉORÈME 4 ($K = 2$) pour un triangle $\sigma = \{x_1, x_2, x_3\}$ obtus en x_3 , c'est-à-dire que $S = \{x_1, x_2\}$. Si le simplexe n'est pas de GABRIEL, B_σ (de rayon r) contient donc un "intrus" z . Les facettes τ_1 et τ_2 , actives pour une filtration $< r$, sont connectées au moyen de z (les 2-simplexes σ_s^z et σ_t^z).	92
9.1	Illustration de la preuve de PROP. 9. Si un triangle obtus $\sigma = \{x_1, x_2, x_3\}$ est de GABRIEL, sa boule minimale B_σ de diamètre $[x_2, x_3]$ est vide de tout "intrus". L'on peut alors y inscrire deux disques D_{x_3} et D_{x_2} inclus dans B_σ (et donc également vides de tout point de $\mathcal{X}$). Ces disques vides attestent que $[x_1, x_2]$ et $[x_1, x_3]$ sont bien de DELAUNAY.	102
11.1	Modèle bayésien général : l' <i>a priori</i> et le canal d'observation induisent une loi jointe, puis une postérieure. La détection consiste à produire une configuration à partir de l'observation.	126
11.2	Un algorithme voit la réalisation observée ; un tirage au hasard connaît seulement le modèle.	127
11.3	Le recouvrement ignore les <i>labels</i> arbitraires des communautés ; c'est la partition induite qui compte.	129
11.4	Les trois régimes de recouvrement de communautés. Dans ce chapitre, le recouvrement partiel est le régime pertinent (il détecte une information globale sans exiger une postérieure quasi-dégénérée).	132
11.5	La vérité cachée Σ peut être remplacée par une réplique postérieure $\Sigma^{(1)}$. Toute l'astuce de la suite du chapitre consiste à construire $\Sigma^{(1)}$ en faisant un pas d'une dynamique de clusters à partir de Σ	133
11.6	Interprétation d'un poids w réel : le signe indique la contrainte ; le module $ w $ indique la force de cette contrainte. Les arêtes positives sont représentées d'un trait plein et les arêtes négatives en pointillés ; un trait plus épais signifie que l'arête est satisfaite.	135
11.7	La frustration apparaît dès qu'un cycle impose un nombre impair d'arêtes négatives. Le triangle pleinement répulsif est le plus petit exemple.	136

11.8	Un pas de SWENDSEN–WANG signé : partant d’une configuration $\sigma : V \rightarrow \{+; -\}$, l’on gèle aléatoirement certaines des arêtes satisfaites (en gras), puis on recolorie aléatoirement les clusters ainsi formés ; on obtient de la sorte une nouvelle configuration σ'	138
11.9	Assemblage d’haplotypes (formulé comme un problème de détection de communautés sur graphe). La vérité terrain $\Sigma \in \{+, -\}^V$ répartit les nœuds sur deux chromosomes homologues. Les lectures s’intersectant produisent une arête. Le bruit inhérent au séquençage est modélisé par un <i>geometric stochastic block model</i> avec $p = \frac{3}{4}$, introduisant de la frustration.	148
12.1	Chaîne de traitement sur une image des Vaches Noires. Ligne du haut : image visible, réponse de FRANGI classique, graphe de similarité, composantes retenues. Ligne du bas : centralité, vérité terrain, squelette prédit, superposition finale.	160
12.2	Comparaison qualitative sur les deux images des Vaches Noires. La vérité terrain apparaît en vert, notre méthode en rouge et U-Net + <i>transfer learning</i> en bleu.	161
12.3	Exemple de fusion multimodale sur FIND (image 0001). La similarité de FRANGI généralisée isole la fissure principale malgré les stries visibles dans l’intensité. Ajouter a) b) c) d) et la fissure (en rouge) daans d)	162
12.4	Retour des axes Dégradation des performances sur FIND bruité. Le bruit augmente de gauche à droite. L’échelle verticale va de 0% à 100%. La méthode géométrique reste plus stable, tandis que CrackSegDiff se dégrade fortement hors de sa distribution d’entraînement.	163
12.5	Exemple VT-GraF. De gauche à droite et de haut en bas : visible, thermique, courbure positive, graphe de similarité, composantes triangles-connexes, centralité, vérité terrain, superposition.	163
12.6	Second exemple VT-GraF. Le $K = 2$ agit comme un filtre de densité locale et supprime une grande partie des artefacts granulaires.	164
12.7	Exemple sur CrackForest, image 001. Le squelette prédit est en rouge, la vérité terrain en vert. Sur cette image : JACCARD = 78%, distance de WASSERSTEIN = 5 px.	164
12.8	Exemples de courbes de sensibilité sur CrackForest (bleu : JACCARD ; vert : TVERSKY ; rouge : WASSERSTEIN). Les réponses les plus instables apparaissent lorsque le graphe est trop fragmenté ou au contraire trop dense. À séparer	165
12.9	Refaire et séparer Interaction entre le rayon du graphe R et l’échelle de base σ_0 sur CrackForest.	165
A.1	Cartographie manuscrit-publications	178

Liste des tableaux

7.1	Vitesse de percolation v en fonction de K pour les dimensions $p = 2$, $p = 3$ et $p = 4$. Les meilleurs résultats sont indiqués en gras.	79
9.1	Résultats partiels de PERSISTABLE et de HGP-Clusterer sur le jeu de données des huiles d'olive italiennes. La notation a/b indique PERSISTABLE/HGP-Clusterer.	105
9.2	Résultats exhaustifs de PERSISTABLE et de HGP-Clusterer sur le jeu de données des huiles d'olive italiennes, après propagation aux points non classés. La notation a/b indique PERSISTABLE/HGP-Clusterer.	106
9.3	Résultats de HDBSCAN et de HGP-Clusterer sur les jeux de données SIPU. n désigne la taille du jeu de données, k le nombre de clusters, ARI l'indice de RAND ajusté, et "classés" la proportion de points affectés à un cluster.	106
11.1	Règles de gel de la dynamique SWENDSEN-WANG triangulaire isotrope. Les lignes indiquent la configuration des spins sur le triangle $t = \{a, b, c\}$ (on fixe le premier spin à + par symétrie). Les colonnes indiquent l'ensemble d'arêtes gelées $\omega \subseteq t$ dans le triangle. Noter que geler deux ou trois arêtes revient au même pour la dynamique.	140
12.1	Comparaison quantitative sur deux images des Vaches Noires. Les valeurs sont calculées entre le squelette expert et le squelette prédit.	160
12.2	Influence des poids de fusion sur FIND. I désigne l'intensité, R la profondeur, F la profondeur filtrée (<i>Filtered</i>).	162
12.3	Comparaison avec CrackSegDiff sur FIND propre.	162

List of Algorithms

1	HGP-CLUSTERER pour $K = 2$ avec sortie en partition stricte	104
2	Extraction d'un squelette par graphe de FRANGI généralisé	156

Utilisation de graphes pour la classification et l'extraction de structures. Généralisation à des interactions d'ordre supérieur.

Louis HAUSEUX

Résumé

Problématique Au cours de cette thèse, nous nous penchons sur le problème de structuration automatique de données à partir d'observations locales, imparfaites et parfois bruitées. Le point de départ en est le clustering. Nous avons alors rencontré à de multiples reprises – et par des voies toutes différentes – l'algorithme du Single-Linkage. Nous nous sommes concentrés sur trois approches : une approche heuristique (construction de l'arbre minimum couvrant sur les données) ; une approche géométrique (persistance des composantes d'un graphe géométrique) ; ainsi qu'une approche statistique (estimation des clusters de forte densité). La première approche permet de disposer d'un algorithme optimisé (notamment dans l'espace euclidien) ; la seconde permet de comprendre le mécanisme mathématique à l'œuvre (la percolation) et la dernière approche permet d'avoir un cadre mathématique satisfaisant et de comprendre le Single-Linkage au sein d'un modèle statistique non paramétrique.

Les limites du Single-Linkage (et de ses descendants) Il manque néanmoins au Single-Linkage une notion de robustesse : en dimension $p \geq 2$, des ponts de bruit peuvent fusionner prématurément des clusters distincts (c'est l'effet de chaînage). Les méthodes proposées jusqu'à nos jours, telles le Robust Single-Linkage, DBSCAN puis HDBSCAN introduisent une notion densité locale fondée sur les K plus proches voisins (là où le Single-Linkage ne prenait en compte que le plus proche voisin). Cependant, ces algorithmes font l'erreur d'imposer une condition d'ordre K aux points tout en propageant la connexité à l'ordre 1 (connexité binaire par arêtes).

Contribution principale La contribution centrale de cette thèse est l'algorithme HGP-Clusterer. L'idée est de remplacer le graphe géométrique par le complexe de Čech. Pour $K \geq 2$, les objets élémentaires ne sont plus les arêtes, mais les $(K - 1)$ -simplexes, qui encodent l'intersection simultanée de K boules. Nous établissons la correspondance exacte entre les clusters de forte densité de l'estimateur des K -voisins – et ce à tout niveau de la hiérarchie – et les composantes que notre algorithme identifie, les K -polyèdres. Après cette généralisation des approches géométrique et statistique, nous finissons l'analogie en identifiant la bonne structure contenant toute l'information du K -arbre minimum couvrant (et disposer ainsi d'un algorithme pratique optimisé dans le cadre euclidien) : il s'agit de la mosaïque de DELAUNAY d'ordre K .

Percolation et analyse La percolation continue sert ensuite d'outil d'analyse. Elle explique l'inconsistance du Single-Linkage et permet de comparer théoriquement Robust Single-Linkage, (H)DBSCAN et HGP-Clusterer au niveau de leur *fraction* de consistance partielle (fraction d'un cluster récupérable avant fusion parasite).

Applications et extensions Finalement, les différentes hiérarchies que nous construisons sont aussi des espaces de résolution pratique : y injecter des *a priori* permet de résoudre des tâches complexes sans apprentissage (anomalies LiDAR 3D, segmentation d'instance 4D). Surtout, le paradigme couplant « ordre supérieur » et « percolation » s'exporte bien au-delà du cadre euclidien. Sur les graphes signés, il inspire de nouvelles dynamiques bayésiennes de clusters (généralisant SWENDSEN-WANG) qui conduisent à des bornes de recouvrement plus fines. En imagerie, le filtre de FRANGI est étendu en un hypergraphe spatial où la connexité d'ordre supérieur bloque la percolation du bruit, assurant une extraction robuste de réseaux de fissures.

Conclusion La thèse propose ainsi une généralisation naturelle du Single-Linkage qui recourt à des interactions d'ordre supérieur et donne un rôle central à la percolation dans l'analyse des performances. Ces deux idées dépassent largement le cadre euclidien initialement